

# Introduction

Expliquer ou prévoir : deux objectifs distincts

## Feuille d'exercices

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger  
Exercices et corrigés · Apprentissage statistique

## 1 Exercices du chapitre

### Exercice 1 — Décomposer l'erreur réductible et irréductible

Un modèle de prévision de défaut affiche une erreur quadratique totale de 12,5. Des études antérieures sur ce marché ont établi que le bruit irréductible vaut  $\sigma^2 = 3,2$ .

- (a) Calculer l'erreur réductible de ce modèle.
- (b) Une nouvelle méthode ramène l'erreur réductible à 2,1. Calculer la nouvelle erreur totale.
- (c) Ce modèle peut-il un jour atteindre une erreur totale strictement inférieure à 3,2? Justifier.

### Exercice 2 — Découper une base en apprentissage, validation et test

Une base de 5 000 dossiers de crédit doit être découpée en trois ensembles.

- (a) Avec un découpage 60 % / 20 % / 20 %, calculer l'effectif de chacun des trois ensembles.
- (b) Avec un découpage 70 % / 15 % / 15 %, recalculer ces trois effectifs.
- (c) Pourquoi ne faut-il jamais calculer une moyenne ou un écart-type de normalisation sur l'ensemble des 5 000 dossiers *avant* d'effectuer ce découpage?

### Exercice 3 — Diagnostiquer un sous-ajustement ou un sur-ajustement

Deux modèles sont entraînés sur les mêmes données. Le modèle A affiche une erreur d'apprentissage de 0,02 et une erreur de test de 0,35. Le modèle B affiche une erreur d'apprentissage de 0,28 et une erreur de test de 0,31.

- (a) Calculer l'écart entre erreur de test et erreur d'apprentissage pour chacun des deux modèles.
- (b) Lequel des deux modèles souffre manifestement de sur-ajustement? Justifier par l'écart calculé, et non par le seul niveau de l'erreur de test.
- (c) Sans changer de méthode, quel levier simple évoqué dans le chapitre permettrait de rapprocher le modèle A du modèle B?

## 2 Applications en sciences économiques

### Exercice 4 — Une fuite de données dans un scoring de crédit

Une banque construit un modèle de scoring de défaut. Avant de découper ses données, l'équipe calcule la moyenne et l'écart-type de chaque variable sur l'ensemble des 5 000 dossiers, puis normalise toutes les variables avec ces valeurs, et découpe *ensuite* en apprentissage/validation/test. Le modèle atteint une AUC de 0,91 sur l'ensemble de test interne, mais seulement 0,68 une fois mis en production sur de nouveaux dossiers.

- (a) Identifier précisément l'erreur méthodologique commise par l'équipe.
- (b) Calculer l'écart entre l'AUC annoncée en interne et l'AUC réellement observée en production.
- (c) Décrire l'ordre correct des opérations qui aurait évité cette fuite.

### Exercice 5 — Choisir entre expliquer et prévoir dans un projet marketing

Une équipe marketing dispose de 40 variables décrivant ses clients et cherche à comprendre *pourquoi* certains clients résilient leur abonnement, afin d'écrire des recommandations pour la direction. Un data scientist propose un modèle très flexible combinant les 40 variables, dont le pouvoir prédictif interne atteint  $R^2 = 0,82$ .

- (a) Le besoin de l'équipe marketing correspond-il à l'objectif «expliquer» ou à l'objectif «prévoir» au sens du chapitre?

- (b) Pourquoi un modèle très flexible à 40 variables, même avec  $R^2 = 0,82$ , est-il mal adapté à ce besoin précis, indépendamment de sa qualité de prévision?
- (c) Quel arbitrage du chapitre devrait guider le choix d'un modèle plus simple ici, même au prix d'un  $R^2$  interne plus faible?