

Chapitre 8

Forêts aléatoires et bagging

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre


Correction — Exercice 1

- (a) Variance théorique = $15/50 = 0,3$.
- (b) L'écart entre 4,5 (observé) et 0,3 (théorique) révèle que les 50 arbres du bagging sont **loin d'être indépendants** : ils sont construits sur des échantillons bootstrap qui se recoupent fortement et voient donc presque les mêmes données. S'ils partagent une variable dominante, tous la choisiront en premier et produiront des arbres très similaires – moyenner des modèles aussi corrélés ne réduit que faiblement la variance par rapport au cas indépendant.
- (c) Le chapitre propose la **forêt aléatoire** de Breiman : à chaque nœud, ne considérer qu'un sous-ensemble aléatoire de m variables parmi les p disponibles, tiré à nouveau à chaque nœud. Une variable dominante ne peut alors plus être choisie systématiquement partout, ce qui force les arbres à explorer d'autres découpages et les **décorrèle**, rapprochant la variance réelle de l'ensemble de la borne théorique σ^2/B .




Correction — Exercice 2

- (a) $m \approx \sqrt{36} = 6$.
- (b) $m \approx 36/3 = 12$.
- (c) Avec $m = p = 36$, chaque nœud considérerait **toutes** les variables disponibles, exactement comme dans un arbre classique de bagging (sans restriction de Breiman) : on retrouverait donc le **bagging simple**. La décorrélation disparaîtrait car rien n'empêcherait plus une variable dominante d'être systématiquement choisie en premier dans tous les arbres, qui redeviendraient alors très semblables les uns aux autres.



Correction — Exercice 3


- (a) $n = 10 : (1 - 1/10)^{10} = 0,9^{10} \approx 0,3487$.
- (b) $n = 50 : (1 - 1/50)^{50} \approx 0,3642$. $n = 1\,000 : (1 - 1/1\,000)^{1\,000} \approx 0,3677$.
- (c) Oui, la convergence vers $e^{-1} \approx 0,3679$ est déjà quasi atteinte pour $n = 50$ (écart de seulement 0,0037) et pratiquement parfaite pour $n = 1\,000$ (écart de 0,0002) : même pour des échantillons de taille modeste, la proportion d'observations hors sac reste très proche de 36,8 %, ce qui justifie d'utiliser cette valeur comme repère quasi universel, quelle que soit la taille exacte de l'échantillon.



2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

- (a) Nombre attendu de dossiers hors sac = $0,368 \times 1\,000 = 368$ dossiers, pour un arbre donné.
- (b) Ce nombre (368) est **supérieur** au bloc de validation croisée du chapitre 2 (200 dossiers). L'erreur out-of-bag joue un rôle voisin d'une validation croisée car, pour chaque dossier, on dispose des arbres (environ un tiers de la forêt) qui ne l'ont **jamais vu** lors de leur construction – exactement le principe d'une évaluation sur données non vues, sans qu'il ait fallu réserver explicitement un bloc de validation ni réestimer plusieurs fois le modèle complet comme au chapitre 2.
- (c) Le **biais** d'une forêt aléatoire reste comparable à celui d'un arbre isolé profond, car **moyenner ne change pas le biais** (chapitre 8) : chaque arbre de la forêt, pris individuellement, reste un arbre profond et peu biaisé comme celui du chapitre 7. En revanche, la **variance** chute fortement : avec $B = 300$ arbres décorrélés par le tirage de $m \approx 4$ variables à chaque nœud, la variance de l'ensemble se rapproche de $\sigma^2/300$ (chapitre 8), très inférieure à la variance élevée d'un arbre isolé identifiée comme son défaut majeur au chapitre 7 – exactement le compromis biais-variance du chapitre 1, mais résolu ici en réduisant la variance *sans sacrifier le biais*, plutôt qu'en arbitrant entre les deux.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) Classification : $m \approx \sqrt{49} = 7$. Régression : $m \approx 49/3 \approx 16,33$.
- (b) La classification du défaut (variable qualitative «défaut»/«non défaut») appelle la valeur $m \approx 7$.
- (c) Avec $m = 1$, chaque nœud ne peut choisir son découpage que parmi une **seule** variable tirée au hasard, sans possibilité de comparer plusieurs candidates : chaque arbre devient beaucoup plus faible individuellement, car il ne peut plus systématiquement retenir la meilleure variable disponible à chaque étape – son **biais augmente**, même si les arbres sont alors très fortement décorrélés. C'est exactement l'avertissement du chapitre : « m petit décorrèle davantage mais affaiblit chaque arbre», un nouvel arbitrage biais-variance, cette fois sur le réglage de m lui-même.



Correction — Exercice 6

- (a) Nombre attendu de transactions hors sac = $0,368 \times 1\,500 = 552$ transactions.
- (b) L'erreur out-of-bag est calculée directement lors de l'unique entraînement de la forêt, en utilisant pour chaque transaction les seuls arbres qui ne l'ont pas vue – elle ne nécessite **aucun réentraînement supplémentaire** du modèle. Une validation croisée à 5 blocs exigerait, elle, d'entraîner 5 forêts complètes distinctes (une par bloc laissé de côté), multipliant bien le temps de calcul nocturne par 5, ce que la plateforme ne peut pas se permettre pour un réentraînement quotidien en temps réel.
- (c) L'erreur out-of-bag est une propriété **spécifique** au mécanisme de rééchantillonnage bootstrap de la forêt aléatoire : elle n'a pas d'équivalent direct pour un modèle de boosting, qui n'utilise généralement pas d'échantillons bootstrap indépendants de la même manière (chaque arbre du boosting est construit séquentiellement sur les résidus du précédent, sur l'ensemble des données). Comparer les deux familles de modèles sur des bases différentes (OOB pour l'une, rien d'équivalent pour l'autre) ne garantirait pas une comparaison équitable ; seule une validation croisée classique, appliquée de façon identique aux deux méthodes, permettrait une comparaison rigoureuse entre elles.