

Apprentissage statistique

Chapitre 8 : Forêts aléatoires et bagging

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Diviser la variance, en théorie et en pratique

Un arbre isolé a une variance de 15. On construit un bagging de $B = 50$ arbres.

- (a) Calculer la variance théorique de la moyenne des 50 arbres, *si* ceux-ci étaient parfaitement indépendants.
- (b) En pratique, la variance réellement observée de l'ensemble vaut 4,5, bien au-dessus de la valeur théorique de (a). Que révèle cet écart sur les 50 arbres du bagging?
- (c) Quelle technique précise le chapitre propose-t-il pour réduire cet écart, et sur quel principe repose-t-elle?

Exercice 2 — Régler m pour la forêt aléatoire

Un jeu de données comporte $p = 36$ variables explicatives.

- (a) Calculer la valeur usuelle de m pour une tâche de **classification** ($m \approx \sqrt{p}$).
- (b) Calculer la valeur usuelle de m pour une tâche de **régression** ($m \approx p/3$).
- (c) Si l'on choisissait $m = p = 36$ (aucune restriction du nombre de variables à chaque nœud), quelle méthode retrouverait-on exactement, et pourquoi la décorrélation entre arbres disparaîtrait-elle?

Exercice 3 — Calculer la proportion d'observations hors sac

La probabilité qu'une observation ne soit jamais tirée en n tirages avec remise vaut $(1 - 1/n)^n$.

- (a) Calculer cette probabilité pour $n = 10$.
- (b) Calculer cette probabilité pour $n = 50$, puis pour $n = 1\,000$.
- (c) Comparer les trois valeurs à la limite $e^{-1} \approx 0,3679$. La convergence vers cette limite est-elle déjà quasi atteinte pour des échantillons de taille modeste?

2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Une forêt aléatoire sur le portefeuille de crédit (chapitre 7, chapitre 2, chapitre 1, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, une forêt aléatoire à $B = 300$ arbres est construite avec $p = 20$ variables et $m \approx 4$ (valeur usuelle du chapitre pour la classification avec $p = 20$).

- (a) En utilisant la proportion hors sac de 36,8 % du chapitre, calculer le nombre attendu de dossiers hors sac pour un arbre donné.
- (b) Comparer ce nombre au bloc de validation croisée à 5 blocs du chapitre 2 (composé de 200 dossiers). Pourquoi l'erreur out-of-bag peut-elle jouer, ici, un rôle voisin de celui d'une validation croisée, sans nécessiter de découpage supplémentaire?
- (c) Un arbre unique sur ce portefeuille (chapitre 7) a un biais faible mais une variance très élevée, selon le tableau du chapitre 1. Pourquoi la forêt aléatoire, avec $B = 300$ arbres et $m \approx 4$, conserve-t-elle un biais comparable à celui d'un arbre isolé tout en réduisant fortement la variance?

3 Applications en sciences économiques

Exercice 5 — Régler m pour un scoring agricole

Une coopérative agricole modélise le risque de défaut de ses adhérents à partir de $p = 49$ variables (surfaces cultivées, historique de récoltes, prix des intrants, etc.).

- (a) Calculer $m \approx \sqrt{p}$ pour une classification du défaut, puis $m \approx p/3$ si l'objectif était de prévoir un montant continu (régression).
- (b) La coopérative veut classer chaque adhérent en « défaut » ou « non défaut ». Quelle valeur de m retenir ?
- (c) Un stagiaire propose de fixer $m = 1$ pour maximiser la décorrélation entre arbres. Pourquoi cette décision, bien qu'elle maximise la décorrélation, risquerait-elle d'affaiblir la qualité de chaque arbre pris individuellement ?

Exercice 6 — La valeur économique de l'erreur out-of-bag

Une plateforme de détection de fraude en temps réel réentraîne sa forêt aléatoire chaque nuit sur $n = 1\,500$ transactions étiquetées.

- (a) Calculer le nombre attendu de transactions hors sac pour un arbre donné, avec la proportion de 36,8 % du chapitre.
- (b) La plateforme envisageait initialement une validation croisée explicite à 5 blocs, ce qui aurait multiplié par 5 le temps de calcul de l'entraînement nocturne. Pourquoi l'erreur out-of-bag permet-elle d'éviter ce surcoût ?
- (c) Le chapitre précise que la validation croisée reste préférable « pour comparer des familles de modèles différentes ». Pourquoi l'erreur out-of-bag, propre à la forêt aléatoire, ne suffirait-elle pas si la plateforme voulait comparer sa forêt aléatoire à un modèle de boosting (chapitre suivant) ?


1 Exercices du chapitre

Correction — Exercice 1

(a) Variance théorique = $15/50 = 0,3$.

(b) L'écart entre 4,5 (observé) et 0,3 (théorique) révèle que les 50 arbres du bagging sont **loin d'être indépendants** : ils sont construits sur des échantillons bootstrap qui se recoupent fortement et voient donc presque les mêmes données. S'ils partagent une variable dominante, tous la choisiront en premier et produiront des arbres très similaires – moyenner des modèles aussi corrélés ne réduit que faiblement la variance par rapport au cas indépendant.

(c) Le chapitre propose la **forêt aléatoire** de Breiman : à chaque nœud, ne considérer qu'un sous-ensemble aléatoire de m variables parmi les p disponibles, tiré à nouveau à chaque nœud. Une variable dominante ne peut alors plus être choisie systématiquement partout, ce qui force les arbres à explorer d'autres découpages et les **décorrèle**, rapprochant la variance réelle de l'ensemble de la borne théorique σ^2/B .




Correction — Exercice 2

(a) $m \approx \sqrt{36} = 6$.

(b) $m \approx 36/3 = 12$.

(c) Avec $m = p = 36$, chaque nœud considérerait **toutes** les variables disponibles, exactement comme dans un arbre classique de bagging (sans restriction de Breiman) : on retrouverait donc le **bagging simple**. La décorrélation disparaîtrait car rien n'empêcherait plus une variable dominante d'être systématiquement choisie en premier dans tous les arbres, qui redeviendraient alors très semblables les uns aux autres.




Correction — Exercice 3

(a) $n = 10 : (1 - 1/10)^{10} = 0,9^{10} \approx 0,3487$.

(b) $n = 50 : (1 - 1/50)^{50} \approx 0,3642$. $n = 1\,000 : (1 - 1/1\,000)^{1\,000} \approx 0,3677$.


(c) Oui, la convergence vers $e^{-1} \approx 0,3679$ est déjà quasi atteinte pour $n = 50$ (écart de seulement 0,0037) et pratiquement parfaite pour $n = 1\,000$ (écart de 0,0002) : même pour des échantillons de taille modeste, la proportion d'observations hors sac reste très proche de 36,8 %, ce qui justifie d'utiliser cette valeur comme repère quasi universel, quelle que soit la taille exacte de l'échantillon.



2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4


- (a) Nombre attendu de dossiers hors sac = $0,368 \times 1\,000 = 368$ dossiers, pour un arbre donné.
- (b) Ce nombre (368) est **supérieur** au bloc de validation croisée du chapitre 2 (200 dossiers). L'erreur out-of-bag joue un rôle voisin d'une validation croisée car, pour chaque dossier, on dispose des arbres (environ un tiers de la forêt) qui ne l'ont **jamais vu** lors de leur construction – exactement le principe d'une évaluation sur données non vues, sans qu'il ait fallu réserver explicitement un bloc de validation ni réestimer plusieurs fois le modèle complet comme au chapitre 2.
- (c) Le **biais** d'une forêt aléatoire reste comparable à celui d'un arbre isolé profond, car **moyenner ne change pas le biais** (chapitre 8) : chaque arbre de la forêt, pris individuellement, reste un arbre profond et peu biaisé comme celui du chapitre 7. En revanche, la **variance** chute fortement : avec $B = 300$ arbres décorrélés par le tirage de $m \approx 4$ variables à chaque nœud, la variance de l'ensemble se rapproche de $\sigma^2/300$ (chapitre 8), très inférieure à la variance élevée d'un arbre isolé identifiée comme son défaut majeur au chapitre 7 – exactement le compromis biais-variance du chapitre 1, mais résolu ici en réduisant la variance *sans sacrifier le biais*, plutôt qu'en arbitrant entre les deux.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) Classification : $m \approx \sqrt{49} = 7$. Régression : $m \approx 49/3 \approx 16,33$.
- (b) La classification du défaut (variable qualitative « défaut »/« non défaut ») appelle la valeur $m \approx 7$.
- (c) Avec $m = 1$, chaque nœud ne peut choisir son découpage que parmi une **seule** variable tirée au hasard, sans possibilité de comparer plusieurs candidates : chaque arbre devient beaucoup plus faible individuellement, car il ne peut plus systématiquement retenir la meilleure variable disponible à chaque étape – son **biais augmente**, même si les arbres sont alors très fortement décorrélés. C'est exactement l'avertissement du chapitre : « m petit décorrèle davantage mais affaiblit chaque arbre », un nouvel arbitrage biais-variance, cette fois sur le réglage de m lui-même.



Correction — Exercice 6

- (a) Nombre attendu de transactions hors sac = $0,368 \times 1\,500 = 552$ transactions.
- (b) L'erreur out-of-bag est calculée directement lors de l'unique entraînement de la forêt, en utilisant pour chaque transaction les seuls arbres qui ne l'ont pas vue – elle ne nécessite **aucun réentraînement supplémentaire** du modèle. Une validation croisée à 5 blocs exigerait, elle, d'entraîner 5 forêts complètes distinctes (une par bloc laissé de côté), multipliant bien le temps de calcul nocturne par 5, ce que la plateforme ne peut pas se permettre pour un réentraînement quotidien en temps réel.
- (c) L'erreur out-of-bag est une propriété **spécifique** au mécanisme de rééchantillonnage bootstrap de la forêt aléatoire : elle n'a pas d'équivalent direct pour un modèle de boosting, qui n'utilise généralement pas d'échantillons bootstrap indépendants de la même manière (chaque arbre du boosting est construit séquentiellement sur les résidus du précédent, sur l'ensemble des données). Comparer les deux familles de modèles sur des bases différentes (OOB pour l'une, rien d'équivalent pour l'autre) ne garantirait pas une comparaison équitable ; seule une validation croisée classique, appliquée de façon identique aux deux méthodes, permettrait une comparaison rigoureuse entre elles.