

Chapitre 8

Forêts aléatoires et bagging

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Diviser la variance, en théorie et en pratique

Un arbre isolé a une variance de 15. On construit un bagging de $B = 50$ arbres.

- (a) Calculer la variance théorique de la moyenne des 50 arbres, si ceux-ci étaient parfaitement indépendants.
- (b) En pratique, la variance réellement observée de l'ensemble vaut 4,5, bien au-dessus de la valeur théorique de (a). Que révèle cet écart sur les 50 arbres du bagging?
- (c) Quelle technique précise le chapitre propose-t-il pour réduire cet écart, et sur quel principe repose-t-elle?

Exercice 2 — Régler m pour la forêt aléatoire

Un jeu de données comporte $p = 36$ variables explicatives.

- (a) Calculer la valeur usuelle de m pour une tâche de **classification** ($m \approx \sqrt{p}$).
- (b) Calculer la valeur usuelle de m pour une tâche de **régression** ($m \approx p/3$).
- (c) Si l'on choisissait $m = p = 36$ (aucune restriction du nombre de variables à chaque nœud), quelle méthode retrouverait-on exactement, et pourquoi la décorrélation entre arbres disparaîtrait-elle?

Exercice 3 — Calculer la proportion d'observations hors sac

La probabilité qu'une observation ne soit jamais tirée en n tirages avec remise vaut $(1 - 1/n)^n$.

- (a) Calculer cette probabilité pour $n = 10$.
- (b) Calculer cette probabilité pour $n = 50$, puis pour $n = 1\,000$.
- (c) Comparer les trois valeurs à la limite $e^{-1} \approx 0,3679$. La convergence vers cette limite est-elle déjà quasi atteinte pour des échantillons de taille modeste?

2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Une forêt aléatoire sur le portefeuille de crédit (chapitre 7, chapitre 2, chapitre 1, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, une forêt aléatoire à $B = 300$ arbres est construite avec $p = 20$ variables et $m \approx 4$ (valeur usuelle du chapitre pour la classification avec $p = 20$).

- (a) En utilisant la proportion hors sac de 36,8 % du chapitre, calculer le nombre attendu de dossiers hors sac pour un arbre donné.
- (b) Comparer ce nombre au bloc de validation croisée à 5 blocs du chapitre 2 (composé de 200 dossiers). Pourquoi l'erreur out-of-bag peut-elle jouer, ici, un rôle voisin de celui d'une validation croisée, sans nécessiter de découpage supplémentaire?
- (c) Un arbre unique sur ce portefeuille (chapitre 7) a un biais faible mais une variance très élevée, selon le tableau du chapitre 1. Pourquoi la forêt aléatoire, avec $B = 300$ arbres et $m \approx 4$, conserve-t-elle un biais comparable à celui d'un arbre isolé tout en réduisant fortement la variance?

3 Applications en sciences économiques

Exercice 5 — Régler m pour un scoring agricole

Une coopérative agricole modélise le risque de défaut de ses adhérents à partir de $p = 49$ variables (surfaces cultivées, historique de récoltes, prix des intrants, etc.).

- (a) Calculer $m \approx \sqrt{p}$ pour une classification du défaut, puis $m \approx p/3$ si l'objectif était de prévoir un montant continu (régression).
- (b) La coopérative veut classer chaque adhérent en « défaut » ou « non défaut ». Quelle valeur de m retenir ?
- (c) Un stagiaire propose de fixer $m = 1$ pour maximiser la décorrélation entre arbres. Pourquoi cette décision, bien qu'elle maximise la décorrélation, risquerait-elle d'affaiblir la qualité de chaque arbre pris individuellement ?

Exercice 6 — La valeur économique de l'erreur out-of-bag

Une plateforme de détection de fraude en temps réel réentraîne sa forêt aléatoire chaque nuit sur $n = 1\,500$ transactions étiquetées.

- (a) Calculer le nombre attendu de transactions hors sac pour un arbre donné, avec la proportion de 36,8 % du chapitre.
- (b) La plateforme envisageait initialement une validation croisée explicite à 5 blocs, ce qui aurait multiplié par 5 le temps de calcul de l'entraînement nocturne. Pourquoi l'erreur out-of-bag permet-elle d'éviter ce surcoût ?
- (c) Le chapitre précise que la validation croisée reste préférable « pour comparer des familles de modèles différentes ». Pourquoi l'erreur out-of-bag, propre à la forêt aléatoire, ne suffirait-elle pas si la plateforme voulait comparer sa forêt aléatoire à un modèle de boosting (chapitre suivant) ?