

Chapitre 11

Interpréter un modèle de prévision

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre


Correction — Exercice 1

- (a) $0,20 + 0,15 + 0,10 - 0,05 = 0,40$: c'est bien la probabilité prédite.
- (b) La propriété de Shapley garantit qu'une variable qui ne sert **en rien** au modèle reçoit une contribution exactement nulle – c'est l'une des propriétés qui fondent la méthode, aux côtés de la décomposition exacte de la prédiction.
- (c) Non. La décomposition de Shapley explique ce que le **modèle** fait – elle indique que cette variable, telle qu'elle est actuellement, contribue pour $+0,15$ à la prédiction – mais elle ne dit rien de ce qui se passerait si l'on **intervenait** pour changer sa valeur : c'est une explication du modèle, pas du monde, comme le rappelle explicitement le chapitre.




Correction — Exercice 2

- (a) Dégradation pour X = $0,88 - 0,79 = 0,09$. Dégradation pour Y = $0,88 - 0,87 = 0,01$.
- (b) Le modèle utilise manifestement X (forte dégradation de 0,09) et semble ne presque pas se servir de Y (dégradation quasi nulle de 0,01).
- (c) Oui, c'est exactement la première limite décrite dans le chapitre : si X et Y étaient fortement corrélées, permuter l'une laisserait l'information qu'elle porte encore disponible via l'autre (non permutee), et la dégradation mesurée sous-estimerait l'importance réelle de chacune – les deux pourraient paraître peu utiles individuellement alors qu'ensemble elles contribuent fortement, un même mécanisme que celui déjà rencontré avec l'importance des variables des forêts aléatoires au chapitre 8.



Correction — Exercice 3

- (a) La relation est clairement **non monotone** : elle décroît de 20–30 ans à 40–50 ans, puis remonte de 40–50 ans à 60–70 ans – une forme en U.
- (b) Écart = $0,28 - 0,09 = 0,19$.
- (c) Une régression logistique linéaire en l'âge brut ne peut représenter qu'une relation **monotone** entre l'âge et le logarithme de la cote de défaut (chapitre 5) : elle ne peut donc pas capter une forme en U, où le risque est élevé aux deux extrémités et faible au milieu. Un remède simple, déjà vu dans ce cours, consisterait à ajouter un terme quadratique en l'âge, ou à discrétiser l'âge en tranches (comme le fait naturellement un arbre de décision, chapitre 7, ou une forêt aléatoire, chapitre 8), qui captent nativement ce type de non-linéarité sans qu'on ait à la spécifier.



2 Exercices cumulatifs (chapitre 11 et tout le cours)

Correction — Exercice 4

- (a) $0,10 + 0,22 + 0,13 - 0,05 = 0,40$ ✓, conforme à la probabilité prédite officielle du chapitre.
- (b) Puisque $0,40 > 0,35$, ce dossier est classé « **défaut** » – et donc refusé.
- (c) Non, la contribution de $+0,22$ décrit uniquement ce que le **modèle** fait de la variable endettement, pas ce qui se produirait si l'on intervenait pour la réduire. Ce même avertissement traverse tout le cours sous des formes chiffrées différentes : l'exactitude du modèle ($0,87$) est **battue** par celle du classifieur trivial ($0,90$, chapitre 6) – preuve qu'une performance en apparence élevée ne garantit rien sans comparaison honnête ; le Gini de la racine de l'arbre ($0,18$, chapitre 7) ne fait que mesurer la pureté d'une répartition observée, sans jamais prouver qu'une variable comme l'endettement *cause* le défaut plutôt que d'y être simplement associée. Comme pour le nombre de relances de l'introduction – une conséquence de la difficulté, non sa cause –, aucune méthode d'interprétation, aussi rigoureuse soit sa décomposition mathématique, ne transforme une association en preuve causale. C'est précisément la limite que le cours suivant, *Inférence causale et machine learning*, se propose de lever.

EQM min. (ch. 1)
4,0

CV 5 blocs (ch. 2)
800/200

exact. vs trivial (ch. 6)
 $0,87 < 0,90$

Gini racine (ch. 7)
0,18


hors sac (ch. 8)
36,8 %

Shapley (ch. 11)
0,40

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $p = 0,25 + 0,20 + 0,10 - 0,15 = 0,40$.
- (b) Puisque $0,40 > 0,30$, ce dossier est classé « **défaut** ».
- (c) La contribution négative de l'ancienneté ne prouve **pas** que l'ancienneté rend, en soi, une entreprise plus sûre : c'est une hypothèse plausible parmi d'autres. Elle pourrait tout aussi bien refléter un **biais de survivance** – seules les entreprises qui ont su surmonter leurs difficultés passées atteignent une grande ancienneté, de sorte que l'ancienneté serait davantage une **conséquence** observable d'une bonne gestion passée qu'une **cause** de sécurité future. Le modèle, entraîné uniquement sur des associations observées, ne peut par construction pas trancher entre ces deux interprétations.



Correction — Exercice 6

(a) Ancienneté du contrat : $0,82 - 0,80 = 0,02$. Nombre de renouvellements : $0,82 - 0,81 = 0,01$.

(b) Dégradation combinée = $0,82 - 0,71 = 0,11$.

(c) La somme des deux dégradations individuelles ($0,02 + 0,01 = 0,03$) est très inférieure à la dégradation combinée ($0,11$) car les deux variables sont fortement **corrélées** : quand on permute seulement l'une, l'information qu'elle porte reste largement disponible via l'autre (non permutee), et le modèle compense presque entièrement la perte. Ce n'est que lorsque les **deux** sont détruites simultanément que l'information commune disparaît réellement – exactement la limite de la permutation individuelle décrite dans le chapitre : elle sous-estime l'importance de variables corrélées prises isolément.

