

Apprentissage statistique

Chapitre 11 : Interpréter un modèle de prévision

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Vérifier une décomposition de Shapley

Pour un dossier donné, la prédiction moyenne vaut 0,20. Trois variables contribuent : +0,15, +0,10 et -0,05.

- (a) Calculer la somme de la prédiction moyenne et des trois contributions : doit correspondre à la probabilité prédite.
- (b) Une quatrième variable a une contribution exactement nulle. Que garantit, dans ce cas précis, la propriété de Shapley rappelée dans le chapitre ?
- (c) Cette décomposition permet-elle d'affirmer que réduire la valeur de la première variable ferait baisser la probabilité prédite de 0,15 ? Justifier.

Exercice 2 — Mesurer une importance par permutation

Un modèle atteint une AUC de 0,88. Après permutation aléatoire de la variable X , l'AUC chute à 0,79. Après permutation de la variable Y , l'AUC vaut 0,87.

- (a) Calculer la dégradation de performance associée à chacune des deux variables.
- (b) Laquelle des deux variables le modèle utilise-t-il manifestement, et laquelle semble ne pas lui servir ?
- (c) Si X et Y étaient en réalité fortement corrélées entre elles, cette méthode risquerait-elle de sous-estimer leur importance conjointe ? Expliquer le mécanisme décrit dans le chapitre.

Exercice 3 — Lire un graphique de dépendance partielle non monotone

La dépendance partielle de la probabilité de défaut prédite selon l'âge donne : 20–30 ans : 0,28 ; 30–40 ans : 0,12 ; 40–50 ans : 0,09 ; 50–60 ans : 0,11 ; 60–70 ans : 0,25.

- (a) Décrire la forme de cette relation : est-elle monotone (croissante ou décroissante) ou non monotone ?
- (b) Calculer l'écart entre la valeur la plus élevée et la valeur la plus faible de cette dépendance partielle.
- (c) Pourquoi une régression logistique linéaire en l'âge brut serait-elle incapable de capter cette forme, et quel remède simple le chapitre suggère-t-il implicitement (au vu des méthodes non linéaires déjà vues dans ce cours) ?

2 Exercices cumulatifs (chapitre 11 et tout le cours)

Exercice 4 — Le fil rouge chiffré du cours, revisité (introduction, chapitre 1, chapitre 2, chapitre 6, chapitre 11)

On reprend la décomposition de Shapley officielle du chapitre pour un dossier refusé du portefeuille de **mille dossiers de crédit** de l'introduction : prédiction moyenne 0,10 ; endettement élevé +0,22 ; ancienneté faible +0,13 ; revenu correct -0,05.

- (a) Vérifier que la somme de ces quatre termes redonne bien la probabilité prédite de 0,40.
- (b) La banque fixe son seuil de décision à 0,35 (nettement inférieur à 0,5, conformément à l'avertissement du chapitre 5 sur ce portefeuille à 10 % de défauts). Ce dossier est-il classé « défaut » ou « bon » ?
- (c) La contribution de +0,22 de l'endettement signifie-t-elle que réduire l'endettement de ce client ferait mécaniquement baisser sa probabilité de défaut de 0,22 ? Relier votre réponse à **au moins deux** autres résultats chiffrés du cours – par exemple l'exactitude du modèle (0,87) battue par le classifieur trivial (0,90, chapitre 6) et le Gini de la racine de l'arbre (0,18, chapitre 7) – pour illustrer pourquoi le cours répète, chapitre après chapitre, qu'une association forte n'est jamais

une preuve de causalité.

3 Applications en sciences économiques

Exercice 5 — Expliquer un refus de crédit à une PME

Un dossier de PME refusé affiche : prédiction moyenne 0,25 ; chiffre d'affaires en baisse +0,20 ; retards fournisseurs +0,10 ; ancienneté de l'entreprise -0,15.

- (a) Vérifier que la somme redonne la probabilité prédite (que l'on notera p).
- (b) Avec un seuil de décision de 0,30, ce dossier est-il classé « défaut » ou « bon » ?
- (c) La contribution négative de l'ancienneté (-0,15) signifie-t-elle que l'ancienneté d'une entreprise la rend, en soi, plus sûre ? Ou pourrait-elle refléter un biais de survivance (seules les entreprises qui ont bien géré leurs difficultés atteignent une grande ancienneté) ? Discuter.

Exercice 6 — L'importance sous-estimée de deux variables corrélées


Un modèle de résiliation d'abonnement (*churn*) atteint une AUC de 0,82. Permuter seule l'« ancienneté du contrat » fait chuter l'AUC à 0,80. Permuter seul le « nombre de renouvellements » fait chuter l'AUC à 0,81. Retirer **les deux** variables simultanément fait chuter l'AUC à 0,71.

- (a) Calculer la dégradation individuelle associée à chacune des deux variables.
- (b) Calculer la dégradation lorsque les deux variables sont retirées ensemble.
- (c) Pourquoi la dégradation combinée (0,11) est-elle si supérieure à la somme des deux dégradations individuelles (0,03) ? Relier votre réponse à la limite de la permutation face aux variables corrélées, décrite dans le chapitre.

1 Exercices du chapitre


Correction — Exercice 1

- (a) $0,20 + 0,15 + 0,10 - 0,05 = 0,40$: c'est bien la probabilité prédite.
- (b) La propriété de Shapley garantit qu'une variable qui ne sert **en rien** au modèle reçoit une contribution exactement nulle – c'est l'une des propriétés qui fondent la méthode, aux côtés de la décomposition exacte de la prédiction.
- (c) Non. La décomposition de Shapley explique ce que le **modèle** fait – elle indique que cette variable, telle qu'elle est actuellement, contribue pour $+0,15$ à la prédiction – mais elle ne dit rien de ce qui se passerait si l'on **intervenant** pour changer sa valeur : c'est une explication du modèle, pas du monde, comme le rappelle explicitement le chapitre.




Correction — Exercice 2

- (a) Dégradation pour $X = 0,88 - 0,79 = 0,09$. Dégradation pour $Y = 0,88 - 0,87 = 0,01$.
- (b) Le modèle utilise manifestement X (forte dégradation de 0,09) et semble ne presque pas se servir de Y (dégradation quasi nulle de 0,01).
- (c) Oui, c'est exactement la première limite décrite dans le chapitre : si X et Y étaient fortement corrélées, permuter l'une laisserait l'information qu'elle porte encore disponible via l'autre (non permutée), et la dégradation mesurée sous-estimerait l'importance réelle de chacune – les deux pourraient paraître peu utiles individuellement alors qu'ensemble elles contribuent fortement, un même mécanisme que celui déjà rencontré avec l'importance des variables des forêts aléatoires au chapitre 8.



Correction — Exercice 3

- (a) La relation est clairement **non monotone** : elle décroît de 20–30 ans à 40–50 ans, puis remonte de 40–50 ans à 60–70 ans – une forme en U.
- (b) Écart = $0,28 - 0,09 = 0,19$.
- (c) Une régression logistique linéaire en l'âge brut ne peut représenter qu'une relation **monotone** entre l'âge et le logarithme de la cote de défaut (chapitre 5) : elle ne peut donc pas capter une forme en U, où le risque est élevé aux deux extrémités et faible au milieu. Un remède simple, déjà vu dans ce cours, consisterait à ajouter un terme quadratique en l'âge, ou à discrétiser l'âge en tranches (comme le fait naturellement un arbre de décision, chapitre 7, ou une forêt aléatoire, chapitre 8), qui captent nativement ce type de non-linéarité sans qu'on ait à la spécifier.



2 Exercices cumulatifs (chapitre 11 et tout le cours)

Correction — Exercice 4

- (a) $0,10 + 0,22 + 0,13 - 0,05 = 0,40$ ✓, conforme à la probabilité prédite officielle du chapitre.
- (b) Puisque $0,40 > 0,35$, ce dossier est classé « **défaut** » – et donc refusé.
- (c) Non, la contribution de $+0,22$ décrit uniquement ce que le **modèle** fait de la variable endettement, pas ce qui se produirait si l'on intervenait pour la réduire. Ce même avertissement traverse tout le cours sous des formes chiffrées différentes : l'exactitude du modèle ($0,87$) est **battue** par celle du classifieur trivial ($0,90$, chapitre 6) – preuve qu'une performance en apparence élevée ne garantit rien sans comparaison honnête ; le Gini de la racine de l'arbre ($0,18$, chapitre 7) ne fait que mesurer la pureté d'une répartition observée, sans jamais prouver qu'une variable comme l'endettement *cause* le défaut plutôt que d'y être simplement associée. Comme pour le nombre de relances de l'introduction – une conséquence de la difficulté, non sa cause –, aucune méthode d'interprétation, aussi rigoureuse soit sa décomposition mathématique, ne transforme une association en preuve causale. C'est précisément la limite que le cours suivant, *Inférence causale et machine learning*, se propose de lever.

EQM min. (ch. 1)
4,0

CV 5 blocs (ch. 2)
800/200

exact. vs trivial (ch. 6)
 $0,87 < 0,90$

Gini racine (ch. 7)
0,18


hors sac (ch. 8)
36,8 %

Shapley (ch. 11)
0,40

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $p = 0,25 + 0,20 + 0,10 - 0,15 = 0,40$.
- (b) Puisque $0,40 > 0,30$, ce dossier est classé « **défaut** ».
- (c) La contribution négative de l'ancienneté ne prouve **pas** que l'ancienneté rend, en soi, une entreprise plus sûre : c'est une hypothèse plausible parmi d'autres. Elle pourrait tout aussi bien refléter un **biais de survivance** – seules les entreprises qui ont su surmonter leurs difficultés passées atteignent une grande ancienneté, de sorte que l'ancienneté serait davantage une **conséquence** observable d'une bonne gestion passée qu'une **cause** de sécurité future. Le modèle, entraîné uniquement sur des associations observées, ne peut par construction pas trancher entre ces deux interprétations.



Correction — Exercice 6

(a) Ancienneté du contrat : $0,82 - 0,80 = 0,02$. Nombre de renouvellements : $0,82 - 0,81 = 0,01$.

(b) Dégradation combinée = $0,82 - 0,71 = 0,11$.

(c) La somme des deux dégradations individuelles ($0,02 + 0,01 = 0,03$) est très inférieure à la dégradation combinée ($0,11$) car les deux variables sont fortement **corrélées** : quand on permute seulement l'une, l'information qu'elle porte reste largement disponible via l'autre (non permutee), et le modèle compense presque entièrement la perte. Ce n'est que lorsque les **deux** sont détruites simultanément que l'information commune disparaît réellement – exactement la limite de la permutation individuelle décrite dans le chapitre : elle sous-estime l'importance de variables corrélées prises isolément.

