

Chapitre 11

Interpréter un modèle de prévision

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Vérifier une décomposition de Shapley

Pour un dossier donné, la prédiction moyenne vaut 0,20. Trois variables contribuent : +0,15, +0,10 et -0,05.

- (a) Calculer la somme de la prédiction moyenne et des trois contributions : doit correspondre à la probabilité prédite.
- (b) Une quatrième variable a une contribution exactement nulle. Que garantit, dans ce cas précis, la propriété de Shapley rappelée dans le chapitre ?
- (c) Cette décomposition permet-elle d'affirmer que réduire la valeur de la première variable ferait baisser la probabilité prédite de 0,15 ? Justifier.

Exercice 2 — Mesurer une importance par permutation

Un modèle atteint une AUC de 0,88. Après permutation aléatoire de la variable X, l'AUC chute à 0,79. Après permutation de la variable Y, l'AUC vaut 0,87.

- (a) Calculer la dégradation de performance associée à chacune des deux variables.
- (b) Laquelle des deux variables le modèle utilise-t-il manifestement, et laquelle semble ne pas lui servir ?
- (c) Si X et Y étaient en réalité fortement corrélées entre elles, cette méthode risquerait-elle de sous-estimer leur importance conjointe ? Expliquer le mécanisme décrit dans le chapitre.

Exercice 3 — Lire un graphique de dépendance partielle non monotone

La dépendance partielle de la probabilité de défaut prédite selon l'âge donne : 20–30 ans : 0,28 ; 30–40 ans : 0,12 ; 40–50 ans : 0,09 ; 50–60 ans : 0,11 ; 60–70 ans : 0,25.

- (a) Décrire la forme de cette relation : est-elle monotone (croissante ou décroissante) ou non monotone ?
- (b) Calculer l'écart entre la valeur la plus élevée et la valeur la plus faible de cette dépendance partielle.
- (c) Pourquoi une régression logistique linéaire en l'âge brut serait-elle incapable de capter cette forme, et quel remède simple le chapitre suggère-t-il implicitement (au vu des méthodes non linéaires déjà vues dans ce cours) ?

2 Exercices cumulatifs (chapitre 11 et tout le cours)

Exercice 4 — Le fil rouge chiffré du cours, revisité (introduction, chapitre 1, chapitre 2, chapitre 6, chapitre 11)

On reprend la décomposition de Shapley officielle du chapitre pour un dossier refusé du portefeuille de **mille dossiers de crédit** de l'introduction : prédiction moyenne 0,10 ; endettement élevé +0,22 ; ancienneté faible +0,13 ; revenu correct -0,05.

- (a) Vérifier que la somme de ces quatre termes redonne bien la probabilité prédite de 0,40.
- (b) La banque fixe son seuil de décision à 0,35 (nettement inférieur à 0,5, conformément à l'avertissement du chapitre 5 sur ce portefeuille à 10 % de défauts). Ce dossier est-il classé « défaut » ou « bon » ?
- (c) La contribution de +0,22 de l'endettement signifie-t-elle que réduire l'endettement de ce client ferait mécaniquement baisser sa probabilité de défaut de 0,22 ? Relier votre réponse à **au moins deux** autres résultats chiffrés du cours – par exemple l'exactitude du modèle (0,87) battue par le classifieur trivial (0,90, chapitre 6) et le Gini de la racine de l'arbre (0,18, chapitre 7) – pour illustrer pourquoi le cours répète, chapitre après chapitre, qu'une association forte n'est jamais

3 Applications en sciences économiques

Exercice 5 — Expliquer un refus de crédit à une PME

Un dossier de PME refusé affiche : prédiction moyenne 0,25 ; chiffre d'affaires en baisse +0,20 ; retards fournisseurs +0,10 ; ancienneté de l'entreprise -0,15.

- (a) Vérifier que la somme redonne la probabilité prédite (que l'on notera p).
- (b) Avec un seuil de décision de 0,30, ce dossier est-il classé « défaut » ou « bon » ?
- (c) La contribution négative de l'ancienneté (-0,15) signifie-t-elle que l'ancienneté d'une entreprise la rend, en soi, plus sûre ? Ou pourrait-elle refléter un biais de survivance (seules les entreprises qui ont bien géré leurs difficultés atteignent une grande ancienneté) ? Discuter.

Exercice 6 — L'importance sous-estimée de deux variables corrélées

Un modèle de résiliation d'abonnement (*churn*) atteint une AUC de 0,82. Permuter seule l'« ancienneté du contrat » fait chuter l'AUC à 0,80. Permuter seul le « nombre de renouvellements » fait chuter l'AUC à 0,81. Retirer **les deux** variables simultanément fait chuter l'AUC à 0,71.

- (a) Calculer la dégradation individuelle associée à chacune des deux variables.
- (b) Calculer la dégradation lorsque les deux variables sont retirées ensemble.
- (c) Pourquoi la dégradation combinée (0,11) est-elle si supérieure à la somme des deux dégradations individuelles (0,03) ? Relier votre réponse à la limite de la permutation face aux variables corrélées, décrite dans le chapitre.