

Apprentissage statistique

Chapitre 3 : La régression pénalisée : ridge et lasso

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Comparer ridge et lasso sur les mêmes coefficients OLS

Une régression par moindres carrés (MCO) donne les coefficients $(3,2; -1,8; 0,5; 2,1)$ pour quatre variables. Une régression ridge, pour un certain λ , correspond ici à un rétrécissement uniforme de facteur 0,65 appliqué à chaque coefficient MCO. Une régression lasso, pour un λ comparable, donne $(1,9; -1,0; 0; 1,3)$.

- Calculer les quatre coefficients ridge.
- Quelle variable le lasso a-t-il éliminée du modèle? Le ridge aurait-il pu produire ce même résultat, quel que soit $\lambda > 0$? Justifier.
- Comparer, variable par variable, l'ordre de grandeur des coefficients ridge et lasso obtenus. Lequel des deux rétrécit le plus fortement les coefficients non nuls ici?

Exercice 2 — Calculer les critères pénalisés ridge et lasso

Une régression donne une somme des carrés des résidus de 45,2, pour des coefficients $\beta = (2; -1; 0,5)$ et $\lambda = 0,8$.

- Calculer la pénalité ridge $\lambda \sum_j \beta_j^2$, puis le critère ridge complet.
- Calculer la pénalité lasso $\lambda \sum_j |\beta_j|$, puis le critère lasso complet.
- Le critère lasso obtenu est-il inférieur au critère ridge? Cette comparaison permet-elle de conclure que le lasso prévoit mieux que le ridge sur ces données? Justifier.

Exercice 3 — Lire une trajectoire de sélection lasso

Pour un modèle à 10 variables candidates, le nombre de coefficients lasso non nuls évolue ainsi selon λ :

λ	Nombre de coefficients non nuls
0	10
2	10
8	5
25	1

- Pour quelle valeur de λ le lasso coïncide-t-il exactement avec les MCO? Justifier par la formule du critère lasso.
- La validation croisée désigne $\lambda = 8$ comme optimal. Combien de variables le modèle final retient-il, et combien sont éliminées?
- Que se passerait-il, en théorie, si λ continuait de croître bien au-delà de 25?

2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Régulariser le modèle le plus flexible du chapitre 1 (chapitre 1, chapitre 2, introduction)

On reprend le modèle de complexité 12 de l'exercice 2 du chapitre 1, estimé sur le portefeuille de **mille dossiers de crédit** de l'introduction : biais² = 0,3, variance = 7,0, bruit = 1,2, d'où une EQM de 8,5. Une régularisation ridge, dont le λ est choisi par validation croisée à 5 blocs (comme au chapitre 2), ramène la variance de ce modèle à 2,0 mais fait remonter son biais² à 1,0.

- Calculer la nouvelle EQM du modèle régularisé.
- Comparer cette nouvelle EQM à celle du modèle de complexité 12 non régularisé (8,5), puis à

celle du meilleur modèle non régularisé du chapitre 1, de complexité 6 (4,5).

- (c) En quoi ce résultat illustre-t-il le principe du chapitre 1 selon lequel on peut «brider un modèle flexible plutôt que d'en choisir un simple»? Comment choisirait-on concrètement la valeur de λ à utiliser, en pratique, sur ce portefeuille?

3 Applications en sciences économiques

Exercice 5 — Stabiliser un modèle immobilier par ridge

Un modèle de prix immobilier inclut deux variables très corrélées (corrélation 0,97) : la surface habitable et la surface totale (habitable + annexes). La régression MCO donne des coefficients de 850 et -810 dirhams par m^2 respectivement. Une régression ridge sur les mêmes données donne des coefficients de 48 et 41.

- (a) Calculer l'écart entre les deux coefficients MCO, puis l'écart entre les deux coefficients ridge.
- (b) Que révèle le signe opposé des deux coefficients MCO (850 et -810) quant à la plausibilité économique de cette estimation, sachant que les deux variables mesurent, presque à l'identique, la même surface?
- (c) Pourquoi les deux coefficients ridge, tous deux positifs et proches en valeur, sont-ils économiquement beaucoup plus plausibles que ceux des MCO?

Exercice 6 — Sélection de prédicteurs macroéconomiques en grande dimension


Une équipe de conjoncture dispose de $n = 40$ observations trimestrielles et de $p = 50$ variables macroéconomiques candidates pour prévoir une récession.

- (a) Pourquoi la solution des MCO n'est-elle même pas unique dans cette situation ($p > n$)?
- (b) Un lasso, dont le λ est choisi par validation croisée, retient finalement 6 variables non nulles sur les 50 candidates. Calculer la proportion de variables éliminées.
- (c) L'équipe souhaite présenter les 6 variables retenues comme les « causes » de la récession dans un rapport officiel. Pourquoi cette interprétation est-elle abusive au regard de la mise en garde du chapitre?

1 Exercices du chapitre


Correction — Exercice 1

- (a) Coefficients ridge = $0,65 \times (3,2; -1,8; 0,5; 2,1) = (2,08; -1,17; 0,325; 1,365)$.
- (b) Le lasso a éliminé la **troisième** variable (coefficient MCO $0,5 \rightarrow 0$). Non, le ridge ne peut **jamais** produire ce résultat, quel que soit $\lambda > 0$: sa pénalité en β_j^2 rétrécit continûment les coefficients vers zéro sans jamais les y faire toucher exactement (sauf à la limite $\lambda \rightarrow \infty$, où *tous* les coefficients s'annulent simultanément). Seule la géométrie «à coins» de la pénalité lasso permet à une coordonnée de s'annuler individuellement pour un λ fini.
- (c) Sur les variables communes (1, 2 et 4), le lasso rétrécit davantage : $1,9/3,2 \approx 0,59$, $1,0/1,8 \approx 0,56$ et $1,3/2,1 \approx 0,62$ contre un facteur uniforme de 0,65 pour le ridge – ici le lasso rétrécit plus fortement les coefficients qu'il conserve, en plus d'en annuler un.




Correction — Exercice 2

- (a) $\sum \beta_j^2 = 4 + 1 + 0,25 = 5,25$. Pénalité ridge = $0,8 \times 5,25 = 4,2$. Critère ridge complet = $45,2 + 4,2 = 49,4$.
- (b) $\sum |\beta_j| = 2 + 1 + 0,5 = 3,5$. Pénalité lasso = $0,8 \times 3,5 = 2,8$. Critère lasso complet = $45,2 + 2,8 = 48,0$.
- (c) Oui, $48,0 < 49,4$, mais cette comparaison est **sans portée** : les deux critères pénalisés sont ici calculés pour les *mêmes* coefficients β et le même λ , ce qui n'a aucun sens pratique – en réalité, ridge et lasso ne minimisent *pas* le même critère et n'aboutissent donc *pas* aux mêmes coefficients $\hat{\beta}$ pour un même λ . Seule une comparaison de l'**erreur de test** (ou de son estimation par validation croisée) entre les deux méthodes, chacune avec son propre λ optimal, permettrait de juger laquelle prévoit mieux.



Correction — Exercice 3

- (a) Pour $\lambda = 0$: la pénalité $\lambda \sum |\beta_j|$ s'annule identiquement, quel que soit β , et le critère lasso se réduit exactement à la somme des carrés des résidus des MCO – on retrouve donc leur solution.
- (b) À $\lambda = 8$, le modèle retient 5 variables non nulles et en élimine $10 - 5 = 5$.
- (c) En théorie, au-delà de $\lambda = 25$ (où il ne reste déjà qu'une seule variable), une croissance suffisante de λ finirait par annuler également ce dernier coefficient : à la limite $\lambda \rightarrow \infty$, tous les coefficients sont nuls et le modèle se réduit à une constante – exactement le cas limite décrit pour ridge, à ceci près qu'ici les coefficients l'atteignent pour un λ fini.




2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Nouvelle EQM = $1,0 + 2,0 + 1,2 = 4,2$.

(b) La régularisation fait chuter l'EQM du modèle de complexité 12 de 8,5 à 4,2 – une réduction spectaculaire. Elle fait même **mieux** que le meilleur modèle non régularisé du chapitre 1 (complexité 6, EQM = 4,5) : $4,2 < 4,5$.

(c) Ce résultat illustre exactement le principe du chapitre 1 : plutôt que de choisir *a priori* un modèle plus simple (complexité 6), on peut partir d'un modèle très flexible (complexité 12, biais² minimal mais variance énorme) et le **brider** par pénalisation pour retrancher l'essentiel de sa variance ($7,0 \rightarrow 2,0$) en échange d'un peu de biais supplémentaire ($0,3 \rightarrow 1,0$) – un compromis plus favorable ici que celui obtenu en réduisant directement la complexité du modèle. En pratique, on choisirait λ en le faisant varier sur une grille de valeurs et en retenant celui qui minimise l'erreur moyenne de validation croisée à 5 blocs sur les mille dossiers, exactement comme au chapitre 2.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Écart MCO = $850 - (-810) = 1\,660$ dirhams par m². Écart ridge = $48 - 41 = 7$ dirhams par m².

(b) Le signe opposé des deux coefficients MCO est économiquement **absurde** : puisque les deux variables mesurent presque la même chose (corrélation 0,97), un coefficient positif énorme et un coefficient négatif presque aussi grand signifient que le modèle a appris une compensation artificielle entre les deux (leur somme, $850 - 810 = 40$, reste modérée, mais chaque coefficient pris isolément n'a plus aucun sens économique). C'est la signature classique de la multicollinéarité décrite dans le chapitre.

(c) Les coefficients ridge, tous deux positifs et proches (48 et 41), sont bien plus plausibles car ridge **répartit** l'effet entre les deux variables corrélées plutôt que de laisser les MCO gonfler artificiellement l'une au détriment de l'autre : chaque m² de surface, qu'elle soit comptée comme « habitable » ou comme « totale », contribue de façon comparable et positive au prix, ce qui correspond bien mieux à l'intuition économique.



Correction — Exercice 6

(a) Avec $p = 50$ variables pour $n = 40$ observations seulement, le système des équations normales des MCO est **sous-déterminé** : il existe une infinité de combinaisons de coefficients qui annulent exactement la somme des carrés des résidus (voire l'ajustement est parfait), sans qu'aucune solution ne soit privilégiée mathématiquement. La matrice $X^T X$ n'est même pas inversible dans ce cas.

(b) Proportion éliminée = $(50 - 6)/50 = 44/50 = 88\%$.

(c) C'est exactement la mise en garde du chapitre : le lasso sélectionne ces 6 variables parce qu'elles **prévoient** bien la récession sur cet échantillon, pas parce qu'elles la **causent**. Une variable retenue peut être une conséquence de la récession plutôt que sa cause, ou simplement corrélée à la vraie cause sans lien causal direct – présenter ces 6 variables comme des « causes » dans un rapport officiel relève de l'inférence causale, un exercice que le lasso n'a jamais été conçu pour accomplir.