

Apprentissage statistique

Chapitre 4 : Sélection de variables et grande dimension

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Chiffrer le coût de la sélection exhaustive

- (a) Calculer le nombre de modèles à estimer pour une sélection exhaustive avec $p = 8$, puis avec $p = 15$, puis avec $p = 25$ variables candidates.
- (b) Pour $p = 25$, calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante, et comparer-le au coût exhaustif de la même question.
- (c) Trouver la plus petite valeur entière de p pour laquelle le nombre de modèles de la sélection exhaustive dépasse le million.

Exercice 2 — Comparer deux modèles par AIC et par BIC

Sur $n = 200$ observations, un modèle A a une somme des carrés des résidus de 150 pour $k = 5$ paramètres; un modèle B a une somme des carrés des résidus de 120 pour $k = 12$ paramètres. On utilise $AIC = n \ln(SCR/n) + 2k$ et $BIC = n \ln(SCR/n) + k \ln(n)$ (plus la valeur est faible, meilleur est le modèle).

- (a) Calculer l'AIC du modèle A et celui du modèle B .
- (b) Calculer le BIC du modèle A et celui du modèle B .
- (c) Les deux critères désignent-ils le même modèle comme préférable? Comparer, sur cet exemple, la pénalité par paramètre de l'AIC (2) à celle du BIC ($\ln(200) \approx 5,30$) : lequel des deux pénalise le plus sévèrement chaque paramètre supplémentaire?

Exercice 3 — Reconnaître un régime de grande dimension

Sur un corpus de textes, on dispose de $n = 300$ documents et de $p = 15\,000$ mots (variables). Un lasso, dont le λ est choisi par validation croisée, retient finalement 45 mots non nuls.

- (a) Ce problème est-il en régime $p > n$? Justifier par les chiffres donnés.
- (b) Calculer la proportion de mots retenus par le lasso parmi les 15 000 candidats.
- (c) Pourquoi un calcul de p -value, réalisé pour chacun des 45 mots retenus *sur ces mêmes 300 documents* ayant servi à la sélection, serait-il invalide?

2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2 et introduction)

Exercice 4 — Choisir une méthode de sélection sur le portefeuille de crédit (chapitre 3, chapitre 2, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, une équipe dispose de $p = 60$ variables candidates pour le modèle de complexité 12 régularisé par ridge au chapitre 3 (dont l'EQM validée par croisée à 5 blocs valait 4,2, chapitre 2).

- (a) Calculer, en notation scientifique, l'ordre de grandeur du nombre de modèles que testerait une sélection exhaustive avec $p = 60$ variables.
- (b) Calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante pour ce même $p = 60$.
- (c) Au vu de l'écart entre les réponses de (a) et (b), et sachant que la régularisation du chapitre 3 atteint déjà une EQM de 4,2 validée par la validation croisée du chapitre 2, pourquoi la régularisation (ridge, lasso) est-elle en général préférée à une recherche exhaustive ou même ascendante/descendante dans ce type de contexte?

3 Applications en sciences économiques

Exercice 5 — Sélection de mots dans un scoring de prêt participatif

Une plateforme de prêt participatif (P2P lending) extrait, pour $n = 600$ dossiers de prêt, $p = 5\,000$ variables textuelles (fréquences de mots dans la description du projet). Un lasso, validé par validation croisée, retient 80 mots non nuls.

- (a) Ce problème est-il en régime $p > n$? Justifier.
- (b) Calculer la proportion de mots retenus par le lasso parmi les 5 000 candidats.
- (c) La plateforme souhaite publier, pour chacun des 80 mots retenus, une p -value calculée sur ces mêmes 600 dossiers ayant servi à la sélection. Pourquoi cette pratique est-elle invalide, et quelle solution plus sûre le chapitre propose-t-il?

Exercice 6 — Le danger d'une recherche exhaustive en finance quantitative


Un fonds quantitatif teste $p = 300$ indicateurs techniques candidats pour construire une stratégie de trading, sur seulement $n = 250$ jours de données. Une recherche exhaustive testerait 2^{300} combinaisons.

- (a) Calculer l'ordre de grandeur, en notation scientifique, de 2^{300} .
- (b) Calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante pour ce même $p = 300$.
- (c) Même avec cette approche ascendante bien moins coûteuse que l'exhaustive, pourquoi le fonds risque-t-il encore de « choisir le plus chanceux » parmi les indicateurs testés, s'il ne réintègre pas la sélection à l'intérieur de chaque bloc de validation croisée?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $p = 8 : 2^8 = 256$. $p = 15 : 2^{15} = 32\,768$. $p = 25 : 2^{25} = 33\,554\,432$, soit plus de 33 millions de modèles.
(b) Coût ascendant/descendant pour $p = 25 : 25^2/2 = 312,5$, à comparer aux 33,5 millions de la sélection exhaustive – un facteur d'environ 100 000 entre les deux approches.
(c) $2^{19} = 524\,288 < 10^6$ et $2^{20} = 1\,048\,576 > 10^6$: c'est donc à partir de $p = 20$ que le nombre de modèles exhaustifs dépasse le million.



Correction — Exercice 2


- (a) $AIC_A = 200 \ln(150/200) + 2 \times 5 = 200 \times (-0,2877) + 10 \approx -57,54 + 10 = -47,54$. $AIC_B = 200 \ln(120/200) + 2 \times 12 = 200 \times (-0,5108) + 24 \approx -102,17 + 24 = -78,17$.
(b) $BIC_A = 200 \ln(0,75) + 5 \ln(200) \approx -57,54 + 5 \times 5,2983 = -57,54 + 26,49 = -31,05$. $BIC_B = 200 \ln(0,6) + 12 \ln(200) \approx -102,17 + 12 \times 5,2983 = -102,17 + 63,58 = -38,59$.
(c) Ici, l'**AIC** et le **BIC** désignent tous les deux le modèle B comme préférable ($-78,17 < -47,54$ et $-38,59 < -31,05$). Sur cet exemple, la pénalité par paramètre du BIC ($\ln(200) \approx 5,30$) est nettement supérieure à celle de l'AIC (2) : le BIC pénalise donc plus sévèrement chaque paramètre ajouté. Cela ne garantit pas pour autant que les deux critères s'accordent toujours – avec d'autres valeurs de SCR et de k , un modèle plus riche pourrait être préféré par l'AIC (orienté prévision) et rejeté par le BIC (plus parcimonieux).



Correction — Exercice 3

- (a) Oui : $p = 15\,000$ est très largement supérieur à $n = 300$, ce qui place le problème en plein régime $p > n$, où les MCO admettraient une infinité de solutions ajustant parfaitement les 300 documents.
(b) Proportion retenue = $45/15\,000 = 0,30\%$.
(c) Parce que ces 45 mots ont été **choisis** par le lasso précisément parce qu'ils semblaient les plus liés à Y sur ces mêmes 300 documents : calculer une p -value sur les données mêmes qui ont servi à la sélection revient à tester une hypothèse formulée après avoir regardé les résultats, ce qui invalide l'interprétation classique de la p -value. C'est l'inférence après sélection décrite dans le chapitre : elle


produit des résultats systématiquement trop optimistes.



2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2 et introduction)

Correction — Exercice 4

- (a) $2^{60} \approx 1,153 \times 10^{18}$ modèles – plus d'un milliard de milliards.
- (b) Coût ascendant/descendant pour $p = 60$: $60^2/2 = 1\,800$ modèles.
- (c) L'écart entre $1,15 \times 10^{18}$ et 1 800 est colossal : même la sélection ascendante/descendante, pourtant bien plus rapide que l'exhaustive, resterait coûteuse et exposée au biais de « choisir le plus chanceux » décrit dans le chapitre si elle n'est pas réintégrée dans chaque bloc de validation croisée. La régularisation (ridge, lasso) évite ce problème *par construction* : elle ne teste pas des sous-ensembles discrets de variables un par un, mais résout un seul problème d'optimisation continue en λ , dont la valeur est elle-même validée par la validation croisée à 5 blocs du chapitre 2 – et elle atteint déjà, sur ce portefeuille, une EQM de 4,2 (chapitre 3), sans jamais avoir eu besoin d'énumérer le moindre sous-ensemble de variables.




3 Applications en sciences économiques

Correction — Exercice 5

- (a) Oui : $p = 5\,000$ dépasse très largement $n = 600$, ce qui place clairement ce problème en régime $p > n$.
- (b) Proportion retenue = $80/5\,000 = 1,60\%$.
- (c) La pratique est invalide pour la même raison qu'à l'exercice 3 : les 80 mots ont été sélectionnés *sur ces mêmes 600 dossiers*, et calculer une p -value dessus revient à tester une hypothèse formulée après avoir vu les données qui la confirment. La solution la plus sûre proposée par le chapitre est de **séparer**

les données : sélectionner les mots pertinents sur une moitié de l'échantillon, puis estimer et tester leurs coefficients sur l'autre moitié, jamais vue lors de la sélection.



Correction — Exercice 6

- (a) $2^{300} \approx 2,037 \times 10^{90}$ – un nombre plus grand que l'estimation du nombre total d'atomes dans l'univers observable (de l'ordre de 10^{80}), et donc absolument hors de portée de tout calcul.
- (b) Coût ascendant/descendant pour $p = 300$: $300^2/2 = 45\,000$ modèles.
- (c) Même à 45 000 modèles (bien moins que 2^{300}), le fonds explore un très grand nombre de combinaisons d'indicateurs sur seulement $n = 250$ jours de données : avec autant de candidats testés, un sous-ensemble d'indicateurs finira par paraître excellent par pur hasard, sans aucun pouvoir prédictif réel – c'est exactement le sur-ajustement du *choix de modèle* décrit dans le chapitre, distinct du sur-ajustement des paramètres. Pour l'éviter, la sélection des indicateurs doit être refaite à l'intérieur de **chaque bloc** de la validation croisée, et non effectuée une fois pour toutes sur l'ensemble des 250 jours avant d'évaluer la stratégie.