

Chapitre 4

Sélection de variables et grande dimension

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Chiffrer le coût de la sélection exhaustive

- (a) Calculer le nombre de modèles à estimer pour une sélection exhaustive avec $p = 8$, puis avec $p = 15$, puis avec $p = 25$ variables candidates.
- (b) Pour $p = 25$, calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante, et comparer-le au coût exhaustif de la même question.
- (c) Trouver la plus petite valeur entière de p pour laquelle le nombre de modèles de la sélection exhaustive dépasse le million.

Exercice 2 — Comparer deux modèles par AIC et par BIC

Sur $n = 200$ observations, un modèle A a une somme des carrés des résidus de 150 pour $k = 5$ paramètres; un modèle B a une somme des carrés des résidus de 120 pour $k = 12$ paramètres. On utilise $AIC = n \ln(SCR/n) + 2k$ et $BIC = n \ln(SCR/n) + k \ln(n)$ (plus la valeur est faible, meilleur est le modèle).

- (a) Calculer l'AIC du modèle A et celui du modèle B .
- (b) Calculer le BIC du modèle A et celui du modèle B .
- (c) Les deux critères désignent-ils le même modèle comme préférable? Comparer, sur cet exemple, la pénalité par paramètre de l'AIC (2) à celle du BIC ($\ln(200) \approx 5,30$) : lequel des deux pénalise le plus sévèrement chaque paramètre supplémentaire?

Exercice 3 — Reconnaître un régime de grande dimension

Sur un corpus de textes, on dispose de $n = 300$ documents et de $p = 15\,000$ mots (variables). Un lasso, dont le λ est choisi par validation croisée, retient finalement 45 mots non nuls.

- (a) Ce problème est-il en régime $p > n$? Justifier par les chiffres donnés.
- (b) Calculer la proportion de mots retenus par le lasso parmi les 15 000 candidats.
- (c) Pourquoi un calcul de p -value, réalisé pour chacun des 45 mots retenus *sur ces mêmes 300 documents* ayant servi à la sélection, serait-il invalide?

2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2 et introduction)

Exercice 4 — Choisir une méthode de sélection sur le portefeuille de crédit (chapitre 3, chapitre 2, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, une équipe dispose de $p = 60$ variables candidates pour le modèle de complexité 12 régularisé par ridge au chapitre 3 (dont l'EQM validée par croisée à 5 blocs valait 4,2, chapitre 2).

- (a) Calculer, en notation scientifique, l'ordre de grandeur du nombre de modèles que testerait une sélection exhaustive avec $p = 60$ variables.
- (b) Calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante pour ce même $p = 60$.
- (c) Au vu de l'écart entre les réponses de (a) et (b), et sachant que la régularisation du chapitre 3 atteint déjà une EQM de 4,2 validée par la validation croisée du chapitre 2, pourquoi la régularisation (ridge, lasso) est-elle en général préférée à une recherche exhaustive ou même ascendante/descendante dans ce type de contexte?

3 Applications en sciences économiques

Exercice 5 — Sélection de mots dans un scoring de prêt participatif

Une plateforme de prêt participatif (P2P lending) extrait, pour $n = 600$ dossiers de prêt, $p = 5\,000$ variables textuelles (fréquences de mots dans la description du projet). Un lasso, validé par validation croisée, retient 80 mots non nuls.

- (a) Ce problème est-il en régime $p > n$? Justifier.
- (b) Calculer la proportion de mots retenus par le lasso parmi les 5 000 candidats.
- (c) La plateforme souhaite publier, pour chacun des 80 mots retenus, une p -value calculée sur ces mêmes 600 dossiers ayant servi à la sélection. Pourquoi cette pratique est-elle invalide, et quelle solution plus sûre le chapitre propose-t-il?

Exercice 6 — Le danger d'une recherche exhaustive en finance quantitative

Un fonds quantitatif teste $p = 300$ indicateurs techniques candidats pour construire une stratégie de trading, sur seulement $n = 250$ jours de données. Une recherche exhaustive testerait 2^{300} combinaisons.

- (a) Calculer l'ordre de grandeur, en notation scientifique, de 2^{300} .
- (b) Calculer le coût approximatif ($p^2/2$) d'une sélection ascendante ou descendante pour ce même $p = 300$.
- (c) Même avec cette approche ascendante bien moins coûteuse que l'exhaustive, pourquoi le fonds risque-t-il encore de « choisir le plus chanceux » parmi les indicateurs testés, s'il ne réintègre pas la sélection à l'intérieur de chaque bloc de validation croisée?