

Apprentissage statistique

Chapitre 10 : Les machines à vecteurs de support

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Rendre séparable par l'astuce du noyau

Cinq points sont donnés : classe A en $(0; 0)$ et $(0,5; 0,3)$; classe B en $(3; 0)$, $(0; 3)$ et $(2; 2)$. Aucune droite du plan ne sépare les deux classes.

- (a) Calculer la troisième coordonnée $z = x_1^2 + x_2^2$ pour chacun des cinq points.
- (b) Trouver un seuil k tel que $z < k$ pour tous les points de la classe A et $z > k$ pour tous les points de la classe B .
- (c) En quoi ce seuil correspond-il à «un simple plan horizontal» séparant les deux classes dans l'espace à trois coordonnées, comme le décrit le chapitre ?

Exercice 2 — Chiffrer le coût de calcul quadratique en n

Le coût d'entraînement d'une SVM est proportionnel à n^2 .

- (a) Calculer le rapport de coût entre un entraînement sur $n = 5\,000$ observations et un entraînement sur $n = 1\,000$ observations.
- (b) Calculer ce même rapport pour $n = 20\,000$ contre $n = 1\,000$.
- (c) Pourquoi ce coût quadratique rend-il la SVM mal adaptée à des bases de plusieurs millions d'observations, même si elle reste très efficace en grande dimension avec n modéré ?

Exercice 3 — Diagnostiquer le sur-ajustement par le réglage de C

Deux réglages de C sont testés sur $n = 50$ observations d'apprentissage. $C = 0,1$: 15 violations de marge, erreur d'apprentissage 15 %, erreur de test 17 %. $C = 100$: 1 violation de marge, erreur d'apprentissage 1 %, erreur de test 23 %.

- (a) Calculer la proportion de violations de marge pour chacun des deux réglages.
- (b) Calculer l'écart entre erreur de test et erreur d'apprentissage pour chacun des deux réglages.
- (c) Lequel des deux réglages montre les signes d'un sur-ajustement les plus nets ? Lequel choisirait-on au vu de la seule erreur de test ?

2 Exercices cumulatifs (chapitre 10, chapitre 8, chapitre 3, chapitre 1 et introduction)

Exercice 4 — Une SVM sur le portefeuille de crédit : coût et réglage de C (chapitre 8, chapitre 2, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, avec $p = 20$ variables (comme au chapitre 8), une équipe entraîne une SVM à noyau gaussien.

- (a) Calculer le rapport de coût de calcul entre un entraînement sur les 1 000 dossiers complets et un entraînement sur l'ensemble d'apprentissage d'un seul bloc de validation croisée du chapitre 2 (800 dossiers).
- (b) La validation croisée à 5 blocs du chapitre 2 est utilisée pour choisir C : $C = 0,05$ donne une erreur de validation de 12 %, $C = 50$ donne une erreur de validation de 19 %. Lequel des deux C la validation croisée retiendrait-elle ?
- (c) Le chapitre affirme que C pose «la même question» que λ (chapitre 3) et α (chapitre 7). En quoi ces trois paramètres jouent-ils, dans le langage du chapitre 1, exactement le même rôle dans le compromis biais-variance ?

3 Applications en sciences économiques

Exercice 5 — Une SVM sur des données textuelles d'assurance

Un assureur dispose de $p = 8\,000$ variables textuelles (fréquences de mots) mais de seulement $n = 600$ réclamations étiquetées pour détecter la fraude.

- (a) Ce contexte (p grand, n modéré) correspond-il au cas où le chapitre recommande la SVM, ou au cas où il recommande plutôt le boosting du chapitre 9?
- (b) Calculer le rapport de coût de calcul si l'assureur passait de $n = 600$ à $n = 6\,000$ réclamations étiquetées (coût proportionnel à n^2).
- (c) Ce rapport de coût reste-t-il compatible avec un usage pratique de la SVM si l'assureur venait à disposer, à terme, de plusieurs millions de réclamations?

Exercice 6 — Pourquoi une fintech de paiement écarte la SVM


Une fintech de paiement traite $n = 50\,000\,000$ transactions par mois et souhaite entraîner un modèle de détection de fraude en temps quasi réel.

- (a) Calculer le rapport de coût de calcul entre un entraînement sur les 50 millions de transactions et un entraînement sur un échantillon de $n = 10\,000$ transactions.
- (b) Ce rapport est-il compatible avec un réentraînement fréquent (par exemple quotidien) du modèle?
- (c) Parmi les méthodes vues dans ce cours (régression pénalisée, arbre, forêt aléatoire, boosting, SVM), lesquelles seraient plus adaptées à ce volume, et pourquoi?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $(0,0) : z = 0$. $(0,5; 0,3) : z = 0,25 + 0,09 = 0,34$. $(3,0) : z = 9$. $(0,3) : z = 9$. $(2,2) : z = 4 + 4 = 8$.
- (b) N'importe quel seuil $k \in]0,34; 8[$ convient, par exemple $k = 1$: les points de la classe A ont $z \in \{0; 0,34\} < 1$, ceux de la classe B ont $z \in \{8; 9; 9\} > 1$.
- (c) Dans l'espace à trois coordonnées (x_1, x_2, z) , l'ensemble des points vérifiant $z = k = 1$ est un plan **horizontal**. Les points de la classe A, dont le z est inférieur à 1, se trouvent *sous* ce plan ; ceux de la classe B se trouvent *au-dessus*. Ce plan horizontal réalise donc exactement la séparation qu'aucune droite ne pouvait réaliser dans le plan d'origine (x_1, x_2) – la transformation $z = x_1^2 + x_2^2$ a rendu linéairement séparable ce qui ne l'était pas.




Correction — Exercice 2

- (a) Rapport $= (5\,000/1\,000)^2 = 5^2 = 25$.
- (b) Rapport $= (20\,000/1\,000)^2 = 20^2 = 400$.
- (c) Avec un coût proportionnel à n^2 , multiplier n par 1 000 (par exemple passer de quelques milliers à quelques millions d'observations) multiplierait le coût de calcul par $1\,000^2 = 1$ million : un temps d'entraînement de quelques minutes deviendrait des années de calcul. C'est précisément l'inverse du régime où la SVM excelle – p grand, n modéré – car sa complexité ne dépend pas de p de la même façon pénalisante que de n .



Correction — Exercice 3

- (a) $C = 0,1 : 15/50 = 30\%$ de violations. $C = 100 : 1/50 = 2\%$ de violations.
- (b) $C = 0,1 : \text{écart} = 17\% - 15\% = 2$ points. $C = 100 : \text{écart} = 23\% - 1\% = 22$ points.
- (c) Le réglage $C = 100$ montre un sur-ajustement bien plus net : un écart de 22 points entre erreur d'apprentissage quasi nulle (1 %) et erreur de test élevée (23 %) est la signature classique décrite dès le chapitre 1. Sur la seule erreur de test, on choisirait $C = 0,1$ (erreur de 17 %, contre 23 % pour $C = 100$) : la marge plus large, qui tolère davantage de violations à l'entraînement, généralise mieux ici.




2 Exercices cumulatifs (chapitre 10, chapitre 8, chapitre 3, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\text{Rapport} = (1\,000/800)^2 = 1,25^2 = 1,5625$.

(b) La validation croisée retiendrait $C = 0,05$, dont l'erreur de validation (12 %) est inférieure à celle de $C = 50$ (19 %).

(c) C , λ et α sont les trois **mêmes** type de paramètre sous des noms différents : chacun contrôle, dans son modèle respectif, l'arbitrage entre s'ajuster fidèlement aux données d'apprentissage (moins de biais, plus de variance) et rester contraint (plus de biais, moins de variance). Un C petit, un λ grand et un α grand pénalisent tous davantage la complexité du modèle ; les trois se choisissent par la même procédure – la validation croisée du chapitre 2 – car aucun ne peut se fixer a priori sans consulter les données.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Ce contexte – $p = 8\,000$ grand, $n = 600$ modéré – correspond exactement au cas où le chapitre recommande la **SVM**, précisément celui où les méthodes d'ensemble du chapitre 9 manquent d'observations pour exploiter pleinement leur avantage.

(b) $\text{Rapport} = (6\,000/600)^2 = 10^2 = 100$.

(c) Non : un rapport de 100 pour un facteur 10 sur n montre bien la croissance quadratique, mais reste gérable. En revanche, si l'assureur passait à plusieurs **millions** de réclamations (un facteur 1 000 ou plus par rapport aux 600 initiales), le coût serait multiplié par au moins $1\,000^2 = 1$ million, rendant la SVM totalement impraticable à cette échelle – il faudrait alors migrer vers une méthode au coût sous-quadratique, comme le boosting du chapitre 9.



Correction — Exercice 6

(a) Rapport = $(50\,000\,000/10\,000)^2 = 5\,000^2 = 25\,000\,000$ (vingt-cinq millions).

(b) Non, absolument pas : un rapport de coût de 25 millions par rapport à un échantillon de 10 000 transactions rend tout réentraînement, *a fortiori* quotidien, totalement hors de portée d'une SVM sur ce volume.

(c) La **forêt aléatoire** (chapitre 8) et le **boosting de gradient** (chapitre 9) sont bien mieux adaptés à ce volume : leur coût de calcul croît beaucoup plus modérément avec n (approximativement linéaire par arbre), ils se parallélisent naturellement (la forêt en particulier), et ils dominent déjà, selon le chapitre 9, sur les données tabulaires structurées – exactement le type de données qu'une fintech de paiement manipule (montants, horodatages, identifiants marchands).