

Chapitre 10

Les machines à vecteurs de support

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Rendre séparable par l'astuce du noyau

Cinq points sont donnés : classe A en $(0; 0)$ et $(0,5; 0,3)$; classe B en $(3; 0)$, $(0; 3)$ et $(2; 2)$. Aucune droite du plan ne sépare les deux classes.

- (a) Calculer la troisième coordonnée $z = x_1^2 + x_2^2$ pour chacun des cinq points.
- (b) Trouver un seuil k tel que $z < k$ pour tous les points de la classe A et $z > k$ pour tous les points de la classe B .
- (c) En quoi ce seuil correspond-il à «un simple plan horizontal» séparant les deux classes dans l'espace à trois coordonnées, comme le décrit le chapitre ?

Exercice 2 — Chiffrer le coût de calcul quadratique en n

Le coût d'entraînement d'une SVM est proportionnel à n^2 .

- (a) Calculer le rapport de coût entre un entraînement sur $n = 5\,000$ observations et un entraînement sur $n = 1\,000$ observations.
- (b) Calculer ce même rapport pour $n = 20\,000$ contre $n = 1\,000$.
- (c) Pourquoi ce coût quadratique rend-il la SVM mal adaptée à des bases de plusieurs millions d'observations, même si elle reste très efficace en grande dimension avec n modéré ?

Exercice 3 — Diagnostiquer le sur-ajustement par le réglage de C

Deux réglages de C sont testés sur $n = 50$ observations d'apprentissage. $C = 0,1$: 15 violations de marge, erreur d'apprentissage 15 %, erreur de test 17 %. $C = 100$: 1 violation de marge, erreur d'apprentissage 1 %, erreur de test 23 %.

- (a) Calculer la proportion de violations de marge pour chacun des deux réglages.
- (b) Calculer l'écart entre erreur de test et erreur d'apprentissage pour chacun des deux réglages.
- (c) Lequel des deux réglages montre les signes d'un sur-ajustement les plus nets ? Lequel choisirait-on au vu de la seule erreur de test ?

2 Exercices cumulatifs (chapitre 10, chapitre 8, chapitre 3, chapitre 1 et introduction)

Exercice 4 — Une SVM sur le portefeuille de crédit : coût et réglage de C (chapitre 8, chapitre 2, introduction)

Sur le portefeuille de **mille dossiers de crédit** de l'introduction, avec $p = 20$ variables (comme au chapitre 8), une équipe entraîne une SVM à noyau gaussien.

- (a) Calculer le rapport de coût de calcul entre un entraînement sur les 1 000 dossiers complets et un entraînement sur l'ensemble d'apprentissage d'un seul bloc de validation croisée du chapitre 2 (800 dossiers).
- (b) La validation croisée à 5 blocs du chapitre 2 est utilisée pour choisir C : $C = 0,05$ donne une erreur de validation de 12 %, $C = 50$ donne une erreur de validation de 19 %. Lequel des deux C la validation croisée retiendrait-elle ?
- (c) Le chapitre affirme que C pose «la même question» que λ (chapitre 3) et α (chapitre 7). En quoi ces trois paramètres jouent-ils, dans le langage du chapitre 1, exactement le même rôle dans le compromis biais-variance ?

3 Applications en sciences économiques

Exercice 5 — Une SVM sur des données textuelles d'assurance

Un assureur dispose de $p = 8\,000$ variables textuelles (fréquences de mots) mais de seulement $n = 600$ réclamations étiquetées pour détecter la fraude.

- (a) Ce contexte (p grand, n modéré) correspond-il au cas où le chapitre recommande la SVM, ou au cas où il recommande plutôt le boosting du chapitre 9?
- (b) Calculer le rapport de coût de calcul si l'assureur passait de $n = 600$ à $n = 6\,000$ réclamations étiquetées (coût proportionnel à n^2).
- (c) Ce rapport de coût reste-t-il compatible avec un usage pratique de la SVM si l'assureur venait à disposer, à terme, de plusieurs millions de réclamations?

Exercice 6 — Pourquoi une fintech de paiement écarte la SVM

Une fintech de paiement traite $n = 50\,000\,000$ transactions par mois et souhaite entraîner un modèle de détection de fraude en temps quasi réel.

- (a) Calculer le rapport de coût de calcul entre un entraînement sur les 50 millions de transactions et un entraînement sur un échantillon de $n = 10\,000$ transactions.
- (b) Ce rapport est-il compatible avec un réentraînement fréquent (par exemple quotidien) du modèle?
- (c) Parmi les méthodes vues dans ce cours (régression pénalisée, arbre, forêt aléatoire, boosting, SVM), lesquelles seraient plus adaptées à ce volume, et pourquoi?