

Apprentissage statistique

Chapitre 2 : Rééchantillonnage et validation croisée

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer les tailles de blocs pour différents K

Une base de 3 600 observations doit être découpée pour une validation croisée à K blocs.

- (a) Pour $K = 6$, calculer l'effectif de chaque bloc de validation et l'effectif de l'ensemble d'apprentissage à chaque itération.
- (b) Pour $K = 9$, recalculer ces deux effectifs.
- (c) Entre $K = 6$ et $K = 9$, lequel donne un biais d'estimation plus faible mais une variance plus élevée? Justifier par la taille de l'ensemble d'apprentissage à chaque itération.

Exercice 2 — Moyenner les erreurs d'une validation croisée à 5 blocs

Une validation croisée à 5 blocs donne les erreurs suivantes sur chaque bloc : 0,18 ; 0,21 ; 0,15 ; 0,24 ; 0,17.

- (a) Calculer l'erreur moyenne de validation croisée.
- (b) Calculer l'écart entre l'erreur la plus élevée et l'erreur la plus faible parmi les 5 blocs.
- (c) Un collègue propose de ne retenir que le meilleur des 5 blocs (0,15) comme estimation de l'erreur de test. Pourquoi cette pratique est-elle incorrecte au regard du principe de la validation croisée?

Exercice 3 — Chiffrer le coût du leave-one-out

Une base contient $n = 50$ observations.

- (a) Pour le leave-one-out ($K = n$), calculer l'effectif de l'ensemble d'apprentissage à chaque itération, l'effectif de validation, et le nombre total de modèles estimés.
- (b) Calculer le rapport entre le nombre de modèles estimés en leave-one-out et le nombre de modèles estimés pour une validation croisée à $K = 5$ blocs.
- (c) Pourquoi le leave-one-out, malgré un biais d'estimation quasi nul, n'est-il pas recommandé en général? Répondre sans invoquer uniquement le coût de calcul.

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Vérifier par validation croisée l'EQM du chapitre 1 (introduction, chapitre 1)

On reprend le portefeuille de l'introduction, **mille dossiers de crédit**, avec une validation croisée à $K = 5$ blocs.

- (a) Calculer l'effectif de chaque bloc de validation et l'effectif de l'ensemble d'apprentissage à chaque itération.
- (b) Le modèle de complexité 6 de l'exercice 2 du chapitre 1 (dont l'EQM théorique valait 4,5) est évalué par cette validation croisée. Les 5 blocs donnent les erreurs suivantes : 4,3 ; 4,7 ; 4,4 ; 4,6 ; 4,5. Calculer l'erreur moyenne de validation croisée.
- (c) Cette moyenne est-elle cohérente avec l'EQM théorique du chapitre 1? Qu'est-ce que cela illustre sur le rôle de la validation croisée dans l'estimation d'une quantité normalement inobservable?

3 Applications en sciences économiques

Exercice 5 — Stratifier une validation croisée sur des défauts rares

Une banque dispose de 2 000 prêts, dont 8 % sont en défaut. Elle souhaite évaluer son modèle par validation croisée stratifiée à 5 blocs.

- (a) Calculer le nombre total de défauts dans la base.
- (b) Sous stratification, calculer le nombre de défauts et le nombre de non-défauts que doit contenir chaque bloc.
- (c) Pourquoi une validation croisée *non* stratifiée risquerait-elle de produire, sur au moins un des 5 blocs, une estimation de performance très instable ?

Exercice 6 — Éviter la fuite par client dans un modèle de fraude


Une base de détection de fraude contient 5 000 transactions, provenant de seulement 800 clients distincts (chaque client ayant réalisé plusieurs transactions). L'équipe envisage une validation croisée *groupée* par client, à $K = 5$ blocs.

- (a) Calculer le nombre moyen de clients affectés à chaque bloc sous ce découpage groupé.
- (b) Pourquoi une validation croisée classique, qui répartirait les 5 000 *transactions* au hasard entre les 5 blocs sans tenir compte du client, produirait-elle une estimation de performance trop optimiste ?
- (c) Un second analyste propose de découper les transactions par ordre chronologique plutôt que par client. Ce découpage règle-t-il le même problème que le découpage par groupe ? Justifier.

1 Exercices du chapitre


Correction — Exercice 1

- (a) $K = 6$: bloc = $3\,600/6 = 600$, apprentissage = $3\,600 - 600 = 3\,000$.
(b) $K = 9$: bloc = $3\,600/9 = 400$, apprentissage = $3\,600 - 400 = 3\,200$.
(c) $K = 9$ donne un biais d'estimation plus faible (on apprend sur 3 200 observations, plus proche des 3 600 totales que les 3 000 de $K = 6$) mais une variance plus élevée (les 9 modèles, appris sur des ensembles qui ne diffèrent que de 400 observations sur 3 200, sont plus corrélés entre eux que les 6 modèles de $K = 6$).




Correction — Exercice 2

- (a) Moyenne = $(0,18 + 0,21 + 0,15 + 0,24 + 0,17)/5 = 0,95/5 = 0,19$.
(b) Écart = $0,24 - 0,15 = 0,09$.
(c) C'est incorrect car cela revient à choisir, *a posteriori*, le bloc le plus favorable – exactement le type de sélection que la validation croisée cherche à éviter. Le principe même de la méthode est de **moyenner** les K erreurs pour obtenir une estimation stable de la performance attendue sur des données nouvelles, non tirées au hasard ; ne retenir que le minimum surestime systématiquement la performance réelle du modèle.



Correction — Exercice 3


- (a) Apprentissage = $50 - 1 = 49$, validation = 1 , nombre de modèles = 50 .
(b) Rapport = $50/5 = 10$: le leave-one-out demande 10 fois plus de modèles que $K = 5$.
(c) Même en ignorant le coût de calcul, le leave-one-out reste déconseillé car les 50 modèles sont estimés sur des échantillons qui ne diffèrent que d'une seule observation : ils sont **presque identiques**, donc leurs erreurs sont **fortement corrélées**. Moyenner 50 quantités très corrélées ne réduit pratiquement pas la variance de l'estimation finale, contrairement à ce que suggérerait l'intuition d'un « biais quasi nul ».



2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4


- (a) Bloc de validation = $1\,000/5 = 200$, apprentissage = $1\,000 - 200 = 800$ – ce sont exactement les effectifs annoncés par le cours pour ce même portefeuille.
- (b) Moyenne = $(4,3 + 4,7 + 4,4 + 4,6 + 4,5)/5 = 22,5/5 = 4,5$.
- (c) Oui, cette moyenne coïncide **exactement** avec l'EQM théorique de 4,5 calculée à l'exercice 2 du chapitre 1 pour ce même niveau de complexité. Cela illustre précisément le rôle de la validation croisée : estimer, à partir des seules données d'apprentissage et sans jamais consulter le test, une quantité (l'EQM de test) qui resterait sinon totalement inobservable. Ici, la moyenne des 5 blocs retrouve la valeur théorique – dans la pratique, un écart resterait normal, mais l'estimation reste sans biais en espérance.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) Nombre total de défauts = $2\,000 \times 0,08 = 160$.
- (b) Sous stratification, chaque bloc doit contenir $160/5 = 32$ défauts et $(2\,000 - 160)/5 = 1\,840/5 = 368$ non-défauts.
- (c) Avec seulement 8% de défauts au total (160 sur 2000), un tirage purement aléatoire pourrait, par simple variabilité d'échantillonnage, produire un bloc contenant très peu de défauts (voire aucun dans les cas extrêmes). L'erreur de validation calculée sur un tel bloc serait alors quasi inexploitable – estimée sur une poignée d'exemples positifs, voire zéro – rendant l'estimation de performance de ce bloc extrêmement instable, contrairement au bloc voisin qui pourrait en contenir deux fois plus.



Correction — Exercice 6

- (a) Nombre moyen de clients par bloc = $800/5 = 160$ clients.
- (b) Une validation croisée classique, qui répartit les 5 000 **transactions** sans respecter les clients, risquerait de placer plusieurs transactions d'un **même client** à la fois en apprentissage et en validation. Le modèle pourrait alors « reconnaître » ce client (son montant habituel, ses horaires, ses commerçants) plutôt que d'apprendre une règle de fraude généralisable – il s'agit d'une fuite de données au sens du chapitre, qui gonfle artificiellement la performance mesurée en validation, laquelle ne se reproduira pas sur des clients réellement nouveaux.
- (c) Non, ce n'est pas le même problème. Le découpage **chronologique** répond à une contrainte temporelle (ne pas apprendre sur le futur pour prévoir le passé), qui n'existe pas nécessairement ici s'il n'y a pas de dépendance dans le temps entre clients. Le découpage **par groupe** répond à une contrainte d'**identité** (ne pas laisser un même client apparaître des deux côtés du découpage) : découper chronologiquement ne garantit en rien qu'un client donné ne se retrouve pas de part et d'autre de la coupure temporelle si ses transactions s'étalent sur toute la période. Les deux découpages répondent à deux fuites de nature différente et peuvent, au besoin, se combiner.