

Chapitre 2

Rééchantillonnage et validation croisée

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Calculer les tailles de blocs pour différents K

Une base de 3 600 observations doit être découpée pour une validation croisée à K blocs.

- (a) Pour $K = 6$, calculer l'effectif de chaque bloc de validation et l'effectif de l'ensemble d'apprentissage à chaque itération.
- (b) Pour $K = 9$, recalculer ces deux effectifs.
- (c) Entre $K = 6$ et $K = 9$, lequel donne un biais d'estimation plus faible mais une variance plus élevée? Justifier par la taille de l'ensemble d'apprentissage à chaque itération.

Exercice 2 — Moyenner les erreurs d'une validation croisée à 5 blocs

Une validation croisée à 5 blocs donne les erreurs suivantes sur chaque bloc : 0,18 ; 0,21 ; 0,15 ; 0,24 ; 0,17.

- (a) Calculer l'erreur moyenne de validation croisée.
- (b) Calculer l'écart entre l'erreur la plus élevée et l'erreur la plus faible parmi les 5 blocs.
- (c) Un collègue propose de ne retenir que le meilleur des 5 blocs (0,15) comme estimation de l'erreur de test. Pourquoi cette pratique est-elle incorrecte au regard du principe de la validation croisée?

Exercice 3 — Chiffrer le coût du leave-one-out

Une base contient $n = 50$ observations.

- (a) Pour le leave-one-out ($K = n$), calculer l'effectif de l'ensemble d'apprentissage à chaque itération, l'effectif de validation, et le nombre total de modèles estimés.
- (b) Calculer le rapport entre le nombre de modèles estimés en leave-one-out et le nombre de modèles estimés pour une validation croisée à $K = 5$ blocs.
- (c) Pourquoi le leave-one-out, malgré un biais d'estimation quasi nul, n'est-il pas recommandé en général? Répondre sans invoquer uniquement le coût de calcul.

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Vérifier par validation croisée l'EQM du chapitre 1 (introduction, chapitre 1)

On reprend le portefeuille de l'introduction, **mille dossiers de crédit**, avec une validation croisée à $K = 5$ blocs.

- (a) Calculer l'effectif de chaque bloc de validation et l'effectif de l'ensemble d'apprentissage à chaque itération.
- (b) Le modèle de complexité 6 de l'exercice 2 du chapitre 1 (dont l'EQM théorique valait 4,5) est évalué par cette validation croisée. Les 5 blocs donnent les erreurs suivantes : 4,3 ; 4,7 ; 4,4 ; 4,6 ; 4,5. Calculer l'erreur moyenne de validation croisée.
- (c) Cette moyenne est-elle cohérente avec l'EQM théorique du chapitre 1? Qu'est-ce que cela illustre sur le rôle de la validation croisée dans l'estimation d'une quantité normalement inobservable?

3 Applications en sciences économiques

Exercice 5 — Stratifier une validation croisée sur des défauts rares

Une banque dispose de 2 000 prêts, dont 8 % sont en défaut. Elle souhaite évaluer son modèle par validation croisée stratifiée à 5 blocs.

- (a) Calculer le nombre total de défauts dans la base.
- (b) Sous stratification, calculer le nombre de défauts et le nombre de non-défauts que doit contenir chaque bloc.
- (c) Pourquoi une validation croisée *non* stratifiée risquerait-elle de produire, sur au moins un des 5 blocs, une estimation de performance très instable ?

Exercice 6 — Éviter la fuite par client dans un modèle de fraude

Une base de détection de fraude contient 5 000 transactions, provenant de seulement 800 clients distincts (chaque client ayant réalisé plusieurs transactions). L'équipe envisage une validation croisée *groupée* par client, à $K = 5$ blocs.

- (a) Calculer le nombre moyen de clients affectés à chaque bloc sous ce découpage groupé.
- (b) Pourquoi une validation croisée classique, qui répartirait les 5 000 *transactions* au hasard entre les 5 blocs sans tenir compte du client, produirait-elle une estimation de performance trop optimiste ?
- (c) Un second analyste propose de découper les transactions par ordre chronologique plutôt que par client. Ce découpage règle-t-il le même problème que le découpage par groupe ? Justifier.