

Apprentissage statistique

Chapitre 8 : Forêts aléatoires et bagging

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 25 septembre 2026

Moyenner pour stabiliser

La forêt aléatoire

Deux sous-produits utiles

Ce qu'il faut retenir

Moyenner pour stabiliser

Le résultat qui fonde le chapitre

La variance d'une moyenne

Pour B variables indépendantes de variance σ^2 , la moyenne a pour variance

$$\frac{\sigma^2}{B}$$

Moyenner 100 modèles indépendants divise donc la variance par 100 — **sans toucher au biais**.

Pourquoi c'est exactement ce qu'il fallait

L'arbre du chapitre 7 avait peu de biais et beaucoup de variance.

Moyenner ne change pas le biais et écrase la variance : l'opération est taillée sur mesure pour lui. C'est la raison pour laquelle les méthodes d'ensemble reposent sur des arbres et non sur des régressions.

Le bagging

La forêt aléatoire

Le défaut du bagging

Le problème de la corrélation

La division par B suppose les modèles **indépendants**. Or les arbres du bagging ne le sont pas : ils voient presque les mêmes données.

Si une variable domine, **tous** les arbres la choisiront en premier, et se ressembleront. Moyenner des modèles corrélés ne réduit guère la variance.

L'idée de Breiman

À **chaque nœud**, ne considérer qu'un sous-ensemble aléatoire de m variables parmi p , tiré à nouveau à chaque fois.

Une variable dominante ne peut donc pas être choisie partout : les arbres sont forcés d'explorer d'autres découpages, et se **décorrèlent**.

Le réglage usuel de m

Tâche

Valeur courante

Deux sous-produits utiles

L'erreur out-of-bag

Out-of-bag

Un échantillon bootstrap laisse de côté environ **un tiers** des observations. Chaque observation est donc « hors sac » pour environ un tiers des arbres.

On peut la prédire avec **ces arbres-là seulement** — qui ne l'ont jamais vue.

Le calcul de la proportion

La probabilité qu'une observation ne soit jamais tirée en n tirages avec remise :

$$\left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368$$

Environ 36,8 % des observations sont hors sac pour un arbre donné.

Une validation croisée gratuite

L'erreur **out-of-bag** estime l'erreur de test sans découpage supplémentaire ni calcul additionnel.

L'importance des variables

Deux mesures

Par l'impureté — cumuler la réduction de Gini apportée par chaque variable sur tous les arbres. Rapide, mais **biaisée** en faveur des variables à nombreuses modalités.

Par permutation — mélanger au hasard une variable et mesurer la dégradation de l'erreur out-of-bag. Plus coûteuse, plus fiable.

Importante ne veut pas dire causale

Une variable peut être jugée importante parce qu'elle est corrélée à la vraie cause, ou parce qu'elle en est une conséquence.

De plus, entre deux variables très corrélées, la forêt **répartit** l'importance entre elles, ce qui fait paraître les deux modérément utiles alors que l'une suffirait.

L'importance mesure la contribution à la prévision, jamais un effet. C'est le même avertissement qu'au chapitre 3 sur le lasso, et il vaut pour tout ce cours.

Ce qu'il faut retenir

Le résumé du chapitre

Cinq points

1. Moyenner B modèles indépendants divise la variance par B , **sans toucher au biais**.
2. Le **bagging** agrège des arbres profonds construits sur échantillons bootstrap.
3. La **forêt aléatoire** ajoute un tirage de m variables à chaque nœud, ce qui **décorrèle** les arbres.
4. $m \approx \sqrt{p}$ en classification ; augmenter B ne sur-ajuste jamais.
5. L'erreur **out-of-bag** — sur les 36,8 % non tirés — donne une estimation gratuite de l'erreur de test.

La suite

Le bagging construit les arbres **en parallèle**, chacun ignorant les autres. Le chapitre 9 les construit **en séquence**, chacun corrigeant les erreurs du précédent.