


# Apprentissage statistique

## Chapitre 4 : La régression pénalisée : ridge et lasso



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 24 août 2026

Pourquoi pénaliser

La régression ridge

Le lasso

Ce qu'il faut retenir

## Pourquoi pénaliser

---

## Ce que font les MCO

Les moindres carrés minimisent la somme des carrés des résidus :

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Ils fournissent l'estimateur **sans biais** de variance minimale parmi les estimateurs linéaires — c'est le théorème de Gauss-Markov.

## Sans biais n'est pas ce qu'on veut ici

Gauss-Markov garantit la variance minimale **parmi les estimateurs sans biais**. Rien n'interdit qu'un estimateur légèrement biaisé ait une variance bien plus faible, et donc une erreur totale inférieure.

C'est exactement ce que fait la pénalisation. Le chapitre 2 l'avait annoncé : **accepter du biais pour retrancher de la variance**.

### Définition

1. **La multicolinéarité** — des variables très corrélées rendent les coefficients instables et énormes, de signes parfois absurdes.
2. **La grande dimension** — si  $p > n$ , la solution des MCO n'est même pas unique.

## La régression ridge

---

### Le critère ridge

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Le second terme **pénalise** les coefficients trop grands.  $\lambda \geq 0$  règle la sévérité.

## Définition

| $\lambda$            | Effet                                                   |
|----------------------|---------------------------------------------------------|
| 0                    | on retrouve les MCO                                     |
| croissant            | les coefficients <b>rétrécissent</b> vers zéro          |
| $\rightarrow \infty$ | tous tendent vers zéro, le modèle devient une constante |

Le biais **augmente** avec  $\lambda$ , la variance **diminue**. Il existe donc un  $\lambda$  optimal, qu'on choisit par **validation croisée**.

### Intuition

Deux variables très corrélées peuvent recevoir des coefficients de  $+500$  et  $-498$  : leur somme est stable, chacun ne l'est pas.

Ridge interdit cette compensation en punissant le carré des coefficients. Il les **répartit** entre variables corrélées plutôt que d'en gonfler un.

### Application en gestion

1. **Standardiser** les variables. La pénalité porte sur l'échelle : une variable en dirhams et une en milliers de dirhams seraient traitées différemment sans cela.
2. **Ne pas pénaliser la constante**. Elle ne mesure aucun effet, et la pénaliser rendrait le modèle dépendant du centrage de  $Y$ .

Ces deux points sont la source d'erreur la plus fréquente dans les premières mises en œuvre.

## Le lasso

---

# Une pénalité qui sélectionne

## Le critère lasso

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

La seule différence est la **valeur absolue** au lieu du carré. Sa conséquence est considérable.

## La différence décisive

|       | Pénalité         | Coefficients                               |
|-------|------------------|--------------------------------------------|
| Ridge | $\sum \beta_j^2$ | rétrécissent, <b>jamais nuls</b>           |
| Lasso | $\sum  \beta_j $ | certains deviennent <b>exactement nuls</b> |

Le lasso fait donc de la sélection de **variables**, ridge non.

### Intuition

Géométriquement, la contrainte du lasso a des **coins** sur les axes — un losange en dimension deux — tandis que celle de ridge est un cercle, sans angle.

La solution touche la contrainte, et il est bien plus probable de toucher un losange à un coin qu'un cercle en un point particulier. Or être sur un coin signifie qu'une coordonnée est nulle.

## Choisir entre les deux

### Quand préférer l'un ou l'autre

| Situation                               | Méthode            |
|-----------------------------------------|--------------------|
| Beaucoup de variables faiblement utiles | <b>ridge</b>       |
| Peu de variables vraiment utiles        | <b>lasso</b>       |
| Variables corrélées par blocs           | <b>elastic net</b> |
| Modèle à interpréter et présenter       | <b>lasso</b>       |

### L'elastic net

Il combine les deux pénalités. Il sélectionne comme le lasso, tout en répartissant entre variables corrélées comme ridge.

Le lasso, entre deux variables très corrélées, en garde **une au hasard** et annule l'autre — ce qui rend son résultat instable d'un échantillon à l'autre. L'elastic net corrige ce défaut.

### Application en gestion

Qu'une variable soit retenue par le lasso ne prouve **pas** qu'elle cause quoi que ce soit. Elle peut être retenue parce qu'elle est corrélée à la vraie cause, ou parce qu'elle est une conséquence.

Le lasso sélectionne pour **prévoir**, pas pour expliquer. Lire ses variables retenues comme des facteurs causaux est l'erreur que le chapitre 12, puis tout le cours d'*Inférence causale*, s'emploieront à écarter.

Ce qu'il faut retenir

---

### Cinq points

1. Les MCO sont optimaux **parmi les sans-biais** — ce qui n'est pas le critère en prévision.
2. **Ridge** pénalise  $\sum \beta_j^2$  : les coefficients rétrécissent sans jamais s'annuler.
3. **Lasso** pénalise  $\sum |\beta_j|$  : certains deviennent exactement nuls, d'où une **sélection**.
4.  $\lambda$  se choisit par **validation croisée**; il faut **standardiser** et ne pas pénaliser la constante.
5. La sélection du lasso est **prédictive**, jamais causale.

### La suite

Le lasso a introduit la sélection de variables. Le chapitre 5 examine ce que devient ce problème quand les variables sont plus nombreuses que les observations.