Échantillonnage

Chapitre 7 : L'allocation optimale et l'effet de plan

Jaouad Madkour

30 octobre 2026

Plan du chapitre

Le problème de l'allocation **2**
Une question laissée ouverte . . . 2
Sur la mini-population . . . 2
Trois répartitions de 200 ménages . . . 3

L'allocation de Neyman **3**
La règle de Neyman . . . 3
La démonstration . . . 3
Sur les provinces . . . 5
Un gain modeste, et pourquoi . . . 5
Quand les dispersions diffèrent beaucoup . . . 6

Coûts et dispersions inconnues **7**
Quand une interview coûte plus cher . . . 7
Rural et urbain . . . 8
À budget égal . . . 8
Quand les écarts-types sont inconnus . . . 9

L'allocation égale et les domaines **9**
Cinquante ménages par province . . . 9
La précision dans chaque province . . . 10
Le compromis . . . 11
Suréchantillonner une petite strate . . . 11

L'effet de plan **11**
La définition de Kish . . . 11
Taille effective et taille nécessaire . . . 12
L'échelle des effets de plan . . . 12

Proportions et plusieurs variables **13**
Le cas d'une proportion . . . 13
Une allocation pour plusieurs variables . . . 13

S'entraîner **13**

Exercice 1 : l'allocation de Neyman 13
Exercice 1 : solution 14
Exercice 2 : des coûts différents 14
Exercice 2 : solution 14
Exercice 3 : effet de plan et taille effective 15
Exercice 3 : solution 15

Ce qu'il faut retenir **15**
Le résumé du chapitre 15

Le problème de l'allocation

Une question laissée ouverte

La variance dépend de la répartition

La taille n et les strates sont fixées. Reste à choisir $n_1, \dots, n_H$, avec $\sum_h n_h = n$. Comme $W_h/N_h = 1/N$:

$$V(\overline{y}_{st}) = \sum_h W_h^2 \,(1 - f_h)\, \frac{S_h^2}{n_h} = \underbrace{\sum_h \frac{W_h^2\, S_h^2}{n_h}}_{\text{dépend des } n_h} - \underbrace{\frac{1}{N} \sum_h W_h\, S_h^2}_{\text{fixe}}$$

Sur les provinces, le terme fixe vaut $15\,142\,148/2\,000 = 7\,571{,}1$.

Trois objectifs, trois répartitions

1. La **précision de la moyenne d'ensemble** : l'allocation de Neyman.
2. Le **coût** : tirer moins là où une interview coûte cher.
3. La **précision dans chaque strate** : l'allocation égale, ou un compromis.

Sur la mini-population

Strates A, B, C et D, E : trois ménages à répartir

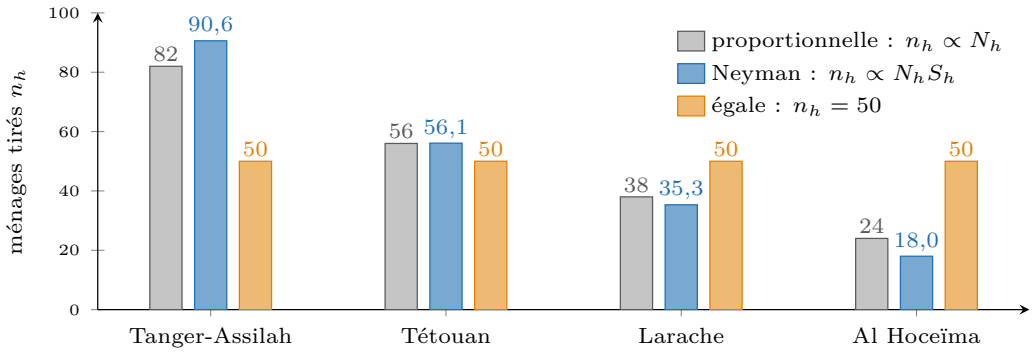
Répartition (n_1, n_2)	$(2,1)$	$(1,2)$
Strate 1 : $0{,}36\,(1-f_1)\,S_1^2/n_1$	0,14	0,56
Strate 2 : $0{,}16\,(1-f_2)\,S_2^2/n_2$	1	0
$V(\overline{y}_{st})$	1,14	0,56

Dépenses 4, 6, 7 puis 9, 14 : $S_1^2 = 7/3$ et $S_2^2 = 12{,}5$; poids $W_1 = 0{,}6$ et $W_2 = 0{,}4$.

Tirer davantage là où cela varie

L'allocation proportionnelle (1,8 et 1,2) conduit à $(2, 1)$. Or la strate D, E est petite mais **très dispersée** : en la recensant, on supprime sa variance, et V est divisée par deux. Vérification : les trois échantillons possibles donnent 7 ; 8,2 ; 8,8, de variance 0,56. Un sondage aléatoire simple de trois ménages : 1,93.

Trois répartitions de 200 ménages



Même taille, trois précisions

Variance de $\overline{y}_{st}$: 68 139,7 (proportionnelle), 67 172,3 (Neyman), 89 027,4 (égale), contre 71 435,5 pour un sondage aléatoire simple. La meilleure répartition **suit la population** en l'inclinant vers les provinces les plus dispersées ; la répartition égale fait **moins bien** que le hasard simple.

L'allocation de Neyman

La règle de Neyman

L'allocation de Neyman (1934)

Pour une taille n fixée, la variance de $\overline{y}_{st}$ est minimale pour

$$n_h = n \, \frac{N_h \, S_h}{\sum_k N_k \, S_k}$$

Le taux de sondage $f_h = n_h / N_h$ est alors **proportionnel à** S_h.

Deux raisons de tirer davantage dans une strate

1. Elle est **grande** (N_h) : elle pèse lourd dans la moyenne d'ensemble.
2. Elle est **dispersée** (S_h) : la même précision y demande plus d'unités.

Si tous les S_h sont égaux, on retrouve l'allocation proportionnelle $n_h = n \, W_h$.

La démonstration

Par l'inégalité de Cauchy-Schwarz

On minimise $\sum_h W_h^2 S_h^2/n_h$ sous la contrainte $\sum_h n_h = n$. Pour des nombres positifs, $\left(\sum a_h^2\right)\left(\sum b_h^2\right) \geq \left(\sum a_h b_h\right)^2$; avec $a_h = \sqrt{n_h}$ et $b_h = W_h S_h/\sqrt{n_h}$:

$$n \times \sum_h \frac{W_h^2\, S_h^2}{n_h} \;\geq\; \Big(\sum_h W_h\, S_h\Big)^2$$

L'égalité a lieu quand $b_h/a_h = W_h S_h/n_h$ est constant : $n_h \propto W_h S_h$, c'est-à-dire $n_h \propto N_h S_h$.

La variance minimale

$$V_{Ney} = \frac{\overline{S}^2}{n} - \frac{1}{N}\sum_h W_h\, S_h^2 \qquad \text{où} \qquad \overline{S} = \sum_h W_h\, S_h$$

$\overline{S}$ est la **moyenne pondérée des écarts-types** des strates.

Démonstration : L'allocation de Neyman minimise la variance

Ce qui dépend de l'allocation. Comme $f_h = n_h/N_h$, on a $\dfrac{1-f_h}{n_h} = \dfrac{1}{n_h} - \dfrac{1}{N_h}$; et comme $W_h^2/N_h = W_h/N$,

$$V = \sum_h \frac{W_h^2\, S_h^2}{n_h} - \frac{1}{N}\sum_h W_h\, S_h^2 = A - K, \qquad A = \sum_h \frac{W_h^2\, S_h^2}{n_h}.$$

Le terme K ne dépend pas des n_h : minimiser V, c'est minimiser A sous la contrainte $\sum_h n_h = n$.

Une inégalité. Pour tous réels a_h et b_h, $\left(\sum a_h b_h\right)^2 \leq \left(\sum a_h^2\right)\left(\sum b_h^2\right)$ (Cauchy-Schwarz). En effet, pour tout réel t,

$$0 \leq \sum_h (t\, a_h - b_h)^2 = t^2 \sum a_h^2 - 2\, t \sum a_h b_h + \sum b_h^2.$$

Un trinôme du second degré toujours positif ou nul a un discriminant négatif ou nul : $4\left(\sum a_h b_h\right)^2 - 4 \sum a_h^2 \sum b_h^2 \leq 0$. L'égalité a lieu si et seulement si le trinôme s'annule pour un t, c'est-à-dire si $b_h = t\, a_h$ pour tout h.

Une borne. Prenons $a_h = \sqrt{n_h}$ et $b_h = W_h\, S_h/\sqrt{n_h}$. Alors $a_h b_h = W_h\, S_h$, $\sum a_h^2 = n$ et $\sum b_h^2 = A$, d'où

$$n\, A \;\geq\; \Big(\sum_h W_h\, S_h\Big)^2 = \overline{S}^2 \qquad \text{soit} \qquad A \geq \frac{\overline{S}^2}{n}.$$

Cette borne vaut pour **toute** répartition de somme n, et ne dépend pas d'elle.

La borne est atteinte. L'égalité exige $b_h = t\, a_h$, c'est-à-dire $W_h\, S_h/\sqrt{n_h} = t\sqrt{n_h}$, soit $n_h = W_h\, S_h/t$: n_h est proportionnel à $W_h\, S_h$, donc à $N_h\, S_h$. La somme valant n, on a $1/t = n/\overline{S}$ et

$$n_h = n\,\frac{W_h\, S_h}{\overline{S}} = n\,\frac{N_h\, S_h}{\sum_k N_k\, S_k}.$$

Pour cette allocation, $A = \sum_h W_h^2 S_h^2 \cdot \dfrac{\overline{S}}{n W_h S_h} = \dfrac{\overline{S}}{n}\sum_h W_h S_h = \dfrac{\overline{S}^2}{n}$, d'où $V_{Ney} = \dfrac{\overline{S}^2}{n} - K$.

Ce que cela dit. Aucune répartition ne fait mieux que la règle de Neyman, et elle seule atteint la borne. La règle donne en général des nombres non entiers ; sur les provinces (90,6 ; 56,1 ; 35,3 ; 18,0), un parcours exhaustif de toutes les répartitions entières de 200 ménages (au moins 2 par province) montre que la meilleure est $(91, 56, 35, 18)$, de variance 67 174,1 contre 67 172,3 à l'optimum réel. Si la formule donne $n_h > N_h$, elle est irréalisable : on recense la strate et l'on répartit le reste (section sur la strate exhaustive).

■

Sur les provinces

Deux cents ménages répartis selon Neyman

Province	$N_h S_h$	part	n_h	f_h
Tanger-Assilah	3 502 379	45,3 %	90,6	0,110
Tétouan	2 168 943	28,0 %	56,1	0,100
Larache	1 365 406	17,7 %	35,3	0,093
Al Hoceïma	695 975	9,0 %	18,0	0,075

La variance

$\overline{S} = 0{,}41 \times 4\,271{,}19 + 0{,}28 \times 3\,873{,}11 + 0{,}19 \times 3\,593{,}17 + 0{,}12 \times 2\,899{,}90 = 3\,866{,}35.$

$$V_{Ney} = \frac{3\,866{,}35^2}{200} - 7\,571{,}1 = 74\,743{,}4 - 7\,571{,}1 = 67\,172{,}3$$

Erreur-type 259,2 dh ; *deff* = 67 172,3/71 435,5 = 0,940. Arrondie à 91, 56, 35, 18 : V = 67 174,1, la même.

Un gain modeste, et pourquoi

Ce que Neyman gagne sur la proportionnelle

Comme $V_{prop} = \sum_h W_h S_h^2/n - \sum_h W_h S_h^2/N$:

$$V_{prop} - V_{Ney} = \frac{1}{n}\Big(\sum_h W_h\, S_h^2 - \overline{S}^2\Big) = \frac{1}{n}\sum_h W_h\,(S_h - \overline{S})^2 \;\geq\; 0$$

Le gain est la **variance des écarts-types** des strates, divisée par n.

Démonstration : Ce que Neyman gagne sur la proportionnelle

Les deux variances. Comme $f/n = 1/N$, on a $\dfrac{1-f}{n} = \dfrac{1}{n} - \dfrac{1}{N}$, donc

$$V_{prop} = \frac{1-f}{n}\sum_h W_h\,S_h^2 = \frac{1}{n}\sum_h W_h\,S_h^2 - \frac{1}{N}\sum_h W_h\,S_h^2, \qquad V_{Ney} = \frac{\overline{S}^{\,2}}{n} - \frac{1}{N}\sum_h W_h\,S_h^2.$$

Le terme fixe se retranche :

$$V_{prop} - V_{Ney} = \frac{1}{n}\Big(\sum_h W_h\,S_h^2 - \overline{S}^{\,2}\Big).$$

Une variance pondérée. Les poids W_h ont pour somme 1 et $\overline{S} = \sum_h W_h\,S_h$:

$$\begin{aligned}\sum_h W_h\,(S_h - \overline{S})^2 &= \sum_h W_h\,S_h^2 - 2\,\overline{S}\sum_h W_h\,S_h + \overline{S}^{\,2}\sum_h W_h \\ &= \sum_h W_h\,S_h^2 - 2\,\overline{S}^{\,2} + \overline{S}^{\,2} = \sum_h W_h\,S_h^2 - \overline{S}^{\,2}.\end{aligned}$$

Le gain est donc $\dfrac{1}{n}\sum_h W_h\,(S_h - \overline{S})^2$, somme de termes positifs, nulle si et seulement si tous les S_h sont égaux à $\overline{S}$.

Ce que cela dit. Neyman ne gagne sur la proportionnelle que dans la mesure où les écarts-types des strates diffèrent ; s'ils sont égaux, les deux allocations coïncident. Sur les provinces : 15 142 148 − 14 948 674 = 193 474, et 193 474/200 = 967,4.

■

Les provinces

$\sum_h W_h\,(S_h - \overline{S})^2 = 193\,474$, d'où un gain de $193\,474/200 = 967{,}4 = 68\,139{,}7 - 67\,172{,}3$. La variance ne baisse que de 1,4 % : les S_h vont de 2 900 à 4 271 dh, ils se ressemblent trop pour que les répartir autrement change beaucoup.

Quand les dispersions diffèrent beaucoup

Le chiffre d'affaires de 1 200 entreprises, chiffres inventés

Taille	N_h	S_h (millions de dh)	proportionnelle	Neyman
Petites	1 000	1	83,3	20
Moyennes	150	10	12,5	30
Grandes	50	60	4,2	50

Pour $n = 100$, la règle donne 54,5 grandes entreprises, plus qu'il n'y en a : on les prend **toutes**, et l'on répartit les 50 autres selon Neyman. Variance : 1,497, puis 0,076, divisée par 20.

La strate exhaustive

Quand $n_h > N_h$, on recense la strate ($f_h = 1$: aucune erreur d'échantillonnage) et l'on répartit le reste. Dans les enquêtes auprès des entreprises, les plus grandes sont **toujours** interrogées.

Coûts et dispersions inconnues

Quand une interview coûte plus cher

L'allocation optimale avec coûts

Le coût de l'enquête est $C = c_0 + \sum_h c_h\, n_h$: frais fixes, plus c_h par unité de la strate h. À budget donné, la variance est minimale pour

$$n_h \propto \frac{N_h\, S_h}{\sqrt{c_h}}$$

La démonstration par le lagrangien

On minimise $\sum_h W_h^2 S_h^2/n_h + \lambda\,(\sum_h c_h n_h - C)$. La dérivée en n_h s'annule :

$$-\frac{W_h^2\, S_h^2}{n_h^2} + \lambda\, c_h = 0 \quad\Longrightarrow\quad n_h = \frac{W_h\, S_h}{\sqrt{\lambda}\,\sqrt{c_h}}$$

La constante $\sqrt{\lambda}$ s'obtient en épuisant le budget. Si les c_h sont égaux, on retrouve Neyman.

Démonstration : L'allocation avec coûts par l'inégalité de Cauchy-Schwarz

Le problème. Soit C le budget des interviews, frais fixes c_0 déduits : $\sum_h c_h\, n_h = C$. Le terme K ne dépend pas des n_h (démonstration précédente) : on minimise $A = \sum_h W_h^2\, S_h^2/n_h$ sous cette contrainte de coût.

Une borne. Prenons $a_h = \sqrt{c_h\, n_h}$ et $b_h = W_h\, S_h/\sqrt{n_h}$. Alors $a_h b_h = W_h\, S_h\, \sqrt{c_h}$, $\sum a_h^2 = \sum c_h\, n_h = C$ et $\sum b_h^2 = A$. L'inégalité de Cauchy-Schwarz, démontrée plus haut, donne

$$C \times A \;\geq\; \Big(\sum_h W_h\, S_h\, \sqrt{c_h}\Big)^2.$$

Le cas d'égalité. Il faut $b_h = t\, a_h$, c'est-à-dire $W_h\, S_h/\sqrt{n_h} = t\,\sqrt{c_h}\,\sqrt{n_h}$, soit $n_h = \dfrac{W_h\, S_h}{t\,\sqrt{c_h}}$: n_h est proportionnel à $N_h\, S_h/\sqrt{c_h}$. Écrivons $n_h = \lambda\, N_h\, S_h/\sqrt{c_h}$; le budget fixe la constante, car $\sum_h c_h\, n_h = \lambda \sum_h N_h\, S_h\, \sqrt{c_h} = C$. Donc

$$n_h = C\,\frac{N_h\, S_h/\sqrt{c_h}}{\sum_k N_k\, S_k\, \sqrt{c_k}}.$$

La variance minimale. Pour cette allocation, $A = \Big(\sum_h W_h\, S_h\, \sqrt{c_h}\Big)^2/C$, d'où

$$V_{opt} = \frac{1}{C}\Big(\sum_h W_h\, S_h\, \sqrt{c_h}\Big)^2 - \frac{1}{N}\sum_h W_h\, S_h^2.$$

Si tous les coûts valent c, alors $C = c\,n$ et l'on retrouve $\overline{S}^2/n - K$: l'allocation de Neyman.

Ce que cela dit. Annuler la dérivée du lagrangien donne un candidat ; l'inégalité prouve que c'est bien le minimum : aucune autre répartition de même coût ne fait mieux. Sur le milieu rural ($c = 2$) et urbain ($c = 1$), avec un budget de 200 : $n_h = 30{,}06$ et $139{,}88$ (coût $2 \times 30{,}06 + 139{,}88 = 200$), $V_{opt} = 82\,718{,}5$. Parmi toutes les répartitions entières de coût au plus 200, la meilleure est $(30, 140)$.

■

Rural et urbain

Un ménage rural coûte deux fois plus, budget de 200 unités

Milieu	N_h	S_h	c_h	$N_h\,S_h/\sqrt{c_h}$	n_h
Rural	562	3 215,03	2	1 277 634	30,1
Urbain	1 438	4 134,11	1	5 944 846	139,9

$$n_h = 200 \times \frac{N_h\,S_h/\sqrt{c_h}}{\sum_k N_k\,S_k\,\sqrt{c_k}} \qquad \text{avec} \qquad \sum_k N_k\,S_k\,\sqrt{c_k} = 8\,500\,114$$

Coût : $2 \times 30{,}06 + 139{,}88 = 200$.

Moins de ruraux, mais plus de ménages

Taux de sondage : 5,3 % à la campagne, 9,7 % en ville. Le budget achète 169,9 ménages ; la variance vaut 82 718,5, l'erreur-type 287,6 dh.

À budget égal

Comparer à l'allocation proportionnelle de même coût

Un ménage coûte en moyenne $0{,}281 \times 2 + 0{,}719 \times 1 = 1{,}281$: le budget en paie $200/1{,}281 = 156{,}1$.

Allocation de même coût	ruraux	urbains	V	erreur-type
Optimale	30,1	139,9	82 718,5	287,6
Proportionnelle	43,9	112,3	89 713,8	299,5

À coût égal, la variance baisse de 7,8 %. Un sondage aléatoire simple de 156 ménages ferait pire : 93 739,2.

Le prix de l'économie

La moyenne **rurale** perd en précision : erreur-type 570,5 dh contre 466,1. Si elle doit être publiée, il faut un plancher. Et le surcoût rural vient surtout des **déplacements** : le chapitre 9 le réduira en regroupant les interviews.

Quand les écarts-types sont inconnus

Où trouver les écarts-types des strates

1. Une enquête antérieure, ou une enquête pilote (chapitre 5).
2. Une variable liée, connue par le recensement.
3. Un **coefficient de variation** supposé commun : $S_h \approx CV \times \overline{Y}_h$, d'où $n_h \propto N_h \overline{Y}_h$, le **total** de la strate.

Une erreur sur les écarts-types se paie

Dans les provinces, $S_h/\overline{Y}_h$ va de 0,475 à 0,495 : la répartition au prorata des totaux (89,4 ; 57,7 ; 34,8 ; 18,1) a un *deff* de 0,941, presque celui de Neyman. Mais avec S_h surestimé de 30 % à Tanger-Assilah et sous-estimé de 30 % à Al Hoceïma, $deff = 0{,}978$: **moins bien que la proportionnelle** (0,954).

L'allocation égale et les domaines

Cinquante ménages par province

Une allocation qui fait perdre

$V = 89\,027{,}4$, soit $deff = 1{,}246$: ce plan stratifié est **moins précis** qu'un sondage aléatoire simple de même taille. Les poids $d_k = N_h/50$ vont de 16,4 à Tanger-Assilah à 4,8 à Al Hoceïma (chapitre 1).

Des poids inégaux sans raison

Si toutes les strates avaient la même dispersion, sans correction de population finie :

$$deff = n \sum_h \frac{W_h^2}{n_h} = 4 \sum_h W_h^2 = 4 \times 0{,}297 = 1{,}188 = 1 + CV^2(d_k)$$

C'est la formule de **Kish** : des poids inégaux coûtent $1 + CV^2$ des poids. Ils ne se justifient que par des S_h ou des coûts différents, ou par un autre objectif.

Démonstration : La formule de Kish

Le cadre. Supposons que toutes les strates ont la même dispersion, $S_h = S$, et négligeons la correction de population finie. Alors $V = \sum_h W_h^2 \, S^2/n_h$ et $V_{SAS} = S^2/n$, d'où

$$deff = \frac{\sum_h W_h^2 \, S^2/n_h}{S^2/n} = n \sum_h \frac{W_h^2}{n_h}.$$

Les poids de l'échantillon. Une unité de la strate h a le poids $d_h = N_h/n_h$; l'échantillon contient n_h unités de poids d_h. La moyenne des poids est $\overline{d} = \frac{1}{n}\sum_h n_h \frac{N_h}{n_h} = \frac{N}{n}$. La variance des poids (diviseur n) est la moyenne des carrés moins le carré de la moyenne, et son coefficient de variation vérifie

$$CV^2(d) = \frac{\frac{1}{n}\sum_h n_h \, d_h^2}{\overline{d}^{\,2}} - 1.$$

Le calcul. Comme $n_h\, d_h^2 = N_h^2/n_h = N^2\, W_h^2/n_h$, on a $\dfrac{1}{n}\sum_h n_h\, d_h^2 = \dfrac{N^2}{n}\sum_h \dfrac{W_h^2}{n_h}$. En divisant par $\overline{d}^{\,2} = N^2/n^2$,

$$1 + CV^2(d) = n\sum_h \frac{W_h^2}{n_h} = \textit{deff}.$$

Jamais mieux que 1. Cauchy-Schwarz, avec $a_h = \sqrt{n_h}$ et $b_h = W_h/\sqrt{n_h}$, donne $n\sum_h W_h^2/n_h \geq \left(\sum_h W_h\right)^2 = 1$, avec égalité si et seulement si $n_h \propto W_h$: l'allocation proportionnelle, dont les poids sont tous égaux ($CV = 0$).

Sur l'allocation égale. Avec $n_h = 50$: $\sum_h W_h^2 = 0{,}41^2 + 0{,}28^2 + 0{,}19^2 + 0{,}12^2 = 0{,}297$, d'où $\textit{deff} = 200 \times 0{,}297/50 = 1{,}188$. Les poids sont 16,4 ; 11,2 ; 7,6 ; 4,8, de moyenne 10 : leur CV^2 vaut 0,188.

Ce que cela dit. À dispersions égales, des poids inégaux ne rapportent rien et coûtent $1 + CV^2(d)$ en variance. Le plan réel a un effet de plan un peu plus fort, 1,246 : la formule néglige la correction de population finie (qui donne 1,209) et suppose des S_h égaux, alors que les provinces sous-représentées, les plus peuplées, sont aussi les plus dispersées.

■

La précision dans chaque province

Erreur-type de la moyenne provinciale, en dh

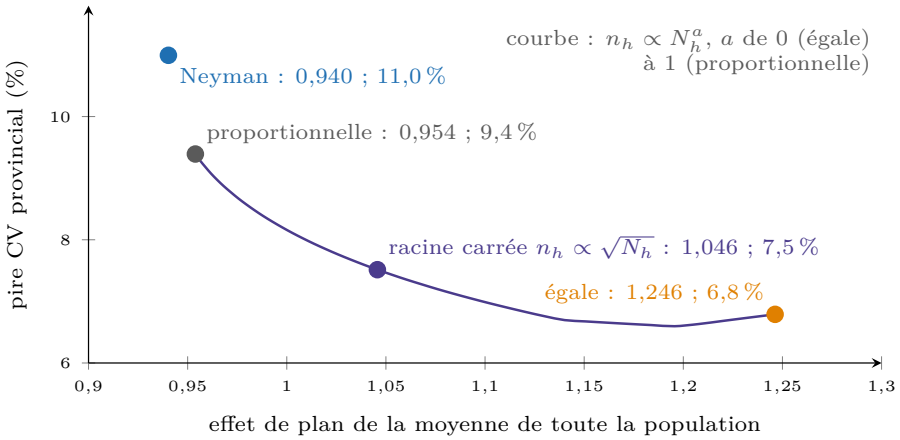
$\sqrt{(1 - f_h)\, S_h^2/n_h}$ pour chaque province ; dernière ligne : la moyenne d'ensemble.

Province	proportionnelle	Neyman	égale
Tanger-Assilah	447,5	423,3	585,3
Tétouan	491,0	490,5	522,7
Larache	553,0	575,9	473,5
Al Hoceïma	561,6	657,4	364,9
Ensemble	261,0	259,2	298,4

Chaque domaine est une petite enquête

Pour publier la dépense d'Al Hoceïma, Neyman est le pire choix : 18 ménages, une marge de ±1 288 dh. L'allocation égale la ramène à ±715 dh. Ce qui est optimal pour la région ne l'est pas pour chaque province.

Le compromis



Lire la courbe

En abscisse, l'effet de plan de la moyenne régionale ; en ordonnée, le pire coefficient de variation provincial. La règle $n_h \propto \sqrt{N_h}$ (65,6 ; 54,2 ; 44,7 ; 35,5) abaisse ce pire CV de 9,4 % à 7,5 %, pour un *deff* de 1,046 au lieu de 0,954.

Suréchantillonner une petite strate

Un plancher de 30 ménages à Al Hoceïma

On donne 30 ménages à Al Hoceïma et l'on répartit les 170 autres au prorata : 79,2 ; 54,1 ; 36,7. Poids : 10,35 dans les trois grandes provinces, 8 à Al Hoceïma. Résultat : *deff* = 0,975, et la marge d'Al Hoceïma passe de ±1 101 à ±971 dh.

Suréchantillonner, puis repondérer

On **suréchantillonne** les domaines trop petits pour être bien estimés, puis l'on rend à chaque ménage son poids $d_k = N_h/n_h$ dans les estimations d'ensemble. L'effet de plan, un peu plus élevé, est le prix de la précision locale : un choix de diffusion, pas une erreur.

L'effet de plan

La définition de Kish

Effet de plan, taille effective

Pour un estimateur $\hat{\theta}$ et un plan de taille n :

$$deff = \frac{V_{plan}(\hat{\theta})}{V_{SAS}(\hat{\theta})} \qquad n_{eff} = \frac{n}{deff} \qquad deft = \sqrt{deff}$$

où V_{SAS} est la variance d'un sondage aléatoire simple de **même taille** n.

Trois lectures d'un même nombre

Allocation égale, $deff = 1{,}246$:

- la **variance** est supérieure de 24,6 % à celle du sondage aléatoire simple ;
- les 200 ménages **valent** $n_{eff} = 160{,}5$ ménages tirés au hasard simple ;
- la **marge** est plus large de $deft - 1 = 11{,}6\,\%$: ±584,8 dh au lieu de ±523,9.

Taille effective et taille nécessaire

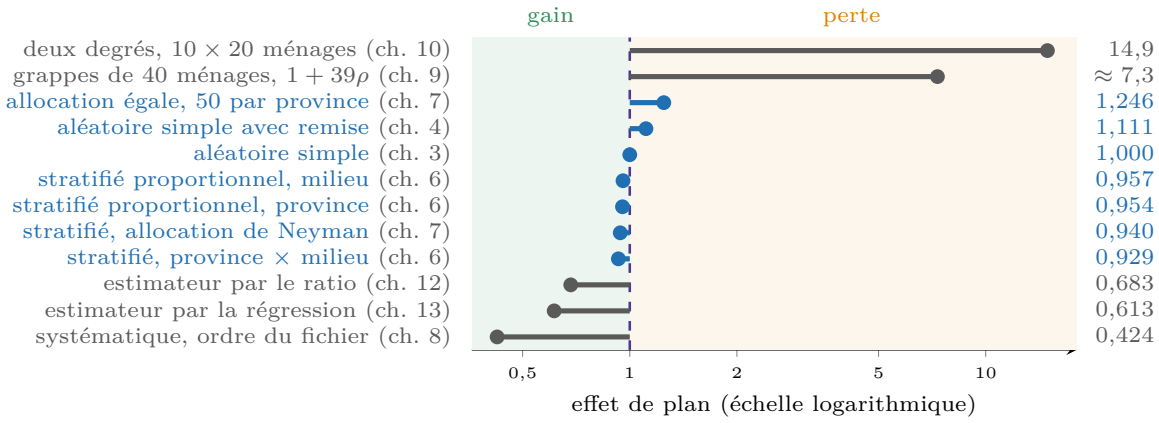
Les allocations de 200 ménages, dépense

Plan	*deff*	n_{eff}	marge à 95 %
Aléatoire simple	1	200	±523,9
Stratifié, proportionnelle	0,954	209,7	±511,6
Stratifié, Neyman	0,940	212,7	±508,0
Stratifié, égale	1,246	160,5	±584,8

L'effet de plan multiplie le budget

Pour une marge de ±300 dh, le chapitre 5 demandait 507 ménages en aléatoire simple. Le calcul exact donne 483 avec Neyman et 624 avec l'allocation égale. L'allocation égale exige 23 % d'interviews de plus que le hasard simple : l'effet de plan se lit comme un **coût**.

L'échelle des effets de plan



Ce que montre l'échelle

En bleu, les plans déjà vus : entre 0,93 et 1,25, **stratifier rapporte peu** sur cette population. En gris, la suite : les grappes multiplient la variance par 7 à 15 ; ratio, régression ou ordre du fichier la divisent par 1,5 à 2,4.

Proportions et plusieurs variables

Le cas d'une proportion

Neyman pour une proportion

$$S_h^2 = \frac{N_h}{N_h - 1} P_h (1 - P_h) \qquad \text{d'où, à peu près,} \qquad n_h \propto N_h \sqrt{P_h (1 - P_h)}$$

Or $\sqrt{P(1-P)}$ varie peu : 0,50 pour $P = 0{,}5$; 0,46 pour 0,3 ; 0,40 pour 0,2. Il ne tombe vite que pour les proportions **rares** : 0,14 pour 0,02.

Les ménages connectés, stratifiés par milieu

$P_h = 0{,}434$ (rural) et 0,768 (urbain), d'où $S_h = 0{,}496$ et 0,422. Neyman : 62,9 ruraux et 137,1 urbains, contre 56,2 et 143,8 en proportionnelle. Effet de plan : 0,893 contre 0,898. Pour une proportion, **Neyman se confond presque avec la proportionnelle**.

Une allocation pour plusieurs variables

Effet de plan pour la dépense et pour internet, 200 ménages

Allocation	n_h	dépense	internet
Proportionnelle	82, 56, 38, 24	0,954	0,966
Neyman dépense	91, 56, 35, 18	0,940	0,997
Neyman internet	78, 55, 41, 26	0,968	0,963
Égale	50 partout	1,246	1,122

La proportionnelle, un compromis robuste

L'allocation optimale pour une variable est médiocre pour une autre : Neyman pour la dépense ne gagne **rien** sur internet. La proportionnelle n'est jamais loin de la meilleure. En pratique : on optimise pour la variable principale, on contrôle les autres, et l'on ajoute des planchers pour les domaines.

S'entraîner

Exercice 1 : l'allocation de Neyman

Trois catégories d'exploitations agricoles

Une province compte 1 000 exploitations. On veut estimer leur superficie cultivée moyenne, en hectares, avec $n = 140$ exploitations.

Strate	Petites	Moyennes	Grandes
N_h	600	300	100
S_h (hectares)	2	5	15

1. Calculer l'allocation proportionnelle et l'allocation de Neyman.
2. Calculer les deux variances de $\overline{y}_{st}$.
3. Retrouver leur différence par $\frac{1}{n}\sum_h W_h\,(S_h - \overline{S})^2$.
4. Quels sont le taux de sondage et le poids d'une grande exploitation ?

Exercice 1 : solution

Les deux allocations

1. Proportionnelle : 84, 42, 14. $N_h S_h$ = 1 200, 1 500, 1 500, de somme 4 200 : Neyman donne 40, 50, 50.
2. $\sum_h W_h S_h^2 = 2{,}4 + 7{,}5 + 22{,}5 = 32{,}4$; $V_{prop} = (1 - 0{,}14) \times 32{,}4/140 = 0{,}1990$. $\overline{S} = 1{,}2 + 1{,}5 + 1{,}5 = 4{,}2$; $V_{Ney} = 4{,}2^2/140 - 32{,}4/1\,000 = 0{,}126 - 0{,}0324 = 0{,}0936$: la variance est **divisée par** 2,1.

Le gain et les poids

3. $0{,}6 \times 2{,}2^2 + 0{,}3 \times 0{,}8^2 + 0{,}1 \times 10{,}8^2 = 2{,}904 + 0{,}192 + 11{,}664 = 14{,}76$; $14{,}76/140 = 0{,}1054 = 0{,}1990 - 0{,}0936$. Les S_h sont très inégaux : le gain est fort.
4. $f_h = 50/100 = 0{,}5$ et $d_k = 2$ pour une grande exploitation, contre $f_h = 0{,}067$ et $d_k = 15$ pour une petite.

Exercice 2 : des coûts différents

Ville et campagne

Une enquête sur la dépense porte sur 6 000 ménages urbains (S_h = 4 000 dh) et 4 000 ruraux (S_h = 3 000 dh). Un questionnaire coûte 100 dh en ville et 400 dh à la campagne ; le budget des questionnaires est de 60 000 dh.

1. Calculer l'allocation optimale.
2. Calculer l'allocation proportionnelle de même coût.
3. Comparer les variances de $\overline{y}_{st}$.
4. Que perd-on sur la moyenne rurale ?

Exercice 2 : solution

Les deux allocations

1. $N_h S_h/\sqrt{c_h}$: $6\,000 \times 4\,000/10 = 2\,400\,000$ et $4\,000 \times 3\,000/20 = 600\,000$, soit $n_u = 4\,n_r$. Le budget : $100 \times 4\,n_r + 400\,n_r = 800\,n_r = 60\,000$, d'où $n_r = 75$ et $n_u = 300$.
2. Coût moyen : $0{,}6 \times 100 + 0{,}4 \times 400 = 220$ dh, donc $n = 272{,}7$: 163,6 urbains et 109,1 ruraux.

Les variances

3. Optimale : $0{,}36 \times 0{,}95 \times 16\,000\,000/300 = 18\,240$ en ville, $0{,}16 \times 0{,}981 \times 9\,000\,000/75 = 18\,840$ à la campagne, d'où V_{opt} = 37 080. Proportionnelle : $V_{prop} = (1 - 0{,}0273) \times 13\,200\,000/272{,}7 = 47\,080$. Soit 21 % de variance en moins, au même prix.
4. L'erreur-type de la moyenne rurale passe de 283,3 à 343,1 dh. Si elle doit être publiée, on impose un plancher.

Exercice 3 : effet de plan et taille effective

Cent ménages par milieu, le retour

On reprend le plan des chapitres 1 et 6 : 100 ménages urbains et 100 ruraux. Sa variance vaut 88 918,3, contre 71 435,5 pour un sondage aléatoire simple de 200 ménages.

1. Calculer *deff*, n_{eff} et *deft*. Interpréter.
2. Calculer les poids, puis l'effet de plan de Kish $n \sum_h n_h d_h^2 / \left(\sum_h n_h d_h\right)^2$. Pourquoi est-il plus faible que le vrai ?
3. Répartir 200 ménages selon Neyman, avec S_h = 4 134,11 (urbain) et 3 215,03 (rural). Son effet de plan vaut 0,945 : conclure.

Exercice 3 : solution

Le plan à 100 et 100

1. *deff* = 88 918,3/71 435,5 = 1,245 ; n_{eff} = 200/1,245 = 160,7 ; *deft* = 1,116. Les 200 ménages en valent 161 tirés au hasard simple ; la marge est 11,6 % plus large.
2. Poids 14,38 et 5,62 ; Kish : $200 \times 100 \times (14{,}38^2 + 5{,}62^2)/2\,000^2 = 1{,}192$. Le vrai est plus fort, car la strate **sous-représentée**, l'urbaine, est aussi la **plus dispersée**.

Neyman par milieu

3. $N_h S_h$ = 5 944 846 (urbain) et 1 806 848 (rural) : 76,7 % et 23,3 %, soit 153,4 urbains et 46,6 ruraux. C'est l'inverse du plan à 100 et 100 : moins de ruraux que la proportionnelle (56,2), et un gain au lieu d'une perte.

Ce qu'il faut retenir

Le résumé du chapitre

Sept points

1. À n fixé, seul $\sum_h W_h^2 S_h^2 / n_h$ dépend de la répartition de l'échantillon.
2. **Neyman** : $n_h \propto N_h S_h$ minimise la variance ; f_h est proportionnel à S_h.
3. Son gain sur la proportionnelle vaut $\frac{1}{n} \sum_h W_h (S_h - \overline{S})^2$: faible si les S_h se ressemblent, énorme sinon (strate exhaustive).
4. Avec des coûts c_h : $n_h \propto N_h S_h / \sqrt{c_h}$.
5. L'allocation égale sert les **domaines**, au prix d'un *deff* de 1,246 ici.
6. $deff = V_{plan}/V_{SAS}$, $n_{eff} = n/deff$; des poids inégaux coûtent $1 + CV^2$ (Kish).
7. Pour les proportions et quand il y a plusieurs variables, la proportionnelle est un compromis robuste.

La suite

Le chapitre 8 tire un ménage tous les k dans une liste ordonnée : le **sondage systématique**, une stratification implicite qui ne dit pas son nom.