Échantillonnage

Chapitre 12 : L'estimateur par le ratio

Jaouad Madkour

21 octobre 2026

Plan du chapitre

L'information auxiliaire **2**
Ce que l'on sait avant l'enquête . . . 2
La dépense suit la taille . . . 2
L'estimateur par le ratio . . . 3
Sur la mini-population . . . 3
Dix échantillons, dix estimations . . . 3

Le biais **4**
Pourquoi le ratio est biaisé . . . 4
Un biais d'ordre 1/n . . . 4
Négligeable devant l'erreur-type . . . 4

La précision **5**
La variance approchée . . . 5
Sur la population du cours . . . 5
Quand le ratio gagne-t-il ? . . . 6
Le gain selon la corrélation . . . 6

L'échantillon fil rouge **7**
L'estimation . . . 7
Le ratio a trop corrigé . . . 7
La précision estimée sur l'échantillon . . . 7
En moyenne, le ratio fait mieux . . . 8
Juger une méthode, pas un résultat . . . 8

Ratios et domaines **9**
La dépense par personne . . . 9
Un ratio n'est pas une moyenne de ratios . . . 9
La moyenne d'un domaine est un ratio . . . 9
Quand la taille de l'échantillon est aléatoire . . . 10

Bien utiliser le ratio **10**
Ratio, strates ou régression . . . 10
Une variable auxiliaire mal choisie . . . 11

Quand l'employer 11

S'entraîner **11**
Exercice 1 : quatre exploitations 11
Exercice 1 : solution 12
Exercice 2 : la masse salariale 12
Exercice 2 : solution 12
Exercice 3 : choisir la variable auxiliaire 13
Exercice 3 : solution 13

Ce qu'il faut retenir **13**
Le résumé du chapitre 13

L'information auxiliaire

Ce que l'on sait avant l'enquête

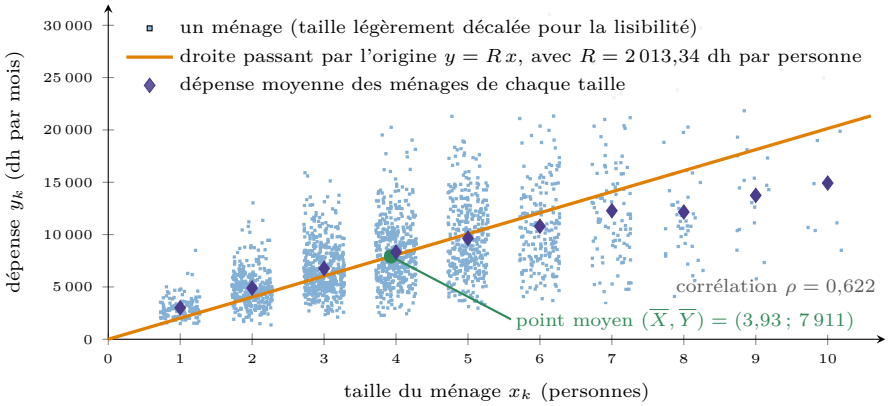
Une variable auxiliaire

Une **variable auxiliaire** x est mesurée sur chaque unité tirée, et son **total** $X = \sum_{k \in U} x_k$ est connu pour toute la population, par un recensement ou un fichier administratif. On note $\overline{X} = X/N$ sa moyenne, $\overline{x}$ sa moyenne dans l'échantillon.

Le nombre de personnes

Le recensement donne le nombre de personnes de la population du cours : $X = 7\,859$ pour $N = 2\,000$ ménages, soit $\overline{X} = 3{,}93$ personnes par ménage (le RGPH 2024 en compte 3,9 pour tout le pays). L'enquête demande la taille de chaque ménage tiré : l'échantillon fil rouge en compte $\overline{x} = 3{,}805$ en moyenne.

La dépense suit la taille



Lire le nuage

Les grands ménages dépensent plus : $\rho = 0{,}622$. La droite issue de l'origine, de pente $R = Y/X = 2\,013{,}34$ dh par personne, résume ce lien. Des ménages tirés **plus petits** que la moyenne donnent une dépense moyenne **trop basse**.

L'estimateur par le ratio

Corriger la moyenne par la taille

On estime le ratio $R = Y/X$ par $\widehat{R} = \overline{y}/\overline{x}$, puis on le multiplie par le total connu :

$$\widehat{Y}_R = X\,\widehat{R} = X\,\frac{\overline{y}}{\overline{x}}, \qquad \widehat{\overline{Y}}_R = \overline{X}\,\frac{\overline{y}}{\overline{x}} = \overline{y} \times \frac{\overline{X}}{\overline{x}}$$

Un facteur de correction

Si les ménages tirés sont plus petits que l'ensemble ($\overline{x} < \overline{X}$), le facteur $\overline{X}/\overline{x}$ dépasse 1 et **relève** la moyenne ; s'ils sont plus grands, il l'**abaisse**. Si $\overline{x} = \overline{X}$, l'estimateur vaut $\overline{y}$. Il ne demande qu'une chose de plus que $\overline{y}$: le total X.

Sur la mini-population

Dépense et taille des cinq ménages, sondage de deux ménages

Tailles 2, 3, 3, 4, 6 : $X = 18$, $\overline{X} = 3{,}6$, $R = 40/18 = 2{,}22$. Estimateur : $3{,}6\,\overline{y}/\overline{x}$.

Échantillon	AB	AC	AD	AE	BC
$\overline{y}$	5	5,5	6,5	9	6,5
$\overline{x}$	2,5	2,5	3	4	3
Ratio	7,2	7,92	7,8	8,1	7,8

Échantillon	BD	BE	CD	CE	DE
$\overline{y}$	7,5	10	8	10,5	11,5
$\overline{x}$	3,5	4,5	3,5	4,5	5
Ratio	7,71	8	8,23	8,4	8,28

Dix échantillons, dix estimations

Les deux estimateurs sur les dix échantillons

	Moyenne $\overline{y}$	Ratio
Espérance	8	7,944
Biais	0	−0,056
Variance	4,35	0,108
Valeurs extrêmes	5 et 11,5	7,2 et 8,4

Un petit biais, une variance divisée par quarante

La dépense est presque proportionnelle à la taille : y_k/x_k ne varie que de 2 à 2,33 milliers de dh par personne. Le ratio efface l'essentiel des écarts entre échantillons : la variance tombe de 4,35 à 0,108. Il n'est plus exactement sans biais, mais son erreur quadratique moyenne,

0,111, reste 39 fois plus faible que celle de $\overline{y}$.

Le biais

Pourquoi le ratio est biaisé

L'espérance d'un quotient

$\overline{y}$ et $\overline{x}$ sont sans biais, mais $E(\overline{y}/\overline{x}) \quad \neq \quad E(\overline{y})/E(\overline{x})$: l'espérance d'un quotient n'est pas le quotient des espérances. Sur la mini-population, l'estimateur vaut 7,944 en moyenne au lieu de 8.

L'erreur s'écrit avec des résidus

Posons $e_k = y_k - R\,x_k$: l'écart du ménage k à la droite de pente R. Leur moyenne dans la population est **nulle**, car $\sum_{k\in U} e_k = Y - R\,X = 0$. Comme $R = \overline{Y}/\overline{X}$:

$$\widehat{\overline{Y}}_R - \overline{Y} = \frac{\overline{X}}{\overline{x}}\,(\overline{y} - R\,\overline{x}) = \frac{\overline{X}}{\overline{x}}\,\overline{e}$$

où $\overline{e}$ est la moyenne des e_k des unités tirées.

Un biais d'ordre 1/n

Le biais approché

$$B(\widehat{\overline{Y}}_R) \approx \frac{1-f}{n}\cdot\frac{R\,S_x^2 - S_{xy}}{\overline{X}} = \overline{Y}\,\frac{1-f}{n}\,\left(CV_x^2 - \rho\,CV_x\,CV_y\right)$$

S_{xy} est la covariance de x et y dans la population (en $N-1$), $CV_x = S_x/\overline{X}$ et $CV_y = S/\overline{Y}$ leurs coefficients de variation.

La démonstration courte

Pour $\overline{x}$ proche de $\overline{X}$, $\overline{X}/\overline{x} \approx 1 - (\overline{x} - \overline{X})/\overline{X}$, d'où

$$\widehat{\overline{Y}}_R - \overline{Y} \approx \overline{e} - \frac{\overline{e}\,(\overline{x} - \overline{X})}{\overline{X}}$$

Le premier terme est d'espérance nulle (sondage aléatoire simple des e_k, de moyenne 0). Le second a pour espérance $-\mathrm{Cov}(\overline{e},\overline{x})/\overline{X} = -(1-f)\,S_{ex}/(n\,\overline{X})$, avec $S_{ex} = S_{xy} - R\,S_x^2$.

Négligeable devant l'erreur-type

Sur la population du cours

$CV_x^2 = 0{,}1989$ et $\rho\,CV_x\,CV_y = 0{,}1397$. Pour $n = 200$: biais relatif $(0{,}9/200) \times 0{,}0592 = 0{,}027\,\%$, soit 2,11 dh.

Taille de l'échantillon n	20	50	200	800
Biais (dh)	23,2	9,1	2,1	0,35
Erreur-type (dh)	732	460	221	90
Biais / erreur-type	0,032	0,020	0,010	0,004

Le biais s'efface plus vite que l'erreur-type

Le biais décroît comme $1/n$, l'erreur-type comme $1/\sqrt{n}$: leur rapport tend vers 0. Dès $n = 20$, le carré du biais fait 0,1 % de l'erreur quadratique moyenne. La formule est fiable même sur la mini-population : −0,053, pour un biais exact de −0,056.

La précision

La variance approchée

Variance de l'estimateur par le ratio

$$V(\widehat{\overline{Y}}_R) \approx \frac{1-f}{n} S_e^2, \qquad S_e^2 = \frac{1}{N-1}\sum_{k\in U}(y_k - R\,x_k)^2 = S^2 - 2R\,S_{xy} + R^2 S_x^2$$

Pour le total : $V(\widehat{Y}_R) \approx N^2\,(1-f)\,S_e^2/n$.

La démonstration courte

Au premier ordre, $\widehat{\overline{Y}}_R - \overline{Y} \approx \overline{e}$, la moyenne d'un sondage aléatoire simple de la variable e_k. Le chapitre 3 donne sa variance : $(1-f)\,S_e^2/n$. Le ratio se comporte comme $\overline{y}$, **avec les résidus e_k à la place des y_k**. Sur la mini-population, l'approximation donne 0,091 pour une variance exacte de 0,108 : grossière avec $n = 2$, mais du bon ordre de grandeur.

Sur la population du cours

Moyenne simple et ratio, 200 ménages

	Moyenne simple	Ratio
Dispersion de la variable	$S = 3\,984{,}29$	$S_e = 3\,292{,}09$
Variance de l'estimateur	71 435,5	48 770,3
Erreur-type (dh)	267,27	220,84
Effet de plan	1	0,683

Ce que vaut l'information

L'erreur-type baisse de 17 %. Avec la taille du ménage, 200 ménages valent $200/0{,}683 = 293$ ménages interrogés sans elle : c'est la **taille effective** (chapitre 7). Il a suffi d'une question de plus dans l'enquête, et du total X fourni par le recensement.

Quand le ratio gagne-t-il ?

La condition de gain

Le ratio est plus précis que $\overline{y}$ si et seulement si $S_e^2 < S^2$, c'est-à-dire

$$\rho > \frac{CV_x}{2\,CV_y}$$

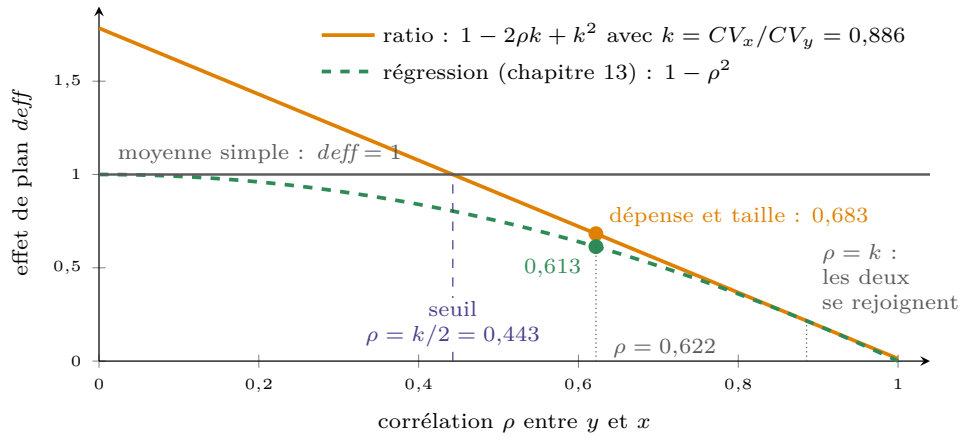
La démonstration

$S_e^2 < S^2 \iff R^2 S_x^2 < 2R\,S_{xy} = 2R\,\rho\,S_x\,S$. On divise par $2R\,S_x\,S > 0$: $\rho > \dfrac{R\,S_x}{2S} = \dfrac{S_x/\overline{X}}{2\,S/\overline{Y}}$, puisque $R = \overline{Y}/\overline{X}$.

Dépense et taille

$CV_x = 0{,}446$ et $CV_y = 0{,}504$: il faut $\rho > 0{,}443$. Avec $\rho = 0{,}622$, la condition est remplie.

Le gain selon la corrélation



Lire la figure

L'effet de plan du ratio vaut $S_e^2/S^2 = 1 - 2\rho k + k^2$, avec $k = CV_x/CV_y = 0{,}886$. Sous le seuil $\rho = 0{,}443$, le ratio fait **pire** que $\overline{y}$. La régression (chapitre 13) fait toujours au moins aussi bien ; les deux coïncident quand $\rho = k$.

L'échantillon fil rouge

L'estimation

Les 200 ménages du chapitre 3

	Échantillon	Population
Taille moyenne (personnes)	3,805	3,9295
Dépense moyenne (dh)	7 843,05	7 911,44
Dépense par personne (dh)	2 061,25	2 013,34

L'enquêteur ne connaît, dans la seconde colonne, que $\overline{X} = 7\,859/2\,000$.

Des ménages tirés un peu petits

Les ménages tirés comptent 0,12 personne de moins que l'ensemble : le facteur $\overline{X}/\overline{x} = 1{,}0327$ relève la moyenne de 3,3 %.

$$\widehat{\overline{Y}}_R = \overline{X}\,\widehat{R} = 3{,}9295 \times 2\,061{,}25 = 8\,099{,}68 \text{ dh}$$

Total estimé : $X\,\widehat{R} = 16\,199\,351$ dh, pour un vrai total de 15 822 870 dh.

Le ratio a trop corrigé

Plus loin de la vérité que la moyenne simple

Erreur de $\overline{y}$: $7\,843{,}05 - 7\,911{,}44 = -68{,}39$ dh. Erreur du ratio : $8\,099{,}68 - 7\,911{,}44 = +188{,}24$ dh. **Sur cet échantillon, le ratio fait moins bien que la moyenne simple.**

Deux erreurs qui se compensaient

L'erreur de $\overline{y}$ se décompose : $\overline{y} - \overline{Y} = R\,(\overline{x} - \overline{X}) + \overline{e} = -250{,}7 + 182{,}3 = -68{,}4$.

- $R\,(\overline{x} - \overline{X}) = 2\,013{,}34 \times (-0{,}1245)$: les ménages tirés sont **trop petits** ;
- $\overline{e} = +182{,}3$: à taille égale, ils **dépensent plus** que la moyenne.

$\overline{y}$ cumule les deux erreurs, qui se compensent presque. Le ratio retire la première et garde la seconde : $\frac{\overline{X}}{\overline{x}}\,\overline{e} = 1{,}0327 \times 182{,}28 = 188{,}24$.

La précision estimée sur l'échantillon

Estimer la variance

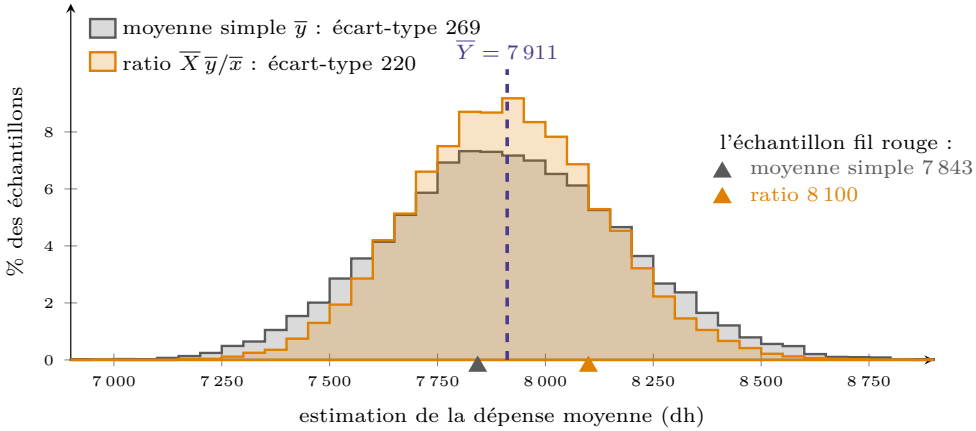
On remplace R par $\widehat{R}$ et S_e^2 par sa version d'échantillon :

$$\widehat{V}(\widehat{\overline{Y}}_R) = \frac{1-f}{n}\,s_e^2, \qquad s_e^2 = \frac{1}{n-1}\sum_{k\in S}\left(y_k - \widehat{R}\,x_k\right)^2 = s_y^2 - 2\widehat{R}\,s_{xy} + \widehat{R}^2 s_x^2$$

L'échantillon fil rouge

$s_y = 3\,829{,}16$, $s_x = 1{,}7812$, $s_{xy} = 4\,630{,}25$ (corrélation 0,679), d'où $s_e = 3\,009{,}13$ et une erreur-type estimée de $\sqrt{0{,}0045} \times 3\,009{,}13 = 201{,}86$ dh. Intervalle à 95 % : $8\,099{,}68 \pm 395{,}6$, soit $[7\,704{,}0\,;8\,495{,}3]$, qui contient $\overline{Y}$. La moyenne simple avait une erreur-type estimée de 256,87 dh.

En moyenne, le ratio fait mieux



Vingt mille sondages de 200 ménages

Les deux distributions sont centrées sur $\overline{Y}$: le biais du ratio, 2 dh, est invisible. Celle du ratio est plus **resserrée** : écart-type 220 dh, comme le prévoyait la formule (220,84), contre 269 pour $\overline{y}$. Le fil rouge tombe à gauche pour $\overline{y}$, à droite pour le ratio.

Juger une méthode, pas un résultat

Ce que disent les simulations

Sur 20 000 échantillons	Moyenne simple	Ratio
Erreur de moins de 300 dh	73,4 %	82,8 %
Racine de l'erreur quadratique moyenne	269,3	220,1
Couverture de l'intervalle à 95 %	94,6 %	94,7 %

Le ratio est le plus proche de $\overline{Y}$ dans 57,3 % des échantillons ; dans les 42,7 % restants, comme le fil rouge, c'est $\overline{y}$.

Choisir l'estimateur avant de voir le résultat

On choisit un estimateur pour sa **loi** sur tous les échantillons, pas pour sa valeur sur celui qu'on a tiré : $\overline{Y}$ étant inconnu, on ne sait jamais lequel est tombé le plus près. Retenir après coup celui qui « arrange » fausserait toutes les marges d'erreur.

Ratios et domaines

La dépense par personne

Un ratio comme paramètre

$R = Y/X$ s'estime par $\widehat{R} = \overline{y}/\overline{x}$, **sans** avoir besoin de X. Même linéarisation : $\widehat{R} - R = \overline{e}/\overline{x} \approx \overline{e}/\overline{X}$, d'où

$$V(\widehat{R}) \approx \frac{1-f}{n} \cdot \frac{S_e^2}{\overline{X}^2}, \qquad \widehat{V}(\widehat{R}) = \frac{1-f}{n} \cdot \frac{s_e^2}{\overline{x}^2}$$

Sur l'échantillon fil rouge

$\widehat{R} = 2\,061{,}25$ dh par personne, d'erreur-type estimée $201{,}86/3{,}805 = 53{,}05$ dh. Intervalle à 95 % : $[1\,957{,}3\,;2\,165{,}2]$, qui contient $R = 2\,013{,}34$. La vraie erreur-type vaut $220{,}84/3{,}9295 = 56{,}2$ dh.

Un ratio n'est pas une moyenne de ratios

Dépense par personne selon la taille du ménage

Taille du ménage	Ménages	Dépense moyenne	Par personne
1 personne	119	3 005	3 005
2 personnes	318	4 899	2 450
3 personnes	454	6 769	2 256
4 personnes	419	8 326	2 082
5 personnes	338	9 645	1 929
6 personnes et plus	352	11 606	1 719

Des économies d'échelle

Logement, équipement et cuisine se partagent : la dépense par personne baisse avec la taille. La moyenne des y_k/x_k des 2 000 ménages, 2 147,75 dh, compte autant un ménage d'une personne qu'un ménage de huit ; $R = 2\,013{,}34$ dh compte chaque **personne** une fois (chapitre 1).

La moyenne d'un domaine est un ratio

Un domaine, deux totaux

Avec $\delta_k = 1$ si le ménage est rural et 0 sinon, $\overline{y}_d = \sum_S \delta_k\, y_k \big/ \sum_S \delta_k$ est le ratio de la variable $\delta_k\, y_k$ à la variable δ_k. La linéarisation, avec $e_k = \delta_k\,(y_k - \overline{y}_d)$ et $\overline{x} = n_d/n$, donne

$$\widehat{V}(\overline{y}_d) = \frac{1-f}{n} \cdot \frac{s_e^2}{(n_d/n)^2}$$

Les ruraux de l'échantillon fil rouge

$n_d = 48$, $\overline{y}_d = 6\,916{,}67$ dh, erreur-type 458,49 dh. Le chapitre 4, à n_d fixé, donnait 465,9 dh ; en y remplaçant n_d/N_d par f, on obtient 462,18 dh. Le rapport de ces deux dernières variances, $(n_d - 1)\,n/[n_d\,(n-1)] = 0{,}984$, tend vers 1 : pour un domaine de quelques dizaines de ménages, les deux approches **coïncident**.

Quand la taille de l'échantillon est aléatoire

Le tirage de Bernoulli du chapitre 4

Avec $\pi = 0{,}1$, le tirage a donné $n = 202$ ménages : $\widehat{Y} = 16\,018\,000$ dh et $\widehat{N} = 2\,020$.

Estimateur de la moyenne	Valeur	Erreur-type
$\widehat{Y}/N$ (Horvitz-Thompson)	8 009,0	594,2
$\widehat{Y}/\widehat{N} = \overline{y}$	7 929,7	267,2

Le ratio absorbe la taille aléatoire

$\widehat{Y}$ et $\widehat{N}$ varient ensemble : un tirage qui ramène trop de ménages gonfle les deux. Leur rapport efface cet aléa et retrouve la précision d'un sondage aléatoire simple (267,3) : c'était l'annonce du chapitre 4. Même mécanisme pour les grappes de tailles inégales (chapitre 9) : effet de plan 32,2 pour Horvitz-Thompson, 8,4 pour le ratio.

Bien utiliser le ratio

Ratio, strates ou régression

Trois façons d'utiliser la taille, 200 ménages

Méthode	Effet de plan
Moyenne simple	1
Strates de taille (1–2, 3, 4, 5, 6+), proportionnelle	0,626
Estimateur par le ratio	0,683
Estimateur par la régression (chapitre 13)	0,613

Stratifier exige la taille de **chaque** ménage de la base ; le ratio, le seul total X.

Ce que coûte la droite par l'origine

$1 - 2\rho k + k^2 = (1-\rho^2) + (\rho - k)^2 = 0{,}613 + 0{,}070$. La régression ajuste la meilleure droite ; le ratio l'impose **par l'origine**. Or les petits ménages dépensent plus que $R\,x_k$, les grands moins.

Une variable auxiliaire mal choisie

Trois variables auxiliaires pour la dépense

Variable auxiliaire x	ρ	Seuil	Effet de plan
Taille du ménage	0,622	0,443	0,683
Accès à internet (0/1)	0,276	0,691	2,145
Milieu urbain (0/1)	0,208	0,621	2,025

Le seuil est $CV_x/(2\,CV_y)$; l'effet de plan, S_e^2/S^2.

Un ratio peut doubler la variance

Les ménages connectés dépensent plus, mais la dépense n'est pas **proportionnelle** à l'indicatrice : un ménage non connecté ($x_k = 0$) dépense quand même. Sous le seuil, le ratio fait pire que $\overline{y}$: ici, deux fois pire. Avant d'employer un ratio, on vérifie la condition sur une enquête antérieure.

Quand l'employer

Trois conditions

1. x_k est mesuré sur chaque unité tirée, et X est **connu** : recensement, fichier administratif.
2. y est à peu près **proportionnel** à x : un nuage allongé le long d'une droite qui passe près de l'origine.
3. $\rho > CV_x/(2\,CV_y)$, vérifié sur une enquête antérieure ou une enquête pilote.

Des usages courants en économie

- La production agricole et la **superficie** cultivée.
- Le chiffre d'affaires ou la masse salariale et l'**effectif** de l'entreprise.
- La valeur actuelle d'une variable et sa valeur au **dernier recensement** : le ratio estime alors une évolution.

S'entraîner

Exercice 1 : quatre exploitations

Production et superficie

Quatre exploitations ont une superficie x_k de 2, 3, 5 et 6 ha, et une production y_k de 5, 8, 11 et 16 tonnes. On en tire deux par sondage aléatoire simple ; la superficie totale est connue.

1. Calculer $\overline{Y}$, $\overline{X}$ et R.
2. Pour chacun des six échantillons, calculer $\overline{y}$, $\overline{x}$ et l'estimateur par le ratio $\overline{X}\,\overline{y}/\overline{x}$.
3. Calculer l'espérance et la variance des deux estimateurs. Le ratio est-il sans biais ? Lequel préférer ?
4. Comparer la variance du ratio à l'approximation $(1-f)\,S_e^2/n$.

Exercice 1 : solution

Les six échantillons

1. $\overline{Y} = 40/4 = 10$ t, $\overline{X} = 16/4 = 4$ ha, $R = 40/16 = 2{,}5$ t par ha.
2. L'estimateur vaut $4\,\overline{y}/\overline{x}$:

Exploitations	1, 2	1, 3	1, 4	2, 3	2, 4	3, 4
$\overline{y}$	6,5	8	10,5	9,5	12	13,5
$\overline{x}$	2,5	3,5	4	4	4,5	5,5
Ratio	10,4	9,14	10,5	9,5	10,67	9,82

Espérance et variance

3. $E(\overline{y}) = 10$, $V(\overline{y}) = 0{,}5 \times 22/2 = 5{,}5$. Ratio : $E = 60{,}03/6 = 10{,}005$ (biais $+0{,}005$), $V = 1{,}872/6 = 0{,}312$, 18 fois plus faible : on le préfère.
4. $e_k = y_k - 2{,}5\,x_k$ vaut 0 ; 0,5 ; $-1{,}5$; 1, d'où $S_e^2 = 3{,}5/3 = 1{,}167$ et $0{,}5 \times 1{,}167/2 = 0{,}292$, proche de 0,312.

Exercice 2 : la masse salariale

Une zone industrielle

Une zone industrielle compte $N = 500$ entreprises qui emploient, selon un fichier administratif, $X = 12\,000$ salariés. Un sondage aléatoire simple de $n = 50$ entreprises donne, pour la masse salariale mensuelle y (milliers de dh) et l'effectif x :

$$\overline{y} = 110, \quad \overline{x} = 25, \quad s_y = 80, \quad s_x = 15, \quad r = 0{,}9$$

1. Estimer la masse salariale moyenne par $\overline{y}$, puis par le ratio. Pourquoi diffèrent-elles ?
2. Calculer l'erreur-type et l'intervalle à 95 % des deux estimations.
3. Estimer la masse salariale totale par le ratio, et l'effet de plan.

Exercice 2 : solution

Les deux estimations

1. $\overline{X} = 24$; $\widehat{R} = 110/25 = 4{,}4$ milliers de dh par salarié, d'où $24 \times 4{,}4 = 105{,}6$. Les entreprises tirées sont un peu plus grandes que la moyenne (25 salariés contre 24) : $\overline{y}$ surestime, le ratio corrige.
2. Avec $s_{xy} = 0{,}9 \times 15 \times 80 = 1\,080$, on obtient $s_e^2 = 80^2 - 2 \times 4{,}4 \times 1\,080 + 4{,}4^2 \times 15^2 = 1\,252$. Avec $(1-f)/n = 0{,}018$: ratio, $\sqrt{0{,}018 \times 1\,252} = 4{,}75$, intervalle $[96{,}3\,;114{,}9]$; moyenne simple, $\sqrt{0{,}018 \times 6\,400} = 10{,}73$, intervalle $[89{,}0\,;131{,}0]$.

Le total

3. $X\,\widehat{R} = 12\,000 \times 4{,}4 = 52\,800$ milliers de dh, soit 52,8 millions de dh par mois, d'erreur-type $500 \times 4{,}75 = 2\,374$ milliers de dh. Effet de plan estimé : $22{,}54/115{,}2 = 0{,}196$. L'effectif explique l'essentiel des écarts de masse salariale.

Exercice 3 : choisir la variable auxiliaire

Une enquête sur la production de blé

On veut estimer la production moyenne de blé de 15 000 exploitations ($CV_y = 0{,}8$). Un recensement agricole fournit trois variables auxiliaires :

Variable x	Corrélation ρ avec y	CV_x
Superficie totale	0,85	0,7
Superficie en céréales	0,95	0,9
Nombre d'actifs familiaux	0,4	0,5

1. Pour chaque variable, vérifier la condition de gain et calculer l'effet de plan du ratio.
2. Laquelle choisir ? Pour $n = 100$, quelle est la taille effective (on néglige f) ?
3. Comparer à l'effet de plan $1 - \rho^2$ de la régression.

Exercice 3 : solution

Seuils et effets de plan

1. Avec $k = CV_x/CV_y$, seuil $k/2$ et $deff = 1 - 2\rho k + k^2$:

Variable	k	Seuil	*deff* du ratio
Superficie totale	0,875	0,4375	0,2781
Superficie en céréales	1,125	0,5625	0,1281
Actifs familiaux	0,625	0,3125	0,8906

Les trois corrélations dépassent leur seuil.

Le choix

2. La superficie en céréales. 100 exploitations valent alors $100/0{,}1281 \approx 780$ exploitations tirées sans information auxiliaire.
3. Régression : 0,2775 ; 0,0975 ; 0,84. Superficie totale : $\rho \approx k$, le ratio fait presque aussi bien. Ailleurs, l'écart $(\rho - k)^2$ pèse.

Ce qu'il faut retenir

Le résumé du chapitre

Sept points

1. Une variable auxiliaire de total X connu améliore l'estimation : $\widehat{Y}_R = X\,\overline{y}/\overline{x}$.
2. Le ratio est biaisé, mais d'ordre $1/n$: négligeable devant l'erreur-type.
3. $V \approx (1-f)\,S_e^2/n$ avec $e_k = y_k - R\,x_k$, estimée par $(1-f)\,s_e^2/n$.
4. Il gagne si $\rho > CV_x/(2\,CV_y)$; dépense et taille : effet de plan 0,683.
5. Sur le fil rouge, il fait moins bien que $\overline{y}$; en moyenne, mieux : on juge une **méthode**.
6. $\overline{y}/\overline{x}$ estime aussi un ratio (dépense par personne) et une moyenne de domaine.

7. Le ratio neutralise une taille d'échantillon aléatoire (Bernoulli, grappes).

La suite

Le chapitre 13 remplace la droite par l'origine par la meilleure droite : l'estimateur par la **régression**. Il combine ensuite plusieurs informations auxiliaires : post-stratification et **calage**.