Échantillonnage

Chapitre 1 : Population, paramètres et plan de sondage

Jaouad Madkour

21 octobre 2026

Plan du chapitre

Ce que l'on cherche **2**
- Les paramètres d'une population . . . 2
- Une proportion est une moyenne . . . 2
- Sur une mini-population de cinq ménages . . . 2
- Sur la population du cours . . . 3

La dispersion **3**
- Deux variances de la population . . . 3
- Ce que change la convention . . . 3
- La variance d'une proportion . . . 4

Le plan de sondage **4**
- Combien d'échantillons possibles ? . . . 4
- La définition . . . 4
- Le plan aléatoire simple sur la mini-population . . . 5
- Un autre plan sur la même population . . . 5
- Ce que montre la comparaison . . . 6
- Avec ou sans remise, taille fixe ou aléatoire . . . 6

Les probabilités d'inclusion **6**
- La chance qu'a chaque unité d'être tirée . . . 6
- Une propriété utile : la somme des probabilités . . . 7
- Les probabilités d'inclusion doubles . . . 7
- L'outil central : les indicatrices d'appartenance . . . 8
- Un signe à comprendre . . . 8

Sur la population du cours **8**
- Deux plans de 200 ménages . . . 8
- Le poids de sondage . . . 9
- Ce que coûte un oubli des poids . . . 9

S'entraîner **9**
- Exercice 1 : énumérer un plan . . . 9
- Exercice 1 : solution . . . 10

Exercice 2 : un plan de taille aléatoire 10
Exercice 2 : solution 10
Exercice 3 : urbain et rural 10
Exercice 3 : solution 11

Ce qu'il faut retenir **11**
Le résumé du chapitre 11

Ce que l'on cherche

Les paramètres d'une population

Quatre paramètres

Une variable y prend la valeur y_k pour chaque unité k de la population $U = \{1, \dots, N\}$.

Paramètre	Définition	Exemple
Total	$Y = \sum_{k \in U} y_k$	dépense de tous les ménages
Moyenne	$\overline{Y} = Y/N$	dépense par ménage
Proportion	$P =$ moyenne d'une variable 0/1	part des ménages connectés
Ratio	$R = Y/X$	dépense par personne

Le total d'abord

La comptabilité nationale, la fiscalité ou la politique sociale ont besoin de **totaux** : masse des dépenses, nombre de chômeurs, nombre de ménages pauvres. La moyenne s'en déduit en divisant par N, quand N est connu.

Une proportion est une moyenne

La variable indicatrice

Si $y_k = 1$ quand le ménage k a accès à internet et $y_k = 0$ sinon, alors

$$Y = \sum_{k \in U} y_k = \text{nombre de ménages connectés}, \qquad \overline{Y} = \frac{Y}{N} = P$$

Une seule théorie pour deux questions

Tout ce que le cours établit pour une moyenne vaut donc pour une proportion : il suffit de coder la caractéristique en 0/1. Le chapitre 4 en tirera les formules particulières.

Sur une mini-population de cinq ménages

Cinq ménages : dépense en milliers de dh, taille en personnes

Ménage	A	B	C	D	E	Total
Dépense y_k	4	6	7	9	14	40

Taille x_k	2	3	3	4	6	18

Les quatre paramètres

Total $Y = 40$; moyenne $\overline{Y} = 40/5 = 8$; proportion des ménages dépensant plus de 8 : $P = 2/5 = 0{,}4$ (D et E) ; dépense par personne $R = 40/18 = 2{,}22$ milliers de dh.

Sur la population du cours

Les paramètres que l'enquêteur cherche

Paramètre	Valeur
Total des dépenses Y	15 822 870 dh
Dépense moyenne $\overline{Y}$	7 911,44 dh
Proportion de ménages connectés P	0,674
Total des personnes X	7 859
Dépense par personne $R = Y/X$	2 013,34 dh

Un ratio n'est pas une moyenne de ratios

R divise la dépense **totale** par le nombre **total** de personnes. La moyenne des dépenses par personne de chaque ménage donnerait autre chose, car elle compte autant un ménage d'une personne qu'un ménage de dix.

La dispersion

Deux variances de la population

Diviser par N ou par N − 1

$$\sigma^2 = \frac{1}{N}\sum_{k\in U}(y_k - \overline{Y})^2 \qquad S^2 = \frac{1}{N-1}\sum_{k\in U}(y_k - \overline{Y})^2 = \frac{N}{N-1}\,\sigma^2$$

La convention des sondages : S²

La statistique descriptive divise par N. La théorie des sondages préfère S^2, divisée par $N-1$, pour une seule raison : avec elle, la variance d'un sondage aléatoire simple s'écrit $(1-f)\,S^2/n$, une formule **exacte** et simple. Le chapitre 3 le démontrera.

Ce que change la convention

Sur la mini-population

Écarts à la moyenne : -4, -2, -1, 1, 6 ; somme des carrés : $16 + 4 + 1 + 1 + 36 = 58$.

$$\sigma^2 = 58/5 = 11{,}6 \qquad S^2 = 58/4 = 14{,}5$$

Sur la population du cours

$\sigma = 3\,983{,}29$ dh et $S = 3\,984{,}29$ dh : un dirham d'écart sur $N = 2\,000$ ménages. La convention ne compte que sur de petites populations.

La variance d'une proportion

Une formule fermée

Pour une variable 0/1, $y_k^2 = y_k$, d'où $\sigma^2 = P - P^2 = P(1-P)$ et

$$S^2 = \frac{N}{N-1}\,P\,(1-P)$$

Les ménages connectés

$P = 0{,}674$, donc $S^2 = \dfrac{2\,000}{1\,999} \times 0{,}674 \times 0{,}326 = 0{,}2198$. La dispersion d'une proportion se déduit de la proportion elle-même : c'est ce qui permettra de dimensionner une enquête **avant** de la faire (chapitre 5).

Le plan de sondage

Combien d'échantillons possibles ?

Un échantillon est une partie de U

Un échantillon sans répétition s est un sous-ensemble de U. Il y a $\binom{N}{n}$ échantillons de taille n.

De dix à un nombre astronomique

Population	Taille	Nombre d'échantillons
Mini-population, $N = 5$	$n = 2$	$\binom{5}{2} = 10$
Population du cours, $N = 2\,000$	$n = 100$	environ 10^{171}
Population du cours, $N = 2\,000$	$n = 200$	environ 10^{281}

On ne les énumère jamais

Les formules du cours remplacent l'énumération : elles donnent la moyenne et la variance d'un estimateur sur **tous** les échantillons possibles, sans en tirer un seul.

La définition

Plan de sondage

Un **plan de sondage** est une loi de probabilité $p(\cdot)$ sur l'ensemble des échantillons possibles :

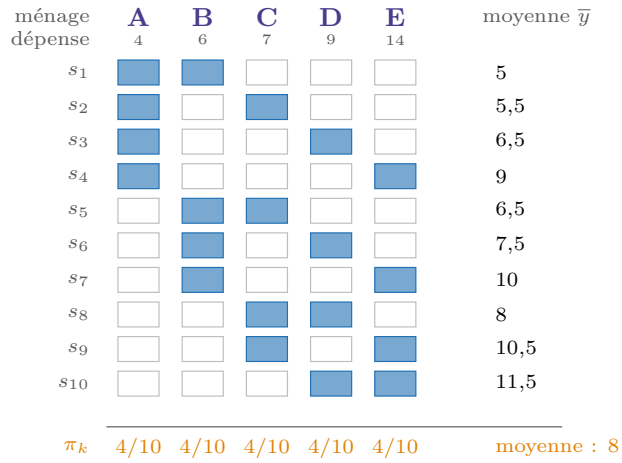
$$p(s) \geq 0 \text{ pour tout } s, \qquad \sum_s p(s) = 1$$

L'échantillon effectivement tiré, S, est une variable aléatoire de loi p.

Ce que le plan contient

Le plan dit **tout** : quels échantillons sont possibles, lesquels sont plus probables, quelle taille ils ont. Il est choisi par l'enquêteur, **avant** le tirage, et c'est lui qui rend l'erreur calculable.

Le plan aléatoire simple sur la mini-population



Dix échantillons de même probabilité

Chaque ligne est un échantillon de deux ménages, de probabilité $p(s) = 1/10$. La moyenne des dix moyennes vaut exactement $8 = \overline{Y}$.

Un autre plan sur la même population

Un ménage parmi A, B, C, un ménage parmi D, E

On sépare les petits budgets (A, B, C) des grands (D, E), et l'on tire un ménage dans chaque groupe. Il n'y a plus que $3 \times 2 = 6$ échantillons possibles, chacun de probabilité 1/6 :

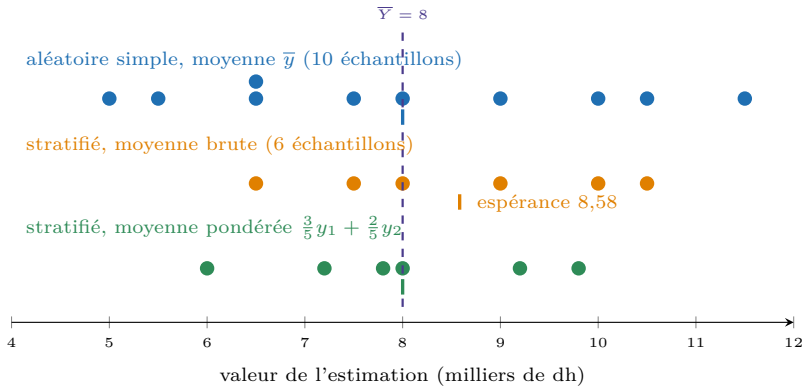
Échantillon	AD	AE	BD	BE	CD	CE
Moyenne brute	6,5	9	7,5	10	8	10,5
Moyenne pondérée	6	8	7,2	9,2	7,8	9,8

Brute : $\frac{1}{2}(y_1 + y_2)$. Pondérée : $\frac{3}{5}\,y_1 + \frac{2}{5}\,y_2$, où y_1 vient du premier groupe.

Le plan a changé, l'estimateur doit suivre

Moyenne des six moyennes brutes : $51{,}5/6 = 8{,}58 \neq 8$. Le premier groupe compte trois ménages sur cinq, mais n'en fournit qu'un sur deux : il faut lui redonner son **poids**, 3/5.

Ce que montre la comparaison



Un estimateur se juge avec son plan

La même moyenne $\overline{y}$ est juste en moyenne sous le plan aléatoire simple, faussée sous le second plan. Un estimateur n'est bon ou mauvais que **relativement au plan** qui a produit l'échantillon.

Avec ou sans remise, taille fixe ou aléatoire

Trois distinctions

- **Sans remise** : une unité figure au plus une fois. **Avec remise** : elle peut être tirée plusieurs fois (chapitre 4).
- **Taille fixe** : tous les échantillons possibles ont n unités. **Taille aléatoire** : n dépend du tirage.
- **Probabilités égales** ou **inégales** pour les unités (chapitre 11).

Un plan de taille aléatoire : le tirage de Bernoulli

On décide pour chaque ménage, **indépendamment**, de le garder avec probabilité 0,4. La taille n suit une loi binomiale $\mathcal{B}(5\,;0{,}4)$: en moyenne 2, mais $P(n = 0) = 0{,}6^5 = 0{,}078$. Une fois sur treize, l'enquête n'interroge personne.

Les probabilités d'inclusion

La chance qu'a chaque unité d'être tirée

Probabilité d'inclusion

$$\pi_k = P(k \in S) = \sum_{s \ni k} p(s)$$

On additionne les probabilités des échantillons qui **contiennent** k.

Sous les deux plans de la mini-population

- Aléatoire simple : chaque ménage figure dans 4 échantillons sur 10, donc $\pi_k = 0{,}4 = n/N$.
- Un ménage par groupe : $\pi_A = \pi_B = \pi_C = 1/3$ et $\pi_D = \pi_E = 1/2$.

Lire la matrice des échantillons

π_k est la part des lignes où la colonne k est cochée, chaque ligne étant pondérée par sa probabilité.

Une propriété utile : la somme des probabilités

La somme des probabilités d'inclusion

$$\sum_{k\in U} \pi_k = E(n) \qquad \text{et donc} \qquad \sum_{k\in U} \pi_k = n \text{ pour un plan de taille fixe}$$

La démonstration en une ligne

$\sum_k \pi_k = \sum_k \sum_{s\ni k} p(s) = \sum_s p(s) \times (\text{nombre d'unités de } s) = \sum_s p(s)\, n(s) = E(n)$: on intervertit les deux sommes.

Vérification

Aléatoire simple : $5 \times 0{,}4 = 2$. Un ménage par groupe : $3 \times \frac{1}{3} + 2 \times \frac{1}{2} = 2$. Bernoulli : $5 \times 0{,}4 = 2 = E(n)$.

Les probabilités d'inclusion doubles

Être tirés ensemble

$$\pi_{kl} = P(k \in S \text{ et } l \in S) = \sum_{s\ni k,\, l} p(s), \qquad k \neq l$$

Pour un plan aléatoire simple : $\pi_{kl} = \dfrac{n(n-1)}{N(N-1)}$.

Sur la mini-population

- Aléatoire simple : chaque paire forme exactement un échantillon, $\pi_{kl} = 1/10 = \dfrac{2\times 1}{5\times 4}$.
- Un ménage par groupe : $\pi_{AD} = 1/6$, mais $\pi_{AB} = 0$ et $\pi_{DE} = 0$: deux ménages d'un même groupe ne sont **jamais** tirés ensemble.

La variance d'un estimateur dépend des π_{kl} (chapitre 2). Quand certaines sont nulles, elle ne peut plus être estimée à partir de l'échantillon seul : ce sera le cas du tirage systématique (chapitre 8).

L'outil central : les indicatrices d'appartenance

Une variable aléatoire par unité

$I_k = 1$ si l'unité k est tirée, 0 sinon. C'est une variable de Bernoulli :

$$E(I_k) = \pi_k \qquad V(I_k) = \pi_k(1-\pi_k) \qquad \mathrm{Cov}(I_k, I_l) = \pi_{kl} - \pi_k\,\pi_l$$

Le hasard est dans les I, pas dans les y

Tout estimateur s'écrit avec les I_k : par exemple $\sum_{k\in S} y_k \quad = \quad \sum_{k\in U} I_k\, y_k$. Les y_k sont des nombres fixes, les I_k portent tout l'aléa. Les calculs d'espérance et de variance du cours se ramènent à ceux des I_k.

Un signe à comprendre

Aléatoire simple sur la mini-population

$V(I_k) = 0{,}4 \times 0{,}6 = 0{,}24$ et

$$\mathrm{Cov}(I_k, I_l) = 0{,}1 - 0{,}4 \times 0{,}4 = -0{,}06$$

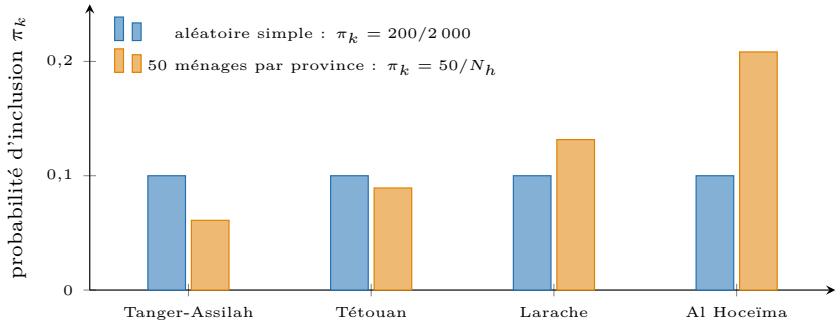
Une covariance négative

L'échantillon n'a que deux places : si A est tiré, il en reste une seule pour les quatre autres. Être tiré **diminue** la chance des autres de l'être. En général, pour un plan aléatoire simple :

$$\mathrm{Cov}(I_k, I_l) = \frac{n(n-1)}{N(N-1)} - \frac{n^2}{N^2} = -\frac{n\,(N-n)}{N^2\,(N-1)} < 0$$

Sur la population du cours

Deux plans de 200 ménages



Même taille, autres probabilités

- **Aléatoire simple** de 200 ménages : $\pi_k = 200/2\,000 = 0{,}1$ pour tous.
- **50 ménages par province** : $\pi_k \;=\; 50/N_h$, de 0,061 à Tanger-Assilah ($N_h \;=\; 820$) à 0,208 à Al Hoceïma ($N_h = 240$).

Le poids de sondage

Combien de ménages représente un ménage tiré

Le **poids** de l'unité k est $d_k = 1/\pi_k$. Un ménage tiré avec la probabilité 0,1 « représente » 10 ménages de la population, lui compris.

Les poids du plan à 50 ménages par province

Province	Tanger-Assilah	Tétouan	Larache	Al Hoceïma
N_h	820	560	380	240
Poids $d_k = N_h/50$	16,4	11,2	7,6	4,8

La somme des poids des 200 ménages tirés vaut $50 \times (16{,}4 + 11{,}2 + 7{,}6 + 4{,}8) = 2\,000 = N$.

Ce que coûte un oubli des poids

Une erreur de 411 dirhams

Avec 50 ménages par province, la moyenne **non pondérée** des 200 ménages vaut en espérance la moyenne des quatre moyennes provinciales :

$$\tfrac{1}{4}\,(8\,621 + 8\,146 + 7\,255 + 5\,979) = 7\,500{,}29 \text{ dh, contre } \overline{Y} = 7\,911{,}44$$

Al Hoceïma, la province la moins dépensière, pèse un quart dans l'échantillon mais 12 % dans la population.

La règle

Dès que les π_k ne sont pas tous égaux, il faut **pondérer**. Le chapitre 2 donne l'estimateur qui le fait automatiquement : chaque unité tirée y compte pour $d_k = 1/\pi_k$.

S'entraîner

Exercice 1 : énumérer un plan

Quatre boutiques

Quatre boutiques ont un chiffre d'affaires mensuel de 2, 5, 8 et 9 milliers de dh. On en tire deux par sondage aléatoire simple.

1. Calculer $\overline{Y}$ et S^2.
2. Énumérer les échantillons possibles, leur probabilité et la moyenne de chacun.
3. Calculer la moyenne des moyennes. Conclure.
4. Calculer π_k et π_{kl} ; vérifier que $\sum_k \pi_k = n$.

Exercice 1 : solution

Paramètres et échantillons

1. $\overline{Y} = 24/4 = 6$; écarts -4, -1, 2, 3 ; $S^2 = (16+1+4+9)/3 = 10$.
2. $\binom{4}{2} = 6$ échantillons, chacun de probabilité 1/6 : $\{2,5\}$: 3,5 ; $\{2,8\}$: 5 ; $\{2,9\}$: 5,5 ; $\{5,8\}$: 6,5 ; $\{5,9\}$: 7 ; $\{8,9\}$: 8,5.

Espérance et probabilités d'inclusion

3. $(3{,}5+5+5{,}5+6{,}5+7+8{,}5)/6 = 36/6 = 6 = \overline{Y}$: en moyenne sur les tirages, la moyenne d'échantillon retrouve la vraie moyenne.
4. Chaque boutique figure dans 3 échantillons sur 6 : $\pi_k = 0{,}5 = n/N$, et $\sum_k \pi_k = 4 \times 0{,}5 = 2 = n$. Chaque paire forme un seul échantillon : $\pi_{kl} = 1/6 = \dfrac{2 \times 1}{4 \times 3}$.

Exercice 2 : un plan de taille aléatoire

Le tirage de Bernoulli

Dans une population de $N = 6$ ménages, chaque ménage est retenu indépendamment avec la probabilité $\pi = 0{,}5$.

1. Quelle est la loi de la taille n de l'échantillon ? Son espérance ?
2. Calculer $P(n=0)$ et $P(n=3)$.
3. Quelle est la probabilité d'inclusion de chaque ménage ? Vérifier la relation $\sum_k \pi_k = E(n)$.
4. Pourquoi les instituts préfèrent-ils les plans de taille fixe ?

Exercice 2 : solution

Une binomiale

1. n compte les succès de 6 épreuves indépendantes : $n \sim \mathcal{B}(6\,;0{,}5)$, d'espérance 3.
2. $P(n=0) = 0{,}5^6 = 1/64 = 0{,}016$; $P(n=3) = \binom{6}{3}\,0{,}5^6 = 20/64 = 0{,}3125$.
3. $\pi_k = 0{,}5$ pour chacun ; $\sum_k \pi_k = 6 \times 0{,}5 = 3 = E(n)$.

Le budget

4. Le coût d'une enquête est proportionnel au nombre de questionnaires : avec une taille aléatoire, ni le budget ni la précision ne sont connus à l'avance. Ici, deux fois sur trois, la taille n'est pas celle prévue : $P(n=3) = 0{,}31$ seulement.

Exercice 3 : urbain et rural

Cent ménages dans chaque milieu

La population du cours compte 1 438 ménages urbains (dépense moyenne 8 430 dh) et 562 ruraux (6 585 dh). On tire 100 ménages au hasard dans chaque milieu.

1. Calculer les probabilités d'inclusion et les poids de chaque milieu.
2. Vérifier que $\sum_k \pi_k = 200$ et que la somme des poids des ménages tirés vaut N.
3. Que vaut, en espérance, la moyenne non pondérée des 200 ménages ? Quelle erreur

commet-elle ?

Exercice 3 : solution

Probabilités et poids

1. Urbain : $\pi_k = 100/1\,438 = 0{,}0695$, poids 14,38. Rural : $\pi_k = 100/562 = 0{,}178$, poids 5,62.
2. $1\,438 \times \frac{100}{1\,438} + 562 \times \frac{100}{562} = 200$; $100 \times 14{,}38 + 100 \times 5{,}62 = 2\,000$.

Le biais de la moyenne brute

3. Elle vaut en espérance $\frac{1}{2}(8\,430 + 6\,585) = 7\,507$ dh, contre 7 911 : elle sous-estime de 404 dh. Les ruraux, 28 % de la population, font la moitié de l'échantillon. La moyenne pondérée $\frac{1\,438}{2\,000}\,\overline{y}_{\text{urb}} + \frac{562}{2\,000}\,\overline{y}_{\text{rur}}$ corrige ce déséquilibre.

Ce qu'il faut retenir

Le résumé du chapitre

Sept points

1. On cherche des **paramètres** de la population : total, moyenne, proportion, ratio.
2. Une proportion est la moyenne d'une variable 0/1, de variance $S^2 = \frac{N}{N-1}P(1-P)$.
3. Les sondages emploient S^2, divisée par $N-1$.
4. Un **plan de sondage** est une loi de probabilité sur les échantillons possibles.
5. $\pi_k = P(k \in S)$, et $\sum_k \pi_k = n$ pour un plan de taille fixe.
6. Les indicatrices I_k portent tout l'aléa : $E(I_k) = \pi_k$, $\text{Cov}(I_k, I_l) = \pi_{kl} - \pi_k\pi_l$.
7. Quand les π_k diffèrent, chaque unité tirée doit compter pour son **poids** $d_k = 1/\pi_k$.

La suite

Le chapitre 2 construit, pour n'importe quel plan, un estimateur sans biais du total, et calcule sa précision.