Échantillonnage

Chapitre 11 : Les probabilités inégales

Jaouad Madkour

21 octobre 2026

Plan du chapitre

Tirer selon la taille **2**
Des districts de tailles inégales . . . 2
La dépense d'un district suit sa taille . . . 2
Une probabilité proportionnelle à la taille . . . 3

Avec remise : Hansen-Hurwitz **3**
La méthode des tailles cumulées . . . 3
L'estimateur de Hansen-Hurwitz . . . 3
Sa variance et son estimation . . . 4
Sur la mini-population . . . 4

Cinq districts tirés selon leur taille **5**
La moyenne des moyennes de district . . . 5
Un tirage de cinq districts . . . 5
Estimer la précision . . . 6
Le gain . . . 6
Vingt mille enquêtes . . . 7

Sans remise : Horvitz-Thompson **7**
Éviter les répétitions . . . 7
Le tirage systématique proportionnel à la taille . . . 7
Cinq districts sur l'axe des ménages . . . 8
Sur la mini-population . . . 8
La variance de Sen-Yates-Grundy . . . 9

Deux degrés autopondéré **9**
Districts selon leur taille, ménages en nombre fixe . . . 9
Pourquoi les instituts l'aiment . . . 9
La variance et son estimation . . . 10
Vingt districts de dix ménages sur la population . . . 10

Le risque d'une mauvaise mesure de taille **11**
Une mesure de taille, plusieurs variables . . . 11
Quand la taille va à rebours . . . 11

Une taille périmée 11

S'entraîner **12**
Exercice 1 : quatre villages 12
Exercice 1 : solution 12
Exercice 2 : huit douars 12
Exercice 2 : solution 13
Exercice 3 : vingt-cinq districts de huit ménages 13
Exercice 3 : solution 13

Ce qu'il faut retenir **14**
Le résumé du chapitre 14

Tirer selon la taille

Des districts de tailles inégales

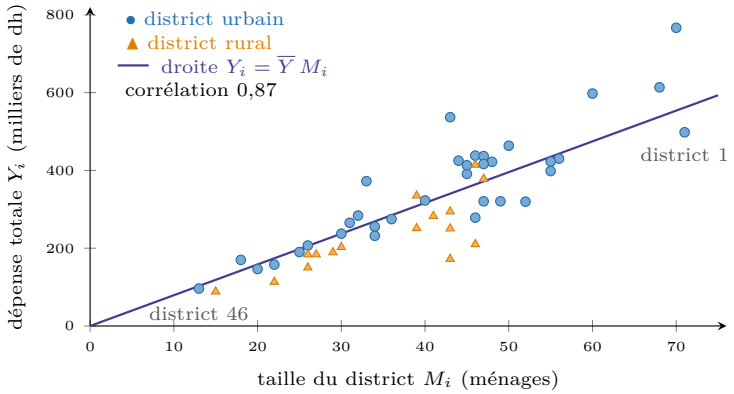
Cinq districts tirés à probabilités égales (chapitre 9)

Estimateur de la dépense moyenne	Écart-type	*deff*
Aléatoire simple de 200 ménages	267,3	1
5 districts, Horvitz-Thompson	1 516,6	32,2
5 districts, ratio	773,8	8,4

Ce qui fait varier le total d'un district

Les districts comptent de 13 à 71 ménages. Le total Y_i d'un district dépend d'abord de sa **taille** M_i, ensuite seulement de la dépense de ses ménages. Tirés à probabilités égales, cinq districts héritent de toute la variation des tailles : c'est elle qui gonfle la variance de Horvitz-Thompson.

La dépense d'un district suit sa taille



Une corrélation de 0,87

Les points s'alignent autour de la droite $Y_i = \overline{Y}\, M_i$: la moyenne $\overline{Y}_i = Y_i/M_i$ varie beaucoup moins que le total Y_i. Coefficient de variation des totaux : 0,45 ; des moyennes : 0,21.

Une probabilité proportionnelle à la taille

Le tirage proportionnel à la taille

On connaît pour chaque unité i, avant l'enquête, une **mesure de taille** $x_i > 0$, de total X. On tire l'unité i avec la probabilité

$$p_i = \frac{x_i}{X}, \qquad \sum_i p_i = 1$$

On parle de tirage **PPT** (probabilité proportionnelle à la taille). Pour les districts : $x_i = M_i$, $X = N = 2\,000$ et $p_i = M_i/2\,000$.

Le plus grand et le plus petit district

District 1 : $p_1 = 71/2\,000 = 0{,}0355$. District 46 : $p_{46} = 13/2\,000 = 0{,}0065$. Le premier a $71/13 = 5{,}46$ fois plus de chances d'être tiré que le second.

Avec remise : Hansen-Hurwitz

La méthode des tailles cumulées

Tirer selon la taille avec un seul nombre

1. Calculer les tailles cumulées $C_i = x_1 + \cdots + x_i$, avec $C_0 = 0$.
2. Tirer un entier a au hasard entre 1 et X.
3. Retenir l'unité i telle que $C_{i-1} < a \leq C_i$.

L'unité i occupe x_i entiers sur X : elle sort avec la probabilité x_i/X. On répète n fois, **indépendamment** : c'est un tirage avec remise.

La mini-population, avec la taille pour mesure

Tailles 2, 3, 3, 4, 6 ; cumuls 2, 5, 8, 12, 18. On tire a entre 1 et 18 : A si $a \leq 2$, B de 3 à 5, C de 6 à 8, D de 9 à 12, E de 13 à 18. Ainsi $p_A = 2/18 = 1/9$ et $p_E = 6/18 = 1/3$.

Tirer un ménage, garder son district

Pour les districts, $X = N$: tirer a, c'est tirer **un ménage** au hasard et retenir son district.

L'estimateur de Hansen-Hurwitz

Une estimation par tirage, puis leur moyenne

Au tirage j sort une unité de valeur $y_{(j)}$ et de probabilité $p_{(j)}$. Ce tirage fournit à lui seul

l'estimation $z_j = y_{(j)}/p_{(j)}$ du total, et

$$\widehat{Y}_{HH} = \frac{1}{n}\sum_{j=1}^{n} z_j = \frac{1}{n}\sum_{j=1}^{n} \frac{y_{(j)}}{p_{(j)}}$$

Sans biais, en une ligne

z_j vaut y_i/p_i avec la probabilité p_i, donc

$$E(z_j) = \sum_i p_i \frac{y_i}{p_i} = \sum_i y_i = Y$$

La moyenne de n estimations sans biais est sans biais. Avec $p_i = 1/N$, on retrouve $N\,\overline{y}_{AR}$, l'estimateur avec remise du chapitre 4.

Sa variance et son estimation

Des tirages indépendants et de même loi

$$V(\widehat{Y}_{HH}) = \frac{1}{n}\sum_i p_i \left(\frac{y_i}{p_i} - Y\right)^2 \qquad \widehat{V}(\widehat{Y}_{HH}) = \frac{s_z^2}{n} = \frac{1}{n\,(n-1)}\sum_{j=1}^{n}\left(z_j - \widehat{Y}_{HH}\right)^2$$

La démonstration

Les z_j sont indépendants, d'espérance Y et de variance $V(z) = \sum_i p_i\,(y_i/p_i - Y)^2$: leur moyenne a la variance $V(z)/n$. La variance s_z^2 des n valeurs z_j est sans biais pour $V(z)$ (Statistique inférentielle, chapitre 3), quels que soient les p_i.

Une variance nulle

Si y_i/p_i est le même pour toutes les unités, chaque tirage donne exactement Y : il faudrait des p_i **proportionnels aux** y_i. Comme les y_i sont inconnus, on prend une taille x_i qui leur est à peu près proportionnelle.

Sur la mini-population

Deux tirages proportionnels à la taille

Ménage	A	B	C	D	E
y_i (milliers de dh)	4	6	7	9	14
$p_i = x_i/18$	1/9	1/6	1/6	2/9	1/3
$z_i = y_i/p_i$	36	36	42	40,5	42

$V(z) = \frac{1}{18}(2\times 4^2 + 3\times 4^2 + 3\times 2^2 + 4\times 0{,}5^2 + 6\times 2^2) = \frac{117}{18} = 6{,}5$, d'où $V(\widehat{Y}_{HH}) = 6{,}5/2 = 3{,}25$.

Trente-trois fois moins que le sondage aléatoire simple

À probabilités égales, $V(\widehat{Y}) = 25 \times 4{,}35 = 108{,}75$ sans remise (chapitre 2), $25 \times 5{,}8 = 145$ avec remise (chapitre 4). Ici 3,25 : la dépense par personne y_i/x_i ne va que de 2 à 2,33, et chaque z_i reste proche de $Y = 40$.

Cinq districts tirés selon leur taille

La moyenne des moyennes de district

Hansen-Hurwitz pour des grappes

Avec $p_i = M_i/N$ et $y_i = Y_i$, chaque tirage donne $z_j = Y_i/p_i = N\,\overline{Y}_i$. La dépense moyenne s'estime par la **moyenne simple** des moyennes des districts tirés :

$$\frac{\widehat{Y}_{HH}}{N} = \frac{1}{n_I}\sum_{j=1}^{n_I} \overline{Y}_{(j)} \qquad V\Big(\frac{\widehat{Y}_{HH}}{N}\Big) = \frac{1}{n_I}\sum_{i=1}^{N_I} \frac{M_i}{N}(\overline{Y}_i - \overline{Y})^2$$

Les tailles ont disparu

La variance ne dépend plus que des écarts entre **moyennes** de district : $\sum_i \frac{M_i}{N}(\overline{Y}_i - \overline{Y})^2 = 2\,844\,644$, soit 18 % seulement de S^2. Pour $n_I = 5$: $2\,844\,644/5 = 568\,929$, et l'écart-type vaut 754,3 dh.

Un tirage de cinq districts

Cinq nombres entre 1 et 2 000, graine 2026

Nombre a	District	Province, milieu	M_i	$\overline{Y}_i$
1 704	42	Larache, rural	43	6 845,35
358	7	Tanger-Assilah, urbain	70	10 953,29
53	1	Tanger-Assilah, urbain	71	7 014,65
1 280	30	Tétouan, rural	26	7 074,23
731	16	Tanger-Assilah, rural	47	8 046,17

L'estimation

$\frac{1}{5}(6\,845{,}35 + 10\,953{,}29 + 7\,014{,}65 + 7\,074{,}23 + 8\,046{,}17) = 7\,986{,}74$ dh, pour $\overline{Y} = 7\,911{,}44$. On a enquêté 257 ménages. Les deux plus grands districts, 1 et 7, sont tirés tous les deux : le plan les favorise.

Estimer la précision

Cinq moyennes, une variance

Écarts des $\overline{Y}_i$ à leur moyenne : $-1\,141{,}4$; $2\,966{,}5$; $-972{,}1$; $-912{,}5$; $59{,}4$. Somme des carrés $11\,884\,335$, d'où $s^2 = 11\,884\,335/4 = 2\,971\,084$ et

$$\widehat{V} = \frac{2\,971\,084}{5} = 594\,217 \qquad \text{erreur-type estimée } 770{,}9 \text{ dh}$$

Intervalle à 95 %, Student à 4 degrés de liberté : $7\,986{,}7 \pm 2{,}776 \times 770{,}9 = [5\,846{,}8\,;\,10\,126{,}6]$.

Cinq observations, pas 257

La variance se calcule sur les **cinq** moyennes de district : c'est le tirage des districts qui porte l'aléa, et les ménages d'un même district se ressemblent. L'erreur-type estimée, 770,9, est proche de la vraie, 754,3 ; l'erreur commise, +75 dh, est bien couverte.

Le gain

Cinq districts, trois façons de faire

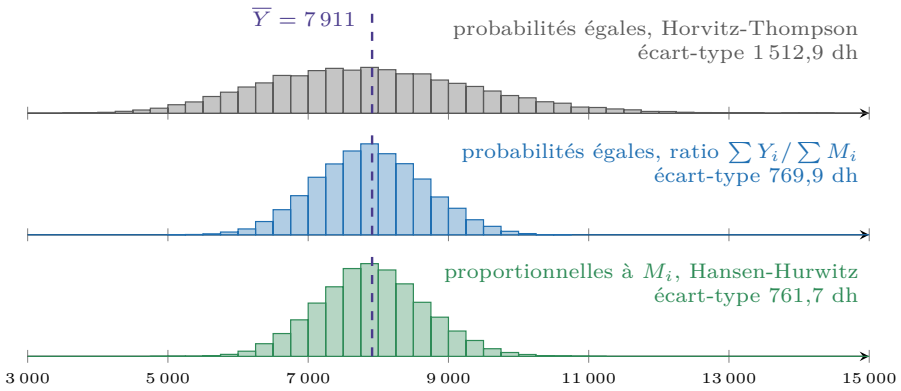
Cinq districts, estimateur	Ménages	Écart-type	*deff*
(aléatoire simple de 200 ménages)	200	267,3	1
Égales, Horvitz-Thompson	200	1 516,6	32,2
Égales, ratio	200	773,8	8,4
PPT, Hansen-Hurwitz	222,6	754,3	8,0

Ménages : nombre moyen de ménages enquêtés. Effet de plan rapporté à l'aléatoire simple de 200 ménages.

Aussi bon que le ratio, sans ses défauts

Le tirage PPT fait aussi bien que le ratio, mais son estimateur est **exactement sans biais**, et sa variance s'estime par une formule exacte. Le prix : les grands districts, plus souvent tirés, font enquêter en moyenne $\sum_i M_i^2/N \;=\; 44{,}5$ ménages par tirage, soit 222,6 au lieu de 200.

Vingt mille enquêtes



Trois estimateurs, cinq districts, graine 11

Horvitz-Thompson à probabilités égales se trompe de plus de 2 000 dh dans 18,6 % des enquêtes, le ratio dans 0,7 %, Hansen-Hurwitz dans 0,8 %. Écarts-types simulés : 1 512,9, 769,9 et 761,7 dh.

Sans remise : Horvitz-Thompson

Éviter les répétitions

Un district tiré deux fois

Avec remise, cinq tirages donnent cinq districts **distincts** avec la probabilité 0,795 seulement : une enquête sur cinq tire deux fois le même district, et n'apprend rien de plus la seconde fois.

Des probabilités d'inclusion proportionnelles à la taille

Sans remise, on vise $\pi_i = n\,x_i/X$, ce qui exige $n\,x_i \leq X$, et l'on emploie l'estimateur de Horvitz-Thompson (chapitre 2), $\widehat{Y}_{HT} = \sum_{i \in S} y_i/\pi_i$. Pour 5 districts, $\pi_i = 5\,M_i/2\,000 = M_i/400$, de 0,0325 à 0,1775 : $\widehat{Y}_{HT}/N$ est encore la moyenne simple des $\overline{Y}_i$ tirés.

Les unités trop grandes

Si $n\,x_i > X$, l'unité est prise d'office ($\pi_i = 1$) et l'on tire les autres parmi le reste. Avec 40 districts, $\pi_i = M_i/50$ dépasserait 1 pour les 8 districts de plus de 50 ménages.

Le tirage systématique proportionnel à la taille

Tailles cumulées et pas constant

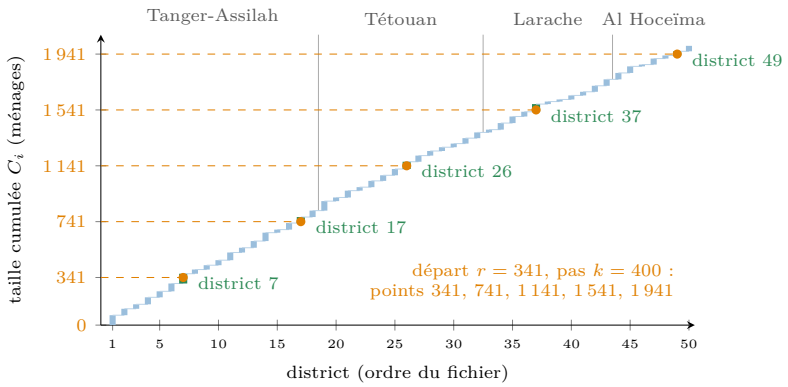
1. Ranger les unités dans un ordre choisi ; calculer les tailles cumulées C_i.
2. Fixer le pas $k = X/n$; tirer un départ r au hasard entre 1 et k.
3. Retenir les unités dont l'intervalle $]C_{i-1}\,;C_i]$ contient l'un des points r, $r+k$, ..., $r+(n-$

$1)\,k$.
Si $x_i \leq k$, l'intervalle de l'unité i reçoit un point pour exactement x_i des k départs : $\pi_i = x_i/k = n\,x_i/X$.

Cinq districts dans l'ordre du fichier

$k = 2\,000/5 = 400$; départ tiré (graine 2026) : $r = 341$. Les points 341, 741, 1 141, 1 541 et 1 941 tombent dans les districts 7, 17, 26, 37 et 49.

Cinq districts sur l'axe des ménages



L'estimation et sa précision

$\frac{1}{5}\,(10\,953{,}29 + 5\,828{,}14 + 6\,146{,}35 + 7\,688{,}91 + 6\,758{,}33) = 7\,475{,}0$ dh, soit 436 dh de moins que $\overline{Y}$. Sur les 400 départs possibles, l'écart-type exact vaut 668,3 dh, contre 754,3 avec remise : chaque province reçoit sa part de points, une **stratification implicite** (chapitre 8).

Sur la mini-population

Deux ménages, pas de 9, ordre A à E

$\pi_i = 2\,x_i/18$: $\frac{2}{9}$, $\frac{1}{3}$, $\frac{1}{3}$, $\frac{4}{9}$, $\frac{2}{3}$; y_i/π_i : 18, 18, 21, 20,25, 21. Les 9 départs donnent cinq échantillons :

Échantillon	AD	BD	BE	CE	DE
Probabilité	2/9	1/9	2/9	3/9	1/9
$\widehat{Y}_{HT}$	38,25	38,25	39	42	41,25

Sans remise, un peu mieux

$E(\widehat{Y}_{HT}) = 360/9 = 40 = Y$ et $V(\widehat{Y}_{HT}) = 2{,}75$, contre 3,25 avec remise : aucun tirage n'est perdu à reprendre un ménage déjà tiré. Mais AB, AC, AE, BC et CD ne sont **jamais** tirés ensemble : $\pi_{kl} = 0$ pour cinq paires sur dix.

La variance de Sen-Yates-Grundy

La forme du chapitre 2, pour un plan de taille fixe

$$V(\widehat{Y}_{HT}) = \frac{1}{2}\sum_{k}\sum_{l\neq k}(\pi_k\,\pi_l - \pi_{kl})\left(\frac{y_k}{\pi_k} - \frac{y_l}{\pi_l}\right)^2$$

Mini-population : les dix paires, multipliées par 81, donnent 54 (AC), −50,625 (AD), 108 (AE), 81 (BC), 15,1875 (BD), 6,75 (CD), 8,4375 (DE), 0 pour les autres. Total : 222,75/81 = 2,75, la variance de l'énumération.

Pas d'estimation sans biais

$\widehat{V}_{SYG}$ divise chaque paire par π_{kl} : il exige $\pi_{kl} > 0$. Or 1 028 paires de districts sur 1 225 (84 %) ne sont jamais tirées ensemble. On calcule alors la variance **comme avec remise**, s^2/n_I sur les $\overline{Y}_i$ tirés : erreur-type 925,6 dh ici, $\sqrt{599\,512} = 774{,}3$ dh en moyenne sur les 400 départs, pour un écart-type vrai de 668,3. C'est **prudent**.

Deux degrés autopondéré

Districts selon leur taille, ménages en nombre fixe

Le plan

1. Tirer n_I districts proportionnellement à leur taille : $\pi_i = n_I\,M_i/N$.
2. Dans chaque district tiré, tirer m ménages par sondage aléatoire simple, **le même nombre partout**.

Un ménage du district i est tiré avec la probabilité

$$\pi_k = \frac{n_I\,M_i}{N} \times \frac{m}{M_i} = \frac{n_I\,m}{N}$$

la même pour tous : le plan est **autopondéré**.

Vingt districts de dix ménages

$\pi_i = 20\,M_i/2\,000 = M_i/100$, de 0,13 à 0,71 ; $\pi_k = 200/2\,000 = 0{,}1$ et $d_k = 10$ pour chacun des 200 ménages. L'estimateur est la simple moyenne $\overline{y}$ des 200 ménages.

Pourquoi les instituts l'aiment

Trois avantages pratiques

1. **Une charge fixe par district** : chaque équipe réalise m entretiens, quel que soit le district.
2. **Une taille d'échantillon fixée** à $n_I\,m$ ménages, donc un budget connu.
3. **Des poids égaux** : moyennes et proportions se calculent sans pondération.

Ce que le chapitre 10 ne réunissait pas

À probabilités égales, m ménages par district donnent des poids $d_k = N_I\, M_i/(n_I\, m)$ qui varient de 3,25 à 17,75 ; des m_i proportionnels à M_i rendent le plan autopondéré, mais la charge devient inégale. Le tirage selon la taille réunit les deux avantages.

La variance et son estimation

Districts tirés avec remise

Chaque tirage donne la moyenne $\overline{y}_{(j)}$ de m ménages d'un district ; l'estimateur est $\overline{y} = \frac{1}{n_I}\sum_j \overline{y}_{(j)}$, de variance

$$V(\overline{y}) = \frac{1}{n_I}\Big[\underbrace{\sum_i \frac{M_i}{N}(\overline{Y}_i - \overline{Y})^2}_{\text{entre districts}} + \underbrace{\sum_i \frac{M_i}{N}\Big(1 - \frac{m}{M_i}\Big)\frac{S_i^2}{m}}_{\text{dans les districts}}\Big]$$

où S_i^2 est la variance des dépenses dans le district i.

Une estimation qui voit les deux degrés

Les n_I moyennes $\overline{y}_{(j)}$ sont indépendantes et de même loi, d'espérance $\sum_i \frac{M_i}{N}\overline{Y}_i = \overline{Y}$. Donc $\widehat{V}(\overline{y}) = s_b^2/n_I$, où s_b^2 est la variance de ces n_I moyennes : les deux degrés y sont, sans calculer un seul S_i^2.

Vingt districts de dix ménages sur la population

Deux plans de 200 ménages

Districts tirés	Entre	Dans	Écart-type	*deff*
Probabilités égales	383 368	59 169	665,2	6,20
Selon leur taille	142 232	50 528	439,0	2,70

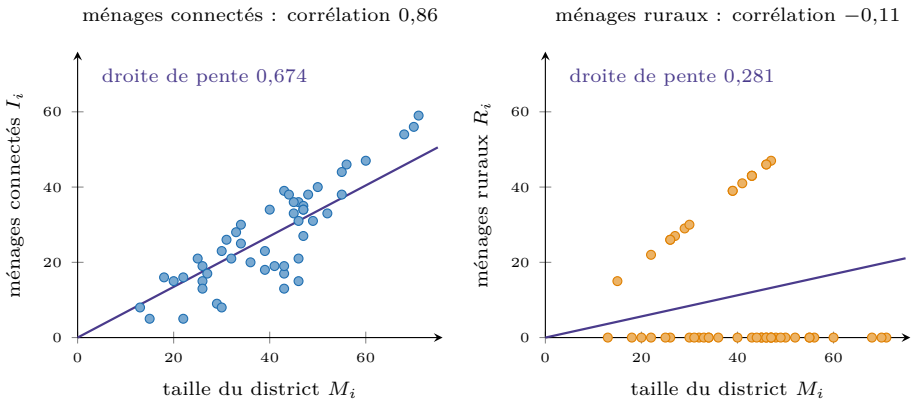
Variance de $\overline{y}$ **entre** districts et **dans** les districts. PPT : $2\,844\,644/20 = 142\,232$ et $10\,105\,597/200 = 50\,528$, où $10\,105\,597 = \sum_i \frac{M_i}{N}(1 - \frac{10}{M_i})S_i^2$.

Le premier degré reste le plus lourd

Le tirage selon la taille divise par 2,7 la variance entre districts et ramène l'effet de plan de 6,20 à 2,70. Le premier degré fait encore 74 % de la variance. Pour le plan 10×20 du chapitre 10 ($deff = 14{,}9$), l'effet de plan tomberait à 4,5 environ.

Le risque d'une mauvaise mesure de taille

Une mesure de taille, plusieurs variables



Le total estimé avec cinq districts

Ménages connectés : coefficient de variation de 11,6 % en PPT, contre 20,8 % à probabilités égales. Ménages ruraux : 71,5 % en PPT, contre 65,9 % : le tirage selon la taille fait **moins bien**.

Quand la taille va à rebours

La mini-population, tailles inversées

Avec les tailles 6, 4, 3, 3, 2 pour A à E : $z_i = y_i/p_i = 12, 27, 42, 54, 126$, et $V(z) = 20\,772/18 = 1\,154$. Avec les vraies tailles, $V(z) = 6{,}5$; à probabilités égales, 290, soit quatre fois mieux.

Une petite probabilité sur une grande valeur

$V(z) = \sum_i p_i\,(y_i/p_i - Y)^2$ explose quand une unité a une **grande valeur** y_i et une **petite probabilité** p_i : E, qui dépense le plus, n'a plus que $p_E = 2/18$ et compte, s'il est tiré, pour 126 au lieu de 40. Les ruraux sont un cas voisin : R_i/p_i vaut N pour un district rural, 0 pour un district urbain.

Une taille périmée

Un district qui a quadruplé

Un district compté 13 ménages au recensement en abrite aujourd'hui 52, après la construction d'un lotissement. Tiré avec $p_i = 13/2\,000$, il fournit à lui seul $z_j/2\,000 = 52\,\overline{Y}_i/13 = 4\,\overline{Y}_i$. L'estimateur reste sans biais, car p_i est la vraie probabilité de tirage, mais sa variance s'envole ; en deux degrés, ses m ménages devraient peser **quatre fois** plus que les autres : le plan n'est plus autopondéré.

Bien choisir la mesure de taille

1. **Liée à la variable principale** : y_i/x_i doit varier peu d'une unité à l'autre.
2. **À jour** : recensement récent, liste actualisée, ou dénombrement des districts tirés avant l'enquête.
3. **Adaptée à toutes les variables** : une taille en ménages convient aux totaux qui croissent avec la taille ; pour un groupe concentré dans certains districts, comme les ruraux, mieux vaut **stratifier** (chapitre 6).

S'entraîner

Exercice 1 : quatre villages

Hansen-Hurwitz sur quatre villages

Quatre villages comptent 10, 20, 30 et 40 ménages ; leurs dépenses totales sont 60, 140, 180 et 320 milliers de dh. On tire deux villages avec remise, proportionnellement au nombre de ménages.

1. Calculer les p_i, les $z_i = Y_i/p_i$, et vérifier que $E(z) = Y$.
2. Calculer $V(\widehat{Y}_{HH})$. Comparer à deux tirages avec remise à probabilités égales.
3. On tire les villages 2 et 4. Calculer $\widehat{Y}_{HH}$, son erreur-type estimée, et la dépense moyenne par ménage estimée.

Exercice 1 : solution

Probabilités et variance

1. $p_i = 0{,}1$; $0{,}2$; $0{,}3$; $0{,}4$ et $z_i = 600$, 700, 600, 800. $E(z) = 60 + 140 + 180 + 320 = 700 = Y$.
2. $V(z) = 0{,}1 \times 100^2 + 0 + 0{,}3 \times 100^2 + 0{,}4 \times 100^2 = 8\,000$, d'où $V(\widehat{Y}_{HH}) = 4\,000$. À probabilités égales, $z_i = 4\,Y_i = 240$, 560, 720, $1\,280$: $V(z) = 142\,000$ et $V = 71\,000$, soit 17,75 fois plus.

Une estimation

3. $\widehat{Y}_{HH} = (700 + 800)/2 = 750$ milliers de dh ; $\widehat{V} = \frac{1}{2\times 1}(50^2 + 50^2) = 2\,500$, erreur-type 50. Par ménage : $750/100 = 7{,}5$ milliers de dh, pour une vraie valeur de 7.

Exercice 2 : huit douars

Un tirage systématique proportionnel à la taille

Huit douars comptent, dans l'ordre de la liste, 12, 30, 18, 25, 40, 15, 35 et 25 ménages. On en tire 4 par tirage systématique proportionnel à la taille, et l'on enquête tous leurs ménages.

1. Calculer les tailles cumulées, le pas k et les π_i. Tous les π_i sont-ils inférieurs à 1 ?
2. Avec le départ $r = 37$, quels douars sont tirés ?
3. Leurs dépenses moyennes sont 6,2 ; 7,5 ; 5,8 et 6,9 milliers de dh. Estimer la dépense moyenne et le total.
4. Peut-on estimer la variance sans biais ? Que faire ?

Exercice 2 : solution

Le tirage

1. Cumuls : 12, 42, 60, 85, 125, 140, 175, 200 ; $k = 200/4 = 50$; $\pi_i = 4\,M_i/200 = M_i/50$, de 0,24 à 0,8 : tous les douars ont $M_i \leq 50$.
2. Points 37, 87, 137, 187 : douars 2 (]12 ; 42]), 5 (]85 ; 125]), 6 (]125 ; 140]) et 8 (]175 ; 200]).

L'estimation

3. $Y_i/\pi_i = M_i\overline{Y}_i/(M_i/50) = 50\,\overline{Y}_i$: $\widehat{Y}_{HT} = 50 \times 26{,}4 = 1\,320$ milliers de dh, et la moyenne vaut $1\,320/200 = 6{,}6$, la moyenne simple des quatre $\overline{Y}_i$.
4. Non : sept paires, dont les douars 1 et 2, ne sont jamais tirées ensemble ($\pi_{kl} = 0$). On calcule comme avec remise : $s^2 = 1{,}7/3 = 0{,}5667$, $\widehat{V} = 0{,}5667/4 = 0{,}1417$, erreur-type 0,376 millier de dh, une valeur prudente.

Exercice 3 : vingt-cinq districts de huit ménages

Un plan autopondéré sur la population du cours

On tire 25 districts par tirage systématique proportionnel à la taille, puis 8 ménages dans chacun ; la variance se calcule comme si les districts étaient tirés avec remise.

1. Calculer π_k et le poids des ménages, puis π_i pour les districts de 71 et de 13 ménages.
2. Avec $\sum_i \frac{M_i}{N}(\overline{Y}_i - \overline{Y})^2 = 2\,844\,644$ et $\sum_i \frac{M_i}{N}(1 - \frac{8}{M_i})S_i^2 = 10\,753\,679$, calculer $V(\overline{y})$, l'écart-type et l'effet de plan ($V_{SAS} = 71\,435{,}5$).
3. Pourquoi ne pourrait-on pas tirer ainsi 40 districts de 5 ménages ?

Exercice 3 : solution

Probabilités et variance

1. $\pi_k = 25 \times 8/2\,000 = 0{,}1$ et $d_k = 10$ pour tous. $\pi_i = 25\,M_i/2\,000 = M_i/80$: 0,8875 et 0,1625.
2. $2\,844\,644/25 = 113\,786$ et $10\,753\,679/(25 \times 8) = 53\,768$: $V = 167\,554$, écart-type 409,3 dh, *deff* $= 167\,554/71\,435{,}5 = 2{,}35$, contre 4,45 si les districts sont tirés à probabilités égales.

Les grands districts

3. $\pi_i = 40\,M_i/2\,000 = M_i/50$ dépasserait 1 pour les 8 districts de plus de 50 ménages. Il faudrait les prendre d'office, et y tirer $M_i/10$ ménages pour garder $\pi_k = 0{,}1$.

Ce qu'il faut retenir

Le résumé du chapitre

Sept points

1. Tirer **proportionnellement à une taille** : $p_i = x_i/X$, par les tailles cumulées.
2. Hansen-Hurwitz : $\widehat{Y}_{HH} = \frac{1}{n}\sum_j y_{(j)}/p_{(j)}$, sans biais, et $\widehat{V} = s_z^2/n$.
3. Sa variance est faible quand y_i/x_i varie peu, nulle si y_i est proportionnel à x_i.
4. Cinq districts selon leur taille : écart-type 754,3 dh, contre 1 516,6 à probabilités égales.
5. Sans remise : $\pi_i = n\,x_i/X$ et Horvitz-Thompson ; des π_{kl} nuls, une variance prudente.
6. Districts selon leur taille, puis m ménages : un plan **autopondéré** à charge fixe.
7. Une taille mal liée à y, ou périmée, peut faire **pire** que les probabilités égales.

La suite

Le chapitre 12 se sert de l'information auxiliaire pour **estimer**, non plus pour tirer : connaissant le nombre total de personnes, $X = 7\,859$, l'estimateur par le ratio corrige la moyenne de l'échantillon.