

Économétrie avancée

Introduction : Nature de l'économétrie et données économiques

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Corrélation, causalité, et ce qui manque

Une entreprise observe que les salariés ayant suivi une formation interne gagnent, en moyenne, 15 % de plus que les autres.

- (a) Cette comparaison brute des moyennes mesure-t-elle un effet *ceteris paribus* de la formation sur le salaire ?
- (b) Proposer au moins deux caractéristiques des salariés (autres que la formation elle-même) qui pourraient être à la fois liées à la décision de se former et au niveau de salaire.
- (c) Pourquoi l'absence d'assignation aléatoire à la formation rend-elle cette comparaison potentiellement trompeuse ?
- (d) Que faudrait-il faire, en principe, pour isoler l'effet *ceteris paribus* de la formation sur le salaire ?

Exercice 2 — Identifier la structure des données

Quatre bases de données sont décrites.

D_1 . Le cours de clôture quotidien d'un seul indice boursier sur dix ans.

D_2 . Le chiffre d'affaires de 200 entreprises pour l'année en cours.

D_3 . Le bilan annuel de 50 entreprises cotées, observé chaque année pendant dix ans.

D_4 . Le taux de chômage trimestriel d'un seul pays sur vingt ans.

- (a) Identifier la structure de chacune des quatre bases : coupe transversale, série temporelle, ou panel.
- (b) Pour D_1 et D_4 , quelle propriété statistique des observations successives faut-il attendre, à la différence d'une coupe transversale ?
- (c) Pour D_3 , quel avantage propre aux données de panel permet-il de séparer ce qui est propre à chaque entreprise de ce qui est commun à une année donnée (par exemple, une crise économique) ?
- (d) D_2 suppose-t-elle une hypothèse d'indépendance entre les entreprises plausible a priori ? Dans quel cas cette hypothèse serait-elle mise à mal (indice : penser à des entreprises d'un même secteur ou d'une même région) ?

Exercice 3 — Pourquoi la structure des données change la méthode

Le cours affirme que les techniques valables sur coupe transversale ne le sont « plus automatiquement » sur séries temporelles.

- (a) Quelle hypothèse usuelle sur coupe transversale (à propos de l'indépendance des observations) est directement mise en cause par la nature d'une série temporelle ?
- (b) Pourquoi l'ordre des observations, sans importance sur une coupe transversale, devient-il essentiel sur une série temporelle ?
- (c) Le cours évoque le « clustering de volatilité » sur les rendements financiers. Que ce terme suggère-t-il quant à la dépendance entre observations successives ?
- (d) En quoi savoir reconnaître la structure de ses données est-il, selon le cours, un « préalable à tout choix de méthode » plutôt qu'un simple détail descriptif ?

2 Applications en sciences économiques

Exercice 4 — Comparer des fonds sans se tromper de question

Un analyste souhaite déterminer si les fonds d'investissement gérés activement surperforment les fonds indiciels.

- (a) S'il compare la performance moyenne de 300 fonds actifs et 300 fonds indiciels sur l'année écoulée, de quelle structure de données s'agit-il ?
- (b) S'il suit plutôt la performance de ces mêmes 600 fonds chaque année pendant dix ans, quelle structure obtient-il, et quel avantage supplémentaire cela procure-t-il pour contrôler des caractéristiques propres à chaque fonds (style de gestion, ancienneté du gérant) constantes dans le temps ?
- (c) Les fonds gérés activement qui survivent dix ans sont-ils probablement représentatifs de *tous* les fonds actifs lancés dix ans plus tôt ? Quel biais cela pourrait-il introduire dans la comparaison ?
- (d) Formuler, en une phrase, la question *ceteris paribus* précise que l'analyste devrait chercher à isoler, plutôt que la simple comparaison brute des performances moyennes.

Exercice 5 — Évaluer une politique sans expérience contrôlée

Un gouvernement observe que les régions ayant reçu une subvention à l'investissement industriel affichent, cinq ans plus tard, une croissance de l'emploi supérieure aux régions non subventionnées.

- (a) Les régions ont-elles été assignées à la subvention par tirage au sort ? Si non, quel type de données observationnelles cela produit-il ?
- (b) Quelles caractéristiques préexistantes d'une région (avant même l'octroi de la subvention) pourraient expliquer à la fois qu'elle ait été choisie pour recevoir la subvention et qu'elle affiche une meilleure croissance de l'emploi ?
- (c) Pourquoi une comparaison brute des taux de croissance de l'emploi entre régions subventionnées et non subventionnées ne permet-elle pas, à elle seule, de conclure à un effet causal de la subvention ?
- (d) Quel est, selon le cours, le rôle principal de la méthode économétrique face à ce type de données non expérimentales ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Non : cette comparaison brute mesure une simple corrélation entre formation et salaire, pas un effet *ceteris paribus* — elle ne maintient constant aucun autre facteur susceptible d'influencer le salaire.
- (b) Par exemple : la motivation personnelle du salarié (plus motivé, il se forme et travaille aussi mieux indépendamment de la formation) et son ancienneté ou son niveau de responsabilité déjà acquis (les salariés déjà bien positionnés ont souvent plus facilement accès aux formations internes).
- (c) Sans assignation aléatoire, les salariés qui choisissent de se former (ou sont choisis pour l'être) diffèrent probablement déjà, avant la formation, sur des caractéristiques liées au salaire (motivation, ambition, relation avec la hiérarchie) : l'écart de salaire observé mélange alors l'effet propre de la formation et l'effet de ces différences préexistantes.
- (d) Il faudrait, en principe, comparer des salariés identiques en tout point sauf la formation — soit par une expérience contrôlée avec assignation aléatoire de la formation, soit, à défaut, en contrôlant statistiquement (dans un modèle économétrique) les caractéristiques observables qui diffèrent entre les deux groupes.

Correction — Exercice 2

- (a) D_1 : série temporelle. D_2 : coupe transversale. D_3 : panel. D_4 : série temporelle.
- (b) Pour D_1 et D_4 , il faut s'attendre à une **corrélacion** (dépendance) entre observations successives, à la différence de l'indépendance usuellement supposée sur coupe transversale : la valeur de l'indice ou le taux de chômage à une date donnée est généralement lié à sa valeur à la date précédente.
- (c) Les données de panel de D_3 permettent de contrôler des **caractéristiques inobservées propres à chaque entreprise mais constantes dans le temps** (par exemple, la qualité de gestion ou la culture d'entreprise) tout en distinguant les effets communs à une année donnée (une crise économique touchant toutes les entreprises simultanément).
- (d) L'hypothèse d'indépendance entre entreprises n'est pas toujours plausible a priori : elle serait mise à mal si plusieurs entreprises de l'échantillon appartiennent au même secteur ou à la même région, auquel cas un choc commun (une réglementation sectorielle, une crise régionale) affecterait leur chiffre d'affaires de façon corrélée plutôt qu'indépendante.

Correction — Exercice 3

- (a) C'est l'hypothèse d'**indépendance des observations** (échantillonnage aléatoire) qui est directement mise en cause : sur une série temporelle, une observation à la date t est généralement liée statistiquement à celle de la date $t - 1$.
- (b) L'ordre devient essentiel car la dépendance temporelle signifie que la position chronologique d'une observation porte de l'information (sur ce qui l'a précédée et ce qui va suivre) ; réordonner aléatoirement les observations d'une série temporelle détruirait cette information, alors que réordonner une coupe transversale ne change rien puisque les observations y sont supposées indépendantes.
- (c) Le « clustering de volatilité » suggère que les périodes de forte variation des rendements ont tendance à se regrouper dans le temps (une période agitée suit souvent une autre période agitée) : c'est une forme de dépendance temporelle qui porte non pas sur le niveau des rendements eux-mêmes, mais sur l'amplitude de leurs variations.
- (d) Parce que la validité même des formules d'estimation et des tests statistiques usuels (basées sur l'hypothèse d'observations indépendantes) dépend de la structure des données : appliquer aveuglément une méthode de coupe transversale à une série temporelle produirait des résultats et des tests invalides, quelle que soit la qualité apparente de l'ajustement obtenu.

2 Applications en sciences économiques

Correction — Exercice 4

- (a) Il s'agit d'une **coupe transversale** : 600 unités (les fonds) observées à un instant donné (l'année écoulée).
- (b) En suivant les mêmes fonds sur dix ans, l'analyste obtient des données de **panel**. L'avantage supplémentaire est de pouvoir contrôler les caractéristiques propres à chaque fonds qui restent constantes dans le temps (le style de gestion, l'ancienneté du gérant), en les distinguant de l'effet des conditions de marché communes à une année donnée.
- (c) Non : les fonds actifs qui survivent dix ans sont probablement les plus performants, les fonds les moins performants ayant été fermés ou fusionnés en cours de route. Cela introduit un **biais de survie** : comparer uniquement les fonds encore existants au bout de dix ans surestime la performance moyenne réelle de l'ensemble des fonds actifs lancés initialement.
- (d) « Quel est l'effet de la gestion active sur la performance d'un fonds, *toutes choses égales par ailleurs* (à style d'investissement, taille du fonds, et niveau de risque comparables) ? » »

Correction — Exercice 5

- (a) Non, les régions n'ont vraisemblablement pas été assignées par tirage au sort à la subvention (les gouvernements choisissent généralement les régions bénéficiaires selon des critères précis) : cela produit des données **non expérimentales** (observationnelles).
- (b) Par exemple : le dynamisme économique préexistant de la région, la qualité de ses infrastructures, ou l'activisme de ses élus locaux dans la négociation de subventions — autant de caractéristiques qui pourraient expliquer à la fois l'octroi de la subvention (les régions les plus dynamiques ou les mieux organisées l'obtiennent plus facilement) et une meilleure croissance de l'emploi, indépendamment de tout effet propre de la subvention.
- (c) Parce que l'écart observé entre régions subventionnées et non subventionnées peut refléter, en tout ou en partie, ces différences préexistantes plutôt qu'un effet causal de la subvention elle-même — exactement le problème de confusion entre corrélation et causalité illustré par l'exemple de la formation professionnelle.
- (d) Le rôle principal de la méthode économétrique est de **compenser l'absence de contrôle expérimental** propre aux données non expérimentales, en s'efforçant d'isoler statistiquement l'effet *ceteris paribus* recherché malgré l'impossibilité de mener une expérience contrôlée avec assignation aléatoire.