

Chapitre 18

Réaliser un projet empirique

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie avancée

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Non précise** : ni population, ni variable dépendante, ni relation testable ne sont spécifiées. Reformulation possible : « quel est l'effet d'une année de scolarité supplémentaire sur le salaire horaire des travailleurs marocains de 25 à 40 ans ? »
- (b) **Précise** : population définie (travailleurs marocains, 25-40 ans), variable dépendante identifiée (salaire horaire), variable d'intérêt claire (années de scolarité), et contrôles explicites (expérience, région).
- (c) **Non précise** : ni la mesure du « changement climatique » (température ? précipitations ? fréquence d'événements extrêmes ?), ni celle de « l'agriculture » (rendement d'une culture ? revenu agricole ?), ni la population/période ne sont spécifiées.
- (d) Pour les énoncés (a) et (c), le manque de précision risque de conduire, une fois la collecte de données commencée, à découvrir trop tard qu'une variable clé n'a pas été recueillie, ou que l'échantillon disponible ne correspond pas réellement à la population visée par la question — obligeant à revoir tardivement, et à moindres frais, le projet dans son ensemble.

Correction — Exercice 2

- (a) **Confusion** : « un modèle MCO » n'a pas de sens — les MCO sont une méthode d'estimation, pas un modèle. Reformulation : « nous estimons le modèle $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$ par MCO ».
- (b) **Correcte** : le modèle (relation de population) et la méthode d'estimation (MCO) sont clairement distingués.
- (c) **Problématique**, bien que d'une nature différente des deux précédentes : justifier l'omission d'une variable par son insignifiance constatée *a posteriori* confond la présentation du **modèle** (qui doit être motivé par la théorie économique, en amont) avec les **résultats** (constatés en aval) — une pratique explicitement déconseillée par le cours.
- (d) Parce que retirer une variable sur ce seul critère revient à laisser les données elles-mêmes dicter la spécification du modèle après coup, ce qui invalide l'interprétation usuelle des tests de significativité obtenus dans la spécification finale (un cas particulier de dragage de données) — et prive le lecteur de l'information que cette variable a été testée et écartée pour cette raison précise, un choix qui devrait être discuté en toute transparence plutôt que dissimulé par sa simple absence du modèle final.

Correction — Exercice 3

- (a) **Analyse de sensibilité légitime** : le changement de spécification est motivé, documenté, et les **deux** résultats (avec la mesure continue, avec l'indicatrice) sont rapportés.
- (b) **Dragage de données** : ne rapporter que la spécification la plus favorable, parmi 40 essayées, invalide l'interprétation du test de significativité obtenu — le seuil de 5 % n'a plus le sens usuel une fois qu'on a activement recherché la spécification qui le franchit.
- (c) **Analyse de sensibilité légitime** : la règle d'exclusion est définie *a priori* (pas en fonction du résultat obtenu), documentée, et la robustesse aux valeurs exclues est explicitement vérifiée et rapportée.
- (d) Les scénarios (a) et (c) ont en commun la **transparence** : la règle de décision est fixée à l'avance (ou du moins motivée indépendamment du résultat), et **tous** les résultats pertinents (avec et sans la modification) sont rapportés au lecteur. Le scénario (b), à l'inverse, sélectionne *a posteriori* la spécification en fonction du résultat qu'elle produit, et dissimule les 39 autres tentatives — exactement la définition du dragage de données que le cours met en garde de ne jamais pratiquer, ou du moins de ne jamais dissimuler.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Le chercheur devrait estimer la régression de première étape (fréquentation de la bibliothèque sur la distance et les régresseurs exogènes) et rapporter la statistique F de cette première étape, en la comparant à la règle empirique du chapitre 14 ($F > 10$) pour écarter le risque d'instrument faible.
- (b) Le chercheur devrait argumenter, sur des bases économiques, que la distance au domicile n'affecte la réussite académique **que** par le canal de la fréquentation de la bibliothèque — en écartant explicitement d'autres canaux plausibles (par exemple, la distance pourrait être corrélée au milieu socio-économique du quartier de résidence, qui affecterait la réussite indépendamment de la bibliothèque, ce qui violerait l'exogénéité).
- (c) Non : cette phrase ne discute que la **pertinence** (et de façon informelle, sans statistique F rapportée), sans aborder du tout la question, bien plus délicate, de l'**exogénéité** — elle ne satisferait donc pas l'exigence de discussion séparée des deux conditions posée par le chapitre 18.
- (d) Parce que les deux conditions sont de nature **radicalement différente** : la pertinence est **testable** statistiquement (via le F de première étape), tandis que l'exogénéité (l'hypothèse d'exclusion) ne l'est **jamais** directement et repose entièrement sur un raisonnement économique argumenté — les confondre dans une phrase unique masque le fait que l'une des deux exigences ne peut, par nature, être « prouvée » par les données elles-mêmes, et mérite donc une discussion qualitative à part entière.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Exemple : « Parmi les petites entreprises informelles marocaines créées entre 2018 et 2021, l'accès à un microcrédit au cours de la première année d'activité augmente-t-il la probabilité de survie à 3 ans ? » — population, période et variable dépendante (survie à 3 ans, binaire) sont précisées.
- (b) Un **panel** (suivre les mêmes entreprises sur plusieurs années) serait le plus adapté : il permet, via les méthodes des chapitres 12-13, de contrôler les caractéristiques inobservées mais **constantes dans le temps** de chaque entreprise (qualité de gestion, réseau commercial du fondateur), qui biaiserait sinon une simple comparaison en coupe transversale entre entreprises ayant et n'ayant pas obtenu de microcrédit.
- (c) L'**auto-sélection** est la plus préoccupante ici : les entreprises qui demandent (et obtiennent) un microcrédit ne sont probablement pas un échantillon aléatoire — elles pourraient déjà être plus dynamiques, mieux gérées, ou avoir de meilleures perspectives de croissance, ce qui biaiserait à la hausse l'effet apparent du microcrédit sur la survie si cette sélection n'est pas contrôlée.
- (d) Exemple raisonnable : ré-estimer le modèle principal en remplaçant la mesure continue du montant du microcrédit par une simple indicatrice « a obtenu un microcrédit / n'en a pas obtenu », documenter ce choix *a priori*, et rapporter si la conclusion centrale (signe et significativité de l'effet) résiste à ce changement de spécification — sans rechercher activement la spécification la plus favorable parmi de nombreuses variantes non rapportées.

Correction — Exercice 6

- (a) Trois manquements au moins : (1) « modèle MCO » confond modèle et méthode d'estimation ; (2) tester 40 spécifications et ne rapporter que la plus favorable est un dragage de données explicitement mis en garde par le cours ; (3) justifier le retrait d'une variable de contrôle par son insignifiance constatée *a posteriori*, plutôt que par un raisonnement théorique *a priori*, confond de nouveau la présentation du modèle avec celle des résultats.
- (b) Il manque, selon les bonnes pratiques du cours, le nombre d'observations et le R^2 de la régression, ainsi qu'une indication claire de la significativité **statistique** (écart-type, valeur t ou p) du coefficient rapporté — un coefficient seul, sans ces éléments, ne permet pas au lecteur d'en juger la fiabilité.
- (c) Reformulation possible : « notre modèle de population inclut la taille de l'entreprise comme

contrôle, motivée par [raisonnement économique]; nous rapportons les résultats avec et sans ce contrôle en annexe pour vérifier la robustesse de notre conclusion principale » — la variable est motivée *a priori* et son retrait éventuel, documenté et transparent plutôt que silencieusement justifié par le résultat.

(d) Parce que les seuils critiques usuels des tests t et F (par exemple 5 %) supposent une hypothèse nulle testée **une seule fois** sur des données indépendantes du choix de spécification; en recherchant activement, parmi 40 tentatives, celle qui produit un résultat significatif, la probabilité de trouver *par pur hasard* au moins une spécification « significative » devient bien supérieure à 5 % — chaque test individuel reste calculé correctement, mais leur **interprétation collective** comme preuve d'un effet réel devient trompeuse.