

Économétrie avancée

Chapitre 18 : Réaliser un projet empirique

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — D'une idée vague à une question testable

Pour chacun des énoncés suivants, indiquer s'il constitue une question de recherche suffisamment précise selon le critère du cours, et sinon, proposer une reformulation qui le rendrait testable.

- (a) « Je m'intéresse à l'éducation et aux salaires. »
- (b) « Quel est l'effet d'une année de scolarité supplémentaire sur le salaire horaire des travailleurs marocains âgés de 25 à 40 ans, à expérience et région données ? »
- (c) « J'étudie l'impact du changement climatique sur l'agriculture. »
- (d) Pour l'énoncé jugé le moins précis, quelles conséquences pratiques concrètes, rappelées par le cours, risque d'entraîner ce manque de précision une fois la collecte de données commencée ?

Exercice 2 — Modèle contre méthode d'estimation

Pour chacune des phrases suivantes, tirées d'un rapport étudiant fictif, indiquer si elle confond le **modèle** et la **méthode d'estimation**, et proposer, le cas échéant, une reformulation correcte.

- (a) « Nous estimons un modèle MCO de la forme $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$. »
- (b) « Le modèle de population est $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$; nous l'estimons par MCO. »
- (c) « Nous avons retiré la variable *alcohol* du modèle final car son coefficient n'était pas significatif dans nos premières régressions. »
- (d) Pourquoi la pratique décrite en (c) pose-t-elle un problème méthodologique, même si le coefficient retiré était effectivement non significatif ?

Exercice 3 — Analyse de sensibilité ou dragage de données ?

Pour chacun des scénarios suivants, indiquer s'il relève d'une analyse de sensibilité légitime ou d'un dragage de données (*data mining*) à éviter.

- (a) Un chercheur remplace une mesure continue du revenu par une indicatrice de tranche de revenu, pour vérifier si les conclusions résistent à ce changement de spécification, et rapporte les deux résultats.
- (b) Un chercheur teste successivement 40 spécifications différentes (ajout/retrait de variables de contrôle une à une) et ne rapporte, dans son rapport final, que la seule spécification où son coefficient d'intérêt est significatif au seuil de 5 %.
- (c) Un chercheur exclut les valeurs aberrantes de son échantillon selon une règle définie *a priori* (par exemple, le centile supérieur de la variable dépendante), documente ce choix, et vérifie que les résultats principaux sont robustes à leur inclusion.
- (d) Qu'ont en commun les scénarios (a) et (c), qui les distingue nettement du scénario (b) ?

2 Exercice cumulatif (chapitre 18 et chapitre 14)

Exercice 4 — Défendre une stratégie d'identification par variables instrumentales

Le chapitre 18 rappelle que, si une variable instrumentale est utilisée dans un projet empirique, ses deux conditions — pertinence et exogénéité (exclusion), chapitre 14 — doivent être discutées séparément, et non simplement mentionnées. On imagine un projet étudiant sur l'effet de la fréquentation d'une bibliothèque universitaire sur la réussite académique, instrumentée par la distance entre le domicile de l'étudiant et la bibliothèque.

- (a) Pour discuter la condition de **pertinence** (chapitre 14), quelle vérification empirique concrète le chercheur devrait-il réaliser et rapporter dans son rapport ?

- (b) Pour discuter la condition d'**exogénéité** (chapitre 14), quel argument économique — non testable directement — le chercheur devrait-il avancer pour justifier que la distance au domicile n'affecte la réussite académique *que* via la fréquentation de la bibliothèque ?
- (c) Un rapport qui se contenterait d'écrire « nous utilisons la distance comme instrument, car elle est corrélée à la fréquentation », sans plus de discussion, satisferait-il l'exigence du chapitre 18 ?
- (d) Pourquoi le chapitre 18 insiste-t-il pour que les deux conditions soient discutées **séparément**, plutôt qu'ensemble en une seule phrase générale sur la « validité » de l'instrument ?

3 Applications en sciences économiques

Exercice 5 — Concevoir un projet empirique : microcrédit et survie des entreprises

On souhaite étudier l'effet de l'accès au microcrédit sur la probabilité de survie à 3 ans des petites entreprises informelles au Maroc.

- (a) Reformuler cette idée en une question de recherche testable, en précisant la population, la période et la variable dépendante.
- (b) Quelle structure de données (coupe transversale, série temporelle, coupes répétées, panel) serait la plus adaptée pour contrôler l'hétérogénéité inobservée entre entreprises (qualité de gestion, réseau commercial) ? Pourquoi ?
- (c) Parmi les trois sources d'endogénéité rappelées par le cours (auto-sélection, erreur de mesure, simultanéité), laquelle semble la plus préoccupante ici, sachant que ce sont les entreprises elles-mêmes qui choisissent de demander un microcrédit ?
- (d) Proposer une analyse de sensibilité raisonnable (changement de spécification) qui renforcerait la crédibilité des résultats, sans tomber dans le dragage de données.

Exercice 6 — Critiquer un extrait de rapport

Un extrait de rapport étudiant affirme : « Nous avons testé notre modèle MCO de l'effet du salaire minimum sur l'emploi. Après avoir essayé une trentaine de spécifications différentes, nous rapportons celle qui donne les résultats les plus significatifs, avec un coefficient de $-0,45$. Nous avons retiré la variable de contrôle *taille de l'entreprise* car elle n'apportait rien au modèle final. »

- (a) Identifier au moins trois manquements méthodologiques dans cet extrait, en les reliant chacun à un principe précis du chapitre 18.
- (b) Que manque-t-il, concrètement, dans la présentation du résultat (le coefficient $-0,45$), selon les bonnes pratiques de présentation rappelées par le cours ?
- (c) Reformuler la phrase sur le retrait de la variable *taille de l'entreprise* d'une manière qui respecterait la distinction modèle/méthode et éviterait le biais de sélection de spécification.
- (d) Pourquoi le dragage de données invalide-t-il l'interprétation des tests t et F rapportés, même si chaque test individuel est calculé correctement ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Non précise** : ni population, ni variable dépendante, ni relation testable ne sont spécifiées. Reformulation possible : « quel est l'effet d'une année de scolarité supplémentaire sur le salaire horaire des travailleurs marocains de 25 à 40 ans ? »
- (b) **Précise** : population définie (travailleurs marocains, 25-40 ans), variable dépendante identifiée (salaire horaire), variable d'intérêt claire (années de scolarité), et contrôles explicites (expérience, région).
- (c) **Non précise** : ni la mesure du « changement climatique » (température ? précipitations ? fréquence d'événements extrêmes ?), ni celle de « l'agriculture » (rendement d'une culture ? revenu agricole ?), ni la population/période ne sont spécifiées.
- (d) Pour les énoncés (a) et (c), le manque de précision risque de conduire, une fois la collecte de données commencée, à découvrir trop tard qu'une variable clé n'a pas été recueillie, ou que l'échantillon disponible ne correspond pas réellement à la population visée par la question — obligeant à revoir tardivement, et à moindres frais, le projet dans son ensemble.

Correction — Exercice 2

- (a) **Confusion** : « un modèle MCO » n'a pas de sens — les MCO sont une méthode d'estimation, pas un modèle. Reformulation : « nous estimons le modèle $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$ par MCO ».
- (b) **Correcte** : le modèle (relation de population) et la méthode d'estimation (MCO) sont clairement distingués.
- (c) **Problématique**, bien que d'une nature différente des deux précédentes : justifier l'omission d'une variable par son insignifiance constatée *a posteriori* confond la présentation du **modèle** (qui doit être motivé par la théorie économique, en amont) avec les **résultats** (constatés en aval) — une pratique explicitement déconseillée par le cours.
- (d) Parce que retirer une variable sur ce seul critère revient à laisser les données elles-mêmes dicter la spécification du modèle après coup, ce qui invalide l'interprétation usuelle des tests de significativité obtenus dans la spécification finale (un cas particulier de dragage de données) — et prive le lecteur de l'information que cette variable a été testée et écartée pour cette raison précise, un choix qui devrait être discuté en toute transparence plutôt que dissimulé par sa simple absence du modèle final.

Correction — Exercice 3

- (a) **Analyse de sensibilité légitime** : le changement de spécification est motivé, documenté, et les **deux** résultats (avec la mesure continue, avec l'indicatrice) sont rapportés.
- (b) **Dragage de données** : ne rapporter que la spécification la plus favorable, parmi 40 essayées, invalide l'interprétation du test de significativité obtenu — le seuil de 5 % n'a plus le sens usuel une fois qu'on a activement recherché la spécification qui le franchit.
- (c) **Analyse de sensibilité légitime** : la règle d'exclusion est définie *a priori* (pas en fonction du résultat obtenu), documentée, et la robustesse aux valeurs exclues est explicitement vérifiée et rapportée.
- (d) Les scénarios (a) et (c) ont en commun la **transparence** : la règle de décision est fixée à l'avance (ou du moins motivée indépendamment du résultat), et **tous** les résultats pertinents (avec et sans la modification) sont rapportés au lecteur. Le scénario (b), à l'inverse, sélectionne *a posteriori* la spécification en fonction du résultat qu'elle produit, et dissimule les 39 autres tentatives — exactement la définition du dragage de données que le cours met en garde de ne jamais pratiquer, ou du moins de ne jamais dissimuler.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Le chercheur devrait estimer la régression de première étape (fréquentation de la bibliothèque sur la distance et les régresseurs exogènes) et rapporter la statistique F de cette première étape, en la comparant à la règle empirique du chapitre 14 ($F > 10$) pour écarter le risque d'instrument faible.
- (b) Le chercheur devrait argumenter, sur des bases économiques, que la distance au domicile n'affecte la réussite académique **que** par le canal de la fréquentation de la bibliothèque — en écartant explicitement d'autres canaux plausibles (par exemple, la distance pourrait être corrélée au milieu socio-économique du quartier de résidence, qui affecterait la réussite indépendamment de la bibliothèque, ce qui violerait l'exogénéité).
- (c) Non : cette phrase ne discute que la **pertinence** (et de façon informelle, sans statistique F rapportée), sans aborder du tout la question, bien plus délicate, de l'**exogénéité** — elle ne satisferait donc pas l'exigence de discussion séparée des deux conditions posée par le chapitre 18.
- (d) Parce que les deux conditions sont de nature **radicalement différente** : la pertinence est **testable** statistiquement (via le F de première étape), tandis que l'exogénéité (l'hypothèse d'exclusion) ne l'est **jamais** directement et repose entièrement sur un raisonnement économique argumenté — les confondre dans une phrase unique masque le fait que l'une des deux exigences ne peut, par nature, être « prouvée » par les données elles-mêmes, et mérite donc une discussion qualitative à part entière.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Exemple : « Parmi les petites entreprises informelles marocaines créées entre 2018 et 2021, l'accès à un microcrédit au cours de la première année d'activité augmente-t-il la probabilité de survie à 3 ans ? » — population, période et variable dépendante (survie à 3 ans, binaire) sont précisées.
- (b) Un **panel** (suivre les mêmes entreprises sur plusieurs années) serait le plus adapté : il permet, via les méthodes des chapitres 12-13, de contrôler les caractéristiques inobservées mais **constantes dans le temps** de chaque entreprise (qualité de gestion, réseau commercial du fondateur), qui biaiserait sinon une simple comparaison en coupe transversale entre entreprises ayant et n'ayant pas obtenu de microcrédit.
- (c) L'**auto-sélection** est la plus préoccupante ici : les entreprises qui demandent (et obtiennent) un microcrédit ne sont probablement pas un échantillon aléatoire — elles pourraient déjà être plus dynamiques, mieux gérées, ou avoir de meilleures perspectives de croissance, ce qui biaiserait à la hausse l'effet apparent du microcrédit sur la survie si cette sélection n'est pas contrôlée.
- (d) Exemple raisonnable : ré-estimer le modèle principal en remplaçant la mesure continue du montant du microcrédit par une simple indicatrice « a obtenu un microcrédit / n'en a pas obtenu », documenter ce choix *a priori*, et rapporter si la conclusion centrale (signe et significativité de l'effet) résiste à ce changement de spécification — sans rechercher activement la spécification la plus favorable parmi de nombreuses variantes non rapportées.

Correction — Exercice 6

- (a) Trois manquements au moins : (1) « modèle MCO » confond modèle et méthode d'estimation ; (2) tester 40 spécifications et ne rapporter que la plus favorable est un dragage de données explicitement mis en garde par le cours ; (3) justifier le retrait d'une variable de contrôle par son insignifiance constatée *a posteriori*, plutôt que par un raisonnement théorique *a priori*, confond de nouveau la présentation du modèle avec celle des résultats.
- (b) Il manque, selon les bonnes pratiques du cours, le nombre d'observations et le R^2 de la régression, ainsi qu'une indication claire de la significativité **statistique** (écart-type, valeur t ou p) du coefficient rapporté — un coefficient seul, sans ces éléments, ne permet pas au lecteur d'en juger la fiabilité.
- (c) Reformulation possible : « notre modèle de population inclut la taille de l'entreprise comme

contrôle, motivée par [raisonnement économique]; nous rapportons les résultats avec et sans ce contrôle en annexe pour vérifier la robustesse de notre conclusion principale » — la variable est motivée *a priori* et son retrait éventuel, documenté et transparent plutôt que silencieusement justifié par le résultat.

(d) Parce que les seuils critiques usuels des tests t et F (par exemple 5 %) supposent une hypothèse nulle testée **une seule fois** sur des données indépendantes du choix de spécification ; en recherchant activement, parmi 40 tentatives, celle qui produit un résultat significatif, la probabilité de trouver *par pur hasard* au moins une spécification « significative » devient bien supérieure à 5 % — chaque test individuel reste calculé correctement, mais leur **interprétation collective** comme preuve d'un effet réel devient trompeuse.