

Chapitre 18

Réaliser un projet empirique

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie avancée

1 Exercices du chapitre

Exercice 1 — D’une idée vague à une question testable

Pour chacun des énoncés suivants, indiquer s’il constitue une question de recherche suffisamment précise selon le critère du cours, et sinon, proposer une reformulation qui le rendrait testable.

- (a) « Je m’intéresse à l’éducation et aux salaires. »
- (b) « Quel est l’effet d’une année de scolarité supplémentaire sur le salaire horaire des travailleurs marocains âgés de 25 à 40 ans, à expérience et région données ? »
- (c) « J’étudie l’impact du changement climatique sur l’agriculture. »
- (d) Pour l’énoncé jugé le moins précis, quelles conséquences pratiques concrètes, rappelées par le cours, risque d’entraîner ce manque de précision une fois la collecte de données commencée ?

Exercice 2 — Modèle contre méthode d’estimation

Pour chacune des phrases suivantes, tirées d’un rapport étudiant fictif, indiquer si elle confond le **modèle** et la **méthode d’estimation**, et proposer, le cas échéant, une reformulation correcte.

- (a) « Nous estimons un modèle MCO de la forme $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$. »
- (b) « Le modèle de population est $colGPA = \beta_0 + \beta_1 alcohol + \beta_2 hsGPA + u$; nous l’estimons par MCO. »
- (c) « Nous avons retiré la variable *alcohol* du modèle final car son coefficient n’était pas significatif dans nos premières régressions. »
- (d) Pourquoi la pratique décrite en (c) pose-t-elle un problème méthodologique, même si le coefficient retiré était effectivement non significatif ?

Exercice 3 — Analyse de sensibilité ou dragage de données ?

Pour chacun des scénarios suivants, indiquer s’il relève d’une analyse de sensibilité légitime ou d’un dragage de données (*data mining*) à éviter.

- (a) Un chercheur remplace une mesure continue du revenu par une indicatrice de tranche de revenu, pour vérifier si les conclusions résistent à ce changement de spécification, et rapporte les deux résultats.
- (b) Un chercheur teste successivement 40 spécifications différentes (ajout/retrait de variables de contrôle une à une) et ne rapporte, dans son rapport final, que la seule spécification où son coefficient d’intérêt est significatif au seuil de 5 %.
- (c) Un chercheur exclut les valeurs aberrantes de son échantillon selon une règle définie *a priori* (par exemple, le centile supérieur de la variable dépendante), documente ce choix, et vérifie que les résultats principaux sont robustes à leur inclusion.
- (d) Qu’ont en commun les scénarios (a) et (c), qui les distingue nettement du scénario (b) ?

2 Exercice cumulatif (chapitre 18 et chapitre 14)

Exercice 4 — Défendre une stratégie d’identification par variables instrumentales

Le chapitre 18 rappelle que, si une variable instrumentale est utilisée dans un projet empirique, ses deux conditions — pertinence et exogénéité (exclusion), chapitre 14 — doivent être discutées séparément, et non simplement mentionnées. On imagine un projet étudiant sur l’effet de la fréquentation d’une bibliothèque universitaire sur la réussite académique, instrumentée par la distance entre le domicile de l’étudiant et la bibliothèque.

- (a) Pour discuter la condition de **pertinence** (chapitre 14), quelle vérification empirique concrète le chercheur devrait-il réaliser et rapporter dans son rapport ?

- (b) Pour discuter la condition d'**exogénéité** (chapitre 14), quel argument économique — non testable directement — le chercheur devrait-il avancer pour justifier que la distance au domicile n'affecte la réussite académique *que* via la fréquentation de la bibliothèque ?
- (c) Un rapport qui se contenterait d'écrire « nous utilisons la distance comme instrument, car elle est corrélée à la fréquentation », sans plus de discussion, satisferait-il l'exigence du chapitre 18 ?
- (d) Pourquoi le chapitre 18 insiste-t-il pour que les deux conditions soient discutées **séparément**, plutôt qu'ensemble en une seule phrase générale sur la « validité » de l'instrument ?

3 Applications en sciences économiques

Exercice 5 — Concevoir un projet empirique : microcrédit et survie des entreprises

On souhaite étudier l'effet de l'accès au microcrédit sur la probabilité de survie à 3 ans des petites entreprises informelles au Maroc.

- (a) Reformuler cette idée en une question de recherche testable, en précisant la population, la période et la variable dépendante.
- (b) Quelle structure de données (coupe transversale, série temporelle, coupes répétées, panel) serait la plus adaptée pour contrôler l'hétérogénéité inobservée entre entreprises (qualité de gestion, réseau commercial) ? Pourquoi ?
- (c) Parmi les trois sources d'endogénéité rappelées par le cours (auto-sélection, erreur de mesure, simultanéité), laquelle semble la plus préoccupante ici, sachant que ce sont les entreprises elles-mêmes qui choisissent de demander un microcrédit ?
- (d) Proposer une analyse de sensibilité raisonnable (changement de spécification) qui renforcerait la crédibilité des résultats, sans tomber dans le dragage de données.

Exercice 6 — Critiquer un extrait de rapport

Un extrait de rapport étudiant affirme : « Nous avons testé notre modèle MCO de l'effet du salaire minimum sur l'emploi. Après avoir essayé une trentaine de spécifications différentes, nous rapportons celle qui donne les résultats les plus significatifs, avec un coefficient de $-0,45$. Nous avons retiré la variable de contrôle *taille de l'entreprise* car elle n'apportait rien au modèle final. »

- (a) Identifier au moins trois manquements méthodologiques dans cet extrait, en les reliant chacun à un principe précis du chapitre 18.
- (b) Que manque-t-il, concrètement, dans la présentation du résultat (le coefficient $-0,45$), selon les bonnes pratiques de présentation rappelées par le cours ?
- (c) Reformuler la phrase sur le retrait de la variable *taille de l'entreprise* d'une manière qui respecterait la distinction modèle/méthode et éviterait le biais de sélection de spécification.
- (d) Pourquoi le dragage de données invalide-t-il l'interprétation des tests t et F rapportés, même si chaque test individuel est calculé correctement ?