

Économétrie avancée

Chapitre 5 : Régression multiple : approfondissements

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le rééchantillonnage ne change rien à la significativité

Le cours rapporte $\widehat{bwght} = 116,97 - 0,463 \text{ cigs} + 0,093 \text{ faminc}$ (poids en onces), avec un écart-type de 0,0805 sur le coefficient de *cigs*.

- (a) Calculer le t du coefficient de *cigs*.
- (b) Si l'on remplace *cigs* par *packs* = *cigs*/20 (paquets de cigarettes plutôt que cigarettes individuelles), le nouveau coefficient est multiplié par 20. Le calculer.
- (c) Le nouvel écart-type est également multiplié par 20 ($0,0805 \times 20 = 1,61$). Calculer le nouveau t , et vérifier qu'il est identique à celui de la question (a).
- (d) Pourquoi le cours affirme-t-il que « le test de significativité ne dépend jamais de l'unité choisie »?

Exercice 2 — Effet exact contre effet approché

Le cours rapporte $\log(\widehat{price}) = 9,23 - 0,718 \log(nox) + 0,306 \text{ rooms}$.

- (a) Calculer l'approximation usuelle $100 \times 0,306$ pour l'effet d'une pièce supplémentaire.
- (b) Calculer l'effet exact $100[\exp(0,306) - 1]$.
- (c) L'écart entre les deux est-il négligeable?
- (d) Le cours affirme que cet écart se creuse « dès que le coefficient est élevé ». Reprendre le calcul avec un coefficient plus faible, $\beta = 0,05$ au lieu de 0,306, et comparer l'écart obtenu à celui de la question (c).

Exercice 3 — Point de retournement d'un effet quadratique

Le cours rapporte $\widehat{wage} = 3,73 + 0,298 \text{ exper} - 0,0061 \text{ exper}^2$.

- (a) Calculer le point de retournement $x^* = |\hat{\beta}_1 / (2\hat{\beta}_2)|$.
- (b) Que représente économiquement ce point de retournement pour la variable expérience?
- (c) Le cours indique que 28 % de l'échantillon dépasse ce seuil. Pourquoi cette information est-elle nécessaire avant de « prendre au sérieux » l'effet négatif au-delà de x^* ?
- (d) Si seulement 1 % de l'échantillon avait dépassé x^* au lieu de 28 %, la conclusion sur l'effet décroissant de l'expérience au-delà de ce seuil serait-elle aussi fiable? Pourquoi?

2 Exercice cumulatif (chapitre 5 et chapitre 2)

Exercice 4 — Le mauvais contrôle : l'inverse du biais de variable omise

Le chapitre 2 avait établi que le biais de variable omise apparaît quand on **oublie** une variable pertinente corrélée aux régresseurs inclus. Ce chapitre montre, avec l'exemple de la taxe sur la bière et des décès routiers, qu'**ajouter** une variable peut, à l'inverse, détruire l'interprétation recherchée.

- (a) Dans le modèle expliquant les décès routiers par la taxe sur la bière, par quel mécanisme économique la taxe est-elle censée réduire les décès (indice : que fait une taxe plus élevée à la consommation)?
- (b) Si l'on ajoute la consommation de bière comme régresseur dans ce modèle, que devient l'interprétation *ceteris paribus* du coefficient de la taxe (à consommation de bière maintenue constante)?
- (c) En quoi ce cas est-il l'inverse exact du biais de variable omise du chapitre 2 : là où omettre une variable pertinente biaisait un coefficient, ici c'est l'**ajout** d'une variable qui détruit l'information recherchée?

- (d) Formuler, à partir de ces deux chapitres, la question que tout chercheur devrait se poser avant d'ajouter *ou* de retirer une variable d'un modèle, au-delà du seul critère du R^2 ou du R^2 ajusté.

3 Applications en sciences économiques

Exercice 5 — Retransformer une prévision en logarithme

Un modèle log-linéaire du chiffre d'affaires d'une entreprise donne $\widehat{\log(y)} = 2,5$ pour un profil donné, avec $\hat{\sigma} = 0,4$ (écart-type des résidus du modèle en logarithme).

- (a) Calculer la prévision naïve $\exp(\widehat{\log y})$, sans aucune correction.
- (b) Calculer le facteur correctif $\exp(\hat{\sigma}^2/2)$.
- (c) En déduire la prévision corrigée $\hat{y} = \exp(\hat{\sigma}^2/2) \exp(\widehat{\log y})$.
- (d) Pourquoi la prévision naïve « sous-estime systématiquement » le niveau attendu de y , selon le cours ?

Exercice 6 — Un intervalle pour la moyenne, un autre pour un cas individuel

Une banque prévoit le score de crédit moyen d'un profil d'emprunteurs avec $\hat{y}^0 = 650$, $se(\hat{y}^0) = 3$, et $\hat{\sigma} = 45$ (écart-type des résidus du modèle).

- (a) Calculer l'intervalle de confiance à 95 % pour le score **moyen** de ce profil, $\hat{y}^0 \pm 1,96 se(\hat{y}^0)$.
- (b) Calculer $se(\hat{e}^0) = \sqrt{se(\hat{y}^0)^2 + \hat{\sigma}^2}$, puis l'intervalle de **prédiction** à 95 % pour un emprunteur individuel de ce profil.
- (c) Comparer la largeur des deux intervalles. Lequel est le plus large, et de combien environ ?
- (d) Un conseiller qui utiliserait l'intervalle de confiance (celui de la moyenne) pour décider d'accorder un prêt à un emprunteur **individuel** sous-estimerait-il ou surestimerait-il la véritable incertitude sur le score de cet emprunteur ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $t = -0,463/0,0805 \approx -5,752$.
(b) $-0,463 \times 20 = -9,26$.
(c) $t = -9,26/1,61 \approx -5,752$: identique, au signe et à la précision près, au t de la question (a).
(d) Parce que le rééchantillonnage d'un régresseur (ou de la variable expliquée) multiplie à la fois le coefficient et son écart-type par le même facteur : le rapport $t = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$, qui définit la statistique de test, reste donc mathématiquement inchangé quelle que soit l'unité choisie pour mesurer la variable.

Correction — Exercice 2

- (a) $100 \times 0,306 = 30,6\%$.
(b) $100[\exp(0,306) - 1] \approx 35,8\%$.
(c) Non, l'écart ($35,8 - 30,6 = 5,2$ points de pourcentage) n'est pas négligeable : c'est un écart significatif dans l'interprétation économique du résultat.
(d) Avec $\beta = 0,05$: approximation = $100 \times 0,05 = 5\%$, valeur exacte = $100[\exp(0,05) - 1] \approx 5,13\%$. L'écart n'est ici que de 0,13 point de pourcentage, bien plus faible que les 5,2 points de l'exemple avec $\beta = 0,306$: cela confirme que l'écart entre approximation et valeur exacte se creuse effectivement à mesure que le coefficient augmente.

Correction — Exercice 3

- (a) $x^* = |0,298 / (2 \times (-0,0061))| = 0,298/0,0122 \approx 24,4$ années d'expérience.
(b) Ce point de retournement représente le niveau d'expérience au-delà duquel le rendement marginal de l'expérience sur le salaire devient **négatif** : le salaire prédit, selon le modèle, commence à diminuer avec l'expérience au-delà de 24,4 ans.
(c) Cette information est nécessaire car si seule une infime fraction de l'échantillon dépassait ce seuil, le comportement du modèle au-delà de x^* relèverait d'une **extrapolation** hors du domaine réellement observé des données, peu fiable. Avec 28 % de l'échantillon au-delà, le phénomène est observé sur une portion substantielle des données et mérite donc d'être pris au sérieux plutôt qu'écarté comme un simple artefact.
(d) Non, la conclusion serait bien moins fiable : avec seulement 1 % de l'échantillon au-delà de x^* , le modèle serait estimé sur très peu d'observations dans cette zone, rendant l'effet négatif au-delà du seuil beaucoup plus incertain et potentiellement un simple artefact de la forme quadratique imposée, plutôt qu'un phénomène réellement établi par les données.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Une taxe plus élevée sur la bière augmente son prix, ce qui réduit la **consommation** de bière, réduisant à son tour les accidents liés à la conduite en état d'ivresse et donc les décès routiers : la taxe agit *par l'intermédiaire* de la consommation.
(b) En maintenant la consommation de bière constante (*ceteris paribus*), le coefficient de la taxe ne mesurerait plus que son effet **résiduel** sur les décès routiers, une fois son canal d'action principal (la réduction de la consommation) neutralisé — ce qui détruit précisément l'effet total de la taxe que l'on cherchait à estimer.
(c) C'est l'inverse exact car ici, le problème ne vient pas d'un facteur **omis** et corrélé aux régresseurs (comme au chapitre 2), mais d'un facteur **ajouté** qui se trouve être le mécanisme même par lequel la variable d'intérêt agit : contrôler pour ce mécanisme (la consommation) élimine artificiellement l'effet total qu'on voulait mesurer, alors que dans le biais de variable omise, c'est l'absence de contrôle qui

contaminait le coefficient.

(d) Avant d'ajouter ou de retirer une variable, un chercheur devrait toujours se demander : « cette variable est-elle une cause commune de x et y qu'il faut contrôler pour isoler l'effet *ceteris paribus*, ou est-elle plutôt un canal par lequel x agit sur y , qu'il ne faut surtout pas contrôler si l'on veut mesurer l'effet total de x » — un critère théorique, jamais réductible au seul R^2 ou R^2 ajusté.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\exp(2,5) \approx 12,18$.

(b) $\exp(0,4^2/2) = \exp(0,08) \approx 1,0833$.

(c) $\hat{y} = 1,0833 \times 12,18 \approx 13,20$.

(d) La prévision naïve sous-estime systématiquement $E(y | x)$ car $\exp(\cdot)$ est une fonction **convexe** : par l'inégalité de Jensen, $E[\exp(\widehat{\log y})] > \exp(E[\widehat{\log y}])$ — la dispersion des résidus autour de la prédiction en logarithme, une fois retransformée en niveau, ajoute systématiquement un supplément positif que la prévision naïve ignore.

Correction — Exercice 6

(a) $650 \pm 1,96 \times 3 = 650 \pm 5,88 = [644,12 ; 655,88]$.

(b) $\text{se}(\hat{e}^0) = \sqrt{3^2 + 45^2} = \sqrt{9 + 2025} = \sqrt{2034} \approx 45,10$. Intervalle de prédiction : $650 \pm 1,96 \times 45,10 \approx 650 \pm 88,40 = [561,60 ; 738,40]$.

(c) L'intervalle de prédiction est bien plus large : sa largeur totale ($\approx 176,8$) est environ 15 fois celle de l'intervalle de confiance pour la moyenne ($\approx 11,8$). La quasi-totalité de l'incertitude provient de $\hat{\sigma} = 45$ (la dispersion individuelle des scores autour de la moyenne du profil), et non de l'incertitude d'estimation ($\text{se}(\hat{y}^0) = 3$, très faible).

(d) Il **sous-estimerait** gravement la véritable incertitude sur le score de cet emprunteur individuel : l'intervalle de confiance ($[644,12 ; 655,88]$) ne concerne que l'incertitude sur la *moyenne* du profil, alors que le score réel d'un emprunteur individuel peut, selon l'intervalle de prédiction, varier bien plus largement, de 561,6 à 738,4.