

Chapitre 2

Régression multiple — estimation

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie avancée

1 Exercices du chapitre

Correction — Exercice 1

- (a) À score ACT identique, un point de moyenne au lycée (hsGPA) en plus est associé à une hausse de 0,453 point de moyenne universitaire (colGPA).
- (b) À moyenne au lycée identique, un point de plus au score ACT est associé à une hausse de 0,0094 point de moyenne universitaire.
- (c) $\widehat{\text{colGPA}} = 1,29 + 0,453 \times 3,2 + 0,0094 \times 24 = 1,29 + 1,4496 + 0,2256 = \mathbf{2,965}$.
- (d) Non, pas nécessairement : si hsGPA et ACT sont corrélés (ce qui est probable, les deux mesurant des aspects proches de la réussite scolaire), le coefficient de hsGPA dans une régression simple (sans contrôler pour ACT) capterait, en partie, l'effet d'ACT transmis par sa corrélation avec hsGPA — exactement le mécanisme du biais de variable omise.

Correction — Exercice 2

- (a) $R_A^2 = 1 - 25,0/40,0 = \mathbf{0,375}$. $R_B^2 = 1 - 24,95/40,0 = \mathbf{0,37625}$. Oui, le R^2 a augmenté (mécaniquement) en ajoutant la troisième variable.
- (b) $\bar{R}_A^2 = 1 - \frac{25,0/(100 - 2 - 1)}{40,0/(100 - 1)} = 1 - \frac{25,0/97}{40,0/99} = 1 - \frac{0,25773}{0,40404} \approx \mathbf{0,3621}$. $\bar{R}_B^2 = 1 - \frac{24,95/(100 - 3 - 1)}{40,0/99} = 1 - \frac{24,95/96}{0,40404} = 1 - \frac{0,25990}{0,40404} \approx \mathbf{0,3568}$.
- (c) Non, au contraire : le R^2 ajusté a **diminué**, passant de 0,3621 à 0,3568, alors même que le R^2 simple augmentait.
- (d) Ce résultat révèle que la troisième variable contribue trop peu à réduire SSR pour compenser la pénalité liée à la perte d'un degré de liberté supplémentaire : elle n'apporte pas d'information utile au modèle, malgré la hausse mécanique et trompeuse du R^2 simple.

Correction — Exercice 3

- (a) Pour S_1 , la corrélation entre x_1 et x_2 (multicolinéarité, mais non parfaite) ne biaise **pas** les estimateurs (MLR.4 reste satisfaite), mais **gonfle leur variance** : il devient statistiquement plus difficile de démêler l'effet propre de chacune des deux variables corrélées.
- (b) Pour S_2 , x_2 est une combinaison linéaire exacte de x_1 ($x_2 = 2x_1 + 3$) : c'est une violation de **MLR.3** (absence de colinéarité parfaite). L'estimation devient impossible car le rang de X chute, rendant $X^\top X$ non inversible — il n'existe alors pas de solution unique à $\hat{\beta} = (X^\top X)^{-1} X^\top y$.
- (c) Pour S_3 , un **bias de variable omise** apparaît : en omettant x_2 (corrélée à x_1 et pertinente pour y), c'est **MLR.4** (exogénéité, $\mathbb{E}[u | x_1] = 0$) qui est violée pour le modèle restreint à x_1 seul.
- (d) Seule S_3 biaise réellement un coefficient estimé. S_1 n'affecte que la précision (la variance) des estimateurs, sans les biaiser. S_2 ne produit même pas d'estimation (le calcul est impossible), ce qui est un problème différent d'un biais.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Si le temps d'étude hebdomadaire (non observé) influence colGPA et est corrélé à hsGPA (par exemple, les étudiants ayant eu de meilleures notes au lycée étudient peut-être aussi davantage à l'université), alors $\hat{\beta}_{\text{hsGPA}} = 0,453$ est **biaisé** : il capture, en partie, l'effet du temps d'étude transmis par sa corrélation avec hsGPA.
- (b) C'est rigoureusement le même mécanisme qu'au chapitre 1 : dans les deux cas, un facteur pertinent et non observé, corrélé à un régresseur inclus dans le modèle, contamine le terme d'erreur et biaise le coefficient de ce régresseur. Seule la dimension du modèle change (un seul régresseur au chapitre 1,

plusieurs ici) — le principe algébrique du biais est identique.

(c) Non : contrôler pour hsGPA et ACT réduit le risque de biais lié à ces deux facteurs spécifiquement, mais ne garantit en rien l'absence de biais dû à **d'autres** facteurs non observés (temps d'étude, motivation, qualité de l'établissement secondaire) qui pourraient rester corrélés aux régresseurs inclus.

(d) Aucun modèle, aussi riche soit-il en régresseurs, ne peut garantir l'absence de biais de variable omise tant qu'un facteur pertinent reste non observé et potentiellement corrélé aux variables incluses — ajouter des contrôles réduit le risque sans jamais l'éliminer complètement par construction.

3 Applications en sciences économiques

Correction — Exercice 5

(a) L'estimation de $\beta_{i,\text{taille}}$ devient **biaisée** : elle capture, en partie, l'effet du facteur sectoriel omis, transmis via sa corrélation avec le facteur taille.

(b) Selon le principe général du biais de variable omise, seul le coefficient du (ou des) régresseur(s) effectivement corrélé(s) au facteur omis est biaisé : si le facteur sectoriel omis n'est pas corrélé à R_M , l'estimation de α_i et $\beta_{i,\text{marché}}$ reste, en principe, non biaisée ; seul $\beta_{i,\text{taille}}$, corrélé au facteur omis, est affecté.

(c) La seule façon d'éliminer ce biais avec certitude est d'**ajouter le facteur sectoriel omis** directement dans le modèle, s'il est observable.

(d) Parce qu'un facteur de risque omis, s'il est corrélé aux facteurs retenus, fausse silencieusement les sensibilités estimées sans qu'aucun signal dans la sortie du modèle (significativité, R^2) ne le révèle nécessairement — l'analyste doit donc examiner activement, à partir de sa connaissance du secteur et de la théorie financière, quels facteurs pertinents pourraient manquer, plutôt que de se fier uniquement à la qualité statistique apparente du modèle estimé.

Correction — Exercice 6

(a) Oui : le R^2 augmente **mécaniquement** avec l'ajout de n'importe quelle variable, qu'elle soit pertinente ou non, puisqu'elle ne peut jamais faire remonter SSR.

(b) Non : le R^2 ajusté peut tout aussi bien **diminuer** si la variable ajoutée (ici, sans lien théorique avec le salaire) ne réduit pas suffisamment SSR pour compenser la perte d'un degré de liberté — exactement le phénomène illustré à l'exercice 2.

(c) Cette pratique est risquée car elle peut introduire de la **multicolinéarité** inutile (si la variable ajoutée est corrélée par hasard à d'autres régresseurs), gonflant la variance des coefficients d'intérêt sans aucun bénéfice explicatif réel, et peut aussi conduire à des interprétations *ceteris paribus* trompeuses si la variable ajoutée n'a aucune justification théorique claire.

(d) Le chercheur devrait privilégier le R^2 **ajusté** plutôt que le R^2 simple pour juger de la contribution réelle d'une variable, tout en s'appuyant avant tout sur une justification **théorique** de la pertinence économique de chaque variable — un critère purement statistique ne remplaçant jamais le raisonnement économique sur ce qui doit figurer dans le modèle.