

Économétrie avancée

Chapitre 2 : Régression multiple : estimation

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Interpréter et prédire avec plusieurs régresseurs

Le cours rapporte $\widehat{\text{colGPA}} = 1,29 + 0,453 \text{ hsGPA} + 0,0094 \text{ ACT}$.

- (a) Interpréter le coefficient 0,453 de hsGPA en une phrase respectant le *ceteris paribus*.
- (b) Interpréter de même le coefficient 0,0094 de ACT.
- (c) Calculer la prédiction $\widehat{\text{colGPA}}$ pour un étudiant avec $\text{hsGPA} = 3,2$ et $\text{ACT} = 24$.
- (d) Une régression simple de colGPA sur hsGPA seul donnerait-elle nécessairement le même coefficient 0,453 pour hsGPA ? Pourquoi (indice : hsGPA et ACT sont-ils probablement corrélés) ?

Exercice 2 — R^2 ajusté : quand il diminue

Un modèle A ($k = 2$ régresseurs, $n = 100$) donne $\text{SSR}_A = 25,0$ pour $\text{SST} = 40,0$. On ajoute un troisième régresseur peu utile, donnant le modèle B ($k = 3$) avec $\text{SSR}_B = 24,95$.

- (a) Calculer R_A^2 et R_B^2 . Le R^2 a-t-il augmenté en ajoutant la troisième variable ?
- (b) Calculer $\bar{R}_A^2 = 1 - \frac{\text{SSR}_A / (n - k_A - 1)}{\text{SST} / (n - 1)}$ et $\bar{R}_B^2$ de la même façon.
- (c) Le R^2 ajusté a-t-il, lui aussi, augmenté ?
- (d) Que révèle ce résultat sur l'utilité réelle de la troisième variable ajoutée au modèle B ?

Exercice 3 — Trois situations, trois diagnostics différents

Trois situations sont décrites pour un modèle à deux régresseurs x_1, x_2 .

- S_1 . x_1 et x_2 sont corrélés à $r = 0,75$, mais $X^T X$ reste inversible.
 - S_2 . $x_2 = 2x_1 + 3$ exactement, pour toutes les observations de l'échantillon.
 - S_3 . Le vrai modèle contient x_1 et x_2 , mais on estime une régression n'incluant que x_1 , alors que x_1 et x_2 sont corrélés.
- (a) Pour S_1 , quelle conséquence la corrélation entre x_1 et x_2 a-t-elle sur le biais et sur la variance des estimateurs ?
 - (b) Pour S_2 , quelle hypothèse de Gauss-Markov (MLR.3) est violée, et pourquoi l'estimation devient-elle impossible ?
 - (c) Pour S_3 , quel problème apparaît, et quelle hypothèse (MLR.4) est en cause ?
 - (d) Parmi ces trois situations, laquelle biaise réellement un coefficient estimé, et lesquelles n'affectent que sa précision ?

2 Exercice cumulatif (chapitre 2 et chapitre 1)

Exercice 4 — Généraliser le biais de variable omise

Le chapitre 1 avait montré que l'aptitude naturelle, omise de la régression salaire-éducation, pouvait biaiser $\hat{\beta}_1$ si elle est corrélée à l'éducation. Ce chapitre généralise ce mécanisme à SLR.4 devenue MLR.4.

- (a) Dans l'exemple colGPA de ce chapitre, si le « temps d'étude hebdomadaire » (non inclus dans le modèle) influence colGPA et est corrélé à hsGPA, quelle conséquence cela a-t-il sur $\hat{\beta}_{\text{hsGPA}} = 0,453$?
- (b) En quoi ce mécanisme est-il rigoureusement le même que celui du chapitre 1 avec l'aptitude naturelle, à ceci près qu'il s'applique maintenant à un modèle à plusieurs régresseurs ?
- (c) Le chapitre 1 concluait que la régression multiple était la piste pour « rapprocher SLR.4 de la

réalité ». Ce chapitre 2, qui contrôle déjà pour hsGPA et ACT, a-t-il pour autant **éliminé** tout risque de biais de variable omise ?

- (d) Quelle est, en une phrase, la limite fondamentale que ni la régression simple ni la régression multiple ne peuvent lever tant que des facteurs pertinents restent non observés ?

3 Applications en sciences économiques

Exercice 5 — Un facteur de risque omis en finance

Un analyste estime un modèle à deux facteurs, $R_i = \alpha_i + \beta_{i,\text{marché}}R_M + \beta_{i,\text{taille}}\text{SMB} + \varepsilon_i$, pour un fonds spécialisé dans un secteur particulier, sans inclure de facteur sectoriel.

- (a) Si le facteur sectoriel omis est corrélé au facteur « taille » (SMB) dans l'échantillon, que devient l'estimation de $\beta_{i,\text{taille}}$?
- (b) Ce biais affecte-t-il également α_i et $\beta_{i,\text{marché}}$, ou seulement le coefficient corrélé au facteur omis (répondre en fonction du principe général du biais de variable omise) ?
- (c) Quelle est la seule façon, selon le cours, d'éliminer ce biais avec certitude ?
- (d) Pourquoi un analyste financier devrait-il toujours se demander « quel facteur de risque ai-je pu oublier » avant d'interpréter les sensibilités estimées d'un modèle multifactoriel ?

Exercice 6 — Ajouter une variable pour se rassurer, à tort

Un chercheur en économie du travail, peu sûr de la robustesse de son modèle salarial, ajoute systématiquement toute variable disponible dans sa base de données, y compris des variables sans lien théorique évident avec le salaire (par exemple, la couleur préférée déclarée par le répondant lors de l'enquête).

- (a) Le R^2 du modèle augmentera-t-il presque certainement après l'ajout de cette variable, même si elle n'a aucun lien réel avec le salaire ?
- (b) Le R^2 ajusté augmentera-t-il nécessairement, lui aussi ?
- (c) Pourquoi cette pratique (« tout ajouter ») est-elle risquée, au-delà de la seule question du R^2 ajusté, du point de vue de l'interprétation *ceteris paribus* des autres coefficients ?
- (d) Quel critère, plus fiable que le simple R^2 , le chercheur devrait-il utiliser pour juger si une variable mérite réellement de figurer dans le modèle ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) À score ACT identique, un point de moyenne au lycée (hsGPA) en plus est associé à une hausse de 0,453 point de moyenne universitaire (colGPA).
- (b) À moyenne au lycée identique, un point de plus au score ACT est associé à une hausse de 0,0094 point de moyenne universitaire.
- (c) $\widehat{\text{colGPA}} = 1,29 + 0,453 \times 3,2 + 0,0094 \times 24 = 1,29 + 1,4496 + 0,2256 = \mathbf{2,965}$.
- (d) Non, pas nécessairement : si hsGPA et ACT sont corrélés (ce qui est probable, les deux mesurant des aspects proches de la réussite scolaire), le coefficient de hsGPA dans une régression simple (sans contrôler pour ACT) capterait, en partie, l'effet d'ACT transmis par sa corrélation avec hsGPA — exactement le mécanisme du biais de variable omise.

Correction — Exercice 2

- (a) $R_A^2 = 1 - 25,0/40,0 = \mathbf{0,375}$. $R_B^2 = 1 - 24,95/40,0 = \mathbf{0,37625}$. Oui, le R^2 a augmenté (mécaniquement) en ajoutant la troisième variable.
- (b) $\bar{R}_A^2 = 1 - \frac{25,0/(100 - 2 - 1)}{40,0/(100 - 1)} = 1 - \frac{25,0/97}{40,0/99} = 1 - \frac{0,25773}{0,40404} \approx \mathbf{0,3621}$. $\bar{R}_B^2 = 1 - \frac{24,95/(100 - 3 - 1)}{40,0/99} = 1 - \frac{24,95/96}{0,40404} = 1 - \frac{0,25990}{0,40404} \approx \mathbf{0,3568}$.
- (c) Non, au contraire : le R^2 ajusté a **diminué**, passant de 0,3621 à 0,3568, alors même que le R^2 simple augmentait.
- (d) Ce résultat révèle que la troisième variable contribue trop peu à réduire SSR pour compenser la pénalité liée à la perte d'un degré de liberté supplémentaire : elle n'apporte pas d'information utile au modèle, malgré la hausse mécanique et trompeuse du R^2 simple.

Correction — Exercice 3

- (a) Pour S_1 , la corrélation entre x_1 et x_2 (multicolinéarité, mais non parfaite) ne biaise **pas** les estimateurs (MLR.4 reste satisfaite), mais **gonfle leur variance** : il devient statistiquement plus difficile de démêler l'effet propre de chacune des deux variables corrélées.
- (b) Pour S_2 , x_2 est une combinaison linéaire exacte de x_1 ($x_2 = 2x_1 + 3$) : c'est une violation de **MLR.3** (absence de colinéarité parfaite). L'estimation devient impossible car le rang de X chute, rendant $X^T X$ non inversible — il n'existe alors pas de solution unique à $\hat{\beta} = (X^T X)^{-1} X^T y$.
- (c) Pour S_3 , un **bias de variable omise** apparaît : en omettant x_2 (corrélée à x_1 et pertinente pour y), c'est **MLR.4** (exogénéité, $\mathbb{E}[u | x_1] = 0$) qui est violée pour le modèle restreint à x_1 seul.
- (d) Seule S_3 biaise réellement un coefficient estimé. S_1 n'affecte que la précision (la variance) des estimateurs, sans les biaiser. S_2 ne produit même pas d'estimation (le calcul est impossible), ce qui est un problème différent d'un biais.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Si le temps d'étude hebdomadaire (non observé) influence colGPA et est corrélé à hsGPA (par exemple, les étudiants ayant eu de meilleures notes au lycée étudient peut-être aussi davantage à l'université), alors $\hat{\beta}_{\text{hsGPA}} = 0,453$ est **biaisé** : il capture, en partie, l'effet du temps d'étude transmis par sa corrélation avec hsGPA.
- (b) C'est rigoureusement le même mécanisme qu'au chapitre 1 : dans les deux cas, un facteur pertinent et non observé, corrélé à un régresseur inclus dans le modèle, contamine le terme d'erreur et biaise le coefficient de ce régresseur. Seule la dimension du modèle change (un seul régresseur au chapitre 1,

plusieurs ici) — le principe algébrique du biais est identique.

(c) Non : contrôler pour hsGPA et ACT réduit le risque de biais lié à ces deux facteurs spécifiquement, mais ne garantit en rien l'absence de biais dû à **d'autres** facteurs non observés (temps d'étude, motivation, qualité de l'établissement secondaire) qui pourraient rester corrélés aux régresseurs inclus.

(d) Aucun modèle, aussi riche soit-il en régresseurs, ne peut garantir l'absence de biais de variable omise tant qu'un facteur pertinent reste non observé et potentiellement corrélé aux variables incluses — ajouter des contrôles réduit le risque sans jamais l'éliminer complètement par construction.

3 Applications en sciences économiques

Correction — Exercice 5

(a) L'estimation de $\beta_{i,\text{taille}}$ devient **biaisée** : elle capture, en partie, l'effet du facteur sectoriel omis, transmis via sa corrélation avec le facteur taille.

(b) Selon le principe général du biais de variable omise, seul le coefficient du (ou des) régresseur(s) effectivement corrélé(s) au facteur omis est biaisé : si le facteur sectoriel omis n'est pas corrélé à R_M , l'estimation de α_i et $\beta_{i,\text{marché}}$ reste, en principe, non biaisée ; seul $\beta_{i,\text{taille}}$, corrélé au facteur omis, est affecté.

(c) La seule façon d'éliminer ce biais avec certitude est d'**ajouter le facteur sectoriel omis** directement dans le modèle, s'il est observable.

(d) Parce qu'un facteur de risque omis, s'il est corrélé aux facteurs retenus, fausse silencieusement les sensibilités estimées sans qu'aucun signal dans la sortie du modèle (significativité, R^2) ne le révèle nécessairement — l'analyste doit donc examiner activement, à partir de sa connaissance du secteur et de la théorie financière, quels facteurs pertinents pourraient manquer, plutôt que de se fier uniquement à la qualité statistique apparente du modèle estimé.

Correction — Exercice 6

(a) Oui : le R^2 augmente **mécaniquement** avec l'ajout de n'importe quelle variable, qu'elle soit pertinente ou non, puisqu'elle ne peut jamais faire remonter SSR.

(b) Non : le R^2 ajusté peut tout aussi bien **diminuer** si la variable ajoutée (ici, sans lien théorique avec le salaire) ne réduit pas suffisamment SSR pour compenser la perte d'un degré de liberté — exactement le phénomène illustré à l'exercice 2.

(c) Cette pratique est risquée car elle peut introduire de la **multicolinéarité** inutile (si la variable ajoutée est corrélée par hasard à d'autres régresseurs), gonflant la variance des coefficients d'intérêt sans aucun bénéfice explicatif réel, et peut aussi conduire à des interprétations *ceteris paribus* trompeuses si la variable ajoutée n'a aucune justification théorique claire.

(d) Le chercheur devrait privilégier le R^2 **ajusté** plutôt que le R^2 simple pour juger de la contribution réelle d'une variable, tout en s'appuyant avant tout sur une justification **théorique** de la pertinence économique de chaque variable — un critère purement statistique ne remplaçant jamais le raisonnement économique sur ce qui doit figurer dans le modèle.