

# Économétrie avancée

## Chapitre 2 : Régression multiple — estimation

Jaouad Madkour

25 septembre 2026

### Plan du chapitre

|                                                 |          |
|-------------------------------------------------|----------|
| <b>Avant de commencer</b>                       | <b>1</b> |
| Pourquoi ce chapitre . . . . .                  | 1        |
| <b>Le modèle et son estimation</b>              | <b>2</b> |
| Spécification et écriture matricielle . . . . . | 2        |
| <b>Les hypothèses de Gauss-Markov</b>           | <b>2</b> |
| Non-biais et efficacité . . . . .               | 2        |
| Le biais de variable omise . . . . .            | 3        |
| Multicollinéarité . . . . .                     | 3        |
| <b>Qualité de l'ajustement</b>                  | <b>3</b> |
| $R^2$ ajusté . . . . .                          | 3        |
| <b>Synthèse</b>                                 | <b>4</b> |
| Ce qu'il faut retenir . . . . .                 | 4        |

### Avant de commencer

#### Pourquoi ce chapitre

##### Pourquoi ce chapitre ?

La régression simple ne peut contrôler qu'un seul facteur à la fois — une hypothèse SLR.4 rarement crédible. La régression **multiple** contrôle simultanément plusieurs facteurs, rapprochant l'analyse *ceteris paribus* d'une véritable comparaison « toutes choses égales par ailleurs ».

## Le modèle et son estimation

### Spécification et écriture matricielle

#### Modèle de régression multiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u,$$

ou, sous forme matricielle (l'introduction, algèbre linéaire),  $y = X\beta + u$  où  $X$  est la matrice  $n \times (k + 1)$  des régresseurs (une colonne de 1 pour l'intercept, puis une colonne par  $x_j$ ).

#### L'estimateur MCO en notation matricielle

En minimisant  $\sum_i \hat{u}_i^2 = (y - X\hat{\beta})^\top (y - X\hat{\beta})$ , les conditions du premier ordre donnent

$$\hat{\beta} = (X^\top X)^{-1} X^\top y,$$

qui n'existe que si  $X^\top X$  est **inversible** (chapitre 3, algèbre linéaire) — c'est-à-dire si aucun régresseur n'est combinaison linéaire exacte des autres.

#### Chaque $\beta_j$ , toutes choses égales par ailleurs

$\hat{\beta}_j$  mesure l'effet d'une hausse d'une unité de  $x_j$  sur  $y$ , **en maintenant fixes tous les autres régresseurs du modèle** — l'interprétation *ceteris paribus* que la régression simple ne pouvait offrir qu'imparfaitement.

#### Exemple : la moyenne au collège

Sur des données universitaires américaines, la régression de la moyenne au collège (colGPA) sur la moyenne au lycée (hsGPA) et le score à un test d'aptitude (ACT) donne

$$\widehat{\text{colGPA}} = 1,29 + 0,453 \text{ hsGPA} + 0,0094 \text{ ACT}.$$

À score ACT identique, un point de moyenne au lycée en plus est associé à 0,453 point de moyenne universitaire en plus — un effet estimé **en tenant compte** du niveau ACT, ce qu'une régression simple sur hsGPA seul ne pourrait pas garantir.

## Les hypothèses de Gauss-Markov

### Non-biais et efficacité

#### Hypothèses MLR

- **MLR.1–2** : linéarité en les paramètres, échantillonnage aléatoire.
- **MLR.3** (absence de colinéarité parfaite) : aucun  $x_j$  n'est une combinaison linéaire exacte des autres régresseurs.
- **MLR.4** (exogénéité) :  $\mathbb{E}[u \mid x_1, \dots, x_k] = 0$ .
- **MLR.5** (homoscédasticité) :  $\text{Var}(u \mid x_1, \dots, x_k) = \sigma^2$ , constante.

### Théorème de Gauss-Markov

Sous MLR.1 à MLR.4, l'estimateur MCO est **non biaisé** :  $\mathbb{E}[\hat{\beta}_j] = \beta_j$ . Sous MLR.1 à MLR.5 (l'ensemble complet), l'estimateur MCO est en outre le meilleur estimateur linéaire non biaisé (**BLUE** — *Best Linear Unbiased Estimator*) : parmi tous les estimateurs linéaires et non biaisés de  $\beta_j$ , il a la **variance la plus faible**.

## Le biais de variable omise

### Que se passe-t-il si l'on oublie un facteur pertinent ?

Si le « vrai » modèle contient  $x_1$  et  $x_2$ , mais qu'on estime une régression n'incluant que  $x_1$ , l'estimateur de son coefficient est biaisé dès que  $x_1$  et  $x_2$  sont corrélés — l'estimateur simple capture alors, en partie, l'effet de  $x_2$  « transmis » via sa corrélation avec  $x_1$ . C'est le **bias de variable omise**, la généralisation directe du problème rencontré au chapitre 1.

## Multicollinéarité

### Corrélation entre régresseurs : pas de biais, mais de la variance

Une forte corrélation entre régresseurs (**multicolinéarité**) ne biaise **pas** les MCO (MLR.4 reste satisfaite), mais **gonfle la variance** des estimateurs : il devient statistiquement difficile de démêler l'effet propre de chaque variable corrélée. Un cas extrême — une corrélation parfaite — viole directement MLR.3 et rend l'estimation impossible (chapitre 2, algèbre linéaire : le rang de  $X$  chute,  $X^\top X$  n'est plus inversible).

## Qualité de l'ajustement

### $R^2$ ajusté

#### $R^2$ ajusté

Le  $R^2$  **augmente mécaniquement** avec chaque variable ajoutée, utile ou non. Le  $R^2$  ajusté pénalise l'ajout de régresseurs :

$$\bar{R}^2 = 1 - \frac{SSR/(n - k - 1)}{SST/(n - 1)},$$

et peut **diminuer** si la variable ajoutée contribue trop peu à réduire  $SSR$  — un critère de comparaison de modèles plus fiable que le  $R^2$  simple.

### Application en finance : le modèle multifactoriel

Le modèle multifactoriel de l'introduction (économétrie financière),  $R_i = \alpha_i + \sum_k \beta_{ik} F_k + \varepsilon_i$ , est une régression multiple standard : chaque  $\beta_{ik}$  s'interprète *ceteris paribus* — la sensibilité de l'actif au facteur  $k$ , en tenant les autres facteurs constants. Le biais de variable omise y prend un sens concret : oublier un facteur de risque pertinent (par exemple un facteur sectoriel) dans le modèle fausse l'estimation des sensibilités aux facteurs retenus, dès que ce facteur omis est corrélé avec eux.

# Synthèse

## Ce qu'il faut retenir

### L'essentiel du chapitre 2

- $\hat{\beta} = (X^\top X)^{-1} X^\top y$  ; chaque coefficient s'interprète *ceteris paribus*.
- Gauss-Markov : non-biais sous MLR.1–4 ; BLUE (variance minimale parmi les estimateurs linéaires non biaisés) sous MLR.1–5.
- Le biais de variable omise apparaît dès qu'un facteur pertinent, corrélé aux régresseurs inclus, est oublié.
- La multicollinéarité gonfle la variance sans biaiser ; le  $R^2$  ajusté pénalise l'ajout de régresseurs peu utiles.

### Vers le chapitre 3

Estimer un coefficient ne suffit pas : encore faut-il savoir s'il est **statistiquement significatif**, et construire des intervalles de confiance fiables. C'est l'objet de l'inférence.