

Économétrie avancée

Chapitre 1 : Le modèle de régression simple

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer les MCO à la main

Un échantillon de $n = 5$ travailleurs donne les années d'éducation $x = (10, 12, 14, 16, 18)$ et le salaire horaire en dollars $y = (6, 8, 9, 13, 15)$.

- Calculer $\bar{x}$ et $\bar{y}$.
- Calculer $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ et $S_{xx} = \sum_i (x_i - \bar{x})^2$.
- En déduire $\hat{\beta}_1 = S_{xy}/S_{xx}$ et $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.
- Interpréter $\hat{\beta}_1$ en une phrase. L'intercept $\hat{\beta}_0$ a-t-il un sens économique direct ici, sachant qu'aucun travailleur de l'échantillon n'a moins de dix années d'éducation ?

Exercice 2 — Décomposer la variance et lire le R^2

En reprenant les données et les résultats de l'exercice 1 ($\hat{\beta}_0 \approx -5,90$, $\hat{\beta}_1 = 1,15$).

- Calculer les valeurs ajustées $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ pour les cinq observations.
- Calculer $SST = \sum_i (y_i - \bar{y})^2$, $SSE = \sum_i (\hat{y}_i - \bar{y})^2$, $SSR = \sum_i \hat{u}_i^2$.
- Vérifier que $SST = SSE + SSR$ (aux arrondis près), et en déduire R^2 .
- Ce R^2 est-il élevé ou modeste ? Le cours avertit qu'un R^2 faible « n'est pas nécessairement mauvais » en coupe transversale : pourquoi un R^2 modeste n'invalide-t-il pas, en soi, l'estimation d'un effet *ceteris paribus* ?

Exercice 3 — Lire un coefficient log-linéaire

Sur l'échantillon de 526 travailleurs du cours, la régression $\log(\text{salaire}) = 0,584 + 0,083 \text{éduc}$ donne $R^2 = 0,186$.

- Interpréter le coefficient 0,083 en pourcentage.
- Ce $R^2 = 0,186$ porte-t-il sur le salaire en niveau ou sur son logarithme ?
- Le cours rapporte, sur les mêmes données, un modèle en niveau $\widehat{\text{salaire}} = -0,90 + 0,54 \text{éduc}$. Peut-on comparer directement le R^2 de ce modèle en niveau à celui du modèle log-linéaire pour décider lequel « explique mieux » le salaire ?
- Pourquoi le modèle log-linéaire est-il particulièrement adapté pour exprimer un « rendement » économique (ici, le rendement de l'éducation) ?

2 Exercice cumulatif (chapitre 1 et introduction)

Exercice 4 — SLR.4 et le problème de l'introduction

L'introduction du cours illustre, avec l'exemple de la formation professionnelle, comment un facteur non observé (la motivation) peut biaiser une comparaison brute. Ce chapitre formalise cette même idée sous l'hypothèse SLR.4 : $\mathbb{E}[u | x] = 0$.

- Dans la régression $\text{salaire} = \beta_0 + \beta_1 \text{éduc} + u$, quel facteur non observé, cité explicitement par ce chapitre, pourrait à la fois influencer le salaire et être corrélé au niveau d'éducation ?
- Si ce facteur (l'aptitude naturelle) est positivement lié à la fois à l'éducation et au salaire, SLR.4 est-elle respectée ?
- Quelle conséquence cela a-t-il sur l'estimateur $\hat{\beta}_1$ obtenu par MCO : reste-t-il centré sur le vrai effet *ceteris paribus* de l'éducation sur le salaire ?
- L'introduction du cours indiquait que la méthode économétrique cherche à « compenser » l'absence de contrôle expérimental. Quelle est la piste que ce chapitre annonce explicitement pour rapprocher SLR.4 de la réalité, développée au chapitre suivant ?

3 Applications en sciences économiques

Exercice 5 — Le modèle de marché est une régression simple

En finance, le modèle de marché s'écrit $R_i = \alpha_i + \beta_i R_M + \varepsilon_i$, où R_i est le rendement d'un actif et R_M le rendement du marché.

- (a) En quoi ce modèle a-t-il exactement la forme d'une régression simple $y = \beta_0 + \beta_1 x + u$?
- (b) Le cours affirme que β_i s'interprète « directement comme l'élasticité du rendement de l'actif au rendement du marché ». Pourquoi cette interprétation en termes d'élasticité est-elle naturelle, sachant que R_i et R_M sont eux-mêmes des variations logarithmiques de prix ?
- (c) Un actif avec $\hat{\beta}_i = 1,4$ amplifie-t-il ou atténue-t-il les mouvements du marché ?
- (d) Pourquoi la forme log-linéaire, plutôt que la forme en niveau des prix, est-elle la forme naturelle pour ce type de modèle en finance ?

Exercice 6 — Un R^2 modeste, une conclusion tout de même utile

Une étude en coupe transversale sur 300 entreprises régresse la croissance annuelle du chiffre d'affaires sur les dépenses de recherche et développement (R&D) rapportées au chiffre d'affaires, et obtient $R^2 = 0,09$, avec un coefficient positif et significatif.

- (a) Un R^2 de 0,09 signifie que le modèle explique quelle proportion de la variation de la croissance du chiffre d'affaires entre les entreprises ?
- (b) Ce R^2 modeste signifie-t-il que le coefficient estimé de la R&D est nécessairement peu fiable ou peu informatif ?
- (c) Pourquoi s'attend-on, de façon générale, à des R^2 plus modestes sur des données de coupe transversale (comme ici, des entreprises à un instant donné) que sur des séries temporelles agrégées ?
- (d) Quelle serait l'erreur d'un analyste qui rejetterait ce résultat au seul motif que « 91 % de la variation reste inexpliquée » ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\bar{x} = (10 + 12 + 14 + 16 + 18)/5 = 14$. $\bar{y} = (6 + 8 + 9 + 13 + 15)/5 = 10,2$.
(b) $S_{xy} = (-4)(-4,2) + (-2)(-2,2) + (0)(-1,2) + (2)(2,8) + (4)(4,8) = 16,8 + 4,4 + 0 + 5,6 + 19,2 = 46$.
 $S_{xx} = 16 + 4 + 0 + 4 + 16 = 40$.
(c) $\hat{\beta}_1 = 46/40 = 1,15$. $\hat{\beta}_0 = 10,2 - 1,15 \times 14 = 10,2 - 16,1 = -5,90$.
(d) Chaque année d'éducation supplémentaire est associée à une hausse prédite du salaire horaire de 1,15 \$. L'intercept $\hat{\beta}_0 = -5,90$ n'a pas de sens économique direct (un salaire négatif est impossible) : il correspond à une extrapolation en dehors du domaine observé des x_i , puisqu'aucun travailleur de l'échantillon n'a moins de dix années d'éducation.

Correction — Exercice 2

- (a) $\hat{y} = (-5,9 + 1,15 \times 10, \dots) = (5,6, 7,9, 10,2, 12,5, 14,8)$.
(b) $SST = (6 - 10,2)^2 + (8 - 10,2)^2 + (9 - 10,2)^2 + (13 - 10,2)^2 + (15 - 10,2)^2 = 17,64 + 4,84 + 1,44 + 7,84 + 23,04 = 54,80$. $SSE = (5,6 - 10,2)^2 + (7,9 - 10,2)^2 + (10,2 - 10,2)^2 + (12,5 - 10,2)^2 + (14,8 - 10,2)^2 = 21,16 + 5,29 + 0 + 5,29 + 21,16 = 52,90$. $SSR = (6 - 5,6)^2 + (8 - 7,9)^2 + (9 - 10,2)^2 + (13 - 12,5)^2 + (15 - 14,8)^2 = 0,16 + 0,01 + 1,44 + 0,25 + 0,04 = 1,90$.
(c) $SSE + SSR = 52,90 + 1,90 = 54,80 = SST$: l'identité est vérifiée exactement. $R^2 = SSE/SST = 52,90/54,80 \approx 0,965$.
(d) Ce R^2 de 0,965 est très élevé — attendu sur un petit échantillon construit pour l'exercice, où la relation entre éducation et salaire est presque parfaitement linéaire. Sur des données réelles en coupe transversale, avec des centaines d'individus, un R^2 modeste (par exemple 0,186 comme au chapitre pour le modèle log-linéaire) n'invalide pas l'estimation de l'effet *ceteris paribus* : le R^2 mesure la part de la variation **individuelle** expliquée, qui reste naturellement faible quand d'innombrables facteurs propres à chaque individu (motivation, réseau, chance) influencent le salaire sans être dans le modèle — cela n'empêche pas $\hat{\beta}_1$ d'être un estimateur non biaisé du vrai effet moyen de l'éducation, sous SLR.1 à SLR.4.

Correction — Exercice 3

- (a) Une année d'éducation supplémentaire est associée à une hausse d'environ $100 \times 0,083 = 8,3\%$ du salaire.
(b) Ce R^2 porte sur le **logarithme** du salaire, pas sur le salaire en niveau.
(c) Non : les deux R^2 (celui du modèle en niveau et celui du modèle log-linéaire) ne sont pas comparables, car ils mesurent la part de variance expliquée de deux variables différentes (salaire contre $\log(\text{salaire})$), sur des échelles différentes.
(d) La forme log-linéaire est adaptée à un « rendement » car un rendement économique s'exprime naturellement en termes **relatifs** (un pourcentage de hausse), et non en unités absolues : dire qu'une année d'éducation « rapporte » 8,3 % de salaire en plus a un sens économique clair et comparable d'un individu à l'autre, alors qu'un même montant en dollars n'aurait pas la même signification selon le niveau de salaire de départ.

2 Exercice cumulatif

Correction — Exercice 4

- (a) L'**aptitude naturelle** (ou capacité cognitive) du travailleur, explicitement citée par ce chapitre, pourrait à la fois influencer le salaire (les personnes plus aptes sont souvent plus productives) et être corrélée au niveau d'éducation (les personnes plus aptes poursuivent souvent des études plus longues).

(b) Non : si l'aptitude est positivement liée à la fois à l'éducation et au salaire, alors $\mathbb{E}[u | x] \neq 0$ — SLR.4 est violée, puisque le terme d'erreur (qui contient l'aptitude non observée) est corrélé à la variable explicative (l'éducation).

(c) Non : l'estimateur $\hat{\beta}_1$ obtenu par MCO devient **biaisé** — il capture, en partie, l'effet de l'aptitude naturelle en plus de l'effet propre de l'éducation, et surestime donc probablement le vrai rendement *ceteris paribus* de l'éducation sur le salaire.

(d) Ce chapitre annonce explicitement la régression **multiple** (chapitre 2), qui permet de contrôler pour davantage de facteurs simultanément, rapprochant ainsi SLR.4 de la réalité en réduisant le risque qu'un facteur pertinent reste omis et corrélé à la variable d'intérêt.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Ce modèle a exactement la forme $y = \beta_0 + \beta_1 x + u$ en posant $y = R_i$ (le rendement de l'actif, variable expliquée), $x = R_M$ (le rendement du marché, variable explicative), $\beta_0 = \alpha_i$ et $\beta_1 = \beta_i$, et $u = \varepsilon_i$ le terme d'erreur.

(b) Puisque R_i et R_M sont eux-mêmes des variations logarithmiques de prix (des rendements), le coefficient β_i mesure directement la variation **relative** du rendement de l'actif pour une variation relative donnée du rendement du marché — exactement la définition d'une élasticité, sans qu'il soit nécessaire de passer soi-même par une transformation logarithmique supplémentaire (elle est déjà incorporée dans la définition même des rendements).

(c) Un $\hat{\beta}_i = 1,4 > 1$ signifie que l'actif **amplifie** les mouvements du marché : une hausse (ou une baisse) de 1 % du marché est associée, en moyenne, à une variation de 1,4 % du rendement de l'actif.

(d) La forme log-linéaire est naturelle en finance car les rendements eux-mêmes sont, par construction, des écarts logarithmiques de prix ; travailler directement en niveaux de prix poserait des problèmes d'échelle (des actifs à des niveaux de prix très différents ne seraient pas comparables) et ne permettrait pas l'interprétation directe en pourcentage qu'offre le cadre des rendements.

Correction — Exercice 6

(a) Un R^2 de 0,09 signifie que le modèle explique environ 9 % de la variation de la croissance du chiffre d'affaires **entre les entreprises** de l'échantillon.

(b) Non : un R^2 modeste ne signifie pas que le coefficient estimé est peu fiable ou peu informatif — la fiabilité d'un coefficient se juge par sa précision (son écart-type, sa significativité statistique), pas par la part de variance totale expliquée par l'ensemble du modèle. Un coefficient peut être estimé avec précision et significativité même quand le modèle n'explique qu'une faible part de la variation totale.

(c) Sur des données de coupe transversale, chaque entreprise (ou individu) est affectée par d'innombrables facteurs propres et non observés (qualité du management, conjoncture spécifique au secteur, chance) qui créent une forte variation individuelle inexpliquée ; sur des séries temporelles agrégées, ces variations individuelles ont tendance à se compenser ou à suivre des tendances communes, produisant souvent des R^2 plus élevés.

(d) L'erreur serait de confondre la qualité de l'**ajustement global** du modèle avec la validité de l'effet *ceteris paribus* estimé pour la R&D : un coefficient positif et significatif reste une information économique utile et statistiquement fondée, même si 91 % de la variation de la croissance du chiffre d'affaires provient d'autres facteurs non inclus dans ce modèle simple.