

Chapitre 1

Le modèle de régression simple

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie avancée

1 Exercices du chapitre

Exercice 1 — Calculer les MCO à la main

Un échantillon de $n = 5$ travailleurs donne les années d'éducation $x = (10, 12, 14, 16, 18)$ et le salaire horaire en dollars $y = (6, 8, 9, 13, 15)$.

- Calculer $\bar{x}$ et $\bar{y}$.
- Calculer $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ et $S_{xx} = \sum_i (x_i - \bar{x})^2$.
- En déduire $\hat{\beta}_1 = S_{xy}/S_{xx}$ et $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$.
- Interpréter $\hat{\beta}_1$ en une phrase. L'intercept $\hat{\beta}_0$ a-t-il un sens économique direct ici, sachant qu'aucun travailleur de l'échantillon n'a moins de dix années d'éducation ?

Exercice 2 — Décomposer la variance et lire le R^2

En reprenant les données et les résultats de l'exercice 1 ($\hat{\beta}_0 \approx -5,90$, $\hat{\beta}_1 = 1,15$).

- Calculer les valeurs ajustées $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ pour les cinq observations.
- Calculer $SST = \sum_i (y_i - \bar{y})^2$, $SSE = \sum_i (\hat{y}_i - \bar{y})^2$, $SSR = \sum_i \hat{u}_i^2$.
- Vérifier que $SST = SSE + SSR$ (aux arrondis près), et en déduire R^2 .
- Ce R^2 est-il élevé ou modeste ? Le cours avertit qu'un R^2 faible « n'est pas nécessairement mauvais » en coupe transversale : pourquoi un R^2 modeste n'invalide-t-il pas, en soi, l'estimation d'un effet *ceteris paribus* ?

Exercice 3 — Lire un coefficient log-linéaire

Sur l'échantillon de 526 travailleurs du cours, la régression $\log(\text{salaire}) = 0,584 + 0,083 \text{ édu}$ donne $R^2 = 0,186$.

- Interpréter le coefficient 0,083 en pourcentage.
- Ce $R^2 = 0,186$ porte-t-il sur le salaire en niveau ou sur son logarithme ?
- Le cours rapporte, sur les mêmes données, un modèle en niveau $\widehat{\text{salaire}} = -0,90 + 0,54 \text{ édu}$. Peut-on comparer directement le R^2 de ce modèle en niveau à celui du modèle log-linéaire pour décider lequel « explique mieux » le salaire ?
- Pourquoi le modèle log-linéaire est-il particulièrement adapté pour exprimer un « rendement » économique (ici, le rendement de l'éducation) ?

2 Exercice cumulatif (chapitre 1 et introduction)

Exercice 4 — SLR.4 et le problème de l'introduction

L'introduction du cours illustre, avec l'exemple de la formation professionnelle, comment un facteur non observé (la motivation) peut biaiser une comparaison brute. Ce chapitre formalise cette même idée sous l'hypothèse SLR.4 : $\mathbb{E}[u | x] = 0$.

- Dans la régression $\text{salaire} = \beta_0 + \beta_1 \text{édu} + u$, quel facteur non observé, cité explicitement par ce chapitre, pourrait à la fois influencer le salaire et être corrélé au niveau d'éducation ?
- Si ce facteur (l'aptitude naturelle) est positivement lié à la fois à l'éducation et au salaire, SLR.4 est-elle respectée ?
- Quelle conséquence cela a-t-il sur l'estimateur $\hat{\beta}_1$ obtenu par MCO : reste-t-il centré sur le vrai effet *ceteris paribus* de l'éducation sur le salaire ?
- L'introduction du cours indiquait que la méthode économétrique cherche à « compenser » l'absence de contrôle expérimental. Quelle est la piste que ce chapitre annonce explicitement pour rapprocher SLR.4 de la réalité, développée au chapitre suivant ?

3 Applications en sciences économiques

Exercice 5 — Le modèle de marché est une régression simple

En finance, le modèle de marché s'écrit $R_i = \alpha_i + \beta_i R_M + \varepsilon_i$, où R_i est le rendement d'un actif et R_M le rendement du marché.

- (a) En quoi ce modèle a-t-il exactement la forme d'une régression simple $y = \beta_0 + \beta_1 x + u$?
- (b) Le cours affirme que β_i s'interprète « directement comme l'élasticité du rendement de l'actif au rendement du marché ». Pourquoi cette interprétation en termes d'élasticité est-elle naturelle, sachant que R_i et R_M sont eux-mêmes des variations logarithmiques de prix ?
- (c) Un actif avec $\hat{\beta}_i = 1,4$ amplifie-t-il ou atténue-t-il les mouvements du marché ?
- (d) Pourquoi la forme log-linéaire, plutôt que la forme en niveau des prix, est-elle la forme naturelle pour ce type de modèle en finance ?

Exercice 6 — Un R^2 modeste, une conclusion tout de même utile

Une étude en coupe transversale sur 300 entreprises régresse la croissance annuelle du chiffre d'affaires sur les dépenses de recherche et développement (R&D) rapportées au chiffre d'affaires, et obtient $R^2 = 0,09$, avec un coefficient positif et significatif.

- (a) Un R^2 de 0,09 signifie que le modèle explique quelle proportion de la variation de la croissance du chiffre d'affaires entre les entreprises ?
- (b) Ce R^2 modeste signifie-t-il que le coefficient estimé de la R&D est nécessairement peu fiable ou peu informatif ?
- (c) Pourquoi s'attend-on, de façon générale, à des R^2 plus modestes sur des données de coupe transversale (comme ici, des entreprises à un instant donné) que sur des séries temporelles agrégées ?
- (d) Quelle serait l'erreur d'un analyste qui rejeterait ce résultat au seul motif que « 91 % de la variation reste inexpliquée » ?