

# Chapitre 8

Problèmes de spécification et de données

**Corrigé**

---

**Jaouad Madkour**

Faculté d'Économie et de Gestion de Tanger  
Exercices et corrigés · Économétrie avancée

## 1 Exercices du chapitre

### Correction — Exercice 1

- (a)  $F = \frac{(334,17 - 300,00)/2}{300,00/(88 - 3 - 3)} = \frac{34,17/2}{300,00/82} = \frac{17,085}{3,6585} \approx 4,67$ , conforme au RESET rapporté par le cours.
- (b) Oui :  $4,67 > 3,11$ ,  $H_0 : \delta_1 = \delta_2 = 0$  est **rejetée** au seuil de 5 % — le modèle en niveau souffre d'une non-linéarité négligée.
- (c)  $F = \frac{(318,73 - 300,00)/2}{300,00/82} = \frac{18,73/2}{3,6585} = \frac{9,365}{3,6585} \approx 2,56$ , conforme au RESET rapporté par le cours pour le modèle log-log.
- (d) Non :  $2,56 < 3,11$ ,  $H_0$  n'est **pas rejetée** au seuil de 5 % pour le modèle log-log (cohérent avec le  $p = 0,084$  du cours, supérieur à 0,05). Le RESET oriente donc vers la spécification log-log, moins entachée de non-linéarité négligée que la spécification en niveau.
- (e) Non : un rejet du RESET indique seulement qu'une forme de non-linéarité est négligée dans la relation entre  $y$  et les régresseurs inclus — il ne dit pas laquelle (terme quadratique manquant, transformation logarithmique nécessaire, interaction omise...). Le chercheur doit ensuite explorer plusieurs spécifications alternatives pour identifier la source précise.

### Correction — Exercice 2

- (a)  $\frac{64}{64 + 16} = \frac{64}{80} = 0,80$ .
- (b)  $\text{plim}(\hat{\beta}_1) = 2 \times 0,80 = 1,60$ . Atténuation =  $100 \times (1 - 0,80) = 20\%$  : le coefficient estimé sous-estime de 20 % la vraie valeur  $\beta_1 = 2$ .
- (c)  $\frac{64}{64 + 48} = \frac{64}{112} \approx 0,5714$ .  $\text{plim}(\hat{\beta}_1) = 2 \times 0,5714 \approx 1,143$ . Atténuation =  $100 \times (1 - 0,5714) \approx 42,86\%$ .
- (d) Plus l'erreur de mesure est importante relativement à la variance du signal réel ( $\text{Var}(x_1^*)$ ), plus le biais d'atténuation est sévère : une mesure grossière (ici, une variance d'erreur multipliée par 3) ne fait pas que rajouter du bruit, elle rapproche systématiquement  $\hat{\beta}_1$  de zéro, ici de 20 % à près de 43 % d'atténuation.

### Correction — Exercice 3

- (a)  $\text{Var}(v) = \text{Var}(u) + \text{Var}(e_0) = 100 + 44 = 144$ .
- (b) Facteur multiplicatif sur l'écart-type =  $\sqrt{144/100} = \sqrt{1,44} = 1,20$ , soit une hausse de 20 % de l'écart-type des coefficients MCO (et donc des erreurs-types rapportées) par rapport au cas sans erreur de mesure sur  $y$ .
- (c) Oui : tant que  $e_0$  est indépendante des régresseurs, les MCO restent non biaisés et convergents — seule la variance de l'erreur composite augmente (question a), ce qui gonfle les erreurs-types sans introduire de biais sur les coefficients eux-mêmes.
- (d) C'est une sélection **endogène** : le critère de restriction (patrimoine inférieur à un seuil) porte directement sur la variable **dépendante** de l'étude. Cette restriction biaise systématiquement les MCO, car elle tronque artificiellement la distribution de  $y$  et modifie la relation entre  $y$  et les régresseurs dans l'échantillon retenu.
- (e) Non, elle est de nature différente : l'âge (30 à 50 ans) est un **régresseur** potentiel de l'équation de salaire, pas la variable dépendante elle-même. C'est une sélection **exogène**, qui laisse les MCO non biaisés (au prix, éventuellement, d'une perte de généralité des conclusions au-delà de cette tranche d'âge).

## 2 Exercice cumulatif

### Correction — Exercice 4

- (a) Oui, parfaitement cohérent : le biais de variable omise  $\beta_3\delta_1$  est **positif** lorsque  $\beta_3 > 0$  et  $\delta_1 > 0$  (mêmes signes), ce qui pousse le coefficient estimé **sans** contrôle (6,5 %) **au-dessus** du coefficient estimé **avec** contrôle de l'aptitude (5,4 %) — exactement ce qui est observé ici : 6,5 % > 5,4 %.
- (b) La condition de validité (chapitre 8) est que, une fois le QI contrôlé, l'espérance de l'aptitude inobservée ne dépende plus de l'éducation :  $E(\text{aptitude} \mid \text{educ}, \text{QI}) = E(\text{aptitude} \mid \text{QI})$ . Autrement dit, le QI doit capturer **toute** la partie de l'aptitude qui est corrélée à l'éducation, même s'il ne mesure pas l'aptitude à l'identique.
- (c)  $0,36\% \times 15 = 5,4\%$ . Ce nombre est numériquement identique à l'effet estimé d'une année d'éducation supplémentaire une fois le QI contrôlé (5,4 %) — une coïncidence frappante relevée par le cours, qui suggère qu'une hausse d'un écart-type de QI « vaut », en ordre de grandeur, à peu près une année d'éducation sur le salaire dans cet échantillon précis.
- (d) Il manque le coefficient  $\delta_1$  lui-même, c'est-à-dire la pente de la régression auxiliaire de l'aptitude **inobservée** sur l'éducation — par définition, cette régression ne peut pas être estimée puisque l'aptitude n'est jamais observée directement. On ne dispose que de l'écart global (6,5 % – 5,4 % = 1,1 point), qui résulte du *produit combiné*  $\beta_3\delta_1$  sans que l'on puisse séparer les deux facteurs.

## 3 Applications en sciences économiques

### Correction — Exercice 5

- (a)  $0,0006/0,0002 = 3$  : le coefficient triple exactement une fois la firme extrême retirée, conforme à la description du cours.
- (b) Oui :  $t = 2,36 > 1,96$ , le coefficient devient significatif au seuil de 5 % après le retrait de la firme extrême, alors qu'il ne l'était pas ( $t = 0,85$ ) sur l'échantillon complet.
- (c) Parce que les MCO minimisent une somme de carrés de résidus : un résidu associé à une observation aux valeurs extrêmes sur les régresseurs (ici, des ventes plus du double de toute autre firme) pèse démesurément dans l'ajustement, d'autant plus que l'échantillon est petit ( $n = 32$ ) — une seule observation représente alors plus de 3 % du poids total, et peut à elle seule « tirer » la droite estimée et masquer une relation par ailleurs présente dans le reste des données.
- (d) Parce que le logarithme comprime l'échelle des grandes valeurs bien plus que celle des petites (chapitre 5) : une firme dont les ventes sont dix fois supérieures à la moyenne ne l'est plus que d'environ 2,3 fois sur l'échelle logarithmique. La distance entre cette firme et les autres, dans l'espace des régresseurs, est donc mécaniquement réduite, ce qui limite son poids disproportionné dans l'ajustement MCO — retrouvant le lien déjà établi entre transformation logarithmique et moindre sensibilité aux valeurs extrêmes.

### Correction — Exercice 6

- (a) Parce que les villes qui dépensent le plus en sécurité sont typiquement celles qui font déjà face à une criminalité élevée (causalité inverse / choix de politique en réponse au problème) : sans contrôle des facteurs historiques inobservés, la corrélation positive brute entre dépenses et criminalité reflète surtout cette réaction des pouvoirs publics à un problème préexistant, et non un effet causal des dépenses sur la criminalité.
- (b) Le taux de criminalité passé capture des facteurs **historiques persistants et inobservés** propres à chaque ville (culture locale, structure économique, démographie) qui influencent à la fois la criminalité courante et le niveau des dépenses de sécurité décidées — son inclusion neutralise une bonne partie de cette source de confusion.
- (c) Oui, dans son principe c'est rigoureusement le même mécanisme que celui de l'exercice cumulatif : dans les deux cas, une variable **observable** (le QI, la criminalité passée) sert de proxy pour un facteur **inobservable** (l'aptitude, l'historique local de criminalité) corrélé à la fois à la variable d'intérêt ( $y$ ) et à la variable de politique publique ou de choix individuel (*educ*, dépenses de sécurité).

(d) Non, pas nécessairement : comme le rappelle le cours, l'inclusion d'une variable dépendante retardée « n'est pas une solution parfaite ». Si les dépenses de sécurité de la période courante sont elles-mêmes décidées en anticipation de la criminalité *future* (et non passée), un biais de simultanéité peut subsister malgré le contrôle par  $crmrte_{t-5}$  — une prudence interprétative similaire à celle exigée pour toute variable proxy.