

# Économétrie avancée

Chapitre 8 : Problèmes de spécification et de données

## Exercices corrigés

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

## Table des matières

|                                       |   |
|---------------------------------------|---|
| <b>Partie 1 --- Énoncés</b> .....     | 1 |
| <b>Partie 2 --- Corrections</b> ..... | 4 |

## 1 Exercices du chapitre

### Exercice 1 — Reconstituer le test RESET

Sur le modèle de prix immobiliers du chapitre 7 ( $n = 88$ ,  $k = 3$  régresseurs), on estime la régression augmentée du test RESET, qui ajoute  $\hat{y}^2$  et  $\hat{y}^3$  à l'équation initiale. La régression non contrainte (avec les deux termes RESET) donne  $SSR_{ur} = 300,00$ ; la régression initiale (contrainte, sans ces termes) donne  $SSR_r = 334,17$ .

- Calculer  $F = \frac{(SSR_r - SSR_{ur})/q}{SSR_{ur}/(n - k - 3)}$  avec  $q = 2$ , et vérifier qu'il correspond au RESET  $\approx 4,67$  rapporté par le cours pour le modèle en niveau.
- Le seuil  $F_{2,82,0,05}$  vaut approximativement 3,11. L'hypothèse  $H_0 : \delta_1 = \delta_2 = 0$  est-elle rejetée ?
- Sur le modèle log-log, la même démarche donne  $SSR_{ur} = 300,00$  et  $SSR_r = 318,73$  (mêmes  $n, k$ ). Calculer  $F$  et vérifier qu'il correspond au RESET  $\approx 2,56$  rapporté par le cours.
- Ce second  $F$  dépasse-t-il le seuil de 3,11 ? Quelle spécification le RESET recommande-t-il, entre le niveau et le log-log ?
- Un rejet de  $H_0$  indique-t-il précisément *quelle* variable ajouter ou *quelle* transformation appliquer ?

### Exercice 2 — Le biais d'atténuation (CEV)

Une variable explicative vraie  $x_1^*$  a une variance  $\text{Var}(x_1^*) = 64$ . Le coefficient structurel associé est  $\beta_1 = 2$ . On observe seulement  $x_1 = x_1^* + e_1$ , avec  $e_1$  vérifiant l'hypothèse CEV ( $\text{Cov}(x_1^*, e_1) = 0$ ).

- Avec  $\text{Var}(e_1) = 16$ , calculer le ratio  $\frac{\text{Var}(x_1^*)}{\text{Var}(x_1^*) + \text{Var}(e_1)}$ .
- En déduire  $\text{plim}(\hat{\beta}_1)$  et le pourcentage d'atténuation par rapport à  $\beta_1 = 2$ .
- Si la variance de l'erreur de mesure triple ( $\text{Var}(e_1) = 48$ , la variable étant mesurée bien plus grossièrement), recalculer  $\text{plim}(\hat{\beta}_1)$  et le nouveau pourcentage d'atténuation.
- Formuler en une phrase la relation entre la qualité de la mesure d'un régresseur et l'ampleur du biais d'atténuation qui en résulte.

### Exercice 3 — Erreur de mesure sur $y$ , et sélection d'échantillon

La variance du terme d'erreur structurel est  $\text{Var}(u) = 100$ . On suppose qu'une erreur de mesure sur  $y$ , de variance  $\text{Var}(e_0) = 44$  et indépendante des régresseurs, s'ajoute au modèle.

- Calculer la variance de l'erreur composite  $v = u + e_0$ .
- En déduire le facteur multiplicatif sur l'écart-type des coefficients MCO (toutes choses égales par ailleurs), et le pourcentage de hausse par rapport au cas sans erreur de mesure.
- Les coefficients MCO restent-ils non biaisés dans ce cas ? Pourquoi ?
- Un chercheur restreint son échantillon aux ménages dont le **patrimoine déclaré** est inférieur à un seuil, pour étudier les déterminants de ce même patrimoine (la variable dépendante). Cette restriction est-elle une sélection exogène ou endogène ? Biais-t-elle les MCO ?
- Un autre chercheur restreint son échantillon aux salariés âgés de 30 à 50 ans pour étudier les déterminants du salaire. Cette restriction est-elle de même nature que celle du (d) ?

## 2 Exercice cumulatif (chapitre 8 et chapitre 2)

#### Exercice 4 — Le QI comme proxy, et le biais de variable omise

Le chapitre 2 avait établi que, si une variable  $x_3$  corrélée à la fois à  $y$  et à  $x_1$  est omise du modèle, le coefficient estimé de  $x_1$  s'écrit  $b_1 = \beta_1 + \beta_3\delta_1$ , où  $\delta_1$  est le coefficient de la régression auxiliaire de  $x_3$  sur  $x_1$ . Dans une équation de  $\log(\text{salaires})$ , le rendement estimé de l'éducation **sans** contrôle de l'aptitude est de 6,5 %; en ajoutant le QI comme proxy de l'aptitude inobservée, il tombe à 5,4 %. Le coefficient du QI dans cette dernière régression est de +0,36 % par point de QI.

- (a) En notant  $x_3$  = aptitude et  $x_1$  = éducation, l'écart entre 6,5 % et 5,4 % est-il cohérent avec  $\beta_3 > 0$  (l'aptitude est valorisée sur le marché du travail) et  $\delta_1 > 0$  (éducation et aptitude sont positivement corrélées), selon la formule du chapitre 2 ?
- (b) Le QI n'est pas l'aptitude elle-même. Rappeler, à partir du chapitre 8, la condition théorique de validité d'une proxy sous laquelle remplacer l'aptitude inobservée par le QI donne malgré tout un estimateur convergent du rendement de l'éducation.
- (c) Calculer l'effet associé à une hausse d'un écart-type de QI (15 points), sachant que le coefficient du QI est de 0,36 % par point. Comparer ce nombre à l'effet estimé d'une année d'éducation supplémentaire une fois le QI contrôlé (5,4 %).
- (d) Pourquoi ne peut-on pas, à partir des seuls résultats donnés ici, calculer directement et exactement le produit  $\beta_3\delta_1$  du chapitre 2 ?

### 3 Applications en sciences économiques

#### Exercice 5 — Intensité de R&D et taille de firme

Sur un échantillon de 32 firmes chimiques, on régresse l'intensité de R&D ( $rdintens$ , dépenses de R&D rapportées aux ventes) sur la taille de firme ( $sales$ ) et d'autres contrôles. Avec les 32 firmes, le coefficient estimé sur  $sales$  est  $\hat{\beta} = 0,0002$  ( $t = 0,85$ , non significatif). En retirant la seule firme dont les ventes dépassent 40 milliards de dollars (plus du double de toute autre firme de l'échantillon), on obtient, sur les 31 firmes restantes,  $\hat{\beta} = 0,0006$  ( $t = 2,36$ ).

- (a) Calculer le rapport entre le coefficient obtenu avec et sans l'observation extrême. Est-il cohérent avec l'idée que « le coefficient triple » une fois cette firme retirée ?
- (b) Le coefficient devient-il significatif au seuil de 5 % (valeur critique  $t \approx 1,96$ ) après le retrait de la firme extrême ?
- (c) Pourquoi une seule observation, sur 32, peut-elle avoir un tel impact sur l'estimation MCO ?
- (d) Le cours indique qu'une spécification log-log ( $\log(rd)$  sur  $\log(sales)$ ) réduit fortement la sensibilité à cette observation. Pourquoi, en s'appuyant sur le lien déjà établi au chapitre 5 entre logarithmes et robustesse aux valeurs extrêmes ?

#### Exercice 6 — Criminalité et dépenses de sécurité

Une étude sur des villes cherche à mesurer l'effet des dépenses de sécurité publique sur le taux de criminalité courant. Sans aucun contrôle, la régression donne une élasticité **positive** de +0,10 (une hausse des dépenses est associée à une hausse de la criminalité). En ajoutant  $\log(crmrte_{t-5})$  — le taux de criminalité observé cinq ans plus tôt — comme proxy des facteurs historiques inobservés, l'élasticité devient -0,14, conforme au signe attendu.

- (a) Pourquoi l'estimation sans contrôle donne-t-elle un signe économiquement incohérent (dépenses de sécurité positivement liées à la criminalité) ?
- (b) Quel mécanisme le taux de criminalité passé capture-t-il, qui permet de corriger ce biais ?
- (c) Ce mécanisme est-il, dans son principe, similaire à celui de l'exercice cumulatif (le QI comme proxy de l'aptitude) ?
- (d) Cette correction élimine-t-elle tout risque de biais résiduel — par exemple si les dépenses de

sécurité sont elles-mêmes décidées en réponse à une criminalité anticipée ?

## 1 Exercices du chapitre

### Correction — Exercice 1

- (a)  $F = \frac{(334,17 - 300,00)/2}{300,00/(88 - 3 - 3)} = \frac{34,17/2}{300,00/82} = \frac{17,085}{3,6585} \approx 4,67$ , conforme au RESET rapporté par le cours.
- (b) Oui :  $4,67 > 3,11$ ,  $H_0 : \delta_1 = \delta_2 = 0$  est **rejetée** au seuil de 5 % — le modèle en niveau souffre d'une non-linéarité négligée.
- (c)  $F = \frac{(318,73 - 300,00)/2}{300,00/82} = \frac{18,73/2}{3,6585} = \frac{9,365}{3,6585} \approx 2,56$ , conforme au RESET rapporté par le cours pour le modèle log-log.
- (d) Non :  $2,56 < 3,11$ ,  $H_0$  n'est **pas rejetée** au seuil de 5 % pour le modèle log-log (cohérent avec la  $p = 0,084$  du cours, supérieur à 0,05). Le RESET oriente donc vers la spécification log-log, moins entachée de non-linéarité négligée que la spécification en niveau.
- (e) Non : un rejet du RESET indique seulement qu'une forme de non-linéarité est négligée dans la relation entre  $y$  et les régresseurs inclus — il ne dit pas laquelle (terme quadratique manquant, transformation logarithmique nécessaire, interaction omise...). Le chercheur doit ensuite explorer plusieurs spécifications alternatives pour identifier la source précise.

### Correction — Exercice 2

- (a)  $\frac{64}{64 + 16} = \frac{64}{80} = 0,80$ .
- (b)  $\text{plim}(\hat{\beta}_1) = 2 \times 0,80 = 1,60$ . Atténuation =  $100 \times (1 - 0,80) = 20\%$  : le coefficient estimé sous-estime de 20 % la vraie valeur  $\beta_1 = 2$ .
- (c)  $\frac{64}{64 + 48} = \frac{64}{112} \approx 0,5714$ .  $\text{plim}(\hat{\beta}_1) = 2 \times 0,5714 \approx 1,143$ . Atténuation =  $100 \times (1 - 0,5714) \approx 42,86\%$ .
- (d) Plus l'erreur de mesure est importante relativement à la variance du signal réel ( $\text{Var}(x_1^*)$ ), plus le biais d'atténuation est sévère : une mesure grossière (ici, une variance d'erreur multipliée par 3) ne fait pas que rajouter du bruit, elle rapproche systématiquement  $\hat{\beta}_1$  de zéro, ici de 20 % à près de 43 % d'atténuation.

### Correction — Exercice 3

- (a)  $\text{Var}(v) = \text{Var}(u) + \text{Var}(e_0) = 100 + 44 = 144$ .
- (b) Facteur multiplicatif sur l'écart-type =  $\sqrt{144/100} = \sqrt{1,44} = 1,20$ , soit une hausse de 20 % de l'écart-type des coefficients MCO (et donc des erreurs-types rapportées) par rapport au cas sans erreur de mesure sur  $y$ .
- (c) Oui : tant que  $e_0$  est indépendante des régresseurs, les MCO restent non biaisés et convergents — seule la variance de l'erreur composite augmente (question a), ce qui gonfle les erreurs-types sans introduire de biais sur les coefficients eux-mêmes.
- (d) C'est une sélection **endogène** : le critère de restriction (patrimoine inférieur à un seuil) porte directement sur la variable **dépendante** de l'étude. Cette restriction biaise systématiquement les MCO, car elle tronque artificiellement la distribution de  $y$  et modifie la relation entre  $y$  et les régresseurs dans l'échantillon retenu.
- (e) Non, elle est de nature différente : l'âge (30 à 50 ans) est un **régresseur** potentiel de l'équation de salaire, pas la variable dépendante elle-même. C'est une sélection **exogène**, qui laisse les MCO non biaisés (au prix, éventuellement, d'une perte de généralité des conclusions au-delà de cette tranche d'âge).

## 2 Exercice cumulatif

### Correction — Exercice 4

- (a) Oui, parfaitement cohérent : le biais de variable omise  $\beta_3\delta_1$  est **positif** lorsque  $\beta_3 > 0$  et  $\delta_1 > 0$  (mêmes signes), ce qui pousse le coefficient estimé **sans** contrôle (6,5 %) **au-dessus** du coefficient estimé **avec** contrôle de l'aptitude (5,4 %) — exactement ce qui est observé ici :  $6,5\% > 5,4\%$ .
- (b) La condition de validité (chapitre 8) est que, une fois le QI contrôlé, l'espérance de l'aptitude inobservée ne dépende plus de l'éducation :  $E(\text{aptitude} \mid \text{educ}, \text{QI}) = E(\text{aptitude} \mid \text{QI})$ . Autrement dit, le QI doit capturer **toute** la partie de l'aptitude qui est corrélée à l'éducation, même s'il ne mesure pas l'aptitude à l'identique.
- (c)  $0,36\% \times 15 = 5,4\%$ . Ce nombre est numériquement identique à l'effet estimé d'une année d'éducation supplémentaire une fois le QI contrôlé (5,4 %) — une coïncidence frappante relevée par le cours, qui suggère qu'une hausse d'un écart-type de QI « vaut », en ordre de grandeur, à peu près une année d'éducation sur le salaire dans cet échantillon précis.
- (d) Il manque le coefficient  $\delta_1$  lui-même, c'est-à-dire la pente de la régression auxiliaire de l'aptitude **inobservée** sur l'éducation — par définition, cette régression ne peut pas être estimée puisque l'aptitude n'est jamais observée directement. On ne dispose que de l'écart global ( $6,5\% - 5,4\% = 1,1$  point), qui résulte du *produit combiné*  $\beta_3\delta_1$  sans que l'on puisse séparer les deux facteurs.

## 3 Applications en sciences économiques

### Correction — Exercice 5

- (a)  $0,0006/0,0002 = 3$  : le coefficient triple exactement une fois la firme extrême retirée, conforme à la description du cours.
- (b) Oui :  $t = 2,36 > 1,96$ , le coefficient devient significatif au seuil de 5 % après le retrait de la firme extrême, alors qu'il ne l'était pas ( $t = 0,85$ ) sur l'échantillon complet.
- (c) Parce que les MCO minimisent une somme de carrés de résidus : un résidu associé à une observation aux valeurs extrêmes sur les régresseurs (ici, des ventes plus du double de toute autre firme) pèse démesurément dans l'ajustement, d'autant plus que l'échantillon est petit ( $n = 32$ ) — une seule observation représente alors plus de 3 % du poids total, et peut à elle seule « tirer » la droite estimée et masquer une relation par ailleurs présente dans le reste des données.
- (d) Parce que le logarithme comprime l'échelle des grandes valeurs bien plus que celle des petites (chapitre 5) : une firme dont les ventes sont dix fois supérieures à la moyenne ne l'est plus que d'environ 2,3 fois sur l'échelle logarithmique. La distance entre cette firme et les autres, dans l'espace des régresseurs, est donc mécaniquement réduite, ce qui limite son poids disproportionné dans l'ajustement MCO — retrouvant le lien déjà établi entre transformation logarithmique et moindre sensibilité aux valeurs extrêmes.

### Correction — Exercice 6

- (a) Parce que les villes qui dépensent le plus en sécurité sont typiquement celles qui font déjà face à une criminalité élevée (causalité inverse / choix de politique en réponse au problème) : sans contrôle des facteurs historiques inobservés, la corrélation positive brute entre dépenses et criminalité reflète surtout cette réaction des pouvoirs publics à un problème préexistant, et non un effet causal des dépenses sur la criminalité.
- (b) Le taux de criminalité passé capture des facteurs **historiques persistants et inobservés** propres à chaque ville (culture locale, structure économique, démographie) qui influencent à la fois la criminalité courante et le niveau des dépenses de sécurité décidées — son inclusion neutralise une bonne partie de cette source de confusion.
- (c) Oui, dans son principe c'est rigoureusement le même mécanisme que celui de l'exercice cumulatif : dans les deux cas, une variable **observable** (le QI, la criminalité passée) sert de proxy pour un facteur **inobservable** (l'aptitude, l'historique local de criminalité) corrélé à la fois à la variable d'intérêt ( $y$ ) et à la variable de politique publique ou de choix individuel ( $\text{educ}$ , dépenses de sécurité).

(d) Non, pas nécessairement : comme le rappelle le cours, l'inclusion d'une variable dépendante retardée « n'est pas une solution parfaite ». Si les dépenses de sécurité de la période courante sont elles-mêmes décidées en anticipation de la criminalité *future* (et non passée), un biais de simultanéité peut subsister malgré le contrôle par  $crmrt_{t-5}$  — une prudence interprétative similaire à celle exigée pour toute variable proxy.