

Économétrie avancée

Chapitre 16 : Variables dépendantes limitées et sélection d'échantillon

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le Tobit et ses deux espérances (heures travaillées)

Le cours rapporte, pour *kidslt6* dans l'équation des heures travaillées (MROZ) : coefficient Tobit $\hat{\beta} = -894$, facteur d'ajustement pour $E(y \mid y > 0, x)$ d'environ 0,451, et coefficient MCO sur le sous-échantillon des actives de -442 .

- (a) Calculer $\hat{\beta} \times 0,451$.
- (b) Ce résultat est-il, en ordre de grandeur, comparable au coefficient MCO de -442 ?
- (c) Pourquoi comparer directement -894 (coefficient Tobit brut) à -442 (MCO) serait-il trompeur, selon le cours ?
- (d) Le facteur d'ajustement de 0,451 s'applique-t-il à l'effet sur $E(y \mid x)$ (espérance non conditionnelle, incluant les zéros) ou sur $E(y \mid y > 0, x)$ (espérance conditionnelle aux heures strictement positives) ?

Exercice 2 — Semi-élasticité et surdispersion en Poisson

Le cours rapporte que, dans le modèle de comptage des arrestations, une hausse de 0,10 du taux *pcnv* réduit le nombre attendu d'arrestations d'environ 4 %, avec $\hat{\sigma} \approx 1,23$ (surdispersion).

- (a) En utilisant l'approximation $100 \hat{\beta} \times 0,10 \approx -4$, en déduire une valeur approchée de $\hat{\beta}$.
- (b) Avec cette valeur de $\hat{\beta} \approx -0,4$, calculer l'effet **exact** $\exp(0,10 \times \hat{\beta}) - 1$ pour une hausse de 0,10 de *pcnv*, et comparer à l'approximation de -4 %.
- (c) Concrètement, que signifie $\text{Var}(y \mid x) > E(y \mid x)$ (surdispersion) pour la distribution du nombre d'arrestations, par comparaison à la loi de Poisson théorique ?
- (d) Pourquoi l'estimateur du maximum de vraisemblance de Poisson reste-t-il convergent (interprétation QMLE) même en présence de surdispersion, alors que les écarts-types usuels doivent, eux, être corrigés ?

Exercice 3 — Censure et troncature : récidive carcérale

Sur les 1 445 détenus libérés de l'exemple du cours, 893 durées jusqu'à la prochaine arrestation sont censurées (aucune récidive observée pendant la période de suivi).

- (a) Calculer le pourcentage exact de durées censurées, et vérifier qu'il correspond au ≈ 62 % rapporté par le cours.
- (b) Pourquoi ignorer la censure et appliquer les MCO seulement sur les 552 durées **observées** (non censurées) biaiserait-il les coefficients **vers zéro** ?
- (c) La régression censurée exploite-t-elle malgré tout une information utile sur les 893 individus censurés, même si leur durée exacte de récidive reste inconnue ?
- (d) Quelle est la différence essentielle entre « censure » et « troncature » en termes des données disponibles pour les unités situées au-delà du seuil ?

2 Exercice cumulatif (chapitre 16 et chapitre 6)

Exercice 4 — Du modèle de probabilité linéaire (chapitre 6) au probit

Le modèle de probabilité linéaire (chapitre 6) donnait, pour *kidslt6* dans l'équation de participation des femmes mariées au marché du travail, un coefficient brut de $-0,262$. Le chapitre 16 rapporte qu'à la moyenne de l'échantillon, l'effet marginal probit exact est d'environ $-0,33$.

- (a) Calculer l'écart entre ces deux estimations de l'effet d'un enfant de moins de six ans sur la probabilité de participation.

- (b) Le chapitre 6 avait souligné que le MPL impose un effet marginal **constant**, quel que soit le niveau des autres régresseurs. Pourquoi le probit, lui, ne donne-t-il qu'un effet « à la moyenne de l'échantillon », et non un effet universel ?
- (c) Le chapitre 6 avait aussi mis en garde contre le risque de probabilités prédites hors de $[0, 1]$ pour le MPL. En quoi le probit règle-t-il structurellement ce problème, par construction de la fonction $G(\cdot)$?
- (d) Le cours souligne que « MCO (MPL), logit et probit s'accordent sur les signes et la significativité » dans cet exemple. Pourquoi, en pratique, le choix entre ces trois modèles importe-t-il souvent moins pour la significativité que pour l'**amplitude précise** de l'effet estimé ?

3 Applications en sciences économiques

Exercice 5 — La correction de Heckman : salaire offert des femmes mariées

Sur MROZ, l'équation de $\log(\text{salaire})$ estimée sur les 428 femmes actives donne un coefficient d'éducation de 0,108 (MCO) contre 0,109 (Heckit) — pratiquement identique. Le coefficient sur $\hat{\lambda}$ (ratio inverse de Mills) est non significatif ($t = 0,239$).

- (a) Le test t sur $\hat{\lambda}$ ($t = 0,239$) permet-il de rejeter $H_0 : \rho = 0$ au seuil de 5 % (seuil $\approx 1,96$) ?
- (b) Qu'implique concrètement ce résultat sur la nécessité de corriger, pour **cette** relation précise, le biais de sélection dû à la non-participation au marché du travail ?
- (c) Pourquoi un chercheur prudent continuerait-il de **rapporter** les deux estimations (MCO et Heckit), plutôt que de se fier uniquement à l'une, malgré ce test non significatif ?
- (d) La procédure de Heckman exige idéalement au moins une variable de z (l'équation de sélection) absente de x (l'équation de salaire). Pourquoi, sans cette exclusion, $\hat{\lambda}$ serait-il « presque colinéaire » avec x ?

Exercice 6 — Un modèle Tobit pour les dons caritatifs

Sur un échantillon de 500 ménages, 180 déclarent des dons caritatifs annuels nuls (36 %). Un modèle Tobit donne $\hat{\beta}_{\text{revenu}} = 0,015$ (par tranche de 1 000 dh de revenu annuel), avec un facteur d'ajustement $\Phi(x\hat{\beta}/\hat{\sigma}) \approx 0,64$ à la moyenne de l'échantillon.

- (a) En utilisant $\partial E(y | x) / \partial x_j = \hat{\beta}_j \Phi(x\hat{\beta}/\hat{\sigma})$, calculer l'effet marginal d'une hausse de 1 000 dh de revenu sur le don **moyen** attendu $E(y | x)$ (incluant les ménages à zéro).
- (b) Ce facteur multiplicatif (0,64) est-il inférieur à 1 ? Qu'implique cela sur la comparaison entre le coefficient Tobit brut (0,015) et l'effet marginal réel sur $E(y | x)$?
- (c) Pourquoi ne peut-on pas simplement appliquer les MCO sur l'ensemble des 500 ménages, y compris les 180 à don nul, pour estimer cette relation ?
- (d) Pourquoi ne peut-on pas non plus appliquer les MCO seulement sur les 320 ménages ayant fait un don strictement positif ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $-894 \times 0,451 \approx -403,2$.
- (b) Oui : $-403,2$ est, en ordre de grandeur, assez proche de -442 (écart d'environ 9 %) — une fois le facteur d'ajustement appliqué, l'effet Tobit « redevient comparable » au coefficient MCO, comme l'indique le cours.
- (c) Comparer directement -894 à -442 suggérerait à tort que le Tobit « double » l'effet réel : en réalité, le coefficient Tobit brut β_j mesure l'effet sur la variable **latente** y^* , pas directement sur $E(y \mid y > 0, x)$ ni sur $E(y \mid x)$; sans le facteur d'ajustement, la comparaison brute des deux coefficients est trompeuse.
- (d) Le facteur $0,451$ correspond au facteur d'ajustement pour $E(y \mid y > 0, x)$ (espérance conditionnelle aux heures strictement positives) — c'est précisément la grandeur comparable à un coefficient MCO estimé sur le sous-échantillon des femmes actives ($y > 0$).

Correction — Exercice 2

- (a) $100\hat{\beta} \times 0,10 \approx -4 \Rightarrow \hat{\beta} \approx -4/10 = -0,4$.
- (b) $\exp(0,10 \times (-0,4)) - 1 = \exp(-0,04) - 1 \approx -3,92\%$, très proche de l'approximation de -4% — l'écart entre effet exact et approché reste faible ici car $0,10 \times \hat{\beta} = -0,04$ est une petite valeur.
- (c) Cela signifie que la dispersion **réelle** du nombre d'arrestations autour de sa moyenne conditionnelle est plus grande que ne le prédit la loi de Poisson théorique (où variance et espérance sont, par hypothèse, rigoureusement égales) — un phénomène courant avec des données de comptage réelles, souvent lié à une hétérogénéité inobservée entre individus.
- (d) La convergence de l'estimateur du maximum de vraisemblance de Poisson vers les vrais paramètres β ne repose que sur la bonne spécification de l'espérance conditionnelle $E(y \mid x) = \exp(x\beta)$, pas sur l'égalité exacte entre variance et espérance : une variance mal spécifiée (surdispersion) affecte la précision des écarts-types calculés (qui supposent, à tort, l'égalité Poisson), mais pas la convergence des coefficients eux-mêmes — d'où l'interprétation « quasi-maximum de vraisemblance » et la nécessité de corriger seulement les erreurs-types (par le facteur $\hat{\sigma}$).

Correction — Exercice 3

- (a) $893/1\,445 \approx 0,6180$, soit **61,8 %** $\approx 62\%$ — conforme au chiffre rapporté par le cours.
- (b) Se restreindre aux seules durées observées revient à **tronquer** l'échantillon sur les durées les plus longues (celles dépassant la période de suivi sont systématiquement exclues) : cette exclusion sélective écrase la variation des durées vers le bas, aplatissant la relation estimée entre les régresseurs et $\log(\text{durée})$ — exactement le mécanisme de biais vers zéro décrit par le cours pour la troncature.
- (c) Oui : même sans connaître la durée exacte de récidence d'un individu censuré, on sait qu'elle est **au moins** égale à la durée de suivi observée ($y_i \geq c_i$) — une information partielle mais réelle, que la vraisemblance de la régression censurée exploite explicitement (contrairement à une simple exclusion de ces observations).
- (d) En cas de **censure**, l'observation reste dans l'échantillon avec ses régresseurs x_i connus, seule la valeur exacte de y_i étant remplacée par une borne ($w_i = \min(y_i, c_i)$) ; en cas de **troncature**, l'observation est entièrement **absente** de l'échantillon — ni y_i ni x_i ne sont observés pour les individus au-delà du seuil, ce qui fait perdre strictement plus d'information.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $|-0,33 - (-0,262)| = 0,068$: le probit donne un effet marginal (à la moyenne) supérieur d'environ 0,068 point de probabilité, en valeur absolue, à celui du MPL.
- (b) Parce que l'effet marginal du probit, $g(\beta_0 + x\beta)\beta_j$, dépend de la densité $g(\cdot)$ évaluée au point $\beta_0 + x\beta$, lui-même fonction de **toutes** les valeurs des régresseurs : contrairement au MPL, où $\partial P(y = 1 | x) / \partial x_j = \beta_j$ est une constante, l'effet probit varie donc selon le profil de x considéré — « à la moyenne de l'échantillon » n'est qu'un point d'évaluation usuel parmi d'autres possibles.
- (c) Le probit remplace $P(y = 1 | x) = \beta_0 + x\beta$ (potentiellement hors de $[0, 1]$) par $P(y = 1 | x) = \Phi(\beta_0 + x\beta)$, où $\Phi(\cdot)$ est la fonction de répartition d'une loi normale — une fonction dont l'image est, par construction mathématique, **toujours** strictement comprise entre 0 et 1, quelle que soit la valeur de $\beta_0 + x\beta$.
- (d) Parce que la question de la significativité statistique (le signe et le rejet ou non de $H_0 : \beta_j = 0$) est souvent assez robuste au choix de la forme fonctionnelle de $G(\cdot)$, tant que celle-ci est raisonnable (en S , monotone) ; en revanche, l'**ampleur exacte** de l'effet marginal, elle, dépend directement de la forme précise de $G(\cdot)$ et du point d'évaluation — une distinction cruciale dès qu'on veut chiffrer une politique publique (par exemple, l'effet en points de pourcentage d'une aide à la garde d'enfants sur la participation au marché du travail), plutôt que seulement établir l'existence d'un effet.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non : $0,239 < 1,96$, on ne rejette **pas** $H_0 : \rho = 0$ au seuil de 5 %.
- (b) Ce résultat suggère qu'il n'y a **pas** de biais de sélection important détectable dans cette relation précise, une fois contrôlé par éducation et expérience : les femmes qui choisissent de travailler ne semblent pas différer systématiquement, en termes de facteurs inobservés affectant le salaire, de celles qui ne travaillent pas.
- (c) Parce qu'un test non significatif n'**établit** pas l'absence de biais de sélection avec certitude (erreur de deuxième espèce possible, notamment si l'équation de sélection est mal spécifiée ou si $\hat{\lambda}$ est imprécisément estimé) ; rapporter les deux estimations permet au lecteur de juger lui-même de la robustesse du résultat et de la sensibilité de la conclusion au choix de la méthode.
- (d) Le ratio inverse de Mills $\hat{\lambda}(z\hat{\gamma})$ est une fonction **non linéaire mais relativement lisse** de $z\hat{\gamma}$; si z ne contient aucune variable absente de x , cette fonction non linéaire de x (via $z = x$) devient très proche d'une combinaison linéaire des colonnes de x sur la plage de données observée, provoquant une quasi-colinéarité qui rend $\hat{\beta}$ et le coefficient de $\hat{\lambda}$ très imprécisément estimés.

Correction — Exercice 6

- (a) $0,015 \times 0,64 = 0,0096$: une hausse de 1 000 dh de revenu annuel est associée à une hausse d'environ 9,6 dh du don caritatif **moyen** attendu (incluant les ménages à zéro).
- (b) Oui, $0,64 < 1$: le facteur d'ajustement étant strictement inférieur à 1, l'effet marginal réel sur $E(y | x)$ (0,0096) est nécessairement **inférieur** au coefficient Tobit brut (0,015) — comparer directement 0,015 à un effet observé sur les dons moyens surestimerait l'ampleur réelle de l'effet du revenu.
- (c) Parce que $E(y | x)$ n'est **pas** linéaire en $x\beta$ dans un modèle Tobit (elle vaut $\Phi(x\beta/\sigma)E(y | y > 0, x)$, un produit de deux termes non linéaires) : une régression MCO sur l'ensemble des 500 ménages, y compris les 180 à don nul, suppose à tort une relation linéaire et produit des coefficients incohérents.
- (d) Parce que se restreindre aux 320 ménages ayant fait un don positif revient à conditionner sur $y^* > 0$, ce qui corréle le terme d'erreur retenu aux régresseurs (troncature implicite) : les MCO sur ce sous-échantillon sont, eux aussi, incohérents — exactement le même mécanisme que celui expliqué par le cours pour les heures travaillées.