

Économétrie avancée

Chapitre 14 : Variables instrumentales et doubles moindres carrés

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer l'estimateur VI

On dispose de $\text{Cov}(z, y) = 45$ et $\text{Cov}(z, x) = 15$ pour un instrument z jugé valide.

- (a) Calculer $\hat{\beta}_1^{VI} = \frac{\text{Cov}(z, y)}{\text{Cov}(z, x)}$.
- (b) Avec un second instrument z' dix fois moins corrélé au régresseur ($\text{Cov}(z', x) = 1,5$) mais proportionnellement moins corrélé à y ($\text{Cov}(z', y) = 4,5$), calculer $\hat{\beta}_1^{VI}$ avec z' . Le point estimé change-t-il ?
- (c) Un instrument dix fois moins corrélé au régresseur, mais donnant le même point estimé, pose-t-il malgré tout un problème pratique ? Lequel ?
- (d) Que devient l'estimateur VI dans le cas limite où $z = x$ (l'instrument est le régresseur endogène lui-même) ?

Exercice 2 — La statistique F de première étape

Dans la première étape du 2SLS (régression du régresseur endogène sur les instruments et les régresseurs exogènes), on obtient, pour deux instruments candidats :

Instrument	F de première étape
A	4,2
B	23,7

- (a) Selon la règle empirique du cours ($F > 10$), lequel des deux instruments est jugé suffisamment pertinent ?
- (b) Que risque-t-il de se produire si l'on utilise malgré tout l'instrument A ($F = 4,2$) pour estimer le modèle par 2SLS ?
- (c) Le fait qu'un instrument soit statistiquement significatif au seuil de 5 % dans la première étape (donc avec un F nettement supérieur à 1) suffit-il, à lui seul, à garantir qu'il n'est pas « faible » au sens du chapitre 14 ?
- (d) Quelle est la différence conceptuelle entre un instrument « non pertinent » ($\text{Cov}(z, x) = 0$ exactement) et un instrument « faible » ($\text{Cov}(z, x)$ proche de zéro mais non nulle) ?

Exercice 3 — Identifier la source d'endogénéité

Pour chacun des scénarios suivants, identifier la source d'endogénéité en jeu parmi les trois évoquées par le cours (variable omise, erreur de mesure, simultanéité).

- (a) Une équation reliant le taux de criminalité d'une ville aux effectifs de police, alors que les villes ajustent leurs effectifs **en fonction** du niveau de criminalité anticipé.
- (b) Une équation de salaire où l'on contrôle pour l'éducation mais pas pour la capacité innée, inobservée et corrélée à l'éducation.
- (c) Une équation de dépenses des ménages utilisant un revenu **déclaré** par les ménages eux-mêmes, connu pour être imprécisément rapporté.
- (d) Pour le scénario (a), pourquoi les MCO resteraient-ils biaisés même avec un échantillon infiniment grand (c'est-à-dire non convergents, et non pas seulement imprécis à taille finie) ?

2 Exercice cumulatif (chapitre 14 et chapitre 8)

Exercice 4 — L'erreur de mesure : du diagnostic (chapitre 8) au remède (chapitre 14)

Le chapitre 8 avait établi, pour une erreur de mesure classique (CEV) avec $\text{Var}(x_1^*) = 64$, $\text{Var}(e_1) = 16$ et $\beta_1 = 2$, un biais d'atténuation donnant $\text{plim}(\hat{\beta}_1^{\text{MCO}}) = 1,6$ (atténuation de 20 %).

- (a) Pourquoi $x_1 = x_1^* + e_1$ est-il, par construction, corrélé au terme d'erreur composite de la régression — c'est-à-dire pourquoi ce cas relève-t-il bien de la définition d'un régresseur **endogène** du chapitre 14?
- (b) Un instrument valide z pour ce problème doit être corrélé à x_1^* mais **non corrélé** à e_1 . Pourquoi une variable corrélée à x_1 uniquement *parce qu'elle* serait elle-même corrélée à l'erreur de mesure e_1 ne constituerait-elle **pas** un instrument valide?
- (c) Si un instrument z est corrélé à x_1^* et non corrélé à e_1 , l'estimateur $\hat{\beta}_1^{\text{VI}} = \text{Cov}(z, y) / \text{Cov}(z, x_1)$ retrouve-t-il, en principe, le vrai $\beta_1 = 2$, contrairement à l'estimateur MCO biaisé à 1,6?
- (d) Le panel (chapitres 12–13) aurait-il pu corriger ce biais d'atténuation, sachant que l'erreur de mesure e_1 varie ici d'une observation à l'autre plutôt que d'être un effet individuel **constant** dans le temps?

3 Applications en sciences économiques

Exercice 5 — Le rendement de l'éducation, par MCO et par VI

Sur un échantillon de travailleurs, l'estimation MCO du rendement de l'éducation sur le $\log(\text{salaire})$ donne 0,132 (soit 13,2 % par année). En instrumentant l'éducation par la proximité d'une université au moment de l'adolescence, l'estimation VI donne 0,108 (10,8 %).

- (a) Si l'instrument est valide, lequel des deux coefficients est le plus proche de l'effet causal « vrai » de l'éducation sur le salaire?
- (b) Le coefficient VI est **inférieur** au coefficient MCO. Est-ce cohérent avec un biais MCO **positif** dû à la capacité inobservée, corrélée positivement à l'éducation (chapitres 2 et 8)?
- (c) Pourquoi le trimestre de naissance (exemple classique d'Angrist et Krueger) est-il un instrument plausible pour la durée de scolarisation, via la législation sur l'âge légal de début et de fin de scolarité obligatoire?
- (d) Pourquoi le trimestre de naissance doit-il, pour être un instrument valide, n'affecter le salaire **que** via son effet sur la durée de scolarisation — et non directement, par exemple via un lien saisonnier avec la santé à la naissance?

Exercice 6 — Prix et quantité sur le marché du café : la simultanéité

Sur des données mensuelles du marché du café, une régression MCO de la quantité vendue sur le prix donne un coefficient **positif** — contraire à la loi de la demande, qui prédit une relation négative. On instrumente le prix par un indice pluviométrique dans les régions productrices (affectant l'offre, mais pas directement la demande des consommateurs).

- (a) Pourquoi une régression MCO simple de la quantité sur le prix est-elle mal adaptée ici, prix et quantité se déterminant **mutuellement** sur ce marché?
- (b) L'indice pluviométrique vérifie-t-il, en principe, la condition de **pertinence** requise d'un instrument (il est corrélé au prix, via son effet sur l'offre)?
- (c) Pourquoi l'indice pluviométrique doit-il, pour être **exogène**, n'affecter la quantité demandée par les consommateurs qu'à travers son effet sur le prix — et non, par exemple, via un lien direct entre conditions climatiques et préférences de consommation?
- (d) Ce problème de simultanéité prix-quantité est un cas particulier d'un cadre plus général. Comment ce cadre, développé au chapitre suivant du cours, se nomme-t-il?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\hat{\beta}_1^{VI} = 45/15 = 3$.
- (b) $\hat{\beta}_1^{VI} = 4,5/1,5 = 3$ également : le point estimé **ne change pas**, puisque l'estimateur VI est un **rapport** de covariances — une réduction proportionnelle des deux covariances laisse le ratio inchangé.
- (c) Oui : bien que le point estimé coïncide dans cet exemple stylisé, un instrument beaucoup moins corrélé au régresseur endogène produit, en pratique (sur données réelles avec bruit d'échantillonnage), un estimateur VI beaucoup plus **imprécis** — une variance d'estimation nettement plus grande, donc des intervalles de confiance beaucoup plus larges, malgré un point estimé similaire.
- (d) Si $z = x$, alors $\hat{\beta}_1^{VI} = \text{Cov}(x, y) / \text{Cov}(x, x) = \text{Cov}(x, y) / \text{Var}(x)$, qui est exactement la formule de l'estimateur **MCO** en régression simple : les MCO sont donc un cas particulier de VI, celui où le régresseur est son propre instrument.

Correction — Exercice 2

- (a) Seul l'instrument **B** ($F = 23,7 > 10$) est jugé suffisamment pertinent selon la règle empirique du cours ; l'instrument **A** ($F = 4,2 < 10$) est un instrument **faible**.
- (b) Avec l'instrument **A**, l'estimateur 2SLS risque d'être fortement **biaisé en petit échantillon** (potentiellement même plus biaisé que les MCO qu'on cherchait à corriger) et très **imprécis** (grande variance) : la faible corrélation avec le régresseur endogène signifie que l'instrument apporte très peu de variation exogène exploitable.
- (c) Non : un F de première étape peut dépasser le seuil de significativité usuel (donner un instrument « statistiquement non nul ») tout en restant bien en dessous du seuil de 10 recommandé pour éviter les problèmes d'instrument faible — la significativité au sens usuel et la « force » suffisante de l'instrument sont deux exigences distinctes, la seconde étant plus stricte.
- (d) Un instrument « non pertinent » n'apporte, en théorie, **aucune** information utile ($\text{Cov}(z, x) = 0$ exactement) : l'estimateur VI n'est alors même pas défini. Un instrument « faible » apporte, en théorie, un peu d'information ($\text{Cov}(z, x) \neq 0$, l'estimateur est bien défini et convergent asymptotiquement), mais cette information est si ténue qu'elle rend l'estimateur peu fiable en pratique, à taille d'échantillon finie.

Correction — Exercice 3

- (a) **Simultanéité** : la criminalité affecte les effectifs de police (variable de politique publique), qui eux-mêmes affectent (en principe) la criminalité — une détermination mutuelle de y et x .
- (b) **Variable omise** : la capacité innée, corrélée à l'éducation et absente du modèle, biaise le coefficient estimé de l'éducation (biais de variable omise classique, chapitre 2).
- (c) **Erreur de mesure** : le revenu déclaré diffère du revenu réel, et cette erreur (si elle vérifie l'hypothèse CEV du chapitre 8) biaise vers zéro le coefficient estimé du revenu.
- (d) Parce que la simultanéité crée une corrélation **structurelle** et permanente entre le régresseur (effectifs de police) et le terme d'erreur, qui ne s'atténue **pas** quand $n \rightarrow \infty$: contrairement à un problème de précision (variance), qui se résorbe avec un plus grand échantillon, un biais de simultanéité affecte la valeur **limite** elle-même vers laquelle converge l'estimateur MCO — les MCO restent donc non convergents, quelle que soit la taille de l'échantillon.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Le terme d'erreur composite de la régression de y sur x_1 observé inclut, outre u , l'erreur de mesure e_1 (via la substitution $x_1^* = x_1 - e_1$) ; puisque $x_1 = x_1^* + e_1$ contient e_1 par construction, x_1 est mécaniquement corrélé à cette composante de l'erreur — exactement la définition d'un régresseur endogène ($\text{Cov}(x_1, \text{erreur}) \neq 0$) du chapitre 14.
- (b) Une telle variable violerait la condition d'**exogénéité** de l'instrument ($\text{Cov}(z, u) = 0$, ici étendue à la non-corrélation avec e_1) : si z est corrélé à x_1 *via* e_1 plutôt que *via* x_1^* , l'estimateur VI hériterait lui-même du biais d'atténuation qu'on cherche justement à corriger — l'instrument ne ferait alors que « déplacer » le problème sans le résoudre.
- (c) Oui, en principe : un instrument z pertinent (corrélé à x_1^*) et exogène (non corrélé à e_1 et à u) permet à l'estimateur $\hat{\beta}_1^{VI}$ d'isoler la variation de x_1 attribuable au **vrai** signal x_1^* , retrouvant ainsi $\beta_1 = 2$ à la limite — contrairement à l'estimateur MCO, structurellement biaisé à 1,6 quelle que soit la taille de l'échantillon.
- (d) Non : le panel (effets fixes, différence première) élimine spécifiquement une hétérogénéité **constante dans le temps** pour chaque individu (a_i). Une erreur de mesure classique, elle, varie typiquement d'une observation à l'autre (y compris d'une période à l'autre pour un même individu) et n'a donc pas la structure d'un effet fixe : la transformation *within* ou la différence première ne l'éliminerait pas, et pourrait même **aggraver** le biais d'atténuation en réduisant davantage la part de variance utile (« signal ») relativement au bruit de mesure dans les données transformées.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Si l'instrument est valide, le coefficient VI (0,108) est celui qui se rapproche le plus de l'effet causal « vrai », puisque les MCO restent potentiellement biaisés par la capacité inobservée.
- (b) Oui, parfaitement cohérent : un biais MCO **positif** (le coefficient MCO surestime l'effet causal) est exactement ce que prédit un biais de variable omise où la variable omise (capacité) est corrélée **positivement** à la fois à l'éducation et au salaire — le VI, non affecté par ce biais, donne logiquement un coefficient plus faible.
- (c) La législation sur l'âge légal de scolarisation obligatoire fixe généralement des dates d'entrée et de sortie du système scolaire liées à l'**âge en années civiles** : selon le trimestre de naissance, deux enfants nés la même année mais à des trimestres différents peuvent être légalement autorisés à quitter l'école après un nombre d'années de scolarité légèrement différent — créant une variation de la durée de scolarisation corrélée au trimestre de naissance, sans lien direct plausible avec la capacité innée de l'individu.
- (d) Parce que la condition d'exogénéité exige $\text{Cov}(z, u) = 0$: si le trimestre de naissance affectait le salaire par un **autre** canal que la scolarisation (par exemple, un lien saisonnier connu entre le mois de naissance et la santé future, ou des effets de maturité relative parmi les camarades de classe), l'instrument violerait la condition d'exclusion et l'estimateur VI resterait biaisé, tout comme les MCO qu'on cherchait à corriger.

Correction — Exercice 6

- (a) Parce que le prix et la quantité observés sur ce marché résultent de l'**intersection** de l'offre et de la demande : une régression MCO de la quantité sur le prix capte un mélange des deux relations structurelles (offre *et* demande), sans pouvoir isoler l'une ou l'autre — exactement le problème de simultanéité identifié au chapitre 14.
- (b) Oui, en principe : la pluviométrie dans les régions productrices affecte directement les rendements des caféiers, donc l'offre de café, donc (via l'équilibre de marché) le prix — une corrélation plausible entre l'instrument et le régresseur endogène (le **prix**).

(c) Parce que la condition d'exogénéité exige que l'instrument n'affecte y (la quantité demandée) **que** via le canal x (le prix) : si la pluviométrie dans les pays producteurs influençait directement les préférences ou le comportement des consommateurs (par un canal totalement indépendant du prix, ce qui est peu plausible ici mais reste l'exigence théorique), l'instrument violerait la condition d'exclusion.

(d) Ce cadre se nomme les **modèles à équations simultanées**, développés au chapitre 15 du cours.