

Économétrie avancée

Chapitre 6 : Variables qualitatives (indicatrices)

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le piège de la variable indicatrice, et un écart contrôlé

Le cours rapporte $\widehat{wage} = -1,57 - 1,81female + 0,572educ + 0,025exper + 0,141tenure$, contre un écart brut de 2,51 \$ sans variables de contrôle.

- (a) Pourquoi ne peut-on pas inclure à la fois *female* et *male* (avec un intercept général) dans ce modèle ?
- (b) Quel est le groupe de référence dans ce modèle, et comment le sait-on ?
- (c) Interpréter le coefficient $-1,81$ en une phrase respectant le *ceteris paribus*.
- (d) L'écart brut (2,51 \$) est plus grand que l'écart contrôlé (1,81 \$). Que suggère cette différence sur la répartition de l'éducation, de l'expérience et de l'ancienneté entre hommes et femmes de cet échantillon ?

Exercice 2 — Effet exact d'une indicatrice en log-linéaire

Le cours rapporte, pour quatre profils croisés (référence : hommes célibataires), $\log(\widehat{wage}) = 0,321 + 0,213marrmale - 0,198marrfem - 0,110singfem + 0,079educ + \dots$

- (a) Calculer l'approximation usuelle $100 \times 0,213$ pour l'écart des hommes mariés par rapport aux hommes célibataires.
- (b) Calculer l'effet exact $100[\exp(0,213) - 1]$.
- (c) Calculer de même l'effet exact pour les femmes mariées ($\delta = -0,198$), et le comparer à l'approximation $100 \times (-0,198)$.
- (d) Pourquoi la règle « utiliser l'effet exact dès que $|\delta|$ n'est pas petit » du chapitre 5 s'applique-t-elle exactement de la même façon à une indicatrice qu'à n'importe quel coefficient log-linéaire ?

Exercice 3 — Coder une variable ordinale

Une étude sur le classement des écoles de commerce compare deux spécifications : le rang de l'école entré comme variable continue ($\bar{R}^2 = 0,836$), et le rang découpé en tranches par indicatrices, *top10*, *r11_25*, etc. ($\bar{R}^2 = 0,905$).

- (a) Entrer le rang comme variable continue impose quelle hypothèse sur l'effet d'un rang supplémentaire, quel que soit le niveau de départ ?
- (b) Cette hypothèse est-elle empiriquement soutenue par la comparaison des deux $\bar{R}^2$?
- (c) Pourquoi le découpage par tranches permet-il à l'effet du classement de « varier d'un échelon à l'autre », alors que la variable continue l'interdit ?
- (d) Cette comparaison de $\bar{R}^2$ est-elle légitime au sens du chapitre 5 (la variable expliquée est-elle la même dans les deux modèles) ?

2 Exercice cumulatif (chapitre 6 et chapitres précédents)

Exercice 4 — Auto-sélection : un cas particulier du biais de variable omise

Le chapitre 2 avait établi le mécanisme général du biais de variable omise. Ce chapitre l'applique à l'évaluation de politiques : dans $y = \beta_0 + \beta_1partic + u$, l'auto-sélection dans un programme pose $E(u | partic = 1) \neq E(u | partic = 0)$.

- (a) Pourquoi l'auto-sélection dans un programme (plutôt qu'une assignation aléatoire) revient-elle à violer l'hypothèse d'exogénéité du chapitre 2 (MLR.4) ?
- (b) Le cours affirme que « la régression multiple atténue le problème en contrôlant les facteurs observables, mais ne le résout pas ». Pourquoi contrôler pour davantage de variables observables ne suffit-il jamais à garantir l'absence de biais ?

- (c) En quoi ce mécanisme est-il rigoureusement le même biais de variable omise qu'au chapitre 2, appliqué ici à une variable de traitement binaire plutôt qu'à une variable continue ?
- (d) Le cours annonce des « méthodes plus avancées » pour résoudre ce problème quand des facteurs pertinents restent inobservés. Pourquoi le simple ajout de contrôles observables, quelle que soit leur pertinence apparente, ne peut-il jamais constituer une solution complète et définitive ?

3 Applications en sciences économiques

Exercice 5 — Tester la discrimination au crédit

Une banque estime $\widehat{approved} = \hat{\beta}_0 + \hat{\beta}_1 nonwhite + \hat{\beta}_2 income + \dots$ par un modèle de probabilité linéaire, et trouve $\hat{\beta}_1 = -0,08$, statistiquement significatif, à revenu et autres caractéristiques du dossier comparables.

- (a) Interpréter $\hat{\beta}_1 = -0,08$ en termes de points de probabilité d'approbation du prêt.
- (b) Ce résultat, à lui seul, établit-il une discrimination au sens juridique, ou seulement un écart statistique *ceteris paribus* conditionnel aux variables incluses dans le modèle ?
- (c) Quelle limite structurelle du modèle de probabilité linéaire (rappelée par ce chapitre) pourrait affecter la fiabilité des écarts-types de $\hat{\beta}_1$, même si le coefficient lui-même reste non biaisé ?
- (d) Si des facteurs légitimes mais non observés (historique de crédit informel, garanties non déclarées) sont corrélés à *nonwhite* dans cet échantillon, quel principe du chapitre 2 impose-t-on de garder à l'esprit avant de conclure définitivement à une discrimination ?

Exercice 6 — Le test de Chow avant et après une réforme

On teste si la même relation salaire-éducation s'applique avant et après une réforme du marché du travail, sur deux sous-échantillons de 75 salariés chacun ($n = 150$ au total), avec $k + 1 = 4$ paramètres par régression. La régression poolée donne $SSR_p = 500$; les régressions séparées donnent $SSR_1 = 180$ (avant réforme) et $SSR_2 = 250$ (après réforme). Le seuil critique est $F_{4,142,0,05} \approx 2,45$.

- (a) Calculer $F = \frac{[SSR_p - (SSR_1 + SSR_2)]/(k + 1)}{(SSR_1 + SSR_2)/[n - 2(k + 1)]}$.
- (b) La même relation salaire-éducation s'applique-t-elle avant et après la réforme, au seuil de 5 % ?
- (c) Le test de Chow rejette H_0 . Que faudrait-il faire, selon le cours, pour identifier *quelle* différence (intercept, pente, ou les deux) est responsable de ce rejet ?
- (d) Pourquoi un test de Chow global est-il moins informatif, dans ce contexte, qu'un test portant spécifiquement sur les interactions (pentes égales, intercepts libres) ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Parce que $female + male = 1$ pour toutes les observations : inclure les deux indicatrices avec un intercept général créerait une colinéarité parfaite (le piège de la variable indicatrice), rendant $X^T X$ non inversible.
- (b) Le groupe de référence est celui des **hommes** : c'est la modalité omise de la régression, celle qui n'apparaît pas explicitement comme indicatrice (seul *female* figure dans le modèle).
- (c) À éducation, expérience et ancienneté identiques, une femme gagne en moyenne 1,81 \$ de moins par heure qu'un homme.
- (d) Cela suggère que les femmes de cet échantillon ont, en moyenne, un niveau d'éducation, d'expérience ou d'ancienneté **plus faible** que les hommes : une partie de l'écart brut de 2,51 \$ reflète ces différences de capital humain observées plutôt qu'un écart salarial *ceteris paribus* — une fois ces facteurs contrôlés, l'écart résiduel attribuable au genre seul se réduit à 1,81 \$.

Correction — Exercice 2

- (a) $100 \times 0,213 = 21,3 \%$.
- (b) $100[\exp(0,213) - 1] \approx 23,7 \%$.
- (c) Effet exact : $100[\exp(-0,198) - 1] \approx -18,0 \%$, contre une approximation de $-19,8 \%$: ici, l'approximation **surestime** (en valeur absolue) l'ampleur de l'écart.
- (d) Parce qu'une indicatrice, dans un modèle log-linéaire, est un régresseur comme un autre : la formule de conversion exacte $100[\exp(\delta) - 1]$ ne dépend en rien de la nature (continue ou binaire) de la variable associée au coefficient δ — seule l'ampleur de δ détermine si l'approximation reste acceptable.

Correction — Exercice 3

- (a) Entrer le rang comme variable continue impose un effet **constant** par échelon de rang, quel que soit le niveau de départ (par exemple, l'écart entre le rang 1 et le rang 2 aurait le même effet sur le salaire que l'écart entre le rang 50 et le rang 51).
- (b) Oui : la hausse notable du $\bar{R}^2$ ($0,836 \rightarrow 0,905$) en passant à un découpage par tranches indique que l'hypothèse de linéarité était trop restrictive — l'effet du classement sur le salaire de sortie n'est manifestement pas constant sur toute l'échelle.
- (c) Le découpage par tranches attribue une indicatrice (et donc un coefficient propre) à chaque tranche de classement, sans imposer aucune relation particulière entre les coefficients des différentes tranches : l'écart entre « top 10 » et la tranche suivante peut ainsi être très différent de l'écart entre deux tranches plus basses dans le classement.
- (d) Oui, cette comparaison est légitime : dans les deux modèles, la variable expliquée reste le salaire de sortie (ou son logarithme) — seule la façon de coder le rang de l'école change, pas la nature de y . La mise en garde du chapitre 5 ne s'applique qu'aux comparaisons où y lui-même diffère (par exemple, y contre $\log(y)$).

2 Exercice cumulatif

Correction — Exercice 4

- (a) Si les individus choisissent eux-mêmes de participer au programme (plutôt que d'y être assignés au hasard), leur choix est probablement corrélé à des caractéristiques non observées (motivation, anticipation de gains futurs) qui affectent aussi y : le terme d'erreur u devient alors corrélé à *partic*, ce qui est très exactement la violation de MLR.4 ($E(u | x) \neq 0$).
- (b) Parce que contrôler pour des variables observables ne neutralise que les facteurs **mesurés** : tant qu'un facteur pertinent reste non observé (et donc³ absent du modèle) et corrélé à la participation, un

biais subsiste, quelle que soit la richesse des contrôles observables déjà inclus — on ne peut jamais contrôler pour ce qu'on ne peut pas mesurer.

(c) C'est rigoureusement le même mécanisme : au chapitre 2, un facteur pertinent non observé, corrélé à un régresseur continu, biaisait le coefficient de ce régresseur. Ici, le régresseur est une variable de traitement **binaire** (*partic*), et le facteur non observé (motivation, capacités) joue exactement le même rôle de source de corrélation entre le régresseur d'intérêt et le terme d'erreur.

(d) Parce qu'il est, par construction, impossible de vérifier exhaustivement qu'**aucun** facteur pertinent ne reste omis : la liste des facteurs observables inclus dans un modèle est toujours forcément incomplète face à la richesse des déterminants réels d'un comportement humain (motivation, ambition, réseau, anticipations) ; seules des méthodes exploitant une source de variation exogène (assignation aléatoire, variables instrumentales, données de panel) permettent de s'affranchir de cette limite fondamentale.

3 Applications en sciences économiques

Correction — Exercice 5

(a) À revenu et autres caractéristiques du dossier comparables, être classé *nonwhite* est associé à une probabilité d'approbation du prêt inférieure de 8 points de pourcentage.

(b) Ce résultat n'établit, à lui seul, qu'un écart statistique *ceteris paribus* conditionnel aux variables incluses dans le modèle — il ne suffit pas, en soi, à établir juridiquement une discrimination, qui exigerait généralement une analyse plus approfondie tenant compte de toutes les justifications légitimes possibles et des exigences légales propres au contexte.

(c) L'hétéroscédasticité structurelle du modèle de probabilité linéaire ($\text{Var}(y | x) = p(x)[1 - p(x)]$, qui dépend de x) pourrait invalider les écarts-types usuels de $\hat{\beta}_1$, sans pour autant biaiser le coefficient lui-même — une correction des écarts-types (chapitre 7) serait nécessaire pour une inférence fiable.

(d) Il faut garder à l'esprit le principe du **biais de variable omise** : si de tels facteurs légitimes et non observés sont corrélés à *nonwhite* dans cet échantillon, le coefficient $\hat{\beta}_1 = -0,08$ pourrait, en partie, refléter leur effet plutôt qu'une discrimination pure fondée uniquement sur l'appartenance ethnique — la prudence interprétative du chapitre 2 s'applique intégralement ici.

Correction — Exercice 6

(a)
$$F = \frac{[500 - (180 + 250)]/4}{(180 + 250)/[150 - 2 \times 4]} = \frac{70/4}{430/142} = \frac{17,5}{3,028} \approx 5,78.$$

(b) Non : $5,78 > 2,45$, H_0 (mêmes coefficients avant et après la réforme) est **rejetée** au seuil de 5 % — la relation salaire-éducation diffère significativement entre les deux périodes.

(c) Il faudrait tester séparément l'égalité des **intercepts** et l'égalité des **pent**es (par exemple, en testant seulement les termes d'interaction entre l'indicatrice de période et les régresseurs, intercepts libres), afin de déterminer si le changement porte sur le niveau général des salaires, sur le rendement de l'éducation, ou sur les deux à la fois.

(d) Un test de Chow global rejette dès qu'**une** différence quelconque existe (intercept ou pente), sans indiquer laquelle ; un test ciblé sur les seules interactions révèle directement si c'est le **rendement de l'éducation** qui a changé (la question économique la plus intéressante après une réforme du marché du travail), en laissant les intercepts libres de différer pour des raisons moins informatives (niveau général des salaires, inflation).