

Économétrie avancée

Chapitre 6 : Variables qualitatives (indicatrices)

Jaouad Madkour

25 septembre 2026

Plan du chapitre

Avant de commencer	2
Pourquoi ce chapitre	2
Variables indicatrices simples	2
Décrire l'information qualitative	2
Décrire l'information qualitative (suite)	2
Décrire l'information qualitative (suite 2)	3
Indicatrices et variable dépendante en logarithme	3
Catégories et ordinal	3
Plus de deux groupes	3
Information ordinale	3
Interactions et indicatrices	4
Interaction entre deux indicatrices	4
Pentes différentes selon le groupe	4
Le test de Chow	5
La probabilité linéaire	5
Une variable dépendante binaire	5
Une variable dépendante binaire (suite)	6
Évaluation de politiques	6
Groupes de traitement et de contrôle, auto-sélection	6
Synthèse	6
Ce qu'il faut retenir	6

Avant de commencer

Pourquoi ce chapitre

Pourquoi ce chapitre ?

Le genre, la région, le secteur d'activité, un style architectural : autant de facteurs **qualitatifs** qui n'ont pas de magnitude numérique naturelle, mais qui influencent souvent y de façon décisive. Ce chapitre montre comment les faire entrer dans le cadre de la régression multiple sans rien perdre de sa rigueur.

Variables indicatrices simples

Décrire l'information qualitative

Variable indicatrice (dummy)

Une **variable indicatrice** (ou *dummy*) code un fait binaire par 0 ou 1. Le choix de la modalité codée 1 est arbitraire mais doit être **explicite** dans le nom de la variable (par exemple **female** plutôt que **gender**, pour éviter toute ambiguïté).


Interprétation dans une régression

Dans $wage = \beta_0 + \delta_0 female + \beta_1 educ + u$, sous l'hypothèse habituelle $E(u | \cdot) = 0$,

$$\delta_0 = E(wage | female = 1, educ) - E(wage | female = 0, educ) :$$

c'est un **décalage d'ordonnée à l'origine** entre les deux groupes, à niveau d'éducation identique — les deux droites sont parallèles.

Décrire l'information qualitative (suite)



Décrire l'information qualitative (suite 2)

Le piège de la variable indicatrice (dummy variable trap)

Avec deux groupes seulement, il faut **une seule** indicatrice plus l'intercept — pas deux. Inclure à la fois **female** et **male** avec un intercept général crée une colinéarité parfaite ($female + male = 1$). Le groupe omis (ici les hommes) devient le **groupe de référence** ; tous les coefficients d'indicatrices se lisent comme des écarts à ce groupe.

Écart salarial homme-femme

$\widehat{wage} = -1.57 - 1.81 \text{ female} + .572 \text{ educ} + .025 \text{ exper} + .141 \text{ tenure}$: à éducation, expérience et ancienneté égales, une femme gagne en moyenne 1,81 \$ de moins par heure qu'un homme. Sans les variables de contrôle, l'écart brut est de 2,51 \$ — la régression multiple isole la part de l'écart non expliquée par des différences de capital humain observées.

Indicatrices et variable dépendante en logarithme

Effet en pourcentage, exact et approché

Si $\log(y) = \dots + \delta_1 x_1 + u$ où x_1 est une indicatrice, l'approximation $100 \delta_1$ donne l'écart en % ; l'écart **exact** est $100[\exp(\delta_1) - 1]$, à utiliser dès que $|\delta_1|$ n'est pas petit (comme pour tout coefficient log-linéaire, chapitre 5).

Catégories et ordinal

Plus de deux groupes

Règle générale : g groupes, $g - 1$ indicatrices

Pour distinguer g groupes, on inclut un intercept général et $g - 1$ indicatrices (une par groupe, sauf le groupe de référence). Chaque coefficient mesure l'écart d'ordonnée à l'origine entre son groupe et le groupe de référence.

Quatre profils croisés

En croisant genre et statut marital (référence : hommes célibataires), $\log(\widehat{wage}) = .321 + .213 \text{ marrmale} - .198 \text{ marrfem} - .110 \text{ singfem} + .079 \text{ educ} + \dots$ Les hommes mariés gagnent environ 21,3 % de plus que les hommes célibataires ; les femmes mariées, 19,8 % de moins. Pour tester directement l'écart entre deux groupes non-référence (ici, célibataires vs mariées), il faut soit recombinaison des coefficients avec leur covariance, soit changer de groupe de référence et ré-estimer.

Information ordinale

Ordinal vs cardinal

Une variable **ordinale** (note de crédit, catégorie de beauté, tranche de classement) a un ordre mais pas d'écart interprétable entre modalités. L'entrer telle quelle impose un effet **constant** par unité, hypothèse souvent injustifiée. Solution : créer une indicatrice par moda-

lité (sauf la modalité de référence), ce qui laisse l'effet libre de varier d'un échelon à l'autre.

Application : classement des écoles et salaires

Découper le rang d'une école de commerce en tranches (`top10`, `r11_25`, ...) plutôt que de l'entrer en niveau améliore nettement l'ajustement ($\bar{R}^2$ passant de .836 à .905) : l'effet du classement sur le salaire de sortie n'est manifestement pas linéaire en rang. Ce principe s'applique à toute variable de notation — rating de crédit obligataire, scoring de risque — dès lors que rien ne garantit une relation linéaire avec la variable expliquée.

Interactions et indicatrices

Interaction entre deux indicatrices

Retrouver les catégories croisées


Ajouter *female* $\times$ *married* à un modèle contenant déjà *female* et *married* séparément permet à l'écart de mariage de différer entre hommes et femmes — c'est rigoureusement équivalent à définir directement les quatre indicatrices de groupe (chapitre précédent), mais l'écriture en interaction rend le test de l'hétérogénéité (H_0 : coefficient d'interaction = 0) immédiat.

Pentes différentes selon le groupe

Indicatrice $\times$ variable continue

$$\log(\text{wage}) = (\beta_0 + \delta_0 \text{female}) + (\beta_1 + \delta_1 \text{female}) \text{educ} + u$$

donne un intercept et une pente propres à chaque groupe. δ_0 capture l'écart d'intercept, δ_1 l'écart de **rendement de l'éducation** entre les groupes. Économétriquement, ce modèle s'estime en régressant *y* sur *female*, *educ* et *female* $\times$ *educ*.



Attention à la multicollinéarité induite

Quand $female$ et $female \times educ$ sont très corrélées dans l'échantillon (ce qui arrive dès que $educ = 0$ n'apparaît jamais dans les données), l'erreur-type de δ_0 explose : on estime alors mal l'écart au niveau $educ = 0$, point sans intérêt pratique. Recentrer l'interaction sur $(educ - \bar{educ})$ donne un écart interprétable à l'éducation moyenne, avec une erreur-type exploitable.

Le test de Chow

Statistique de Chow

Pour tester si un même modèle décrit deux groupes (H_0 : mêmes coefficients dans les deux), on compare la SSR de la régression **poolée** (SSR_p) à la somme des SSR des régressions **séparées** par groupe ($SSR_1 + SSR_2$) :

$$F = \frac{[SSR_p - (SSR_1 + SSR_2)]/(k+1)}{(SSR_1 + SSR_2)/[n - 2(k+1)]} \sim F_{k+1, n-2(k+1)} \text{ sous } H_0.$$

Équivalent à tester conjointement la significativité de l'indicatrice de groupe et de toutes ses interactions avec les régresseurs.

Chow global vs différence d'intercept seule

Le test de Chow interdit **toute** différence, y compris de pente. S'il rejette H_0 , il faut identifier *quelle* différence compte : tester seulement les interactions (H_0 : pentes égales, intercepts libres) est souvent plus informatif — c'est ce qu'on a fait ci-dessus pour l'écart de rendement de l'éducation.

La probabilité linéaire

Une variable dépendante binaire

Modèle de probabilité linéaire (MPL)

Quand $y \in \{0, 1\}$, $P(y = 1 | x) = E(y | x)$. Le modèle

$$P(y = 1 | x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

s'estime par MCO comme n'importe quel modèle linéaire ; $\hat{\beta}_j$ s'interprète comme la variation de la **probabilité de succès** pour une hausse d'une unité de x_j , toutes choses égales par ailleurs.

Participation au marché du travail

$\widehat{inlf} = .586 - .0034 nwifeinc + .038 educ + .039 exper - .0006 exper^2 - .016 age - .262 kidslt6 + .013 kidsge6$: chaque enfant de moins de 6 ans réduit la probabilité de participation de 26,2 points, alors qu'un enfant plus âgé n'a quasiment aucun effet — un contraste économique très parlant.

Une variable dépendante binaire (suite)

Les limites structurelles du MPL

Le MPL peut prédire des probabilités hors de $[0, 1]$, impose un effet marginal **constant** (irréaliste sur toute la plage de x), et souffre nécessairement d'hétéroscédasticité puisque $\text{Var}(y \mid x) = p(x)[1 - p(x)]$ dépend de x . Cela ne biaise pas $\hat{\beta}_j$ (chapitre 2) mais invalide les erreurs-types usuelles — problème traité au chapitre 7. En pratique, le MPL reste très utilisé pour son interprétabilité directe, surtout près du centre de la distribution des régresseurs.

Évaluation de politiques

Groupes de traitement et de contrôle, auto-sélection

Le problème de l'auto-sélection

Dans $y = \beta_0 + \beta_1 \text{partic} + u$, si la participation à un programme n'est pas assignée aléatoirement, $E(u \mid \text{partic} = 1) \neq E(u \mid \text{partic} = 0)$ est plausible : les participants diffèrent systématiquement des non-participants sur des facteurs **non observés** corrélés à y . La régression multiple atténue le problème en contrôlant les facteurs observables, mais ne le résout pas si des facteurs pertinents restent inobservés — situation qui appelle les méthodes plus avancées (variables instrumentales, données de panel) des chapitres suivants.

Application : subventions à la formation et discrimination au crédit

Deux usages typiques du MPL en évaluation de politiques : tester la discrimination dans l'octroi de prêts ($\text{approved} = \beta_0 + \beta_1 \text{nonwhite} + \beta_2 \text{income} + \dots$, où $\beta_1 < 0$ signale une discrimination *ceteris paribus*), et mesurer l'effet causal d'une subvention à la formation sur la productivité d'une firme. Dans les deux cas, la validité de l'interprétation causale dépend entièrement de la qualité des variables de contrôle incluses.

Synthèse

Ce qu'il faut retenir

L'essentiel du chapitre 6

- Une indicatrice s'interprète comme un décalage d'intercept ; g groupes exigent $g - 1$ indicatrices plus un intercept, sous peine de piège de colinéarité.
- L'information ordinaire se code par indicatrices par modalité plutôt qu'en niveau, sauf si la linéarité est justifiée.
- Les interactions indicatrice×continue permettent des pentes différentes par groupe ; le test de Chow généralise ceci à une différence globale entre groupes.
- Le modèle de probabilité linéaire étend la régression MCO aux variables dépendantes binaires, avec des limites (bornes, hétéroscédasticité) à garder en tête.

Vers le chapitre 7

Le MPL a mis en évidence un problème plus général : l'hétéroscédasticité, c'est-à-dire une variance de l'erreur qui dépend des régresseurs. Le chapitre suivant traite ce problème de

façon systématique — comment le détecter, et comment corriger l'inférence.