


Économétrie avancée

Annexe B : Rappels de probabilité



Avant de commencer

Variables aléatoires et leur distribution

Espérance et variance

Covariance, corrélation, variance d'une somme

La famille normale et ses dérivées

Synthèse

Avant de commencer

Pourquoi ce chapitre ?

Tous les résultats des chapitres 1 à 10 — non-biais, convergence, lois t et F — reposent sur un socle probabiliste précis : variables aléatoires, espérance, variance, covariance, et la famille de lois normale/ χ^2 / t / F . Ce chapitre rassemble ce socle en un seul endroit, comme référence et non comme nouveau cours de probabilité.

Variables aléatoires et leur distribution

Variable aléatoire et fonction de densité

Une **variable aléatoire** prend des valeurs numériques déterminées par le résultat d'une expérience. Une variable **discrète** prend un nombre fini (ou dénombrable) de valeurs, chacune associée à une probabilité $p_j = P(X = x_j)$ (avec $\sum_j p_j = 1$) : c'est la **fonction de densité (pdf)** $f(x)$. Une variable **continue** prend n'importe quelle valeur réelle avec probabilité individuelle nulle; seules les probabilités sur un intervalle, obtenues par l'aire sous f , ont un sens.

Fonction de répartition (cdf)

$$F(x) = P(X \leq x)$$

est toujours croissante, comprise entre 0 et 1. Elle permet de calculer toute probabilité d'intervalle : $P(X > c) = 1 - F(c)$ et $P(a < X \leq b) = F(b) - F(a)$.

Indépendance

X et Y sont **indépendantes** si et seulement si $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ pour tout (x, y) – la probabilité jointe se factorise. L'indépendance implique l'absence de corrélation, mais l'inverse est faux (voir plus bas).

Distribution conditionnelle et espérance conditionnelle

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

L'**espérance conditionnelle** $E(Y | X = x)$ – moyenne de Y pour une valeur donnée de X – est l'outil central de l'économétrie : la fonction de régression $E(y | x)$ des chapitres 2 à 10 n'est rien d'autre que cette notion, appliquée à un modèle linéaire en x .

Espérance et variance

Espérance (moyenne de population)

Pour X discrète, $E(X) = \sum_j x_j f(x_j)$ – une moyenne pondérée par les probabilités. Propriétés essentielles : $E(c) = c$ pour toute constante; $E(aX + b) = aE(X) + b$ (linéarité); plus généralement, $E(\sum_i a_i X_i) = \sum_i a_i E(X_i)$, **sans aucune condition d'indépendance**.

Une mise en garde utile : $E[g(X)] \neq g[E(X)]$

Sauf cas particulier (fonction affine), l'espérance d'une transformation non linéaire de X n'est **pas** la transformation de l'espérance – $E(X^2) \neq [E(X)]^2$ en général. Ce fait rappelle pourquoi $\text{Var}(X) = E(X^2) - [E(X)]^2$ est presque toujours strictement positif.

Variance et écart-type

$$\text{Var}(X) = E[(X - \mu)^2] = E(X^2) - \mu^2, \quad sd(X) = \sqrt{\text{Var}(X)}.$$

$\text{Var}(aX + b) = a^2 \text{Var}(X)$: ajouter une constante ne change pas la dispersion, la multiplier par a multiplie la variance par a^2 (et l'écart-type par $|a|$) – c'est pourquoi l'écart-type, exprimé dans l'unité d'origine, est souvent plus interprétable que la variance.

Standardisation

$$Z = \frac{X - \mu}{\sigma} \implies E(Z) = 0, \text{Var}(Z) = 1.$$

C'est exactement la construction du **coefficient bêta** du chapitre 6 : centrer-réduire une variable pour rendre les comparaisons indépendantes de l'unité de mesure.

Covariance, corrélation, variance d'une somme

Mesurer l'association linéaire

Covariance et corrélation

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - \mu_X \mu_Y, \quad \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{sd(X) sd(Y)} \in [-1, 1].$$

X, Y indépendantes $\Rightarrow \text{Cov}(X, Y) = 0$ (non corrélées) – mais **l'inverse est faux** : X et X^2 peuvent avoir une covariance nulle tout en étant manifestement dépendantes. Covariance et corrélation ne captent que la dépendance **linéaire**.

Un exemple qui piège

Si $E(X) = 0$, alors $\text{Cov}(X, X^2) = E(X^3)$, qui s'annule dès que la distribution de X est symétrique – bien que $Y = X^2$ soit une fonction déterministe (donc parfaitement dépendante) de X . La corrélation nulle ne signifie jamais absence de relation, seulement absence de relation **linéaire**.

Variance d'une combinaison linéaire

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

Si X et Y sont non corrélées, $\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$ – la variance d'une **différence** est

Propriétés de l'espérance conditionnelle

$E[c(X) | X] = c(X)$ (une fonction de X se comporte comme une constante une fois X connu); si $X \perp Y$, $E(Y | X) = E(Y)$; et surtout, la **loi des espérances itérées** :

$$E[E(Y | X)] = E(Y).$$

Si $E(Y | X) = E(Y)$ (l'espérance conditionnelle ne dépend pas de X), alors $\text{Cov}(X, Y) = 0$ – c'est ce résultat qui justifie que $E(u | x) = 0$ (hypothèse centrale de tout ce cours depuis le chapitre 2) implique $\text{Cov}(x, u) = 0$, condition nécessaire à l'absence de biais des MCO.

Pourquoi l'espérance conditionnelle est le meilleur prédicteur

Parmi toutes les fonctions $g(X)$ possibles, $E(Y | X)$ minimise l'erreur quadratique moyenne de prédiction $E\{[Y - g(X)]^2\}$. C'est la justification probabiliste profonde de la régression : quand on écrit $E(y | x) = \beta_0 + \beta_1 x$, on postule que **la meilleure prédiction linéaire** de y est une fonction affine de x .

La famille normale et ses dérivées

Loi normale et loi normale centrée réduite

$X \sim \mathcal{N}(\mu, \sigma^2)$ a pour densité $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp[-(x - \mu)^2/2\sigma^2]$, symétrique autour de μ .

Standardiser X donne $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$, dont la cdf $\Phi(z)$ est tabulée. Toute combinaison linéaire de variables normales indépendantes est elle-même normale — en particulier, la moyenne de n variables i.i.d. $\mathcal{N}(\mu, \sigma^2)$ suit $\mathcal{N}(\mu, \sigma^2/n)$.

Corrélation nulle = indépendance, un cas spécial à la loi normale

En général, absence de corrélation n'implique pas indépendance (voir plus haut) — sauf pour des variables **conjointement normales**, où les deux notions coïncident. C'est une propriété remarquable, propre à la famille gaussienne, qui simplifie beaucoup l'analyse sous l'hypothèse de normalité (MLR.6, chapitre 4).

Construction des trois lois de l'inférence

Avec $Z, Z_1, \dots, Z_n$ des $\mathcal{N}(0, 1)$ indépendantes :

- $\chi_n^2 = \sum_{i=1}^n Z_i^2$ suit une loi du **chi-deux** à n degrés de liberté ($E = n$, $\text{Var} = 2n$), toujours positive, non symétrique.
- $T = Z / \sqrt{\chi_n^2/n}$ (avec Z et χ_n^2 indépendantes) suit une loi de **Student** t_n – plus dispersée que la normale, s'en rapprochant quand $n \rightarrow \infty$.
- $F = (\chi_{k_1}^2/k_1)/(\chi_{k_2}^2/k_2)$ suit une loi de **Fisher** F_{k_1, k_2} .

Pourquoi ces trois lois, précisément

Ce n'est pas un hasard si ce sont exactement les trois lois des chapitres 4 et 8 : le test t sur un coefficient MCO combine un numérateur normal ($\hat{\beta}_j$ centré) et un dénominateur qui est la racine d'un χ^2 (l'estimateur de σ^2 , via $SSR/\sigma^2 \sim \chi_{n-k-1}^2$ sous normalité) – exactement la construction de T ci-dessus. Le test F pour des restrictions multiples est de même un ratio de deux χ^2 normalisés. Toute la théorie exacte du chapitre 4 est une application directe de ces trois définitions.

Synthèse

L'essentiel du chapitre 11

- Espérance et variance obéissent à des règles de linéarité simples, valables sans hypothèse d'indépendance pour l'espérance, avec covariance pour la variance.
- Covariance et corrélation ne mesurent que la dépendance linéaire; l'espérance conditionnelle capture toute la relation, linéaire ou non, et minimise l'erreur quadratique de prédiction.
- $E(u \mid x) = 0 \Rightarrow \text{Cov}(x, u) = 0$ via la loi des espérances itérées : c'est le pont exact entre l'hypothèse fondamentale de la régression et la condition d'orthogonalité utilisée pour dériver les MCO.
- Les lois χ^2 , t et F se construisent toutes à partir de normales indépendantes; ce sont précisément les lois utilisées pour l'inférence exacte en régression (chapitre 4).

Vers le chapitre 12

Ce chapitre a traité les variables aléatoires **individuellement**, comme des objets de population. Le chapitre suivant applique ces mêmes outils à l'**échantillonnage** — comment un estimateur, construit à partir d'un échantillon, hérite lui-même d'une distribution de probabilité, et comment on en tire les propriétés (non-biais, efficacité, convergence) déjà utilisées depuis le chapitre 2.