

# Économétrie avancée

## Annexe C : Rappels de statistique mathématique

---

Jaouad Madkour

19 août 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous?

Échantillonnage et estimateurs

Propriétés à échantillon fini

Propriétés asymptotiques


Méthodes générales d'estimation

Estimation par intervalle et tests d'hypothèses

Synthèse

Où en sommes-nous?

---



### Pourquoi ce chapitre ?

Le chapitre 11 a traité les variables aléatoires comme des objets de population. Ce chapitre franchit l'étape suivante : comment un **estimateur** — construit à partir d'un échantillon — hérite lui-même d'une distribution de probabilité, et quels critères permettent de juger qu'il est « bon ». C'est le socle exact des propriétés (non-biais, BLUE, convergence, normalité asymptotique) invoquées depuis le chapitre 2 sans être redémontrées.

## Échantillonnage et estimateurs

---

## Échantillon aléatoire (i.i.d.)

$\{Y_1, \dots, Y_n\}$  constitue un **échantillon aléatoire** tiré de  $f(y; \theta)$  si les  $Y_i$  sont indépendantes et identiquement distribuées (i.i.d.) selon cette même densité. C'est l'hypothèse MLR.2 du chapitre 2, formulée dans le langage général de la statistique mathématique.

## Estimateur vs estimation

Un **estimateur**  $W = h(Y_1, \dots, Y_n)$  est une règle, fixée avant l'échantillonnage, qui associe à tout échantillon possible une valeur numérique — c'est une variable aléatoire, dotée d'une **distribution d'échantillonnage**. Une fois les données observées,  $w = h(y_1, \dots, y_n)$  est une **estimation** : un simple nombre.

## Propriétés à échantillon fini

---



## Estimateur non biaisé

$W$  est **non biaisé** pour  $\theta$  si  $E(W) = \theta$  pour toute valeur de  $\theta$ . Le non-biais ne garantit **pas** qu'une estimation particulière soit proche de  $\theta$  — seulement que la moyenne sur toutes les répétitions possibles de l'échantillonnage coïnciderait avec  $\theta$ .

## Le non-biais ne suffit pas

Estimer  $\mu$  par la seule première observation  $W = Y_1$  est non biaisé ( $E(Y_1) = \mu$ ) mais gaspille presque toute l'information de l'échantillon : sa variance,  $\text{Var}(Y_1) = \sigma^2$ , ne diminue jamais avec  $n$ , alors que celle de la moyenne d'échantillon  $\bar{Y}$  vaut  $\sigma^2/n$ . Le non-biais seul ne classe donc pas les estimateurs entre eux — il faut aussi comparer les variances.

## Efficacité relative et erreur quadratique moyenne (EQM)

Entre deux estimateurs non biaisés,  $W_1$  est **efficace relativement** à  $W_2$  si  $\text{Var}(W_1) \leq \text{Var}(W_2)$  (strictement pour au moins une valeur de  $\theta$ ). Pour comparer des estimateurs même biaisés, l'**erreur quadratique moyenne**  $EQM(W) = E[(W - \theta)^2] = \text{Var}(W) + [\text{Biais}(W)]^2$  combine les deux sources d'erreur en un seul critère.

## Propriétés asymptotiques

---

## Convergence (consistance)

$W_n$  est **convergent** pour  $\theta$  si, pour tout  $\varepsilon > 0$ ,  $P(|W_n - \theta| > \varepsilon) \rightarrow 0$  quand  $n \rightarrow \infty$  – noté  $\text{plim}(W_n) = \theta$ . Un estimateur non biaisé dont la variance tend vers zéro est automatiquement convergent (cas de  $\bar{Y}$ , via la **loi des grands nombres**).

## Propriétés du plim

Pour  $g$  continue,  $\text{plim } g(W_n) = g(\text{plim } W_n)$ ; et si  $\text{plim}(T_n) = \alpha$ ,  $\text{plim}(U_n) = \beta$ , alors  $\text{plim}(T_n + U_n) = \alpha + \beta$ ,  $\text{plim}(T_n U_n) = \alpha\beta$ , et  $\text{plim}(T_n/U_n) = \alpha/\beta$  (si  $\beta \neq 0$ ). Ces règles simples justifient la convergence de fonctions complexes d'estimateurs convergents – exactement la logique utilisée au chapitre 5 pour établir la convergence des MCO.

## Théorème central limite (TCL)

Pour tout échantillon i.i.d. de moyenne  $\mu$  et variance  $\sigma^2$  finie,

$$Z_n = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1),$$

**quelle que soit** la distribution sous-jacente de  $Y$ . C'est un résultat remarquable : la normalité de  $\bar{Y}$  en grand échantillon ne dépend d'aucune hypothèse sur la forme de la population.

## Le pont vers le chapitre 5 de ce cours

Le TCL est exactement l'outil invoqué pour justifier la normalité asymptotique des MCO sans supposer  $u$  normal (chapitre 5) : la plupart des estimateurs économétriques s'écrivent comme fonctions de moyennes d'échantillon, et héritent donc de la normalité asymptotique du TCL par les propriétés du plim ci-dessus.

## Méthodes générales d'estimation

---

# Trois grandes familles

## Méthode des moments, maximum de vraisemblance, moindres carrés

La **méthode des moments** remplace un moment de population ( $\mu, \sigma_{XY}$ ) par son analogue empirique — c'est ainsi qu'on obtient  $\bar{Y}$ , la covariance ou la corrélation échantillonnales. Le **maximum de vraisemblance (MV)** choisit la valeur de  $\theta$  qui rend l'échantillon observé le plus probable, en maximisant  $L(\theta) = \prod_i f(y_i; \theta)$ ; il est généralement le plus efficace asymptotiquement quand le modèle est correctement spécifié. Les **moindres carrés** minimisent une somme de carrés d'écarts —  $\bar{Y}$  elle-même est l'estimateur des moindres carrés de  $\mu$ . Ces trois principes coïncident souvent (normale, Bernoulli) mais pas toujours.

## Application : où ces méthodes réapparaissent

Les MCO du chapitre 2 sont un estimateur des moindres carrés; l'estimateur du maximum de vraisemblance réapparaît explicitement dans les modèles GARCH (chapitre 4, économétrie financière), où la vraisemblance gaussienne est maximisée numériquement faute de formule fermée — un cas où les trois principes ne coïncident plus et où le choix de la méthode d'estimation devient un choix de modélisation à part entière.

## Estimation par intervalle et tests d'hypothèses

---

## Interprétation correcte d'un intervalle de confiance

Un IC à 95 % pour  $\mu$ ,  $[\bar{y} \pm c \cdot se(\bar{y})]$ , ne signifie **pas** “ $\mu$  a 95 % de chances d’être dans cet intervalle” une fois l’échantillon observé —  $\mu$  et les bornes sont alors des nombres fixes. La bonne lecture : sur 95 % des échantillons aléatoires possibles, l’intervalle **construit selon cette procédure** contiendrait  $\mu$ .

## Règle pratique à retenir

Pour  $n$  grand, un IC à 95 % approché est simplement [estimation  $\pm 2 \times$  erreur-type] — le facteur 1,96 (loi normale) ou la valeur  $t$  correspondante (petits échantillons, chapitre 4) se confondant avec 2 dès que  $n$  dépasse une vingtaine d’observations.



## Hypothèse nulle et hypothèse alternative

$H_0$  est présumée vraie jusqu'à preuve statistique contraire "au-delà du doute raisonnable" — exactement le même principe que le test  $t$  du chapitre 4, ici formulé dans le cadre général de l'inférence statistique plutôt que spécifiquement pour un coefficient de régression.

## Discrimination à l'embauche : un test par paires

Sur 241 paires de candidatures identiques hormis la couleur de peau, 22,4 % des candidats noirs reçoivent une offre contre 35,7 % des candidats blancs. L'IC approché à 95 % pour l'écart de probabilité,  $-.133 \pm 1.96(.482/\sqrt{241}) \approx [-.164, -.102]$ , exclut nettement zéro — même l'IC à 99 % exclut zéro. C'est un exemple archétypal de test par paires appariées (*matched pairs*), une méthode de contrôle des facteurs de confusion évoquée dès le chapitre 3.

## Synthèse

---

## L'essentiel du chapitre 12

- Un estimateur est une variable aléatoire; le non-biais seul ne suffit pas à le juger bon — la variance (ou l'EQM pour les estimateurs biaisés) doit être prise en compte.
- La convergence et la normalité asymptotique (via le théorème central limite) sont les propriétés qui justifient l'inférence en grand échantillon, y compris quand la population sous-jacente n'est pas normale.
- Méthode des moments, maximum de vraisemblance et moindres carrés sont trois grands principes d'estimation, qui coïncident souvent mais pas toujours.
- Un intervalle de confiance se lit comme une propriété de la **procédure** répétée, pas comme une probabilité sur le paramètre une fois l'échantillon observé.

## Vers le chapitre 13

Chapitres 11 et 12 forment ensemble le socle probabiliste et statistique de tout ce cours. Les deux derniers chapitres reformulent la régression multiple elle-même en **notation matricielle** — un langage plus compact qui généralise immédiatement tout ce qui a été vu, du non-biais des MCO (chapitre 2) à l'inférence en grand échantillon (chapitre 5).

# Le fil conducteur du programme

