

# Économétrie avancée

## Chapitre 14 : Le modèle de régression linéaire sous forme matricielle

---

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Le modèle et l'estimateur MCO


Propriétés à échantillon fini

Inférence exacte sous normalité

Synthèse générale du cours

Où en sommes-nous?

---



## Pourquoi ce chapitre ?

Ce chapitre reformule le cours en notations matricielles compactes, tout ce qui a été établi progressivement depuis le chapitre 2 : l'estimateur MCO, son non-biais, sa matrice de variance-covariance, le théorème de Gauss-Markov, et l'inférence exacte sous normalité. Rien de nouveau sur le plan économique — mais une vision d'ensemble, unifiée, du cours entier.

## Le modèle et l'estimateur MCO

---

## Le modèle sous forme matricielle

Avec  $\mathbf{y}$  ( $n \times 1$ ) le vecteur des observations,  $\mathbf{X}$  ( $n \times k$ ) la matrice des régresseurs (première colonne de 1 pour l'intercept) et  $\mathbf{u}$  ( $n \times 1$ ) le vecteur des erreurs, le modèle linéaire s'écrit en une seule équation :

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}.$$

Chacune des  $n$  équations individuelles  $y_t = \mathbf{x}_t\beta + u_t$  (chapitre 3) est une ligne de cette écriture compacte.

## L'estimateur MCO en une formule

Minimiser  $SSR(\mathbf{b}) = (\mathbf{y} - \mathbf{Xb})'(\mathbf{y} - \mathbf{Xb})$  conduit aux équations normales  $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$  – l'équivalent matriciel exact des conditions de premier ordre du chapitre 3 – dont la solution, quand  $\mathbf{X}'\mathbf{X}$  est inversible, est

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Cette formule unique condense tout le système des  $k$  équations à  $k$  inconnues du chapitre 3.

## Le rôle exact du rang plein

$\mathbf{X}'\mathbf{X}$  est inversible si et seulement si  $\text{rang}(\mathbf{X}) = k$  – la traduction matricielle directe de MLP 3

## Propriétés à échantillon fini

---

## Hypothèses E.1–E.3 et non-biais

Sous linéarité (E.1), exogénéité stricte  $E(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$  (E.2, généralisation matricielle de MLR.3-4) et rang plein (E.3), on écrit

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u},$$

d'où  $E(\hat{\beta} \mid \mathbf{X}) = \beta$  immédiatement, puisque  $E(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$ . Toute la démonstration du non-biais MCO (chapitre 3) tient en cette seule ligne de calcul matriciel.



### Homoscédasticité et absence d'autocorrélation réunies

Sous E.4,  $\text{Var}(\mathbf{u} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n$  (chapitre 13), on obtient

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}.$$

La variance de  $\hat{\beta}_j$  est  $\sigma^2$  fois le  $j$ -ième terme diagonal de  $(\mathbf{X}'\mathbf{X})^{-1}$ ; les covariances entre estimateurs, nécessaires pour tester des combinaisons linéaires de coefficients (chapitre 4), sont directement les termes hors diagonale — plus besoin de la formule ad hoc du chapitre 3 pour chaque cas particulier.

## MCO = BLUE, démonstration matricielle

Pour tout estimateur linéaire non biaisé  $\tilde{\beta} = \mathbf{A}\mathbf{y}$  (avec  $\mathbf{A}\mathbf{X} = \mathbf{I}_k$ , condition de non-biais), on montre que

$$\text{Var}(\tilde{\beta} \mid \mathbf{X}) - \text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 \mathbf{A}'\mathbf{M}\mathbf{A},$$

où  $\mathbf{M} = \mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$  est **idempotente** (chapitre 13) — donc  $\mathbf{A}'\mathbf{M}\mathbf{A}$  est semi-définie positive. Pour toute combinaison linéaire  $\mathbf{c}'\beta$ ,  $\text{Var}(\mathbf{c}'\tilde{\beta}) \geq \text{Var}(\mathbf{c}'\hat{\beta})$  : les MCO sont **BLUE**, dans toute leur généralité, pas seulement coefficient par coefficient.

## La matrice $\mathbf{M}$ , déjà rencontrée

$\mathbf{M}$  est exactement la matrice idempotente de rang  $n - k$  introduite au chapitre 13 comme préfiguration des résidus :  $\hat{\mathbf{u}} = \mathbf{M}\mathbf{y} = \mathbf{M}\mathbf{u}$ . Elle joue ici un double rôle — produire les résidus, et démontrer l'optimalité des MCO — ce qui illustre pourquoi les outils du chapitre 13 étaient nécessaires avant d'aborder ce résultat.

### Non-biais de $\hat{\sigma}^2$

Avec  $\hat{\sigma}^2 = \hat{\mathbf{u}}' \hat{\mathbf{u}} / (n - k)$ , en utilisant  $\hat{\mathbf{u}} = \mathbf{M}\mathbf{u}$ ,  $\text{tr}(\mathbf{M}) = n - k$  (chapitre 13) et la propriété  $E[\text{tr}(\mathbf{M}\mathbf{u}\mathbf{u}') \mid \mathbf{X}] = \sigma^2 \text{tr}(\mathbf{M})$ , on obtient  $E(\hat{\sigma}^2 \mid \mathbf{X}) = \sigma^2$  – la démonstration générale, en quelques lignes, de ce qui était admis sans preuve complète au chapitre 3.

## Inférence exacte sous normalité

---

# Normalité de $\hat{\beta}$ et lois exactes

## Le modèle linéaire classique en notation matricielle

Ajoutant  $\mathbf{u} \mid \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$  (E.5, hypothèse MLR.6 du chapitre 4), on obtient

$$\hat{\beta} \mid \mathbf{X} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}),$$

puisque  $\hat{\beta}$  est une transformation linéaire de  $\mathbf{u}$  (propriété de la loi normale multivariée, chapitre 13).

## D'où viennent exactement les lois $t$ et $F$

Trois ingrédients, tous établis au chapitre 13, se combinent : (i)  $(\hat{\beta}_j - \beta_j)/sd(\hat{\beta}_j) \sim \mathcal{N}(0, 1)$ ; (ii)  $(n - k)\hat{\sigma}^2/\sigma^2 = (\mathbf{u}/\sigma)' \mathbf{M}(\mathbf{u}/\sigma) \sim \chi_{n-k}^2$  car  $\mathbf{M}$  est idempotente de rang  $n - k$ ; (iii)  $\hat{\beta}$  et  $\hat{\sigma}^2$  sont **indépendants**, car  $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{M} = \mathbf{0}$ . En combinant (i), (ii) et (iii) selon la définition même de la loi de Student (chapitre 13),

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}.$$

## Le test $t$ du chapitre 4, enfin complètement démontré

Cette dérivation referme une boucle ouverte depuis le chapitre 4 : le résultat

MCO = estimateur à variance minimale, MCO = MV

Sous les hypothèses E.1–E.5, la borne de Cramér-Rao pour tout estimateur non biaisé de  $\beta$  est exactement  $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$  : les MCO sont donc **optimaux parmi tous les estimateurs non biaisés**, pas seulement parmi les estimateurs linéaires (extension du théorème de Gauss-Markov). De plus, sous normalité, maximiser la vraisemblance revient exactement à minimiser  $SSR(\mathbf{b})$  : MCO et maximum de vraisemblance **coïncident** – sauf pour  $\sigma^2$ , où l'estimateur MV ( $SSR/n$ ) est biaisé, contrairement à  $\hat{\sigma}^2 = SSR/(n - k)$  systématiquement préféré en pratique.

## Synthèse générale du cours

---

## L'essentiel du chapitre 14

- $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$  condense en une formule tout le système d'équations normales du chapitre 3; son existence exige le rang plein de  $\mathbf{X}$ .
- Non-biais, matrice de variance-covariance  $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ , et théorème de Gauss-Markov (BLUE) se démontrent en quelques lignes à partir des outils du chapitre 13 — idempotence, positivité semi-définie, propriétés de l'espérance et de la variance matricielles.
- Sous normalité, les lois  $t$  et  $F$  exactes du chapitre 4 découlent directement des propriétés des matrices idempotentes appliquées au vecteur d'erreurs.
- Les MCO sont l'estimateur à variance minimale parmi **tous** les estimateurs non biaisés (pas seulement linéaires) sous normalité, et coïncident avec le maximum de vraisemblance pour  $\beta$ .

## Fin de ce second bloc du cours

Les chapitres 6 à 14 ont approfondi et généralisé les fondations posées aux chapitres 1 à 5 : formes fonctionnelles avancées, variables qualitatives, hétéroscédasticité, problèmes de spécification, séries temporelles, et enfin l'appareil probabiliste et matriciel complet qui sous-tend l'ensemble. Les chapitres suivants (variables instrumentales, données de panel) prolongeront ce cadre vers les situations où l'exogénéité stricte elle-même doit être abandonnée.



# Le fil conducteur du programme

