

Économétrie avancée

Chapitre 14 : Le modèle de régression linéaire sous forme matricielle

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Le modèle et l'estimateur MCO

Propriétés à échantillon fini

Inférence exacte sous normalité

Synthèse générale du cours

Où en sommes-nous?



Pourquoi ce chapitre ?

Ce chapitre reformule le cours en notation matricielle compacte, tout ce qui a été établi progressivement depuis le chapitre 2 : l'estimateur MCO, son non-biais, sa matrice de variance-covariance, le théorème de Gauss-Markov, et l'inférence exacte sous normalité. Rien de nouveau sur le plan économique — mais une vision d'ensemble, unifiée, du cours entier.

Le modèle et l'estimateur MCO

Le modèle sous forme matricielle

Avec $\mathbf{y}$ ($n \times 1$) le vecteur des observations, $\mathbf{X}$ ($n \times k$) la matrice des régresseurs (première colonne de 1 pour l'intercept) et $\mathbf{u}$ ($n \times 1$) le vecteur des erreurs, le modèle linéaire s'écrit en une seule équation :

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}.$$

Chacune des n équations individuelles $y_t = \mathbf{x}_t\beta + u_t$ (chapitre 3) est une ligne de cette écriture compacte.

L'estimateur MCO en une formule

Minimiser $SSR(\mathbf{b}) = (\mathbf{y} - \mathbf{Xb})'(\mathbf{y} - \mathbf{Xb})$ conduit aux équations normales $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$ – l'équivalent matriciel exact des conditions de premier ordre du chapitre 3 – dont la solution, quand $\mathbf{X}'\mathbf{X}$ est inversible, est

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Cette formule unique condense tout le système des k équations à k inconnues du chapitre 3.

Le rôle exact du rang plein

$\mathbf{X}'\mathbf{X}$ est inversible si et seulement si $\text{rang}(\mathbf{X}) = k$ – la traduction matricielle directe de MLP 3

Propriétés à échantillon fini

Hypothèses E.1–E.3 et non-biais

Sous linéarité (E.1), exogénéité stricte $E(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$ (E.2, généralisation matricielle de MLR.3-4) et rang plein (E.3), on écrit

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u},$$

d'où $E(\hat{\beta} \mid \mathbf{X}) = \beta$ immédiatement, puisque $E(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$. Toute la démonstration du non-biais MCO (chapitre 3) tient en cette seule ligne de calcul matriciel.

Homoscédasticité et absence d'autocorrélation réunies

Sous E.4, $\text{Var}(\mathbf{u} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n$ (chapitre 13), on obtient

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}.$$

La variance de $\hat{\beta}_j$ est σ^2 fois le j -ième terme diagonal de $(\mathbf{X}'\mathbf{X})^{-1}$; les covariances entre estimateurs, nécessaires pour tester des combinaisons linéaires de coefficients (chapitre 4), sont directement les termes hors diagonale — plus besoin de la formule ad hoc du chapitre 3 pour chaque cas particulier.

Le théorème de Gauss-Markov, version générale

MCO = BLUE, démonstration matricielle

Pour tout estimateur linéaire non biaisé $\tilde{\beta} = \mathbf{A}\mathbf{y}$ (avec $\mathbf{A}\mathbf{X} = \mathbf{I}_k$, condition de non-biais), on montre que

$$\text{Var}(\tilde{\beta} \mid \mathbf{X}) - \text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 \mathbf{A}'\mathbf{M}\mathbf{A},$$

où $\mathbf{M} = \mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ est **idempotente** (chapitre 13) — donc $\mathbf{A}'\mathbf{M}\mathbf{A}$ est semi-définie positive. Pour toute combinaison linéaire $\mathbf{c}'\beta$, $\text{Var}(\mathbf{c}'\tilde{\beta}) \geq \text{Var}(\mathbf{c}'\hat{\beta})$: les MCO sont **BLUE**, dans toute leur généralité, pas seulement coefficient par coefficient.

La matrice $\mathbf{M}$, déjà rencontrée

$\mathbf{M}$ est exactement la matrice idempotente de rang $n - k$ introduite au chapitre 13 comme préfiguration des résidus : $\hat{\mathbf{u}} = \mathbf{M}\mathbf{y} = \mathbf{M}\mathbf{u}$. Elle joue ici un double rôle — produire les résidus, et démontrer l'optimalité des MCO — ce qui illustre pourquoi les outils du chapitre 13 étaient nécessaires avant d'aborder ce résultat.

Non-biais de $\hat{\sigma}^2$

Avec $\hat{\sigma}^2 = \hat{\mathbf{u}}' \hat{\mathbf{u}} / (n - k)$, en utilisant $\hat{\mathbf{u}} = \mathbf{M}\mathbf{u}$, $\text{tr}(\mathbf{M}) = n - k$ (chapitre 13) et la propriété $E[\text{tr}(\mathbf{M}\mathbf{u}\mathbf{u}') \mid \mathbf{X}] = \sigma^2 \text{tr}(\mathbf{M})$, on obtient $E(\hat{\sigma}^2 \mid \mathbf{X}) = \sigma^2$ – la démonstration générale, en quelques lignes, de ce qui était admis sans preuve complète au chapitre 3.

Inférence exacte sous normalité

Normalité de $\hat{\beta}$ et lois exactes

Le modèle linéaire classique en notation matricielle

Ajoutant $\mathbf{u} \mid \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ (E.5, hypothèse MLR.6 du chapitre 4), on obtient

$$\hat{\beta} \mid \mathbf{X} \sim \mathcal{N}(\beta, \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}),$$

puisque $\hat{\beta}$ est une transformation linéaire de $\mathbf{u}$ (propriété de la loi normale multivariée, chapitre 13).

D'où viennent exactement les lois t et F

Trois ingrédients, tous établis au chapitre 13, se combinent : (i) $(\hat{\beta}_j - \beta_j)/sd(\hat{\beta}_j) \sim \mathcal{N}(0, 1)$; (ii) $(n - k)\hat{\sigma}^2/\sigma^2 = (\mathbf{u}/\sigma)' \mathbf{M}(\mathbf{u}/\sigma) \sim \chi_{n-k}^2$ car $\mathbf{M}$ est idempotente de rang $n - k$; (iii) $\hat{\beta}$ et $\hat{\sigma}^2$ sont **indépendants**, car $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{M} = \mathbf{0}$. En combinant (i), (ii) et (iii) selon la définition même de la loi de Student (chapitre 13),

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}.$$

Le test t du chapitre 4, enfin complètement démontré

Cette dérivation referme une boucle ouverte depuis le chapitre 4 : le résultat

MCO = estimateur à variance minimale, MCO = MV

Sous les hypothèses E.1–E.5, la borne de Cramér-Rao pour tout estimateur non biaisé de β est exactement $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$: les MCO sont donc **optimaux parmi tous les estimateurs non biaisés**, pas seulement parmi les estimateurs linéaires (extension du théorème de Gauss-Markov). De plus, sous normalité, maximiser la vraisemblance revient exactement à minimiser $SSR(\mathbf{b})$: MCO et maximum de vraisemblance **coïncident** – sauf pour σ^2 , où l'estimateur MV (SSR/n) est biaisé, contrairement à $\hat{\sigma}^2 = SSR/(n - k)$ systématiquement préféré en pratique.

Synthèse générale du cours

L'essentiel du chapitre 14

- $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ condense en une formule tout le système d'équations normales du chapitre 3; son existence exige le rang plein de $\mathbf{X}$.
- Non-biais, matrice de variance-covariance $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$, et théorème de Gauss-Markov (BLUE) se démontrent en quelques lignes à partir des outils du chapitre 13 — idempotence, positivité semi-définie, propriétés de l'espérance et de la variance matricielles.
- Sous normalité, les lois t et F exactes du chapitre 4 découlent directement des propriétés des matrices idempotentes appliquées au vecteur d'erreurs.
- Les MCO sont l'estimateur à variance minimale parmi **tous** les estimateurs non biaisés (pas seulement linéaires) sous normalité, et coïncident avec le maximum de vraisemblance pour β .

Fin de ce second bloc du cours

Les chapitres 6 à 14 ont approfondi et généralisé les fondations posées aux chapitres 1 à 5 : formes fonctionnelles avancées, variables qualitatives, hétéroscédasticité, problèmes de spécification, séries temporelles, et enfin l'appareil probabiliste et matriciel complet qui sous-tend l'ensemble. Les chapitres suivants (variables instrumentales, données de panel) prolongeront ce cadre vers les situations où l'exogénéité stricte elle-même doit être abandonnée.

Le fil conducteur du programme

