

Économétrie avancée

Chapitre 2 : Régression multiple — estimation

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 25 septembre 2026

Plan du chapitre

Avant de commencer

Le modèle et son estimation

Les hypothèses de Gauss-Markov

Qualité de l'ajustement

Synthèse

Avant de commencer

Pourquoi ce chapitre ?

La régression simple ne peut contrôler qu'un seul facteur à la fois — une hypothèse SLR.4 rarement crédible. La régression **multiple** contrôle simultanément plusieurs facteurs, rapprochant l'analyse *ceteris paribus* d'une véritable comparaison « toutes choses égales par ailleurs ».

Le modèle et son estimation

Spécification et écriture matricielle

Modèle de régression multiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u,$$

ou, sous forme matricielle (l'introduction, algèbre linéaire), $y = X\beta + u$ où X est la matrice $n \times (k + 1)$ des régresseurs (une colonne de 1 pour l'intercept, puis une colonne par x_j).

L'estimateur MCO en notation matricielle

En minimisant $\sum_i \hat{u}_i^2 = (y - X\hat{\beta})^\top (y - X\hat{\beta})$, les conditions du premier ordre donnent

$$\hat{\beta} = (X^\top X)^{-1} X^\top y,$$

qui n'existe que si $X^\top X$ est **inversible** (chapitre 3, algèbre linéaire) — c'est-à-dire si aucun régresseur n'est combinaison linéaire exacte des autres.

Chaque β_i , toutes choses égales par ailleurs

Les hypothèses de Gauss-Markov

Hypothèses MLR

- **MLR.1–2** : linéarité en les paramètres, échantillonnage aléatoire.
- **MLR.3** (absence de colinéarité parfaite) : aucun x_j n'est une combinaison linéaire exacte des autres régresseurs.
- **MLR.4** (exogénéité) : $\mathbb{E}[u \mid x_1, \dots, x_k] = 0$.
- **MLR.5** (homoscédasticité) : $\text{Var}(u \mid x_1, \dots, x_k) = \sigma^2$, constante.

Théorème de Gauss-Markov

Sous MLR.1 à MLR.4, l'estimateur MCO est **non biaisé** : $\mathbb{E}[\hat{\beta}_j] = \beta_j$. Sous MLR.1 à MLR.5 (l'ensemble complet), l'estimateur MCO est en outre le meilleur estimateur linéaire non biaisé (**BLUE** — *Best Linear Unbiased Estimator*) : parmi tous les estimateurs linéaires et non biaisés de β_j , il a la **variance la plus faible**.

Que se passe-t-il si l'on oublie un facteur pertinent ?

Si le « vrai » modèle contient x_1 et x_2 , mais qu'on estime une régression n'incluant que x_1 , l'estimateur de son coefficient est biaisé dès que x_1 et x_2 sont corrélés — l'estimateur simple capture alors, en partie, l'effet de x_2 « transmis » via sa corrélation avec x_1 . C'est le **biais de variable omise**, la généralisation directe du problème rencontré au chapitre 1.

Corrélation entre régresseurs : pas de biais, mais de la variance

Une forte corrélation entre régresseurs (**multicollinéarité**) ne biaise **pas** les MCO (MLR.4 reste satisfaite), mais **gonfle la variance** des estimateurs : il devient statistiquement difficile de démêler l'effet propre de chaque variable corrélée. Un cas extrême — une corrélation parfaite — viole directement MLR.3 et rend l'estimation impossible (chapitre 2, algèbre linéaire : le rang de X chute, $X^\top X$ n'est plus inversible).

Qualité de l'ajustement

R^2 ajusté

R^2 ajusté

Le R^2 **augmente mécaniquement** avec chaque variable ajoutée, utile ou non. Le R^2 ajusté pénalise l'ajout de régresseurs :

$$\bar{R}^2 = 1 - \frac{SSR/(n - k - 1)}{SST/(n - 1)},$$

et peut **diminuer** si la variable ajoutée contribue trop peu à réduire SSR — un critère de comparaison de modèles plus fiable que le R^2 simple.

Application en finance : le modèle multifactoriel

Le modèle multifactoriel de l'introduction (économétrie financière),

$R_i = \alpha_i + \sum_k \beta_{ik} F_k + \varepsilon_i$, est une régression multiple standard : chaque β_{ik} s'interprète *ceteris paribus* — la sensibilité de l'actif au facteur k , en tenant les autres facteurs constants. Le biais de variable omise y prend un sens concret : oublier un facteur de risque pertinent (par exemple un facteur sectoriel) dans le modèle fausse

Synthèse

L'essentiel du chapitre 2

- $\hat{\beta} = (X^T X)^{-1} X^T y$; chaque coefficient s'interprète *ceteris paribus*.
- Gauss-Markov : non-biais sous MLR.1–4 ; BLUE (variance minimale parmi les estimateurs linéaires non biaisés) sous MLR.1–5.
- Le biais de variable omise apparaît dès qu'un facteur pertinent, corrélé aux régresseurs inclus, est oublié.
- La multicollinéarité gonfle la variance sans biaiser ; le R^2 ajusté pénalise l'ajout de régresseurs peu utiles.

Vers le chapitre 3

Estimer un coefficient ne suffit pas : encore faut-il savoir s'il est **statistiquement significatif**, et construire des intervalles de confiance fiables. C'est l'objet de l'inférence.