

Économétrie avancée


Chapitre 9 : Problèmes de spécification et de données

Jaouad Madkour

30 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous?



Annexes

Pourquoi ce chapitre ?

L'hétéroscédasticité (chapitre 8) est un problème d'**inférence** : les coefficients restent bien estimés. Ce chapitre traite un problème plus grave — la corrélation entre l'erreur u et un régresseur, qui biaise et rend incohérente l'estimation elle-même. Mauvaise forme fonctionnelle, variable omise, erreur de mesure, échantillon non aléatoire, observations aberrantes : autant de sources possibles, chacune avec son diagnostic et, parfois, son remède *via* les MCO.

Mauvaise spécification de la
forme fonctionnelle

Diagnostiquer une forme fonctionnelle incorrecte

Un problème mineur en apparence, sérieux en pratique

Omettre $exper^2$ dans une équation de salaire, ou utiliser $wage$ plutôt que $\log(wage)$ quand ce dernier est la vraie forme, biaise généralement **tous** les coefficients — pas seulement celui de la variable mal spécifiée. Contrairement au cas d'une variable omise inobservable (section suivante), ici les données nécessaires sont disponibles : le problème est réparable en enrichissant la spécification.

Test RESET (Ramsey)

Le test **RESET** ajoute des puissances des valeurs ajustées $\hat{y}$ à l'équation initiale :

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \delta_1 \hat{y}^2 + \delta_2 \hat{y}^3 + \text{erreur},$$

et teste $H_0 : \delta_1 = \delta_2 = 0$ par un F (approximativement $F_{2, n-k-3}$). Un rejet indique une non-linéarité négligée dans la relation entre y et les régresseurs — sans dire laquelle.

Prix immobiliers : niveau contre log-log

Sur les mêmes données, le modèle en niveau donne un RESET = 4.67 ($p = .012$, rejeté), tandis que le modèle log-log donne RESET = 2.56 ($p = .084$, non rejeté à 5 %). Le RESET oriente donc vers la spécification log-log — sans jamais garantir qu'elle est la forme "vraie".

Test de Davidson-MacKinnon

Pour arbitrer entre $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$ et sa variante log-log (non emboîtées, chapitre 6), on estime le modèle rival, on récupère ses valeurs ajustées $\tilde{y}$, et on teste la significativité de $\tilde{y}$ ajoutée au premier modèle : un t significatif rejette ce premier modèle. On peut appliquer le test symétriquement aux deux modèles — les deux peuvent être rejetés, ou aucun.

Variables proxy pour un facteur
inobservé

Le problème de la variable omise inobservable

Quand les données n'existent tout simplement pas

Contrairement à la mauvaise forme fonctionnelle, certains déterminants de y — l'aptitude innée dans une équation de salaire, la qualité de gestion dans une équation de profit — ne sont **jamais observés**. Omettre x_3^* corrélé à x_1 biaise $\hat{\beta}_1$ (chapitre 3); une **variable proxy**, corrélée à x_3^* sans lui être identique, peut atténuer ce biais.

Condition de validité d'une proxy

Avec $x_3^* = \delta_0 + \delta_3 x_3 + v_3$ reliant la variable inobservée x_3^* à sa proxy x_3 , la solution “plug-in” (régresser y sur x_1, x_2, x_3) donne des estimateurs convergents de β_1, β_2 si $E(x_3^* | x_1, x_2, x_3) = E(x_3^* | x_3)$: une fois x_3 contrôlée, l'espérance de x_3^* ne dépend plus de x_1 ni x_2 .

Le QI comme proxy de l'aptitude

Dans une équation de $\log(wage)$, le rendement estimé de l'éducation tombe de 6,5 % à 5,4 % lorsqu'on ajoute le QI comme proxy de l'aptitude — cohérent avec un biais positif de variable omise (aptitude corrélée positivement à l'éducation). Le coefficient sur le QI lui-même (+0,36% par point) devient la quantité d'intérêt : une hausse d'un écart-type de QI (15 points) équivaut approximativement à une année d'éducation supplémentaire.

Contrôler l'historique inobservable

Inclure y_{t-1} (le taux de criminalité passé d'une ville, par exemple) dans une régression en coupe capture des facteurs historiques persistants et inobservés qui influencent à la fois y courant et une variable de politique publique (dépenses de sécurité). Comparer deux villes au même y_{t-1} et même taux de chômage isole mieux l'effet causal des dépenses — sans être une solution parfaite.

Application : criminalité et dépenses de sécurité

Sans le taux de criminalité passé, l'effet estimé des dépenses de sécurité sur la criminalité est faussement positif (villes à forte criminalité dépensent plus). En ajoutant $\log(crmrte_{t-5})$, l'élasticité des dépenses devient négative ($-0,14$) comme attendu — une correction de biais du même esprit que le contrôle par variables de panel (chapitres à venir).

Erreurs de mesure

Erreur sur y : généralement sans conséquence

Si $y = y^* + e_0$ où y^* est la variable d'intérêt réelle et e_0 l'erreur de mesure, et si e_0 est indépendante des régresseurs, les MCO sur y restent non biaisés et convergents — seule la variance de l'erreur augmente ($\sigma_u^2 + \sigma_{e_0}^2$), donc les erreurs-types sont plus grandes. Le biais n'apparaît que si e_0 est corrélée à un régresseur (ex : sous-déclaration systématique corrélée à une politique évaluée).


Erreur de mesure sur une variable explicative

Le modèle classique d'erreur de mesure (CEV)

Si $x_1 = x_1^* + e_1$ avec $\text{Cov}(x_1^*, e_1) = 0$ (hypothèse CEV), alors x_1 et e_1 sont nécessairement corrélées, et régresser y sur x_1 produit un estimateur **biaisé vers zéro** :

$$\text{plim}(\hat{\beta}_1) = \beta_1 \cdot \frac{\text{Var}(x_1^*)}{\text{Var}(x_1^*) + \text{Var}(e_1)}.$$

C'est le **biais d'atténuation** : plus la variance de l'erreur de mesure est grande relative à celle du signal, plus $\hat{\beta}_1$ sous-estime $|\beta_1|$.



Données manquantes,
échantillons non aléatoires,
valeurs aberrantes

Aléatoire ou pas : toute la différence

Si l'absence de données est **indépendante** des variables du modèle, l'échantillon effectif reste aléatoire : on perd en précision, pas en validité. Si l'absence de donnée dépend elle-même de y ou de facteurs corrélés à u , l'échantillon devient non représentatif — c'est la **sélection non aléatoire**, source potentielle de biais.

Sélection exogène vs endogène

Une sélection fondée sur les **régresseurs** (par exemple, un échantillon restreint aux personnes de plus de 35 ans) laisse les MCO non biaisés — c'est une **sélection exogène**. Une sélection fondée sur la **variable dépendante** (ne garder que les ménages dont le patrimoine est inférieur à un seuil) biaise systématiquement l'estimation — c'est une **sélection endogène**, qui exige des méthodes dédiées (chapitres ultérieurs sur les données de panel et les modèles à variable latente).