

# Économétrie avancée

## Chapitre 16 : Variables dépendantes limitées et sélection d'échantillon

---

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Modèles logit et probit pour réponse binaire

Le modèle Tobit

Le modèle de régression de Poisson


Régression censurée et régression tronquée

Corrections de sélection d'échantillon

Synthèse

Où en sommes-nous?

---



## Pourquoi ce chapitre ?

Le modèle de probabilité linéaire (chapitre 7) traite  $y$  binaire comme n'importe quelle variable continue — avec des probabilités prédites parfois hors de  $[0, 1]$ . Beaucoup d'autres variables économiques sont **limitées** de façon similaire : nulles pour une fraction de la population (dépenses caritatives), dénombrées (nombre d'arrestations), censurées (durées suivies jusqu'à une date fixe) ou observées seulement pour un sous-échantillon non aléatoire (salaire offert, non observé pour les inactifs). Ce chapitre présente les modèles non linéaires — logit, probit, Tobit, Poisson, régression censurée/tronquée, correction de Heckman — conçus pour ces situations.

## Modèles logit et probit pour réponse binaire

---

### Spécification générale

Pour  $y \in \{0, 1\}$ , on remplace  $P(y = 1 \mid x) = \beta_0 + x\beta$  (MPL) par

$$P(y = 1 \mid x) = G(\beta_0 + x\beta), \quad 0 < G(z) < 1 \quad \forall z,$$


ce qui garantit des probabilités toujours comprises entre 0 et 1. Le **modèle logit** prend  $G(z) = \Lambda(z) = e^z / (1 + e^z)$  (cdf logistique); le **modèle probit** prend  $G(z) = \Phi(z)$ , la cdf de la loi normale centrée réduite. Les deux fonctions sont croissantes, en forme de S, et quasi indiscernables graphiquement.

### La variable latente sous-jacente

Logit et probit se déduisent d'un modèle à **variable latente**  $y^* = \beta_0 + x\beta + e$ ,  $y = \mathbb{1}[y^* > 0]$ , où  $e$  suit une loi logistique ou normale standard indépendante de  $x$ . Le signe de  $\beta_j$  indique le sens de l'effet sur  $y^*$  — et donc sur  $P(y = 1 \mid x)$  — mais  $y^*$  n'a pas d'unité de mesure interprétable; seuls les effets marginaux sur la probabilité sont économiquement significatifs.

## Maximum de vraisemblance

La densité conditionnelle est  $f(y | x; \beta) = [G(x\beta)]^y [1 - G(x\beta)]^{1-y}$ , d'où la log-vraisemblance individuelle  $\ell_i(\beta) = y_i \log G(x_i\beta) + (1 - y_i) \log[1 - G(x_i\beta)]$ . L'estimateur du maximum de vraisemblance (EMV) qui maximise  $\sum_i \ell_i$  est consistant, asymptotiquement normal et asymptotiquement efficace sous conditions de régularité usuelles; les tests  $t$ , de Wald et du rapport de vraisemblance ( $LR = 2(\ell_{ur} - \ell_r) \sim \chi_q^2$ ) s'appliquent comme au chapitre 5.



## Effet marginal

Pour  $x$  : continue,  $\frac{\partial p(x)}{\partial \beta} = g(\beta_0 + x\beta)\beta$ , où  $g = G'$  est une densité. Le signe de l'effet est

## Le modèle Tobit

---

### Variable latente censurée à zéro

Le **modèle Tobit** s'applique à  $y$  continue sur les valeurs strictement positives mais nulle avec probabilité non négligeable (dépenses caritatives, heures travaillées, montant investi en actions).

Formellement,  $y^* = \beta_0 + x\beta + u$ ,  $u \mid x \sim \mathcal{N}(0, \sigma^2)$ , et  $y = \max(0, y^*)$ . La vraisemblance combine une masse ponctuelle en  $y = 0$ ,  $P(y = 0 \mid x) = 1 - \Phi(x\beta/\sigma)$ , et une densité continue pour  $y > 0$ .

### Pourquoi pas MCO sur le sous-échantillon $y > 0$ ?

Estimer par MCO uniquement sur les observations positives revient à conditionner sur  $y^* > 0$ , ce qui corréle le terme d'erreur retenu à  $x$  (troncature) : les MCO sont incohérents. Estimer par MCO sur l'échantillon complet, en traitant les zéros comme des observations ordinaires, est également incohérent car  $E(y \mid x)$  n'est pas linéaire en  $x\beta$ .

### Espérance conditionnelle et non conditionnelle

$$E(y \mid y > 0, x) = x\beta + \sigma\lambda(x\beta/\sigma), \quad E(y \mid x) = \Phi(x\beta/\sigma) E(y \mid y > 0, x),$$

où  $\lambda(c) = \phi(c)/\Phi(c)$  est le **ratio inverse de Mills**. Les effets partiels de  $x_j$  sur ces deux espérances ne sont **pas** simplement  $\beta_j$  : chacun est multiplié par un facteur d'ajustement strictement compris entre 0 et 1, qui dépend de  $x\beta/\sigma$ . Remarquablement,  $\partial E(y \mid x)/\partial x_j = \beta_j \Phi(x\beta/\sigma)$  – le facteur le plus simple des trois.

### Heures travaillées annuelles (MROZ)

Sur 753 femmes mariées (325 avec zéro heure), le coefficient Tobit sur *kidslt6* (−894) est environ le double du coefficient MCO (−442) – comparaison trompeuse en valeur brute. Une fois multiplié par le facteur d'ajustement pertinent ( $\approx 0,451$  pour l'espérance conditionnelle à  $y > 0$ ), l'effet Tobit redevient comparable en ordre de grandeur à l'estimation MCO, confirmant que le Tobit “moyenne” implicitement la décision de participer et la décision du volume d'heures.

## Le modèle de régression de Poisson

---

# Variables de comptage

## Espérance exponentielle

Pour  $y \in \{0, 1, 2, \dots\}$  (nombre d'arrestations, de brevets déposés, d'enfants), on spécifie  $E(y | x) = \exp(\beta_0 + x\beta)$ , garantissant des prédictions positives. Comme  $\log E(y | x) = \beta_0 + x\beta$ , les  $\beta_j$  s'interprètent en semi-élasticité — exactement comme dans un modèle linéaire pour  $\log(y)$  :  $100\beta_j$  est approximativement le pourcentage de variation de  $E(y | x)$  pour une hausse d'une unité de  $x_j$ ; l'effet exact discret est  $\exp(\beta_j) - 1$ .

## Vraisemblance de Poisson et QMLE

Sous la loi de Poisson,  $P(y = h | x) = \frac{e^{-\exp(x\beta)} [\exp(x\beta)]^h}{h!}$ , d'où une log-vraisemblance simple à maximiser. La loi de Poisson impose  $\text{Var}(y | x) = E(y | x)$ ; en pratique la variance excède souvent la moyenne (**surdispersion**). L'EMV de Poisson reste néanmoins consistant même si cette égalité échoue (**quasi-maximum de vraisemblance**, QMLE); il suffit de corriger les erreurs-types par un facteur  $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$  estimé à partir des résidus standardisés.

## Nombre d'arrestations en 1986

Sur 2 725 jeunes hommes (1 970 avec zéro arrestation), le coefficient de Poisson sur *pcnv* (proportion de condamnations antérieures) implique qu'une hausse de 0{ }10 de ce taux réduit le nombre attendu


## Régression censurée et régression tronquée

---

# Deux problèmes de données distincts

## Censure vs troncature

La **régression censurée** conserve toutes les observations, y compris celles pour lesquelles  $y$  n'est connu qu'au-delà (ou en-deçà) d'un seuil  $c_i$  :  $w_i = \min(y_i, c_i)$  — typiquement un plafonnement (*top coding*) ou une durée suivie jusqu'à une date de fin d'étude. La **régression tronquée** exclut entièrement de l'échantillon les unités situées au-delà du seuil : on n'observe ni  $y_i$  ni  $x_i$  pour ces unités. Les deux problèmes se traitent par maximum de vraisemblance sous normalité, mais la troncature perd strictement plus d'information.



## Corrections de sélection d'échantillon

---

### Quand les MCO sur l'échantillon sélectionné restent valides

Soit  $s_i = 1$  si l'observation  $i$  est retenue, 0 sinon. Régresser  $y$  sur  $x$  sur le sous-échantillon  $\{s_i = 1\}$  équivaut à régresser  $s_i y_i$  sur  $s_i x_i$  sur l'échantillon complet. Les MCO restent consistants si  $E(s u \mid s x_1, \dots, s x_k) = 0$  — condition satisfaite dès lors que la sélection  $s$  ne dépend que des régresseurs exogènes (**sélection exogène**) ou d'un tirage indépendant de  $u$ . La sélection est **endogène**, et les MCO incohérents, dès que  $s$  dépend directement de  $u$  — c'est le cas typique de la troncature sur  $y$ .

# La méthode de Heckman (Heckit)

## Troncature incidente et équation de sélection

Pour le modèle d'intérêt  $y = x\beta + u$  observé seulement si  $s = 1$ , avec  $s = \mathbb{1}[z\gamma + v \geq 0]$  et  $(u, v)$  bivariée normale, on montre que

$$E(y \mid z, s = 1) = x\beta + \rho \lambda(z\gamma).$$

La **méthode de Heckman en deux étapes** : (i) estimer  $\gamma$  par probit de  $s$  sur  $z$  (échantillon complet), calculer  $\hat{\lambda}_i = \lambda(z_i \hat{\gamma})$ ; (ii) régresser  $y$  sur  $x$  et  $\hat{\lambda}$  sur le sous-échantillon sélectionné. Le test  $t$  sur  $\hat{\lambda}$  teste  $H_0 : \rho = 0$  (absence de biais de sélection). La procédure exige idéalement au moins une variable de  $z$  absente de  $x$  – sinon  $\hat{\lambda}$  est presque colinéaire avec  $x$ .

## Équation de salaire offert pour femmes mariées (Heckit)

Sur MROZ, l'équation de  $\log(\text{salaire})$  estimée sur les 428 femmes actives donne un coefficient d'éducation de 0,108 (MCO) contre 0,109 (Heckit) – pratiquement identique. Le coefficient sur  $\hat{\lambda}$  est non significatif ( $t = 0,239$ ) : rien n'indique de biais de sélection important pour cette relation, une fois contrôlé par éducation et expérience.

## Synthèse

---

## L'essentiel du chapitre 16

- Logit et probit corrigent les défauts du MPL (probabilités hors  $[0, 1]$ , effets constants) au prix d'une interprétation plus lourde; estimation par maximum de vraisemblance.
- Le Tobit modélise des solutions en coin ( $y \geq 0$  avec masse en zéro); les effets partiels sur  $E(y \mid x)$  et  $E(y \mid y > 0, x)$  diffèrent des coefficients bruts par des facteurs d'ajustement non linéaires.
- La régression de Poisson (et son extension QMLE) traite les variables de comptage; interprétation en semi-élasticités, correction de surdispersion.
- Censure et troncature sont deux problèmes de données distincts; la censure conserve plus d'information et produit des estimations plus fiables.
- La sélection d'échantillon ne biaise les MCO que si elle est endogène; la méthode de Heckman (probit puis régression augmentée du ratio inverse de Mills) permet de tester et corriger ce biais.

## Vers le chapitre 17

Après les modèles pour variables limitées en coupe transversale, le chapitre suivant revient aux séries temporelles pour des sujets avancés : dynamique de court terme via les modèles à correction d'erreur, tests de racine unitaire, et estimation de systèmes avec variables prédéterminées.

# Le fil conducteur du programme

