

# Économétrie avancée

## Chapitre 7 : Variables qualitatives (indicatrices)

---

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Variables indicatrices simples

Catégories multiples et information ordinale

Interactions impliquant des indicatrices


Le modèle de probabilité linéaire

Évaluation de politiques

Synthèse

Où en sommes-nous?

---



## Pourquoi ce chapitre ?

Le genre, la région, le secteur d'activité, un style architectural : autant de facteurs **qualitatifs** qui n'ont pas de magnitude numérique naturelle, mais qui influencent souvent  $y$  de façon décisive. Ce chapitre montre comment les faire entrer dans le cadre de la régression multiple sans rien perdre de sa rigueur.

## Variables indicatrices simples

---

# Décrire l'information qualitative

## Variable indicatrice (dummy)

Une **variable indicatrice** (ou *dummy*) code un fait binaire par 0 ou 1. Le choix de la modalité codée 1 est arbitraire mais doit être **explicite** dans le nom de la variable (par exemple **femal**e plutôt que **gender**, pour éviter toute ambiguïté).

## Interprétation dans une régression

Dans  $wage = \beta_0 + \delta_0 female + \beta_1 educ + u$ , sous l'hypothèse habituelle  $E(u | \cdot) = 0$ ,

$$\delta_0 = E(wage | female = 1, educ) - E(wage | female = 0, educ) :$$

c'est un **décalage d'ordonnée à l'origine** entre les deux groupes, à niveau d'éducation identique — les deux droites sont parallèles.



### Effet en pourcentage, exact et approché

Si  $\log(y) = \dots + \delta_1 x_1 + u$  où  $x_1$  est une indicatrice, l'approximation  $100 \delta_1$  donne l'écart en %; l'écart **exact** est  $100[\exp(\delta_1) - 1]$ , à utiliser dès que  $|\delta_1|$  n'est pas petit (comme pour tout coefficient log-linéaire, chapitre 6).

## Catégories multiples et information ordinale

---



## Plus de deux groupes

### Règle générale : $g$ groupes, $g - 1$ indicatrices

Pour distinguer  $g$  groupes, on inclut un intercept général et  $g - 1$  indicatrices (une par groupe, sauf le groupe de référence). Chaque coefficient mesure l'écart d'ordonnée à l'origine entre son groupe et le groupe de référence.

### Quatre profils croisés

En croisant genre et statut marital (référence : hommes célibataires),  
 $\log(\widehat{wage}) = .321 + .213 \text{ marrmale} - .198 \text{ marrfem} - .110 \text{ singfem} + .079 \text{ educ} + \dots$  Les hommes mariés gagnent environ 21,3 % de plus que les hommes célibataires; les femmes mariées, 19,8 % de moins. Pour tester directement l'écart entre deux groupes non-référence (ici, célibataires vs mariées), il faut soit recombinaison les coefficients avec leur covariance, soit changer de groupe de référence et ré-estimer.

### Ordinal vs cardinal

Une variable **ordinaire** (note de crédit, catégorie de beauté, tranche de classement) a un ordre mais pas d'écart interprétable entre modalités. L'entrer telle quelle impose un effet **constant** par unité, hypothèse souvent injustifiée. Solution : créer une indicatrice par modalité (sauf la modalité de référence), ce qui laisse l'effet libre de varier d'un échelon à l'autre.

### Application : classement des écoles et salaires

Découper le rang d'une école de commerce en tranches (**top10**, **r11\_25**, ...) plutôt que de l'entrer en niveau améliore nettement l'ajustement ( $\bar{R}^2$  passant de .836 à .905) : l'effet du classement sur le salaire de sortie n'est manifestement pas linéaire en rang. Ce principe s'applique à toute variable de notation — rating de crédit obligataire, scoring de risque — dès lors que rien ne garantit une relation linéaire avec la variable expliquée.

## Interactions impliquant des indicateurs

---

### Retrouver les catégories croisées


Ajouter  $female \times married$  à un modèle contenant déjà **female** et **married** séparément permet à l'écart de mariage de différer entre hommes et femmes — c'est rigoureusement équivalent à définir directement les quatre indicatrices de groupe (chapitre précédent), mais l'écriture en interaction rend le test de l'hétérogénéité ( $H_0$  : coefficient d'interaction = 0) immédiat.

## Pentes différentes selon le groupe

Indicatrice  $\times$  variable continue

$$\log(wage) = (\beta_0 + \delta_0 \textit{female}) + (\beta_1 + \delta_1 \textit{female}) \textit{educ} + u$$

donne un intercept et une pente propres à chaque groupe.  $\delta_0$  capture l'écart d'intercept,  $\delta_1$  l'écart de **rendement de l'éducation** entre les groupes. Économétriquement, ce modèle s'estime en régressant  $y$  sur  $\textit{female}$ ,  $\textit{educ}$  et  $\textit{female} \times \textit{educ}$ .



### Statistique de Chow

Pour tester si un même modèle décrit deux groupes ( $H_0$  : mêmes coefficients dans les deux), on compare la  $SSR$  de la régression **poolée** ( $SSR_p$ ) à la somme des  $SSR$  des régressions **séparées** par groupe ( $SSR_1 + SSR_2$ ) :

$$F = \frac{[SSR_p - (SSR_1 + SSR_2)]/(k+1)}{(SSR_1 + SSR_2)/[n - 2(k+1)]} \sim F_{k+1, n-2(k+1)} \text{ sous } H_0.$$

Équivalent à tester conjointement la significativité de l'indicatrice de groupe et de toutes ses interactions avec les régresseurs.

### Chow global vs différence d'intercept seule

Le test de Chow interdit **toute** différence, y compris de pente. S'il rejette  $H_0$ , il faut identifier *quelle* différence compte : tester seulement les interactions ( $H_0$  : pentes égales, intercepts libres) est souvent plus informatif — c'est ce qu'on a fait ci-dessus pour l'écart de rendement de l'éducation.

## Le modèle de probabilité linéaire

---

# Une variable dépendante binaire

## Modèle de probabilité linéaire (MPL)

Quand  $y \in \{0, 1\}$ ,  $P(y = 1 \mid x) = E(y \mid x)$ . Le modèle

$$P(y = 1 \mid x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

s'estime par MCO comme n'importe quel modèle linéaire;  $\hat{\beta}_j$  s'interprète comme la variation de la **probabilité de succès** pour une hausse d'une unité de  $x_j$ , toutes choses égales par ailleurs.

## Participation au marché du travail

$\widehat{inlf} = .586 - .0034 nwifeinc + .038 educ + .039 exper - .0006 exper^2 - .016 age - .262 kidslt6 + .013 kidsge6$  : chaque enfant de moins de 6 ans réduit la probabilité de participation de 26,2 points, alors qu'un enfant plus âgé n'a quasiment aucun effet — un contraste économiquement très parlant.

## Les limites structurelles du MPL

Le MPL peut prédire des probabilités hors de  $[0, 1]$ , impose un effet marginal **constant** (irréaliste sur toute la plage de  $x$ ), et souffre nécessairement d'hétéroscédasticité puisque

$\text{Var}(y \mid x) = p(x)[1 - p(x)]$  dépend de  $x$ . Cela ne biaise pas  $\hat{\beta}$  (chapitre 3) mais invalide les



## Évaluation de politiques

---

### Le problème de l'auto-sélection

Dans  $y = \beta_0 + \beta_1 \textit{partic} + u$ , si la participation à un programme n'est pas assignée aléatoirement,  $E(u \mid \textit{partic} = 1) \neq E(u \mid \textit{partic} = 0)$  est plausible : les participants diffèrent systématiquement des non-participants sur des facteurs **non observés** corrélés à  $y$ . La régression multiple atténue le problème en contrôlant les facteurs observables, mais ne le résout pas si des facteurs pertinents restent inobservés — situation qui appelle les méthodes plus avancées (variables instrumentales, données de panel) des chapitres suivants.

### Application : subventions à la formation et discrimination au crédit

Deux usages typiques du MPL en évaluation de politiques : tester la discrimination dans l'octroi de prêts ( $\textit{approved} = \beta_0 + \beta_1 \textit{nonwhite} + \beta_2 \textit{income} + \dots$ , où  $\beta_1 < 0$  signale une discrimination *ceteris paribus*), et mesurer l'effet causal d'une subvention à la formation sur la productivité d'une firme. Dans les deux cas, la validité de l'interprétation causale dépend entièrement de la qualité des variables de contrôle incluses.

## Synthèse

---

## L'essentiel du chapitre 7

- Une indicatrice s'interprète comme un décalage d'intercept;  $g$  groupes exigent  $g - 1$  indicatrices plus un intercept, sous peine de piège de colinéarité.
- L'information ordinale se code par indicatrices par modalité plutôt qu'en niveau, sauf si la linéarité est justifiée.
- Les interactions indicatrice  $\times$  continue permettent des pentes différentes par groupe; le test de Chow généralise ceci à une différence globale entre groupes.
- Le modèle de probabilité linéaire étend la régression MCO aux variables dépendantes binaires, avec des limites (bornes, hétéroscédasticité) à garder en tête.

## Vers le chapitre 8

Le MPL a mis en évidence un problème plus général : l'hétéroscédasticité, c'est-à-dire une variance de l'erreur qui dépend des régresseurs. Le chapitre suivant traite ce problème de façon systématique — comment le détecter, et comment corriger l'inférence.

# Le fil conducteur du programme

