# Introduction à l'économétrie

Chapitre 12 : La carte des violations

Jaouad Madkour

29 octobre 2026

## Plan du chapitre

**Une seule ligne compte** **2**
- La carte . . . 2
- La ligne de partage . . . 2
- Cinq problèmes, cinq chapitres . . . 2

**Le rôle des résidus** **3**
- Le seul matériau du diagnostic . . . 3
- Les quatre graphiques à faire systématiquement . . . 3
- Les quatre graphiques de R, sur le modèle M2 . . . 4
- Ce que les quatre graphiques montrent . . . 4

**Comment les tests fonctionnent** **4**
- Un principe commun . . . 4
- La statistique et sa loi . . . 5
- Breusch-Pagan à la main, sur les cinq ménages . . . 6
- Sur les salaires . . . 6
- Une mise en garde sur les tests de diagnostic . . . 6

**Sur machine** **7**
- Breusch-Pagan avec R . . . 7
- Breusch-Pagan et RESET avec Python . . . 7

**S'entraîner** **7**
- Exercice 1 : Breusch-Pagan à la main . . . 7
- Exercice 1 : solution . . . 8
- Exercice 2 : lire un graphique de résidus . . . 8
- Exercice 2 : solution . . . 8
- Exercice 3 : la taille de l'échantillon . . . 8
- Exercice 3 : solution . . . 8

**Ce qu'il faut retenir** **9**
- Le résumé du chapitre . . . 9

# Une seule ligne compte

## La carte

Une seule ligne est en orange, et c'est la seule qui compte vraiment.

| Problème | Biais ? | Écarts-types | Comment le voir | Que faire |
|---|---|---|---|---|
| **Variable omise** H2 violée | **OUI** | faussés | réflexion économique aucun test ne la révèle | ajouter la variable ou instrumenter |
| **Hétéroscédasticité** H3 violée | non | **faussés** | résidus en éventail Breusch-Pagan, White | écarts-types robustes de White |
| **Erreurs groupées** H4 violée | non | **faussés** | résidus liés dans un groupe moyennes par groupe | écarts-types de grappe au niveau du regroupement |
| **Multicolinéarité** H5 presque violée | non | **gonflés** | VIF élevé coefficients instables | retirer, regrouper, ou ne rien faire |
| **Non-normalité** | non | justes si $n$ grand | histogramme, Jarque-Bera | rien, si $n \geq 30$ |

**Toutes les violations ne se valent pas.**

Quatre d'entre elles ne touchent que les *écarts-types* : les coefficients restent justes en moyenne, et une correction technique suffit. On les détecte par un test, on les répare par une formule.

**La variable omise, elle, biaise les coefficients eux-mêmes.** Aucun test ne la signale — puisque la variable manquante n'est pas dans les données. Elle se détecte par le raisonnement économique, et se répare en changeant de modèle ou de méthode.

C'est pourquoi un travail économétrique sérieux consacre plus de temps à la *spécification* qu'à l'estimation.

## La ligne de partage

### Deux familles de problèmes

**Ceux qui faussent les écarts-types** : hétéroscédasticité, erreurs groupées, multicolinéarité, et la non-normalité à petit échantillon. Les coefficients restent justes.
**Celui qui fausse les coefficients** : la variable omise. Rien d'autre ne compte autant.

### La conséquence sur la façon de travailler

Les premiers se **détectent par un test** et se **réparent par une formule**. Ce sont des problèmes techniques, et ils ont des solutions techniques.
Le second se détecte par le **raisonnement économique** — car la variable manquante n'est pas dans les données — et se répare en changeant de modèle. **C'est un problème de spécification, et aucun logiciel ne le résoudra.**

## Cinq problèmes, cinq chapitres

### Le parcours de la cinquième partie

| Problème | Hypothèse | Touche | Terrain | Chapitre |
|---|---|---|---|---|
| Multicolinéarité | H5 presque | écarts-types | salaires | 13 |
| Hétéroscédasticité | H3 | écarts-types | salaires | 14 |
| Erreurs groupées | H4 | écarts-types | ménages | 15 |
| Variable omise | H2 | **coefficients** | salaires | 16 |
| Non-normalité, influence | H6 | tests, droite | salaires | 17 |

**Chaque problème sur le terrain où il se rencontre**

Le regroupement n'existe que dans l'enquête de ménages, tirée par quartiers ; l'hétéroscédasticité est spectaculaire sur les salaires. **On ne fabrique pas les problèmes : on les cherche là où ils sont.**

## Le rôle des résidus

### Le seul matériau du diagnostic

**Ce qu'on regarde**

Les erreurs $\varepsilon_i$ sont inconnues. Les résidus $e_i$ sont calculés.
**Tout diagnostic passe par les résidus** : ils sont la seule trace observable de ce que le modèle n'explique pas.

**Un principe qui ne varie pas**

Sous les hypothèses, les résidus doivent ressembler à du **bruit pur** : aucune structure, aucune tendance, aucune relation avec quoi que ce soit.
**Toute régularité visible dans les résidus est une information que le modèle a laissée échapper.** C'est le fil conducteur des cinq chapitres qui suivent.

### Les quatre graphiques à faire systématiquement

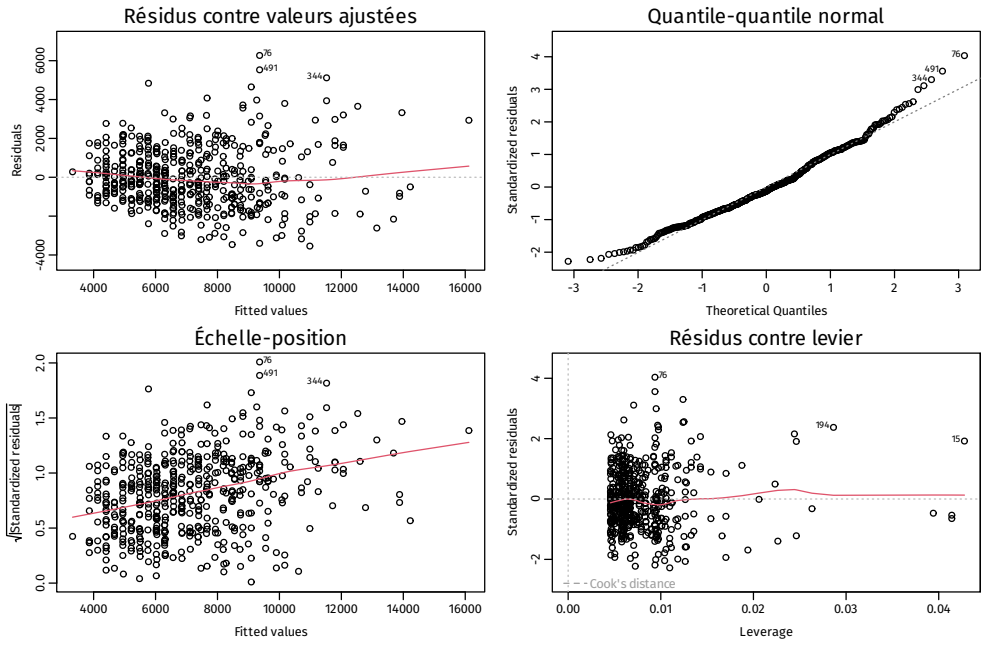
**Avant tout commentaire des coefficients**

| Graphique | Ce qu'il révèle |
|---|---|
| Résidus contre valeurs ajustées | hétéroscédasticité, non-linéarité |
| Résidus moyens par groupe | erreurs groupées |
| Histogramme des résidus | non-normalité, valeurs extrêmes |
| Résidus contre chaque variable | forme fonctionnelle mal choisie |

**Ils coûtent quatre lignes de code**

Aucun de ces quatre graphiques ne prend plus de dix secondes à produire, et l'un d'eux vaut souvent mieux qu'une batterie de tests.
**Un test dit si un problème existe ; un graphique dit à quoi il ressemble.** Les deux sont nécessaires, et le graphique vient d'abord.

### Les quatre graphiques de R, sur le modèle M2




### Ce que les quatre graphiques montrent

**Lecture, panneau par panneau**

**Résidus contre valeurs ajustées** : le nuage s'élargit vers la droite — hétéroscédasticité, chapitre 14.
**Quantile-quantile** : les points décrochent en haut à droite — quelques salaires très au-dessus du modèle, chapitre 17.
**Échelle-position** : la courbe rouge monte — même diagnostic que le premier panneau, en plus net.
**Résidus contre levier** : quelques salariés à fort levier, aucun au-delà des courbes de Cook.

**Trois chapitres annoncés par une figure**

Sans aucun test, la figure désigne déjà les problèmes des chapitres 14 et 17. Les tests confirmeront et chiffreront.

## Comment les tests fonctionnent

### Un principe commun

**La régression auxiliaire**

La plupart des tests de diagnostic suivent le même schéma :

1. estimer le modèle et récupérer les résidus ;
2. **régresser une fonction des résidus** sur quelque chose ;
3. si cette seconde régression explique quelque chose, l'hypothèse est violée.

**Trois tests, un seul principe**

| Test | On régresse | Sur |
|---|---|---|
| Breusch-Pagan | $e_i^2$ | les variables explicatives |
| White | $e_i^2$ | variables, carrés, produits |
| RESET | $y_i$ | variables et puissances de $\widehat{y}_i$ |

## La statistique et sa loi

**Toujours la même**

$$nR^2_{\text{auxiliaire}} \sim \chi^2_q$$

où $q$ est le nombre de variables ajoutées dans la régression auxiliaire.

**Pourquoi un khi-deux**

Parce qu'on additionne des écarts au carré — c'est le signe reconnu au chapitre 18 de l'inférence.
Et le test est **unilatéral à droite** : seule une valeur élevée contredit l'hypothèse d'absence de problème. **Là encore, rien de nouveau : on applique un test appris ailleurs.**

**Démonstration : Pourquoi $nR^2_{\text{aux}}$ suit approximativement un khi-deux à $q$ degrés de liberté**

Dans la régression auxiliaire, soit $q$ le nombre de variables explicatives (hors constante), $R^2$ son coefficient de détermination et $F$ la statistique de Fisher de son test global. D'après la démonstration du $F$ en fonction du $R^2$ (chapitre 9), $qF = R^2\,(n-q-1)/(1-R^2)$, d'où l'identité exacte

$$nR^2 = qF \times \frac{n\,(1-R^2)}{n-q-1}.$$

**Quand rien ne cloche.** Sous l'hypothèse d'absence de problème, la régression auxiliaire n'explique rien : $R^2$ est de l'ordre de $q/n$, donc proche de 0 pour $n$ grand, et le facteur $n(1-R^2)/(n-q-1)$ tend vers 1. Donc $nR^2 \approx qF$.

**La loi de $qF$.** Avec des erreurs normales, $F = (\chi^2_q/q)\big/(\chi^2_\nu/\nu)$ avec $\nu = n-q-1$, les deux khi-deux étant indépendants (chapitre 9). Or $\chi^2_\nu/\nu$ est la moyenne de $\nu$ carrés de normales centrées réduites : elle tend vers 1 quand $\nu$ augmente, par la loi des grands nombres. Donc $qF \approx \chi^2_q$, et $nR^2 \approx \chi^2_q$.

**Quand les erreurs ne sont pas normales (résultat admis).** Les $e_i^2$ sont positifs et asymétriques : les erreurs de la régression auxiliaire ne sont pas normales. On admet que le théorème central limite donne la même loi limite. Le résultat est donc **asymptotique**, d'où la mise en garde du chapitre sur la taille de l'échantillon. Un $R^2$ ne pouvant être négatif, seule une valeur élevée contredit l'hypothèse : le test est unilatéral à droite.

■

## Breusch-Pagan à la main, sur les cinq ménages

**Les carrés des résidus contre le revenu**

| Ménage | A | B | C | D | E |
|---|---|---|---|---|---|
| $R - \overline{R}$ | $-4$ | $-2$ | 0 | 2 | 4 |
| $e^2$ | 0 | 2,25 | 4 | 0,25 | 1 |

Moyenne de $e^2$ : $7{,}5/5 = 1{,}5$. Pente de $e^2$ sur $R$ : $\sum(R-\overline{R})(e^2-1{,}5)/40 = (6-1{,}5+0-2{,}5-2)/40 = 0$.

**Un $R^2$ auxiliaire nul**

La régression auxiliaire n'explique rien : $nR^2 = 0$. Breusch-Pagan ne voit **aucune** hétéroscédasticité liée au revenu. Il ne cherche que des liaisons **linéaires** entre $e^2$ et les variables — et cinq points ne permettraient pas d'en voir d'autres.

## Sur les salaires

**Deux régressions auxiliaires**

**Breusch-Pagan** : $e^2$ régressé sur l'ancienneté et les deux indicatrices de diplôme donne $R^2_{\text{aux}} = 0{,}1152$, d'où $nR^2 = 500 \times 0{,}1152 = 57{,}6$, contre un seuil de 7,81 pour $\chi^2_3$.
**RESET** : ajouter $\hat{y}^2$ au modèle M2 donne $F = 5{,}77$, $p = 0{,}017$.

**Deux signaux, deux chapitres**

Le premier dit que la dispersion des erreurs dépend des variables : c'est le chapitre 14. Le second qu'une courbure a été oubliée : la forme logarithmique du chapitre 18 y répondra.
**Les deux signaux ont la même origine**, comme on le verra : un salaire est une grandeur multiplicative.

## Une mise en garde sur les tests de diagnostic

**Ils sont sensibles à la taille de l'échantillon**

Sur cinq cents observations, la moindre hétéroscédasticité devient significative. Sur trente, une hétéroscédasticité massive peut passer inaperçue.
**Un test qui rejette ne dit pas que le problème est grave.** Il dit qu'il existe. Le graphique dit s'il compte.

**La bonne pratique**

Sur données individuelles, l'usage actuel est de ne même plus tester l'hétéroscédasticité : on la suppose présente et l'on publie directement des écarts-types robustes.
Le test garde son intérêt pédagogique — il fait comprendre le mécanisme — et son intérêt pratique quand le remède coûte quelque chose.

## Sur machine

### Breusch-Pagan avec R

```r
suppressPackageStartupMessages(library(lmtest))
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m2 <- lm(salaire ~ anciennete + diplome, data = sal)
aux <- lm(residuals(m2)^2 ~ anciennete + diplome, data = sal)
500 * summary(aux)$r.squared         # n R2 auxiliaire, à la main
# [1] 57.59655
bptest(m2)                           # la même chose
#
#  studentized Breusch-Pagan test
#
# data:  m2
# BP = 57.597, df = 3, p-value = 1.917e-12
```

### Breusch-Pagan et RESET avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
import statsmodels.stats.diagnostic as dg
sal = pd.read_csv("salaires.csv")
m2 = smf.ols("salaire ~ anciennete + diplome", data=sal).fit()
bp, p_bp, _, _ = dg.het_breuschpagan(m2.resid, m2.model.exog)
print(round(bp, 2), f"{p_bp:.1e}")
# 57.6 1.9e-12
r = dg.linear_reset(m2, power=2, use_f=True)
print(round(r.fvalue, 2), round(r.pvalue, 4))
# 5.77 0.0167
```

## S'entraîner

### Exercice 1 : Breusch-Pagan à la main

**Les quatre magasins**

Les résidus de $\hat{y} = 0{,}5 + 1{,}5\,x$ sont $0$ ; $0{,}5$ ; $-1{,}5$ ; $1$, pour $x = 1, 2, 4, 5$.

1. Calculer les $e^2$ et leur moyenne.
2. Calculer la pente et le $R^2$ de la régression de $e^2$ sur $x$.
3. En déduire la statistique de Breusch-Pagan et conclure ($\chi^2_1 = 3{,}84$).

### Exercice 1 : solution

**Une liaison visible, non significative**

1. $e^2 = 0$ ; 0,25 ; 2,25 ; 1, de moyenne 0,875.
2. Écarts de $x$ : $-2, -1, 1, 2$ ($S_{xx} = 10$). $\sum (x - \overline{x})(e^2 - 0{,}875) = 1{,}75 + 0{,}625 + 1{,}375 + 0{,}25 = 4$ : pente 0,4. SCE $= 0{,}4^2 \times 10 = 1{,}6$ ; SCT $= 3{,}0625$ ; $R^2 = 0{,}522$.
3. $nR^2 = 4 \times 0{,}522 = 2{,}09 < 3{,}84$ : on ne rejette pas. La dispersion semble croître avec $x$, mais quatre points ne suffisent pas à le prouver.

### Exercice 2 : lire un graphique de résidus

**Quatre formes**

Quel problème suggère chacune des formes suivantes du graphique des résidus contre les valeurs ajustées ?

1. Un éventail qui s'ouvre vers la droite.
2. Une courbe en U.
3. Des paquets de points au-dessus, d'autres au-dessous de zéro, selon le quartier.
4. Un nuage sans forme, avec trois points très au-dessus des autres.

### Exercice 2 : solution

**Quatre formes, quatre chapitres**

1. **Hétéroscédasticité** : la dispersion grandit avec le niveau — chapitre 14.
2. **Forme fonctionnelle** : une courbure oubliée, qu'un carré ou un logarithme corrigerait — chapitre 18.
3. **Erreurs groupées** : les ménages d'un quartier partagent une erreur commune — chapitre 15.
4. **Points atypiques** : à examiner un par un, avec leur levier — chapitre 17.

### Exercice 3 : la taille de l'échantillon

**Le même $R^2$ auxiliaire**

Deux études obtiennent le même $R^2_{\text{aux}} = 0{,}02$ dans une régression de Breusch-Pagan à une variable.

1. Calculer la statistique pour $n = 50$ et pour $n = 5\,000$.
2. Conclure dans chaque cas.
3. Le problème est-il plus grave dans la seconde étude ?

### Exercice 3 : solution

**Significatif ne veut pas dire grave**

1. $nR^2 = 1$ pour $n = 50$ ; 100 pour $n = 5\,000$.
2. Non-rejet dans le premier cas ($1 < 3{,}84$), rejet massif dans le second.
3. Non : la régression auxiliaire explique **la même part**, 2 %, de la variance des $e^2$. Le second test rejette parce qu'il a plus d'observations, pas parce que le problème est plus grand. **Le graphique, pas le test, dit si cela compte.**

## Ce qu'il faut retenir

### Le résumé du chapitre

**Six points**

1. Quatre violations ne touchent que les **écarts-types** ; une seule, la variable omise, biaise les **coefficients**.
2. Les premières se détectent par un **test** et se réparent par une **formule** ; la seconde par le raisonnement.
3. Tout diagnostic passe par les **résidus** : ils doivent ressembler à du bruit pur.
4. Quatre graphiques, systématiquement : `plot(m2)` annonce déjà les chapitres 14 et 17.
5. Les tests suivent tous le même schéma : une **régression auxiliaire** et un $nR^2$ lu dans un khi-deux.
6. Salaires : Breusch-Pagan 57,6, RESET 5,77 ; cinq ménages : $nR^2 = 0$.

**La suite**

La carte est dressée. Les cinq chapitres suivants la parcourent case par case. On commence par celui qui n'est pas vraiment une violation, et qui déroute le plus : la **multicolinéarité**.