Introduction à l'économétrie

Chapitre 12 : La carte des violations

Jaouad Madkour

23 octobre 2026

Plan du chapitre

Une seule ligne compte **2**
- La carte . . . 2
- La ligne de partage . . . 2
- Cinq problèmes, cinq chapitres . . . 2

Le rôle des résidus **3**
- Le seul matériau du diagnostic . . . 3
- Les quatre graphiques à faire systématiquement . . . 3
- Les quatre graphiques de R, sur le modèle M2 . . . 4
- Ce que les quatre graphiques montrent . . . 4

Comment les tests fonctionnent **4**
- Un principe commun . . . 4
- La statistique et sa loi . . . 5
- Breusch-Pagan à la main, sur les cinq ménages . . . 5
- Sur les salaires . . . 5
- Une mise en garde sur les tests de diagnostic . . . 6

Sur machine **6**
- Breusch-Pagan avec R . . . 6
- Breusch-Pagan et RESET avec Python . . . 6

S'entraîner **7**
- Exercice 1 : Breusch-Pagan à la main . . . 7
- Exercice 1 : solution . . . 7
- Exercice 2 : lire un graphique de résidus . . . 7
- Exercice 2 : solution . . . 7
- Exercice 3 : la taille de l'échantillon . . . 8
- Exercice 3 : solution . . . 8

Ce qu'il faut retenir **8**
- Le résumé du chapitre . . . 8

Une seule ligne compte

La carte

Une seule ligne est en orange, et c'est la seule qui compte vraiment.

Problème	Biais ?	Écarts-types	Comment le voir	Que faire
Variable omise H2 violée	**OUI**	faussés	réflexion économique aucun test ne la révèle	ajouter la variable ou instrumenter
Hétéroscédasticité H3 violée	non	**faussés**	résidus en éventail Breusch-Pagan, White	écarts-types robustes de White
Erreurs groupées H4 violée	non	**faussés**	résidus liés dans un groupe moyennes par groupe	écarts-types de grappe au niveau du regroupement
Multicolinéarité H5 presque violée	non	**gonflés**	VIF élevé coefficients instables	retirer, regrouper, ou ne rien faire
Non-normalité	non	justes si n grand	histogramme, Jarque-Bera	rien, si $n \geq 30$

Toutes les violations ne se valent pas.

Quatre d'entre elles ne touchent que les *écarts-types* : les coefficients restent justes en moyenne, et une correction technique suffit. On les détecte par un test, on les répare par une formule.

La variable omise, elle, biaise les coefficients eux-mêmes. Aucun test ne la signale — puisque la variable manquante n'est pas dans les données. Elle se détecte par le raisonnement économique, et se répare en changeant de modèle ou de méthode.

C'est pourquoi un travail économétrique sérieux consacre plus de temps à la *spécification* qu'à l'estimation.

La ligne de partage

Deux familles de problèmes

Ceux qui faussent les écarts-types : hétéroscédasticité, erreurs groupées, multicolinéarité, et la non-normalité à petit échantillon. Les coefficients restent justes.
Celui qui fausse les coefficients : la variable omise. Rien d'autre ne compte autant.

La conséquence sur la façon de travailler

Les premiers se **détectent par un test** et se **réparent par une formule**. Ce sont des problèmes techniques, et ils ont des solutions techniques.
Le second se détecte par le **raisonnement économique** — car la variable manquante n'est pas dans les données — et se répare en changeant de modèle. **C'est un problème de spécification, et aucun logiciel ne le résoudra.**

Cinq problèmes, cinq chapitres

Le parcours de la cinquième partie

Problème	Hypothèse	Touche	Terrain	Chapitre
Multicolinéarité	H5 presque	écarts-types	salaires	13
Hétéroscédasticité	H3	écarts-types	salaires	14
Erreurs groupées	H4	écarts-types	ménages	15
Variable omise	H2	**coefficients**	salaires	16
Non-normalité, influence	H6	tests, droite	salaires	17

Chaque problème sur le terrain où il se rencontre

Le regroupement n'existe que dans l'enquête de ménages, tirée par quartiers ; l'hétéroscédasticité est spectaculaire sur les salaires. **On ne fabrique pas les problèmes : on les cherche là où ils sont.**

Le rôle des résidus

Le seul matériau du diagnostic

Ce qu'on regarde

Les erreurs ε_i sont inconnues. Les résidus e_i sont calculés.
Tout diagnostic passe par les résidus : ils sont la seule trace observable de ce que le modèle n'explique pas.

Un principe qui ne varie pas

Sous les hypothèses, les résidus doivent ressembler à du **bruit pur** : aucune structure, aucune tendance, aucune relation avec quoi que ce soit.
Toute régularité visible dans les résidus est une information que le modèle a laissée échapper. C'est le fil conducteur des cinq chapitres qui suivent.

Les quatre graphiques à faire systématiquement

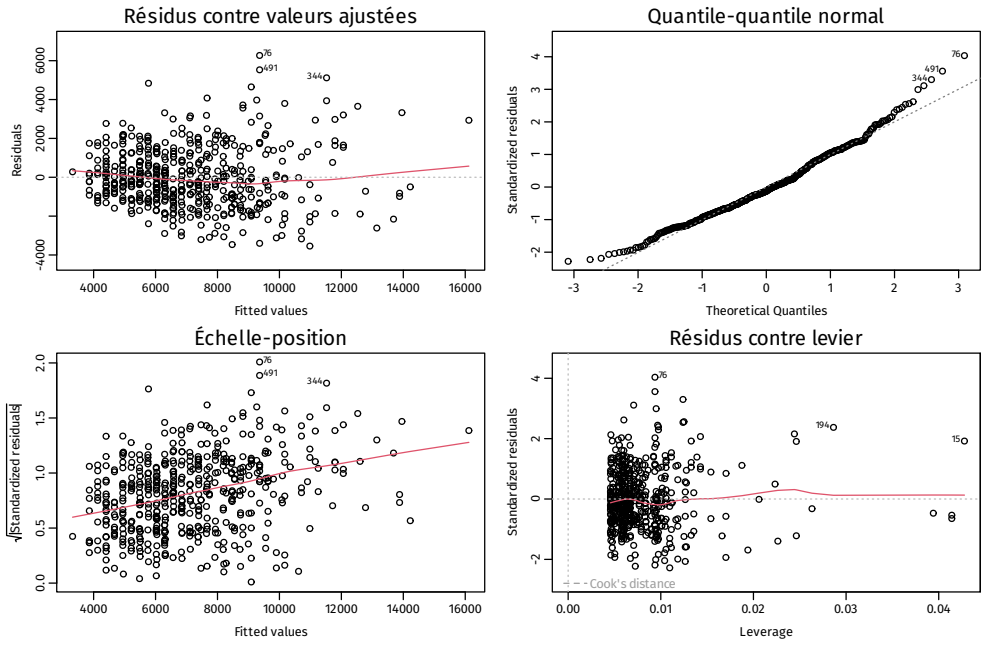
Avant tout commentaire des coefficients

Graphique	Ce qu'il révèle
Résidus contre valeurs ajustées	hétéroscédasticité, non-linéarité
Résidus moyens par groupe	erreurs groupées
Histogramme des résidus	non-normalité, valeurs extrêmes
Résidus contre chaque variable	forme fonctionnelle mal choisie

Ils coûtent quatre lignes de code

Aucun de ces quatre graphiques ne prend plus de dix secondes à produire, et l'un d'eux vaut souvent mieux qu'une batterie de tests.
Un test dit si un problème existe ; un graphique dit à quoi il ressemble. Les deux sont nécessaires, et le graphique vient d'abord.

Les quatre graphiques de R, sur le modèle M2



Ce que les quatre graphiques montrent

Lecture, panneau par panneau

Résidus contre valeurs ajustées : le nuage s'élargit vers la droite — hétéroscédasticité, chapitre 14.
Quantile-quantile : les points décrochent en haut à droite — quelques salaires très au-dessus du modèle, chapitre 17.
Échelle-position : la courbe rouge monte — même diagnostic que le premier panneau, en plus net.
Résidus contre levier : quelques salariés à fort levier, aucun au-delà des courbes de Cook.

Trois chapitres annoncés par une figure

Sans aucun test, la figure désigne déjà les problèmes des chapitres 14 et 17. Les tests confirmeront et chiffreront.

Comment les tests fonctionnent

Un principe commun

La régression auxiliaire

La plupart des tests de diagnostic suivent le même schéma :

1. estimer le modèle et récupérer les résidus ;
2. **régresser une fonction des résidus** sur quelque chose ;
3. si cette seconde régression explique quelque chose, l'hypothèse est violée.

Trois tests, un seul principe

Test	On régresse	Sur
Breusch-Pagan	e_i^2	les variables explicatives
White	e_i^2	variables, carrés, produits
RESET	y_i	variables et puissances de $\hat{y}_i$

La statistique et sa loi

Toujours la même

$$nR^2_{\text{auxiliaire}} \sim \chi^2_q$$

où q est le nombre de variables ajoutées dans la régression auxiliaire.

Pourquoi un khi-deux

Parce qu'on additionne des écarts au carré — c'est le signe reconnu au chapitre 18 de l'inférence.
Et le test est **unilatéral à droite** : seule une valeur élevée contredit l'hypothèse d'absence de problème. **Là encore, rien de nouveau : on applique un test appris ailleurs.**

Breusch-Pagan à la main, sur les cinq ménages

Les carrés des résidus contre le revenu

Ménage	A	B	C	D	E
$R-\overline{R}$	-4	-2	0	2	4
e^2	0	2,25	4	0,25	1

Moyenne de e^2 : $7{,}5/5 = 1{,}5$. Pente de e^2 sur R : $\sum(R-\overline{R})(e^2-1{,}5)/40 = (6-1{,}5+0-2{,}5-2)/40 = 0$.

Un R^2 auxiliaire nul

La régression auxiliaire n'explique rien : $nR^2 = 0$. Breusch-Pagan ne voit **aucune** hétéroscédasticité liée au revenu. Il ne cherche que des liaisons **linéaires** entre e^2 et les variables — et cinq points ne permettraient pas d'en voir d'autres.

Sur les salaires

Deux régressions auxiliaires

Breusch-Pagan : e^2 régressé sur l'ancienneté et les deux indicatrices de diplôme donne $R^2_{\text{aux}} = 0{,}1152$, d'où $nR^2 = 500 \times 0{,}1152 = 57{,}6$, contre un seuil de 7,81 pour χ^2_3.
RESET : ajouter $\hat{y}^2$ au modèle M2 donne $F = 5{,}77$, $p = 0{,}017$.

Deux signaux, deux chapitres

Le premier dit que la dispersion des erreurs dépend des variables : c'est le chapitre 14. Le second qu'une courbure a été oubliée : la forme logarithmique du chapitre 18 y répondra. **Les deux signaux ont la même origine**, comme on le verra : un salaire est une grandeur multiplicative.

Une mise en garde sur les tests de diagnostic

Ils sont sensibles à la taille de l'échantillon

Sur cinq cents observations, la moindre hétéroscédasticité devient significative. Sur trente, une hétéroscédasticité massive peut passer inaperçue.
Un test qui rejette ne dit pas que le problème est grave. Il dit qu'il existe. Le graphique dit s'il compte.

La bonne pratique

Sur données individuelles, l'usage actuel est de ne même plus tester l'hétéroscédasticité : on la suppose présente et l'on publie directement des écarts-types robustes.
Le test garde son intérêt pédagogique — il fait comprendre le mécanisme — et son intérêt pratique quand le remède coûte quelque chose.

Sur machine

Breusch-Pagan avec R

```r
suppressPackageStartupMessages(library(lmtest))
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m2 <- lm(salaire ~ anciennete + diplome, data = sal)
aux <- lm(residuals(m2)^2 ~ anciennete + diplome, data = sal)
500 * summary(aux)$r.squared          # n R2 auxiliaire, à la main
# [1] 57.59655
bptest(m2)                            # la même chose
#
#  studentized Breusch-Pagan test
#
# data:  m2
# BP = 57.597, df = 3, p-value = 1.917e-12
```

Breusch-Pagan et RESET avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
import statsmodels.stats.diagnostic as dg
sal = pd.read_csv("salaires.csv")
m2 = smf.ols("salaire ~ anciennete + diplome", data=sal).fit()
bp, p_bp, _, _ = dg.het_breuschpagan(m2.resid, m2.model.exog)
print(round(bp, 2), f"{p_bp:.1e}")
```

```
# 57.6 1.9e-12
r = dg.linear_reset(m2, power=2, use_f=True)
print(round(r.fvalue, 2), round(r.pvalue, 4))
# 5.77 0.0167
```

S'entraîner

Exercice 1 : Breusch-Pagan à la main

Les quatre magasins

Les résidus de $\hat{y} = 0{,}5 + 1{,}5\,x$ sont 0 ; 0,5 ; $-1{,}5$; 1, pour $x = 1, 2, 4, 5$.

1. Calculer les e^2 et leur moyenne.
2. Calculer la pente et le R^2 de la régression de e^2 sur x.
3. En déduire la statistique de Breusch-Pagan et conclure ($\chi^2_1 = 3{,}84$).

Exercice 1 : solution

Une liaison visible, non significative

1. $e^2 = 0$; 0,25 ; 2,25 ; 1, de moyenne 0,875.
2. Écarts de x : $-2, -1, 1, 2$ ($S_{xx} = 10$). $\sum (x - \overline{x})(e^2 - 0{,}875) = 1{,}75 + 0{,}625 + 1{,}375 + 0{,}25 = 4$: pente 0,4. SCE $= 0{,}4^2 \times 10 = 1{,}6$; SCT $= 3{,}0625$; $R^2 = 0{,}522$.
3. $nR^2 = 4 \times 0{,}522 = 2{,}09 < 3{,}84$: on ne rejette pas. La dispersion semble croître avec x, mais quatre points ne suffisent pas à le prouver.

Exercice 2 : lire un graphique de résidus

Quatre formes

Quel problème suggère chacune des formes suivantes du graphique des résidus contre les valeurs ajustées ?

1. Un éventail qui s'ouvre vers la droite.
2. Une courbe en U.
3. Des paquets de points au-dessus, d'autres au-dessous de zéro, selon le quartier.
4. Un nuage sans forme, avec trois points très au-dessus des autres.

Exercice 2 : solution

Quatre formes, quatre chapitres

1. **Hétéroscédasticité** : la dispersion grandit avec le niveau — chapitre 14.
2. **Forme fonctionnelle** : une courbure oubliée, qu'un carré ou un logarithme corrigerait — chapitre 18.
3. **Erreurs groupées** : les ménages d'un quartier partagent une erreur commune — chapitre 15.
4. **Points atypiques** : à examiner un par un, avec leur levier — chapitre 17.

Exercice 3 : la taille de l'échantillon

Le même R^2 auxiliaire

Deux études obtiennent le même $R^2_{\text{aux}} = 0{,}02$ dans une régression de Breusch-Pagan à une variable.

1. Calculer la statistique pour $n = 50$ et pour $n = 5\,000$.
2. Conclure dans chaque cas.
3. Le problème est-il plus grave dans la seconde étude ?

Exercice 3 : solution

Significatif ne veut pas dire grave

1. $nR^2 = 1$ pour $n = 50$; 100 pour $n = 5\,000$.
2. Non-rejet dans le premier cas ($1 < 3{,}84$), rejet massif dans le second.
3. Non : la régression auxiliaire explique **la même part**, 2 %, de la variance des e^2. Le second test rejette parce qu'il a plus d'observations, pas parce que le problème est plus grand. **Le graphique, pas le test, dit si cela compte.**

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Quatre violations ne touchent que les **écarts-types** ; une seule, la variable omise, biaise les **coefficients**.
2. Les premières se détectent par un **test** et se réparent par une **formule** ; la seconde par le raisonnement.
3. Tout diagnostic passe par les **résidus** : ils doivent ressembler à du bruit pur.
4. Quatre graphiques, systématiquement : `plot(m2)` annonce déjà les chapitres 14 et 17.
5. Les tests suivent tous le même schéma : une **régression auxiliaire** et un nR^2 lu dans un khi-deux.
6. Salaires : Breusch-Pagan 57,6, RESET 5,77 ; cinq ménages : $nR^2 = 0$.

La suite

La carte est dressée. Les cinq chapitres suivants la parcourent case par case. On commence par celui qui n'est pas vraiment une violation, et qui déroute le plus : la **multicolinéarité**.