

Chapitre 19

Choisir un modèle, et le seuil de la causalité

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\ln 500 \approx 6,215$. Pénalité de l'AIC par paramètre : 2. Pénalité du BIC par paramètre : $\ln n \approx 6,215$.
(b) $n \ln(\text{SCR}/n)$ est commun aux deux modèles pour chaque calcul : pour A, $500 \ln(125\,000/500) = 500 \ln(250) \approx 2\,760,73$; pour B, $500 \ln(123\,500/500) = 500 \ln(247) \approx 2\,754,69$. $\text{AIC}_A = 2\,760,73 + 2 \times 4 \approx 2\,768,73$. $\text{AIC}_B = 2\,754,69 + 2 \times 5 \approx 2\,764,69$. L'AIC préfère le modèle B (valeur plus faible).
(c) $\text{BIC}_A = 2\,760,73 + 6,215 \times 4 \approx 2\,785,59$. $\text{BIC}_B = 2\,754,69 + 6,215 \times 5 \approx 2\,785,77$. Le BIC préfère de justesse le modèle A (valeur plus faible).
(d) Non, les deux critères se contredisent ici : l'AIC préfère le modèle plus riche B, le BIC préfère le modèle plus court A. Ce désaccord s'explique par la sévérité relative des deux pénalités : avec $\ln 500 \approx 6,2$ contre 2 pour l'AIC, le BIC pénalise chaque paramètre supplémentaire plus de trois fois plus lourdement, ce qui le rend plus réticent à « payer » une variable de plus pour un gain d'ajustement modeste — exactement la propriété annoncée par le cours : « le BIC est plus sévère et choisit des modèles plus courts ».

Correction — Exercice 2

- (a) « Les salariés syndiqués gagnent 12 % de plus, à ancienneté, diplôme et secteur comparables. »
(b) « L'appartenance syndicale augmente le salaire de 12 %. » — cette formulation dépasse les données.
(c) Parce qu'elle suppose implicitement que, parmi deux salariés par ailleurs identiques sur *toutes* leurs caractéristiques (y compris celles non observées, comme la motivation ou le type de poste), seule l'appartenance syndicale expliquerait l'écart de salaire — alors que l'étude n'a comparé que sur les variables effectivement incluses dans le modèle (ancienneté, diplôme, secteur).
(d) Le problème s'appelle l'**endogénéité** : la variable « syndiqué » serait corrélée au terme d'erreur (via des caractéristiques non observées comme la motivation ou le type de poste), violant l'hypothèse H2 et biaisant le coefficient.

Correction — Exercice 3

- (a) S_1 : **variable omise**. S_2 : **causalité inverse**. S_3 : **erreur de mesure**.
(b) Dans les trois cas, c'est l'hypothèse H2 (exogénéité, $E(\varepsilon|X) = 0$, ou de façon équivalente $\text{cov}(x, \varepsilon) = 0$) qui est violée.
(c) Non, dans aucun des trois cas un test statistique appliqué aux seules données disponibles ne peut détecter le problème : dans les trois cas, la source du problème (la variable omise elle-même, la boucle de rétroaction entre budget et ventes, ou l'erreur de mesure sur le revenu) n'est pas observable ou n'est pas testable directement à partir de l'échantillon dont dispose le chercheur.
(d) Non : aucune correction d'écart-type (robuste de White ou de grappe) ne répare un problème d'endogénéité, quel qu'en soit le type. Ces corrections ne touchent qu'à la précision (l'écart-type) des coefficients, jamais à leur exactitude (le biais), qui est précisément ce que l'endogénéité affecte.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Non, ces deux coûts ne sont pas de même nature : le premier (variable inutile) dégrade la **précision** de l'estimation sans en changer la valeur espérée — l'estimateur reste centré sur la vraie valeur, mais avec plus de variance. Le second (variable omise) dégrade l'**exactitude** même de l'estimation — l'estimateur n'est plus centré sur la vraie valeur, quelle que soit la taille de l'échantillon.
(b) Ces deux erreurs ne se valent pas car un excès de variance peut être compensé en collectant davantage de données (l'imprécision se réduit avec n), alors qu'un biais ne disparaît jamais, aussi

grand que soit l'échantillon : plus de données ne corrigent en rien un coefficient systématiquement faux.

(c) Non : ce biais, comme tout biais de variable omise, ne pouvait pas être détecté par un test statistique appliqué aux seules données disponibles (ancienneté et salaire) — le diplôme, la variable omise, n'étant par définition pas dans ce jeu de données restreint, rien dans la sortie du logiciel (le R^2 , les résidus, les tests) n'aurait signalé son absence, exactement comme le rappelle ce chapitre à propos de l'endogénéité en général.

(d) La règle de prudence commune aux trois chapitres est : en cas de doute sur l'utilité théorique d'une variable, mieux vaut l'inclure que l'omettre, car le coût d'une variable inutile (un excès de variance, réversible avec plus de données) est presque toujours préférable au coût d'une variable omise pertinente (un biais permanent sur le coefficient d'intérêt, invisible dans les résultats du logiciel).

3 Applications en sciences économiques

Correction — Exercice 5

(a) La théorie économique doit l'emporter car le prix est une composante **définitionnelle** de toute relation de demande : une fonction de demande décrit précisément comment la quantité demandée réagit au prix. Le retirer ne produit pas un modèle de demande plus simple, mais un objet qui n'est plus, par définition, un modèle de demande.

(b) Un relecteur en microéconomie serait en droit de rejeter le modèle sur le fond, indépendamment de ses qualités statistiques (AIC, R^2 , résidus propres) : un modèle sans le prix ne peut pas servir à répondre aux questions usuelles de la théorie de la demande (élasticité-prix, surplus du consommateur, effet d'une taxe), quelle que soit sa performance statistique apparente.

(c) Ce cas illustre que les critères d'information optimisent un compromis purement statistique entre ajustement et complexité, sans aucune connaissance de la théorie économique sous-jacente : ils ne peuvent donc jamais se substituer au jugement du chercheur sur ce qu'une variable représente conceptuellement dans le modèle.

(d) Une explication plausible : sur cet échantillon particulier, la variation du prix observée est peut-être trop faible (peu de dispersion) pour permettre une estimation précise de son effet, ou le prix est fortement corrélé à d'autres variables du modèle (par exemple la saison), rendant son coefficient individuellement peu significatif sans que cela signifie que l'effet-prix réel soit nul — un problème de précision, pas d'absence d'effet.

Correction — Exercice 6

(a) « Les salariés de cette branche gagnent, dans cet échantillon, 8 % de plus que les autres à ancienneté, diplôme et région comparables, avec un intervalle de confiance à 95 % allant de 3 % à 13 %. »

(b) « Ce résultat est valide sous l'hypothèse qu'aucune variable pertinente corrélée à la fois à la branche d'activité et au salaire n'a été omise du modèle, et que l'appartenance à cette branche est exogène, c'est-à-dire non corrélée à des caractéristiques non observées des salariés (motivation, capacités, réseau) qui influenceraient elles-mêmes le salaire. »

(c) « Ce résultat ne permet pas de conclure que travailler dans cette branche *cause* une hausse de salaire de 8 % : les salariés de cette branche pourraient différer des autres par des caractéristiques non observées (sélection dans le secteur, compétences spécifiques) qui expliquent une partie de cet écart, indépendamment de tout effet causal de la branche elle-même. »

(d) La significativité statistique (l'intervalle [3 % ; 13 %] excluant zéro) établit seulement que l'écart observé de 8 % n'est vraisemblablement pas dû au hasard de l'échantillonnage — c'est une affirmation sur la **précision** de la mesure. Elle ne dit absolument rien sur son **exactitude** causale : un écart peut être mesuré avec une grande précision statistique et pourtant refléter, en tout ou en partie, un biais d'endogénéité (variable omise, sélection des salariés dans la branche) plutôt qu'un véritable effet causal de la branche sur le salaire. C'est exactement la distinction que le cours résume par « significatif ne veut jamais dire causal ».