

Introduction à l'économétrie

Chapitre 19 : Choisir un modèle, et le seuil de la causalité

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer et comparer AIC et BIC

Deux modèles sont estimés sur $n = 500$ observations. Modèle A : $SCR = 125\,000$, $p = 4$ paramètres. Modèle B (une variable de plus) : $SCR = 123\,500$, $p = 5$ paramètres.

- (a) Calculer $\ln n$ pour $n = 500$. Quelle est la pénalité de complexité de l'AIC par paramètre, et celle du BIC ?
- (b) Calculer l'AIC des deux modèles à l'aide de critère $= n \ln(SCR/n) + \text{pénalité} \times p$. Quel modèle l'AIC préfère-t-il (le critère le plus **faible** l'emporte) ?
- (c) Calculer le BIC des deux modèles. Quel modèle le BIC préfère-t-il ?
- (d) Les deux critères s'accordent-ils ici ? Si non, comment expliquer ce désaccord à partir de la sévérité relative des deux pénalités ?

Exercice 2 — Trois formulations, une seule ligne dépasse les données

On dispose d'un coefficient indiquant que les salariés syndiqués gagnent 12 % de plus, à ancienneté, diplôme et secteur comparables.

- (a) Formuler une phrase **correcte** de type association conditionnelle à partir de ce résultat.
- (b) Formuler une phrase qui **dépasse** les données en affirmant une causalité pleine et entière.
- (c) Pourquoi cette seconde phrase suppose-t-elle implicitement que l'appartenance syndicale est indépendante de toute autre caractéristique du salarié (motivation, ancienneté dans le secteur, type de poste) ?
- (d) Si les salariés syndiqués diffèrent systématiquement des autres par des caractéristiques non observées corrélées au salaire, quel est le nom du problème dont souffre alors la phrase causale ?

Exercice 3 — Identifier la source de l'endogénéité

Trois situations sont décrites.

- S_1 . Une régression du salaire sur le diplôme omet les capacités individuelles, corrélées au diplôme.
 - S_2 . Une régression des ventes sur le budget publicitaire, alors que les entreprises fixent leur budget publicitaire en fonction des ventes de l'année précédente.
 - S_3 . Une régression du rendement scolaire sur le revenu déclaré des parents, ce revenu étant mal mesuré (sous-déclaration fréquente).
- (a) Associer chaque situation à l'une des trois sources d'endogénéité du cours : variable omise, causalité inverse, erreur de mesure.
 - (b) Dans les trois cas, quelle hypothèse de Gauss-Markov (H_2 , exogénéité) est violée ?
 - (c) Un test statistique appliqué aux données disponibles peut-il détecter, dans l'un de ces trois cas, la présence du problème ?
 - (d) Une correction d'écart-type (robuste ou de grappe) peut-elle réparer l'un de ces trois problèmes ?

2 Exercice cumulatif (chapitre 19 et chapitres précédents)

Exercice 4 — Le même arbitrage, deux chapitres plus tard

Le chapitre 13 (multicolinéarité) avertissait qu'un « mauvais échange » consiste à retirer une variable colinéaire pour gagner en précision, au risque de créer un biais de variable omise. Ce chapitre affirme : « en cas de doute, mieux vaut inclure ».

- (a) Ajouter une variable inutile à un modèle coûte de la **précision** (chapitre 13 : gonflement de la variance par la multicolinéarité, ou perte de degrés de liberté). Omettre une variable pertinente

coûte de la **justesse** (chapitre 16 : biais $\gamma\delta$). Ces deux coûts sont-ils de même nature ?

- (b) Pourquoi le cours affirme-t-il que ces deux erreurs « ne se valent pas », alors que toutes deux dégradent la qualité du modèle ?
- (c) Le chapitre 16 avait montré, sur les données réelles du cours, un biais de variable omise chiffré exactement à +6,898 en retirant le diplôme du modèle de l'ancienneté. Ce biais aurait-il pu être détecté par un test statistique appliqué aux seules données disponibles (ancienneté et salaire, sans le diplôme) ?
- (d) En reliant les chapitres 13, 16 et 19, formuler en une phrase la règle de prudence qui traverse les trois : que doit faire un chercheur hésitant entre inclure ou exclure une variable dont l'utilité théorique n'est pas certaine, mais dont l'omission pourrait biaiser un coefficient d'intérêt ?

3 Applications en sciences économiques

Exercice 5 — Une variable qu'aucun critère ne doit faire disparaître

Un économiste estime un modèle de demande d'un bien : quantité demandée en fonction du prix, du revenu des ménages et d'une variable saisonnière. Le critère AIC suggère de retirer le prix, dont le coefficient est peu significatif sur cet échantillon particulier.

- (a) Le cours affirme qu'« un modèle de demande sans le prix n'est pas un modèle de demande, quel que soit son AIC ». Pourquoi la théorie économique doit-elle, ici, l'emporter sur le critère statistique ?
- (b) Si l'économiste suit néanmoins l'AIC et retire le prix, quel type de critique un relecteur spécialisé en microéconomie serait-il en droit de formuler, indépendamment de la qualité statistique du modèle obtenu ?
- (c) En quoi ce cas illustre-t-il que les critères d'information (AIC, BIC) sont des outils **auxiliaires**, et non des substituts au jugement théorique du chercheur ?
- (d) Proposer une explication économique plausible pour laquelle le coefficient du prix serait peu significatif sur cet échantillon particulier, sans que cela remette en cause l'existence réelle d'un effet-prix sur la demande.

Exercice 6 — Un rapport honnête, en trois phrases

Une étude conclut qu'à ancienneté, diplôme et région comparables, les salariés d'une certaine branche gagnent 8 % de plus que les autres, avec un intervalle de confiance à 95 % de [3 % ; 13 %].

- (a) Rédiger la première des trois phrases que le cours recommande à tout économètre : « voici ce que j'ai mesuré, et avec quelle précision », appliquée à ce résultat.
- (b) Rédiger la deuxième phrase, « voici les hypothèses sous lesquelles cette mesure est valide » (mentionner au moins l'absence de biais de variable omise pertinente et l'exogénéité de la variable de branche).
- (c) Rédiger la troisième phrase, « voici ce que je ne peux pas conclure », en particulier concernant la causalité de cet écart salarial.
- (d) Le cours affirme que « significatif » ne veut jamais dire « causal ». Expliquer, à partir de ce même exemple, pourquoi la significativité statistique de l'écart de 8 % (l'intervalle de confiance excluant zéro) n'implique en rien que la branche d'activité *cause* ce supplément de salaire.

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\ln 500 \approx 6,215$. Pénalité de l'AIC par paramètre : 2. Pénalité du BIC par paramètre : $\ln n \approx 6,215$.
- (b) $n \ln(\text{SCR}/n)$ est commun aux deux modèles pour chaque calcul : pour A, $500 \ln(125\,000/500) = 500 \ln(250) \approx 2\,760,73$; pour B, $500 \ln(123\,500/500) = 500 \ln(247) \approx 2\,754,69$. $\text{AIC}_A = 2\,760,73 + 2 \times 4 \approx 2\,768,73$. $\text{AIC}_B = 2\,754,69 + 2 \times 5 \approx 2\,764,69$. L'AIC préfère le modèle B (valeur plus faible).
- (c) $\text{BIC}_A = 2\,760,73 + 6,215 \times 4 \approx 2\,785,59$. $\text{BIC}_B = 2\,754,69 + 6,215 \times 5 \approx 2\,785,77$. Le BIC préfère de justesse le modèle A (valeur plus faible).
- (d) Non, les deux critères se contredisent ici : l'AIC préfère le modèle plus riche B, le BIC préfère le modèle plus court A. Ce désaccord s'explique par la sévérité relative des deux pénalités : avec $\ln 500 \approx 6,2$ contre 2 pour l'AIC, le BIC pénalise chaque paramètre supplémentaire plus de trois fois plus lourdement, ce qui le rend plus réticent à « payer » une variable de plus pour un gain d'ajustement modeste — exactement la propriété annoncée par le cours : « le BIC est plus sévère et choisit des modèles plus courts ».

Correction — Exercice 2

- (a) « Les salariés syndiqués gagnent 12 % de plus, à ancienneté, diplôme et secteur comparables. »
- (b) « L'appartenance syndicale augmente le salaire de 12 %. » — cette formulation dépasse les données.
- (c) Parce qu'elle suppose implicitement que, parmi deux salariés par ailleurs identiques sur *toutes* leurs caractéristiques (y compris celles non observées, comme la motivation ou le type de poste), seule l'appartenance syndicale expliquerait l'écart de salaire — alors que l'étude n'a comparé que sur les variables effectivement incluses dans le modèle (ancienneté, diplôme, secteur).
- (d) Le problème s'appelle l'**endogénéité** : la variable « syndiqué » serait corrélée au terme d'erreur (via des caractéristiques non observées comme la motivation ou le type de poste), violant l'hypothèse H2 et biaisant le coefficient.

Correction — Exercice 3

- (a) S_1 : **variable omise**. S_2 : **causalité inverse**. S_3 : **erreur de mesure**.
- (b) Dans les trois cas, c'est l'hypothèse H2 (exogénéité, $E(\varepsilon|X) = 0$, ou de façon équivalente $\text{cov}(x, \varepsilon) = 0$) qui est violée.
- (c) Non, dans aucun des trois cas un test statistique appliqué aux seules données disponibles ne peut détecter le problème : dans les trois cas, la source du problème (la variable omise elle-même, la boucle de rétroaction entre budget et ventes, ou l'erreur de mesure sur le revenu) n'est pas observable ou n'est pas testable directement à partir de l'échantillon dont dispose le chercheur.
- (d) Non : aucune correction d'écart-type (robuste de White ou de grappe) ne répare un problème d'endogénéité, quel qu'en soit le type. Ces corrections ne touchent qu'à la précision (l'écart-type) des coefficients, jamais à leur exactitude (le biais), qui est précisément ce que l'endogénéité affecte.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Non, ces deux coûts ne sont pas de même nature : le premier (variable inutile) dégrade la **précision** de l'estimation sans en changer la valeur espérée — l'estimateur reste centré sur la vraie valeur, mais avec plus de variance. Le second (variable omise) dégrade l'**exactitude** même de l'estimation — l'estimateur n'est plus centré sur la vraie valeur, quelle que soit la taille de l'échantillon.
- (b) Ces deux erreurs ne se valent pas car un excès de variance peut être compensé en collectant davantage de données (l'imprécision se réduit avec n), alors qu'un biais ne disparaît jamais, aussi

grand que soit l'échantillon : plus de données ne corrigent en rien un coefficient systématiquement faux.

(c) Non : ce biais, comme tout biais de variable omise, ne pouvait pas être détecté par un test statistique appliqué aux seules données disponibles (ancienneté et salaire) — le diplôme, la variable omise, n'étant par définition pas dans ce jeu de données restreint, rien dans la sortie du logiciel (le R^2 , les résidus, les tests) n'aurait signalé son absence, exactement comme le rappelle ce chapitre à propos de l'endogénéité en général.

(d) La règle de prudence commune aux trois chapitres est : en cas de doute sur l'utilité théorique d'une variable, mieux vaut l'inclure que l'omettre, car le coût d'une variable inutile (un excès de variance, réversible avec plus de données) est presque toujours préférable au coût d'une variable omise pertinente (un biais permanent sur le coefficient d'intérêt, invisible dans les résultats du logiciel).

3 Applications en sciences économiques

Correction — Exercice 5

(a) La théorie économique doit l'emporter car le prix est une composante **définitionnelle** de toute relation de demande : une fonction de demande décrit précisément comment la quantité demandée réagit au prix. Le retirer ne produit pas un modèle de demande plus simple, mais un objet qui n'est plus, par définition, un modèle de demande.

(b) Un relecteur en microéconomie serait en droit de rejeter le modèle sur le fond, indépendamment de ses qualités statistiques (AIC, R^2 , résidus propres) : un modèle sans le prix ne peut pas servir à répondre aux questions usuelles de la théorie de la demande (élasticité-prix, surplus du consommateur, effet d'une taxe), quelle que soit sa performance statistique apparente.

(c) Ce cas illustre que les critères d'information optimisent un compromis purement statistique entre ajustement et complexité, sans aucune connaissance de la théorie économique sous-jacente : ils ne peuvent donc jamais se substituer au jugement du chercheur sur ce qu'une variable représente conceptuellement dans le modèle.

(d) Une explication plausible : sur cet échantillon particulier, la variation du prix observée est peut-être trop faible (peu de dispersion) pour permettre une estimation précise de son effet, ou le prix est fortement corrélé à d'autres variables du modèle (par exemple la saison), rendant son coefficient individuellement peu significatif sans que cela signifie que l'effet-prix réel soit nul — un problème de précision, pas d'absence d'effet.

Correction — Exercice 6

(a) « Les salariés de cette branche gagnent, dans cet échantillon, 8 % de plus que les autres à ancienneté, diplôme et région comparables, avec un intervalle de confiance à 95 % allant de 3 % à 13 %. »

(b) « Ce résultat est valide sous l'hypothèse qu'aucune variable pertinente corrélée à la fois à la branche d'activité et au salaire n'a été omise du modèle, et que l'appartenance à cette branche est exogène, c'est-à-dire non corrélée à des caractéristiques non observées des salariés (motivation, capacités, réseau) qui influenceraient elles-mêmes le salaire. »

(c) « Ce résultat ne permet pas de conclure que travailler dans cette branche *cause* une hausse de salaire de 8 % : les salariés de cette branche pourraient différer des autres par des caractéristiques non observées (sélection dans le secteur, compétences spécifiques) qui expliquent une partie de cet écart, indépendamment de tout effet causal de la branche elle-même. »

(d) La significativité statistique (l'intervalle [3 % ; 13 %] excluant zéro) établit seulement que l'écart observé de 8 % n'est vraisemblablement pas dû au hasard de l'échantillonnage — c'est une affirmation sur la **précision** de la mesure. Elle ne dit absolument rien sur son **exactitude** causale : un écart peut être mesuré avec une grande précision statistique et pourtant refléter, en tout ou en partie, un biais d'endogénéité (variable omise, sélection des salariés dans la branche) plutôt qu'un véritable effet causal de la branche sur le salaire. C'est exactement la distinction que le cours résume par « significatif ne veut jamais dire causal ».