Introduction à l'économétrie

Chapitre 19 : Choisir un modèle, et le seuil de la causalité

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Choisir **2**
- Le compromis fondamental . . . 2
- Les critères d'information . . . 2
- Comment les lire . . . 2
- M4 contre M5, à la main . . . 3
- Le BIC, plus sévère ? . . . 4
- Les critères face au hasard . . . 4
- Ce que les critères ne remplacent pas . . . 5

Le seuil de la causalité **5**
- La question que tout le monde pose . . . 5
- Ce qu'un coefficient établit . . . 6
- Le nom du problème . . . 6
- Une simulation où l'on connaît la vérité . . . 6
- L'erreur de mesure, un biais vers zéro . . . 7
- Ce que le cours n'a pas résolu . . . 8

La conclusion du cours **8**
- Ce qu'un économètre doit savoir dire . . . 8
- Ce que quatre cours ont construit . . . 9

Sur machine **9**
- AIC et BIC avec R . . . 9
- La capacité omise, simulée avec R . . . 9
- La capacité omise, simulée avec Python . . . 10

S'entraîner **10**
- Exercice 1 : AIC et BIC à la main . . . 10
- Exercice 1 : solution . . . 10
- Exercice 2 : associé ou causal . . . 10
- Exercice 2 : solution . . . 11
- Exercice 3 : d'où vient l'endogénéité . . . 11
- Exercice 3 : solution . . . 11

Ce qu'il faut retenir **11**
Le résumé du chapitre 11

Choisir

Le compromis fondamental

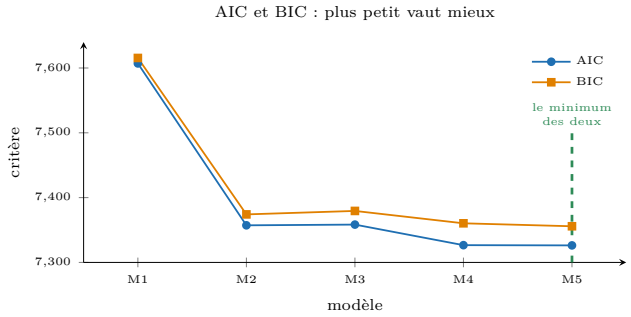
Deux erreurs opposées

Trop peu de variables : risque de **variable omise**, donc de biais.
Trop de variables : perte de degrés de liberté, multicolinéarité, et un modèle qui décrit l'échantillon au lieu de la population.

Les deux erreurs ne se valent pas

Ajouter une variable inutile coûte de la **précision**. Omettre une variable pertinente coûte de la **justesse**.
En cas de doute, mieux vaut inclure. C'est le même arbitrage qu'au chapitre 13 : on ne troque pas un problème de variance contre un problème de biais.

Les critères d'information



Les cinq modèles

M1 ancienneté seule
M2 + diplôme
M3 + sexe
M4 + région
M5 = M4 *sans* le sexe

$\text{AIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + 2p$

$\text{BIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + p \ln n$

Les deux ajoutent une **pénalité** au manque d'ajustement. Le BIC pénalise plus lourdement : il choisit des modèles plus courts.

Ici les deux désignent M5, le modèle sans le sexe. La variable non significative est écartée par le critère, sans qu'on ait eu à trancher à la main.

Comment les lire

La structure commune

$$\text{critère} = \underbrace{n \ln\left(\frac{\text{SCR}}{n}\right)}_{\text{mauvais ajustement}} + \underbrace{\text{pénalité} \times p}_{\text{complexité}}$$

p est le nombre de coefficients estimés, constante comprise. AIC pénalise de 2 par coefficient ; BIC de $\ln n$, soit 6,2 ici. **Le BIC est donc plus sévère et choisit des modèles plus courts.**

Démonstration : D'où viennent l'AIC et le BIC : $n\ln(\text{SCR}/n)$ plus une pénalité

Avec des erreurs normales, la vraisemblance de n observations est un produit de densités, dont le logarithme vaut

$$\ln L = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{S(\beta)}{2\sigma^2},$$

où $S(\beta)$ est la somme des carrés. Pour σ^2 donné, maximiser $\ln L$ en β revient à minimiser $S(\beta)$: le maximum de vraisemblance donne les moindres carrés. Il reste σ^2 : la dérivée $-\frac{n}{2\sigma^2} + \frac{\text{SCR}}{2\sigma^4}$ s'annule en $\widehat{\sigma}^2 = \text{SCR}/n$. En reportant,

$$\ln \widehat{L} = -\frac{n}{2}\Big[\ln\frac{\text{SCR}}{n} + \ln 2\pi + 1\Big].$$

L'AIC vaut $-2\ln\widehat{L} + 2p$ et le BIC $-2\ln\widehat{L} + p\ln n$, où p est le nombre de paramètres. Comme

$$-2\ln\widehat{L} = n\ln\frac{\text{SCR}}{n} + n\,(1 + \ln 2\pi),$$

et que le second terme est **le même pour tous les modèles** estimés sur les mêmes données, on le supprime : il reste $n\ln(\text{SCR}/n) + 2p$ pour l'AIC et $n\ln(\text{SCR}/n) + p\ln n$ pour le BIC.

La constante de R. R compte aussi σ^2 parmi les paramètres $(p+1)$ et garde la constante : son AIC est celui du cours plus $n(1 + \ln 2\pi) + 2$, soit $500 \times 2{,}838 + 2 = 1\,420{,}9$ pour $n = 500$; c'est bien l'écart entre 8 747,6 et 7 326,6. Les différences entre modèles, seules à compter, sont inchangées.

Le BIC plus sévère que l'AIC si et seulement si $\ln n > 2$, c'est-à-dire $n > \mathrm{e}^2 \approx 7{,}39$, soit $n \geq 8$.

■

Sur nos données, les deux s'accordent

Le minimum est atteint par **M5** — le modèle avec ancienneté, diplôme et région, **sans le sexe**.
La variable non significative est écartée par le critère, sans qu'on ait eu à trancher à la main. Les tests, les critères et le R^2 ajusté disent tous la même chose.

M4 contre M5, à la main

Un coefficient de moins

	SCR (millions)	$n\ln(\text{SCR}/n)$	p	AIC	BIC
M4	1 119,21	7 310,64	8	7 326,64	7 360,36
M5	1 122,89	7 312,28	7	7 326,28	7 355,79

Le sexe coûte plus qu'il ne rapporte

Ajouter le sexe fait baisser le premier terme de 1,64 seulement. L'AIC le facture 2 : il préfère M5 de 0,36. Le BIC le facture 6,21 : il préfère M5 de 4,57. **Deux critères, une même réponse, une conviction différente.**

Le BIC, plus sévère ?

Seulement si n dépasse 7

Le BIC pénalise de $\ln n$, l'AIC de 2 : le BIC n'est plus sévère que si $\ln n > 2$, c'est-à-dire $n \geq 8$.

Sur les cinq ménages

Modèle	$n \ln(\mathrm{SCR}/n)$	AIC	BIC
C sur R	$5 \ln 1{,}5 = 2{,}03$	6,03	5,25
C sur R et T	$5 \ln 1 = 0$	6,00	4,83

Avec $\ln 5 = 1{,}61 < 2$, c'est le BIC qui pénalise le moins. Les deux préfèrent de justesse le modèle avec la taille.

Les critères face au hasard

M4, puis M4 plus dix variables de hasard

Critère	M4	M4 +10 hasard	Choix
R^2 ajusté	0,6637	0,6655	le modèle **avec** le hasard
AIC	7 326,6	7 333,6	M4
BIC	7 360,4	7 409,5	M4, nettement

Trois sévérités

Le R^2 ajusté facture une variable au seuil $|t| > 1$: il s'est laissé prendre au chapitre 8. L'AIC exige à peu près $|t| > 1{,}4$, le BIC $|t| > 2{,}5$ sur 500 observations. **Plus le critère est sévère, moins il retient de bruit — et plus il risque d'écarter une variable faible mais réelle.**

Démonstration : Les trois critères comme seuils sur le t

Ajoutons une variable à un modèle court (somme des carrés résiduels SCR_0) pour obtenir le modèle long (SCR_1, $\nu = n - k - 2$ degrés de liberté). Par la démonstration du R^2 ajusté (chapitre 8), $\mathrm{SCR}_0 - \mathrm{SCR}_1 = t^2 \, \mathrm{SCR}_1/\nu$, donc

$$\frac{\mathrm{SCR}_0}{\mathrm{SCR}_1} = 1 + \frac{t^2}{\nu}.$$

Le gain d'ajustement, le premier terme des critères, est alors $n \ln(\mathrm{SCR}_0/n) - n \ln(\mathrm{SCR}_1/n) =$

$n \ln(1 + t^2/\nu)$. Le modèle long est préféré quand ce gain dépasse la pénalité d'un coefficient supplémentaire. Comme $n \approx \nu$ et $\ln(1+a) \approx a$, le gain vaut à peu près t^2 :

- R^2 **ajusté** : $t^2 > 1$ (chapitre 8, exactement) ;
- **AIC** : $n \ln(1 + t^2/\nu) > 2$, soit à peu près $t^2 > 2$, donc $|t| > \sqrt{2} = 1{,}41$;
- **BIC** : $n \ln(1 + t^2/\nu) > \ln n$, soit à peu près $t^2 > \ln n$, donc $|t| > \sqrt{\ln 500} = 2{,}49$ sur 500 observations.

Exactement, les seuils sont $t^2 > \nu\,(\mathrm{e}^{2/n} - 1)$ pour l'AIC et $t^2 > \nu\,(n^{1/n} - 1)$ pour le BIC : 1,40 et 2,48 pour $n = 500$. Le sexe, dans M4, a $t = 1{,}27$ et $t^2 = 1{,}62$: sous le seuil de l'AIC (1,97) comme sous celui du BIC (6,1), d'où la préférence pour M5.

■

Ce que les critères ne remplacent pas

Une variable théoriquement indispensable se garde

Si la théorie économique impose qu'une variable figure dans le modèle, elle y reste — même non significative, même si le critère préfère s'en passer.
Un modèle de demande sans le prix n'est pas un modèle de demande, quel que soit son AIC.

Et la sélection automatique est une mauvaise idée

Les procédures pas à pas — ajouter ou retirer selon les t — enchaînent des dizaines de tests et invalident tous les seuils, exactement comme la pêche aux résultats du chapitre 14 de l'inférence.
Le modèle final n'a alors plus de p-values interprétables, puisqu'il a été choisi *sur* les données qui servent à le tester.

Le seuil de la causalité

La question que tout le monde pose



La variable confondante
elle explique les deux, et fausse β

La causalité inverse
le budget publicitaire suit les ventes passées

Dans les deux cas, la variable explicative est corrélée au terme d'erreur : l'hypothèse H2 tombe, et le coefficient est biaisé.

C'est le mot d'**endogénéité**, et c'est le seuil où s'arrête ce cours. Les capacités non observées gonflent le rendement apparent du diplôme ; les ventes qui gonflent le budget publicitaire font surestimer l'effet de la publicité.

Aucun test ne le révèle, aucune correction d'écarts-types n'y remédie. La sortie du logiciel est parfaitement propre — et le coefficient reste faux.

Les réponses existent : variables instrumentales, doubles différences, discontinuité de régression, expériences contrôlées. Elles font l'objet de l'économétrie de niveau Master, et c'est le sujet qui a valu plusieurs prix Nobel depuis 2000. **Retenez seulement, de ce cours, que « significatif » ne veut jamais dire « causal ».**

Ce qu'un coefficient établit

Trois formulations, une seule correcte

Formulation	Statut
« Les Bac+5 gagnent 54,5 % de plus, à ancienneté comparable »	**correcte**
« Le Bac+5 est associé à 54,5 % de salaire en plus »	correcte
« Le Bac+5 **augmente** le salaire de 54,5 % »	**dépasse les données**

La troisième suppose ce qu'on n'a pas montré

Elle suppose que si l'on donnait un Bac+5 à un salarié pris au hasard, son salaire monterait de 54,5 %.
Or les diplômés diffèrent des autres par bien d'autres choses — capacités, milieu, réseau, ambition — dont aucune n'est dans le fichier. **Une partie de l'écart leur revient.**

Le nom du problème

Endogénéité

La variable explicative est corrélée au terme d'erreur : $\text{cov}(x, \varepsilon) \neq 0$.
L'hypothèse H2 tombe, et le coefficient est **biaisé**.

Ses trois sources

1. **Variable omise** — chapitre 16.
2. **Causalité inverse** — le budget publicitaire suit les ventes autant qu'il les précède.
3. **Erreur de mesure** sur la variable explicative.

Une simulation où l'on connaît la vérité

Des capacités que personne n'observe

On simule 5 000 salariés. La capacité c est tirée au hasard ; les études valent $12 + 2c$ plus un aléa ; le logarithme du salaire vaut $1 + 0{,}08 \times \text{études} + 0{,}10\,c$ plus un aléa.
Le vrai rendement d'une année d'études est 0,08**.**

Ce que trouve la régression sans la capacité

0,122 : une surestimation de moitié. La formule du chapitre 16 la prévoit : $\gamma = 0{,}10$, $\delta = \text{cov}(\text{études}, c)/V(\text{études}) = 2/5 = 0{,}4$, d'où $0{,}08 + 0{,}10 \times 0{,}4 = 0{,}12$.
Avec la capacité dans le modèle : 0,082 — Python, avec un autre tirage, trouve 0,119 et 0,077. **Mais dans un vrai fichier, la capacité n'est pas là.**

Démonstration : Le biais de la simulation : γ, δ avec $\delta = \operatorname{cov}(x,c)/V(x)$

Notons x les études et c la capacité. Le vrai modèle est $\ln S = 1 + 0{,}08\,x + 0{,}10\,c + \eta$, avec un aléa η indépendant de x et de c. Alors

$$\operatorname{cov}(x, \ln S) = 0{,}08\,V(x) + 0{,}10\operatorname{cov}(x,c).$$

La pente de la régression simple, S_{xy}/S_{xx}, tend vers $\operatorname{cov}(x, \ln S)/V(x)$ quand n croît (loi des grands nombres), c'est-à-dire vers

$$0{,}08 + 0{,}10\,\frac{\operatorname{cov}(x,c)}{V(x)}.$$

Avec $x = 12 + 2c + a$, où c et a sont des normales centrées réduites indépendantes, $\operatorname{cov}(x,c) = 2$ et $V(x) = 4+1 = 5$: $\delta = 0{,}4$ et la pente tend vers $0{,}08 + 0{,}10 \times 0{,}4 = 0{,}12$. C'est ce que trouve la simulation (0,122). Quand on met la capacité dans le modèle, la pente de x ne retient que la part des études non expliquée par c, indépendante de c : elle tend vers 0,08.

■

L'erreur de mesure, un biais vers zéro

L'atténuation

Si l'on observe $x^* = x + u$, avec u une erreur de mesure indépendante, la pente estimée tend vers

$$\beta_1 \times \frac{V(x)}{V(x) + V(u)}$$

un facteur **inférieur à un** : le coefficient est tiré vers zéro.

Sur une variable mal déclarée

Les revenus déclarés en enquête sont souvent arrondis, oubliés, sous-estimés. Si la variance de l'erreur de déclaration atteignait 20 % de celle du vrai revenu, la propension marginale estimée ne vaudrait plus que $1/1{,}2 = 83\,\%$ de la vraie. **L'erreur de mesure sur y ajoute du bruit ; sur x, elle biaise.**

Démonstration : L'erreur de mesure sur x tire la pente vers zéro : facteur $V(x)/(V(x)+V(u))$

Le vrai modèle est $y = \beta_0 + \beta_1 x + \varepsilon$, avec ε non corrélée à x. On observe $x^* = x + u$, l'erreur de mesure u étant indépendante de x et de ε. La pente de la régression de y sur x^* tend vers $\operatorname{cov}(x^*, y)/V(x^*)$. Or

$$\operatorname{cov}(x+u,\ \beta_0 + \beta_1 x + \varepsilon) = \beta_1 V(x),$$

car u n'est corrélée ni à x ni à ε, et $V(x^*) = V(x) + V(u)$. La limite est donc

$$\beta_1\,\frac{V(x)}{V(x)+V(u)},$$

un facteur compris entre 0 et 1, d'autant plus petit que l'erreur est grande. Avec $V(u) = 0{,}2\,V(x)$: $1/1{,}2 = 0{,}83$.

Erreur sur y. Si l'on observe $y^* = y + w$, avec w indépendante de x et de ε, alors $\text{cov}(x, y^*) = \text{cov}(x, y)$: la pente est inchangée. L'erreur w s'ajoute à ε : la variance de l'erreur grandit, et les écarts-types avec elle. Du bruit, mais pas de biais.

■

Ce que le cours n'a pas résolu

Et ne pouvait pas résoudre

Aucun test ne détecte l'endogénéité. Aucune correction d'écarts-types n'y remédie. La sortie du logiciel reste parfaitement propre, et le coefficient reste faux.
C'est la limite de tout ce qui précède, et il vaut mieux la connaître que la découvrir dans un rapport publié.

Les réponses existent, et elles sont récentes

Variables instrumentales, doubles différences, discontinuité de régression, expériences contrôlées : ce sont les méthodes de l'**inférence causale**.
Elles font l'objet de l'économétrie de Master, et plusieurs prix Nobel d'économie leur ont été décernés depuis 2000. Toutes reposent sur une idée simple : **trouver, dans les données, quelque chose qui ressemble à une expérience.**

La conclusion du cours

Ce qu'un économètre doit savoir dire

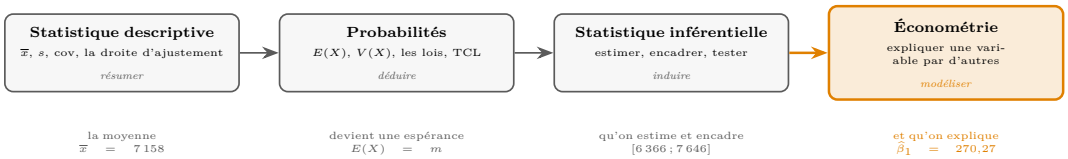
Trois phrases, et elles suffisent

1. « Voici ce que j'ai mesuré, et avec quelle précision. »
2. « Voici les hypothèses sous lesquelles cette mesure est valide. »
3. « Voici ce que je ne peux pas conclure. »

La troisième est celle qui distingue le professionnel

Tout le monde sait produire une régression. Peu savent en énoncer les limites — et ce sont les seuls dont le travail résiste à l'examen.
« Significatif » ne veut jamais dire « causal ». Si vous ne deviez retenir qu'une phrase de ce cours, ce serait celle-là.

Ce que quatre cours ont construit



Un seul jeu de données a traversé les quatre cours : les mêmes cinq cents salariés.

La statistique descriptive en a tiré une moyenne, un écart-type et une droite d'ajustement. Les probabilités ont transformé la fréquence en probabilité et la moyenne en espérance. L'inférence a fait de ces cinq cents individus une population dont on tire des échantillons, pour estimer, encadrer et tester. L'économétrie, enfin, a posé qu'il existe une *relation vraie* entre le salaire, l'ancienneté, le diplôme et la région — et l'a mesurée.

Aucun de ces quatre cours n'a introduit d'outil que les précédents n'annonçaient pas. La covariance de la descriptive est devenue la pente ; le théorème central limite des probabilités a rendu les tests possibles ; l'erreur-type de l'inférence est devenue celle d'un coefficient. **C'est une seule discipline, enseignée en quatre fois.**

Sur machine

AIC et BIC avec R

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m4 <- lm(salaire ~ anciennete + diplome + sexe + region, sal)
m5 <- update(m4, . ~ . - sexe)
c(AIC(m4), AIC(m5))          # à une constante près du cours
# [1] 8747.578 8747.222
c(BIC(m4), BIC(m5))
# [1] 8785.510 8780.939
AIC(m4) - AIC(m5)            # l'écart, lui, est le même : 0,36
# [1] 0.3561047
```

Une constante qui ne change rien

R calcule l'AIC à partir de la vraisemblance, avec une constante en plus de la formule du cours : 8 747,6 au lieu de 7 326,6. **Seules les différences comptent**, et elles sont identiques : 0,36.

La capacité omise, simulée avec R

```r
set.seed(20261022)
n <- 5000
capacite <- rnorm(n)                          # non observée
etudes <- 12 + 2 * capacite + rnorm(n)        # liée à la capacité
lsal <- 1 + 0.08 * etudes + 0.10 * capacite + rnorm(n, 0, 0.3)
round(coef(lm(lsal ~ etudes))[2], 4)              # capacité omise
# etudes
# 0.1222
round(coef(lm(lsal ~ etudes + capacite))[2], 4)  # vrai effet 0,08
# etudes
# 0.0821
```

La capacité omise, simulée avec Python

```
import numpy as np
import statsmodels.api as sm
rng = np.random.default_rng(20261022)
n = 5000
capacite = rng.normal(size=n)                # non observée
etudes = 12 + 2 * capacite + rng.normal(size=n)
lsal = 1 + 0.08 * etudes + 0.10 * capacite + rng.normal(0, 0.3, n)
X1 = sm.add_constant(etudes)
X2 = sm.add_constant(np.column_stack([etudes, capacite]))
print(sm.OLS(lsal, X1).fit().params[1].round(4))   # biaisé
# 0.1193
print(sm.OLS(lsal, X2).fit().params[1].round(4))   # 0,08
# 0.0766
```

S'entraîner

Exercice 1 : AIC et BIC à la main

Deux modèles qui divisent les critères

Sur $n = 100$ observations : modèle A, $p = 3$ coefficients, SCR $= 500$; modèle B, $p = 5$, SCR $= 460$ ($\ln 5 = 1{,}609$; $\ln 4{,}6 = 1{,}526$; $\ln 100 = 4{,}605$).

1. Calculer l'AIC et le BIC des deux modèles.
2. Que choisit chaque critère ?
3. Comment trancher ?

Exercice 1 : solution

L'AIC prend B, le BIC prend A

1. A : $160{,}9 + 6 = 166{,}9$ et $160{,}9 + 13{,}8 = 174{,}8$. B : $152{,}6 + 10 = 162{,}6$ et $152{,}6 + 23{,}0 = 175{,}6$.
2. L'AIC préfère **B**, le BIC préfère **A** : les deux variables de B apportent assez pour l'AIC, pas assez pour le BIC.
3. Par la **théorie** : si les deux variables de B ont une raison économique d'être là, on les garde. Les critères départagent des modèles également justifiés, ils ne remplacent pas la justification.

Exercice 2 : associé ou causal

Quatre phrases de rapport

Lesquelles dépassent ce qu'une régression sur coupe instantanée permet d'affirmer ?

1. « Les ménages urbains consomment 99 dirhams de moins, à revenu et taille égaux. »
2. « Habiter en ville réduit la consommation de 99 dirhams. »
3. « Un dirham de revenu supplémentaire est associé à 0,70 dirham de consommation. »
4. « Augmenter les salaires de 10 % augmentera la consommation de 7 %. »

Exercice 2 : solution

Deux phrases de trop

1. **Correcte** : une association conditionnelle — et d'ailleurs non significative une fois les grappes corrigées, chapitre 15.
2. **Dépasse** : elle affirme qu'un ménage qui déménagerait changerait sa consommation.
3. **Correcte**.
4. **Dépasse** : c'est une prévision causale, et de surcroît une politique — la critique de Lucas du chapitre 6 s'applique.

Exercice 3 : d'où vient l'endogénéité

Trois régressions suspectes

Pour chacune, identifier la source d'endogénéité et le sens probable du biais.

1. Taux de criminalité des villes expliqué par le nombre de policiers.
2. Productivité des salariés expliquée par le suivi d'une formation volontaire.
3. Consommation expliquée par un revenu déclaré, souvent arrondi et mal mémorisé.

Exercice 3 : solution

Trois sources, trois biais

1. **Causalité inverse** : on envoie plus de policiers là où la criminalité est forte. L'effet de la police paraît **moins négatif**, voire positif.
2. **Variable omise** : les plus motivés suivent la formation et sont aussi plus productifs. L'effet de la formation est **surestimé**.
3. **Erreur de mesure** sur l'explicative : la propension marginale est **atténuée**, tirée vers zéro.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Trop peu de variables biaise ; trop de variables imprécise. **En cas de doute, inclure.**
2. **AIC et BIC** ajoutent une pénalité de complexité : 2 et $\ln n$ par coefficient.
3. Sur nos données, les deux choisissent **M5** ; face à dix variables de hasard, ils refusent ce que le R^2 ajusté acceptait.
4. Une variable **théoriquement indispensable** se garde ; la **sélection automatique** invalide les p-values.
5. **Endogénéité** : variable omise, causalité inverse, erreur de mesure — simulée, la capacité omise gonfle le rendement de moitié.
6. **« Significatif » ne veut jamais dire « causal ».**

La suite

Tout le cours a été conduit pièce par pièce. Le chapitre 20 enchaîne les pièces sur deux études complètes ; le chapitre 21 refait l'ensemble en R et en Python.