

Chapitre 15

Les erreurs groupées

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\sqrt{1 + (20 - 1) \times 0,2} = \sqrt{1 + 3,8} = \sqrt{4,8} \approx 2,191$.
- (b) $t_{\text{vrai}} = 4/2,191 \approx 1,826$.
- (c) Non : $1,826 < 1,96$, le résultat n'est plus significatif au seuil usuel une fois le regroupement pris en compte — la conclusion s'effondre, exactement comme l'annonce le cours pour l'exemple des vingt élèves par classe.
- (d) $\sqrt{1 + (10 - 1) \times 0,2} = \sqrt{1 + 1,8} = \sqrt{2,8} \approx 1,673$, contre 2,191 pour $m = 20$. Oui, des grappes plus petites (à corrélation intra-grappe égale) produisent un facteur de Moulton plus faible : le coût du regroupement en termes de sous-estimation de l'écart-type augmente avec la taille moyenne des grappes.

Correction — Exercice 2

- (a) P_1 est fausse : les coefficients estimés restent sans biais, le regroupement non corrigé ne les affecte pas.
- (b) Avec l'hétéroscédasticité, le sens de l'erreur sur l'écart-type MCO n'était **pas prévisible à l'avance** (hausse pour certaines variables, baisse pour d'autres, comme au chapitre 14). Avec le regroupement, l'erreur va **toujours dans le même sens** : les écarts-types MCO sont systématiquement **trop petits**, jamais trop grands.
- (c) Le problème est plus « prévisible » au sens où l'on sait d'avance que l'excès de confiance ira dans un seul sens (on croira à tort avoir plus de précision qu'on n'en a réellement) ; mais il n'est pas moins dangereux, car cette prévisibilité même ne protège pas le chercheur qui oublierait d'appliquer la correction — il surestimerait systématiquement la précision de ses résultats et déclarerait significatifs des effets qui ne le sont pas.
- (d) Le regroupement viole H4 (indépendance des erreurs, $\text{cov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$) : deux ménages du même quartier partagent un terme commun u_g , donc leurs erreurs sont corrélées.

Correction — Exercice 3

- (a) $101,92/55,69 \approx 1,830$: l'écart-type de grappe est environ 83 % plus grand que l'écart-type MCO pour la variable milieu.
- (b) $59,32/55,69 \approx 1,065$: la correction d'hétéroscédasticité seule n'augmente l'écart-type que d'environ 6,5 %.
- (c) Non : la correction d'hétéroscédasticité seule (6,5 % de hausse) ne voit presque rien du problème de regroupement, dont l'ampleur réelle est de 83 % de hausse — ce sont deux problèmes distincts, et corriger l'un ne corrige pas l'autre.
- (d) Une variable constante à l'intérieur de chaque grappe (comme le milieu) est entièrement déterminée par le terme commun de la grappe u_g : chaque observation supplémentaire du même quartier n'apporte, pour cette variable précise, **aucune information nouvelle** — toutes les observations du quartier disent la même chose sur cette variable. Une variable qui varie à l'intérieur de la grappe (comme le revenu, différent d'un ménage à l'autre du même quartier) conserve, elle, une partie de variation utile même après avoir tenu compte de l'appartenance au quartier, donc elle souffre moins du regroupement.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $0,0232/0,0148 \approx 1,568$: il s'agit bien d'une hausse d'environ 57 % de l'écart-type.
- (b) $101,92/55,69 \approx 1,830$ (déjà calculé à l'exercice 3(a)) : c'est également une hausse, d'environ 83 %.
- (c) Ce constat — une hausse pour les deux variables du chapitre 15, contre un mélange de hausses et de baisses au chapitre 14 — illustre exactement la différence de nature identifiée à l'exercice 2(b) : l'hétéroscédasticité corrompt les écarts-types dans un sens qui dépend de la structure fine des données (imprévisible), tandis que le regroupement non corrigé les sous-estime **systématiquement**, quelle que soit la variable considérée.
- (d) Oui, ce serait une erreur : l'exercice 3(c) montre que la correction d'hétéroscédasticité seule (comme celle de White du chapitre 14) ne voit presque rien du problème de regroupement (une hausse de 6,5 % contre une hausse réelle de 83 % pour le milieu). Les deux problèmes — hétéroscédasticité et regroupement — sont distincts et demandent chacun leur propre correction ; appliquer l'un ne dispense pas d'appliquer l'autre si les deux sont présents.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) La réforme s'applique au niveau de la **région** : tous les élèves d'une même région sont soumis (ou non) à la même politique de bourses.
- (b) Selon la règle du cours, les écarts-types de grappe doivent être calculés au niveau de la **région**, c'est-à-dire au niveau où le traitement s'applique — pas au niveau plus fin de l'élève ou de l'école.
- (c) Non : avec seulement 8 régions, la condition usuelle d'au moins 40 grappes est très loin d'être respectée. La correction de grappe elle-même devient peu fiable dans ce cas, quand bien même l'effectif total d'élèves serait très grand — car c'est le nombre de grappes, non celui des individus, qui conditionne la validité de la correction.
- (d) Non, regrouper au niveau de l'école pour « gagner » davantage de grappes ne corrigerait pas correctement le problème : la réforme étant appliquée au niveau régional, tous les élèves d'une même région — donc de plusieurs écoles différentes au sein de cette région — partagent le même traitement. Regrouper au niveau de l'école laisserait subsister une corrélation des erreurs **entre écoles d'une même région**, non corrigée, ce qui sous-estimerait encore les vrais écarts-types.

Correction — Exercice 6

- (a) Plan A ($m = 10$) : $\sqrt{1 + 9 \times 0,2} = \sqrt{2,8} \approx 1,673$. Plan B ($m = 40$) : $\sqrt{1 + 39 \times 0,2} = \sqrt{8,8} \approx 2,966$.
- (b) Le Plan A (beaucoup de petites grappes) souffre nettement moins du regroupement : son facteur de Moulton (1,673) est bien plus proche de 1 (l'absence de tout problème) que celui du Plan B (2,966).
- (c) Le Plan A, avec 40 grappes, respecte tout juste la condition usuelle (« au moins quarante grappes », « le minimum acceptable » selon le cours). Le Plan B, avec seulement 10 grappes, est très en-deçà de cette condition : sa correction de grappe serait elle-même peu fiable.
- (d) Le Plan A l'emporte sur les deux critères statistiques à la fois : un facteur de Moulton plus faible (moins de perte d'information) *et* un nombre de grappes suffisant pour que la correction soit elle-même fiable. Le Plan B, moins coûteux à collecter (moins de quartiers à visiter, donc moins de frais de déplacement et de logistique), est statistiquement moins fiable sur les deux plans. L'arbitrage est donc réel : le planificateur d'enquête doit accepter un coût de collecte plus élevé (multiplier les petites grappes) pour obtenir une inférence statistique de meilleure qualité, et cette décision se prend avant la collecte, quand il est encore possible de choisir la structure de l'échantillon.